


Data 분석의 의미와 관련 용어

- Data 기반 의사결정의 의미를 이해
- Data 관련 용어를 이해





데이터 분석을 통해 정보가 발견되고, 이를 해석하면 지식이 된다.



사전적 정의

데이터란 양적 혹은 질적 **변수들의 값의 집합**이다. 즉, 데이터는 개별 정보를 가진다.
데이터는 현존하는 정보나 지식을 더 잘 활용하거나 처리할 수 있도록 대변하거나 부호화된 것이다.

데이터, **정보, 지식과 지혜**를 매우 밀접한 관계에 있다.
하지만 이들은 서로간의 관계에서 고유한 역할을 하며, 각 용어는 고유한 의미를 가진다.
데이터를 수집하고 분석함으로써 의사 결정에 적합한 정보가 된다.




실무적 정의

: Data란, **현장의 사실을 측정하여 숫자나 문자로 나타낸 것**

현장이란 일이 이루어지는 모든 물리적, 정보적 공간을 포함한다.

- 『숫자』가 모두 『Data』는 아니다
- 『Data』는 『현장/프로세스』의 『사실』을 『의도적』으로 『측정/관찰/조사/검사/실험』한 결과이다.
- Data의 수명은 유한하다.



Knowledge $Y = f(X's)$, Platon

Doxa


I believe it will be true

Episteme

I Know it will be true

“데이터로 거짓말하기는 쉬워도,
데이터 없이 진실을 말하기는 어렵다.”

차기 대선후보 지지율,
안철수 하락세에 양강구도 '흔들'



이번 조사는 지난 21일~22일까지 이틀간 전국 성인남녀 **1030명**을 대상으로 실시했다.

유선전화(45%) 및 휴대전화(55%) RDD(임의 번호 걸기) 방식을 사용했고

표본 오차는 95% 신뢰 수준에서 **±3.1%포인트**, 응답률은 16.0%다.

자세한 내용은 중앙선거여론조사공정심의위원회 홈페이지를 참조하면 된다

알고 싶은 세상

전체 유권자
42,479,710명

1,030명이 전체 유권자를 대변?

No....표본 오차

전국 성인남녀
1,030명

오차를 감안한 의사결정

±3.1%포인트

- 문재인 = 33.4~40.1%
- 안철수 = 23.3~29.5%

- 문재인 : 37.5%
- 안철수 : 26.4%

알고 있는 세상


알고 있는 세상으로 알고 싶은 세상을 합리적으로 추정하여 미래 구간에서 활용

표본
(표본을 측정하여 확인한 사실)


모집단
(지식의 일반화, 미래의 예측)

오차를 감안한 의사결정

일반화, 예측




모집단Population이란, 분석의 대상이 되는 집단(그 특성을 알고 싶은 집단) 전체을 말하며, 표본sample은 모집단의 일부로서, 실제 데이터가 수집되고 분석되는 집단을 말한다.



A 무한모집단인 공정에서 생산된 제품을 Lot를 구성하여 유한 모집단을 만듭니다.


Lot에서 일부를 샘플링하여, Data를 취한 후 통계량을 구합니다. 이렇게 구한 통계량으로 모수를 추정하여, 의사결정을 하게 됩니다. 이때 오차를 감안한 의사 결정을 하게 됩니다.

B 기술의 발달과 더불어 이것이 가능해졌습니다. 공정에서 생산되는 모든 제품을 검사(추정)하여 빅데이터를 수집할 수 있습니다. 이때, 전수 데이터에서 구한 통계량은 유한모집단인 Lot의 모수와 일치합니다. 즉, 통계적 추론(CDA)을 사용할 필요가 없습니다. 하지만 무한모집의 모수는 통계적 추정을 해야 합니다.



우리 홈 페이지를 방문하는 고객 Data를가 왼쪽 그림과 같다면... 즉, 일부의 고객 만이 우리 홈 페이지를 방문하고, 그 중 일부만 디지털 흔적을 남겨서, 그것을 우리가 데이터로 수집한 것이라면,

그렇게 수집된 데이터를 분석하여, 모든 소비자로 일반화 할 수 있을까요?




빅 데이터는 표본의 크기가 엄청 크므로 오차가 작아질 것이라는 기대가 있으며, 따라서 의사 결정의 모호성이 사라질 수 있다는 장점을 누릴 수 있습니다. 즉, Big Data 분석에서는 굳이 확인적 분석을 하지 않아도 될 수 있습니다.


하지만, 편의가 심하다면, 더 큰 오류를 생산하는 위험도 있습니다. 즉, 모든 데이터 기반 의사결정에서는 **일반화의 오류**를 경계해야 하지만 Big Data에서는 그 정도가 심해질 수도 있습니다.

	표본조사 데이터	빅데이터
편향	Bias = 0	Bias ≠ 0
분산	Variance = K/n	Variance ≅ 0

(a) 전체 표본 공간을 포함




(b) 일부 표본 공간만 포함




표본 추출에서 우연히 발생하는 오차는 표본 크기를 키우면 감소하고, 편의(bias)에 의한 오차는 표본추출 방법을 올바르게 적용하여 축소시킬 수 있습니다.

데이터 크기(Data Size)가 커지면 (표본)오차가 줄어든다.

▶ 표본크기별 표본오차 (단위: %포인트, 95% 신뢰수준)




그러나, 수집된 데이터가 **편향**되어 있다면
데이터가 아무리 많아도 좋은 분석결과를 담보할 수 없다.



빅 데이터는 통상적으로 사용되는 데이터 수집, 관리 및 처리 소프트웨어의 수용 한계를 넘어서는 크기의 데이터를 말한다. 빅 데이터의 사이즈는 단일 데이터 집합의 크기가 수십 테라바이트에서 수 페타바이트에 이르며, **그 크기가 끊임없이 변화하는 것이 특징이다.** 빅데이터라는 용어는 1990년대부터 사용되어 왔으며, 존 매쉬가 이 용어를 대중화하였다. (위키 백과)

3V : 빅데이터의 특성






- ④ 사례중심의 귀납적 접근으로,
선입견을 배제한 개방적 논증으로 새로운 해석의 가능성을 높여준다.

Diagram illustrating the difference between '귀납' (Induction) and '연역' (Deduction):

- 귀납 (Induction):** Specific examples (a pink triangle, a light blue pentagon, a purple square, and a light pink hexagon) lead to a general principle (일반적 원리).
- 연역 (Deduction):** A general principle (일반적 원리) leads to specific examples (a pink triangle, a purple square, a light blue pentagon, and a light pink hexagon).


데이터는 숫자를 통해 Common Language가 된다.



10세기에 이르러 중동의 이슬람 세계에서는 아라비아 숫자를 사용하여 십진기 수법을 확립하고 분수의 표기 방식을 정하였다. 이 시기 이슬람 수학의 기수법은 아부 하산 알우크리디시의 저작에 기록되어 유럽으로 전파되었다. 당시 이슬람 세계의 서쪽인 북아프리카와 이베리아 반도를 아우르는 지역인 마그레브에서 아라비아 숫자가 사용되면서 모양에 변화가 생겼다. 마그레브에서는 이 숫자들을 모래판에 쓰는 숫자라는 의미로 구바라고 불렀다. 이 구바 숫자가 오늘날 유럽에서 사용되는 아라비아 숫자의 원형이다

한국에서는 대한제국시기 근대 교육과 함께 아라비아 숫자가 도입되었다. 갑오개혁 이후 각종 수학책이 출판되었는데 1900년 이상설이 지은 《산술신서》는 본문이 모두 한문으로 되어 있으나 숫자는 아라비아 숫자로 표기하였다. 이상설은 1909년 《중등 수학 교과서》를 집필하기도 하였다 (위키)






구분	X1	x2			X755	X756	Y
#1							고양이
#2							강아지
#3							
#4							
#n							

Y : 고양이, 강아지
X1 ~ Xn : 다변수
#n : 수만, 수십만, 수백만 ~ Big Volume

소리의 주파수 특성



옥타브 및 음계별 표준 주파수 (단위 : Hz)


옥타브 음계	1	2	3	4	5	6	7	8
C(도)	32.7032	65.4064	130.8128	261.6256	523.2511	1046.502	2093.005	4186.009
C#	34.6478	69.2957	138.5913	277.1826	554.3653	1108.731	2217.461	4434.922
D(레)	36.7081	73.4162	146.8324	293.6648	587.3295	1174.659	2349.318	4698.636
D#	38.8909	77.7817	155.5635	311.1270	622.2540	1244.508	2489.016	4978.032
E(미)	41.2034	82.4069	164.8138	329.6276	659.2551	1318.510	2637.020	5274.041
F(파)	43.6535	87.3071	174.6141	349.2282	698.4565	1396.913	2793.826	5587.652
F#	46.2493	92.4986	184.9972	369.9944	739.9888	1479.978	2959.955	5919.911
G(솔)	48.9994	97.9989	195.9977	391.9954	783.9909	1567.982	3135.963	6271.927
G#	51.9130	103.8262	207.6523	415.3047	830.6094	1661.219	3322.438	6644.875
A(라)	55.0000	110.0000	220.0000	440.0000	880.0000	1760.000	3520.000	7040.000
A#	58.2705	116.5409	233.0819	466.1638	932.3275	1864.655	3729.310	7458.620
B(시)	61.7354	123.4708	246.9417	493.8833	987.7666	1975.533	3951.066	7902.133

*[참조] sound metrics : Loudness, Sharpness, Fluctuation Strength, Roughness, Tonality, Kurtosis

→ [사례] 고객의 청음(고객평가단) = f (sound metrics)

라만 스펙트럼


[사례] 라만 스펙트럼으로 광물(감람석, 사장석) 분류



No	Sample ID	237	238	239	240	241	242	243	~	1086	1087	1088	1089	1090	Mineral Class
1	R040068	0.003259	0.004326	0.003624	0.005429	0.004885	0.002018	0.006129	~	0.000213	0.000107	0.000336	0.000404	0.000185	Olivine
2	R040129	0.002865	0.001676	0.001555	0.001945	0.004603	0.007943	0.014263	~	0.000035	0.000080	0.000092	0.000153	0.0002	Olivine
3	X050005	0.002865	0.001676	0.001555	0.001945	0.004603	0.007943	0.014263	~	0.00051	0.000786	0.001181	0.00108	0.000719	Olivine
4	X050006	0.0669	0.069453	0.072622	0.076742	0.084247	0.092487	0.104713	~	0.001911	0.001947	0.00231	0.002693	0.003054	Olivine
5	X050007	0.000947	0.001966	0.003866	0.00659	0.01124	0.01622	0.025122	~	0.001585	0.001636	0.001869	0.00193	0.001947	Olivine
6	X050008	0.00065	0.001031	0.002472	0.004672	0.008901	0.013506	0.021513	~	0.000538	0.000478	0.000474	0.00057	0.000759	Olivine
7	X050014	0.28171	0.313477	0.344849	0.376156	0.408943	0.44215	0.475038	~	0.001059	0.000877	0.000873	0.001004	0.001188	Olivine
~	~	~	~	~	~	~	~	~	~	~	~	~	~	~	~
55	R060539	0.004172	0.003197	0.003633	0.00303	0.003011	0.002479	0.001396	~	0.000573	0.000213	3.65E-05	0.00032	0.000121	Olivine
56	R060535	0.007412	0.007557	0.006804	0.005735	0.004551	0.003538	0.003841	~	0.000254	0.000383	0.000364	0.00019	9.24E-05	Olivine
57	R060551	0.011882	0.010991	0.010238	0.009581	0.008809	0.007745	0.006609	~	0.000581	0.000275	0.000331	0.000184	0.000364	Olivine
58	R100099	0.007766	0.010316	0.0139	0.015575	0.014397	0.013641	0.017145	~	0.045869	0.033589	0.039145	0.047037	0.041054	Olivine
59	R100100	0.019494	0.019855	0.019579	0.018243	0.016105	0.013721	0.013281	~	0.000286	0.000829	0.00074	0.000704	0.000528	Olivine
60	R100101	0.023288	0.025338	0.023844	0.021695	0.02049	0.016583	0.017335	~	0.001806	0.002637	0.002066	0.001288	0.000651	Olivine
61	R100140	0.017505	0.016139	0.014505	0.013968	0.011861	0.01066	0.01006	~	0.000733	0.000834	0.000394	0.000734	0.001475	Olivine

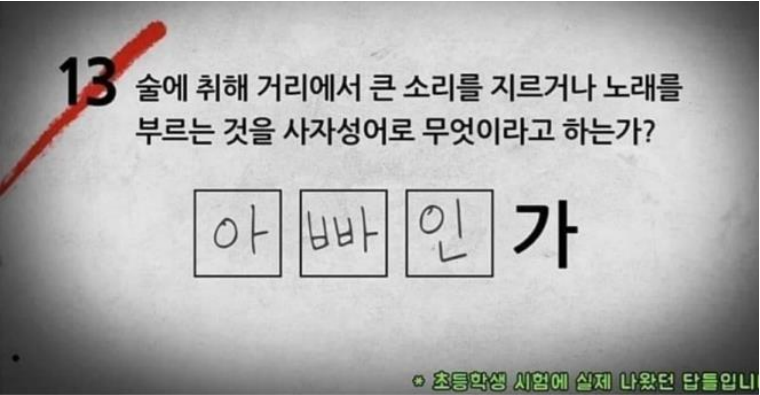

GPT 3

- OpenAI사에서 발표한 초거대 AI
- 2020년 6월 베타 버전 발표
- 3000억개 데이터셋으로 1750억개 매개 변수 학습
- 초기 학습비용 50억원




GPT-3의 알고리즘은...
마치 초등학교 시절의 빈칸 채우기와 유사합니다.

단순화하여 예를 들면,
‘철수와 영희는 학교에서 (~ ~)’
위 문장에서 괄호에 들어갈 단어의
통계적 확률을 계산하는 것이라고 합니다.



측정 척도는 측정해야 할 정보의 양을 결정하고, Data의 유형은 분석 방법을 결정한다.



- * 연속형 데이터가 가장 많은 정보량을 갖고 가장 많은 분석 방법의 적용이 가능하다.
- * 연속형 데이터는 정보량이 많으므로, 이산형 데이터에 비해 적은 수의 데이터로도 질 높은 분석이 가능하다.


(실습) 측정 척도와 데이터의 유형을 구분해 봅시다.
여러분들이 다루는 데이터는 어떤 것 들이 있습니까?

데이터	측정 척도(명목/순서/구간/비율)	유형(연속형/ 이산형)
아파트 평수		
아파트 동 호수		
학교 등수		
학교 점수		
버스 번호		
출퇴근 소요 시간		
자동차 연비		
축구 선수의 백 넘버		
근무 기간		
금메달, 은메달, 동메달		

모든 관심 특성은 **변수Variables**다. **상수Constant**가 관심 대상이 되는 경우는 드물다.
상황이나 조건에 따라 값이 변한다.



변수는 패턴(분포)과 확률로 표현한다.



결과변수와 원인변수(설명 변수)


결과변수(종속변수): Y
프로야구 선수 타자 연봉

$$= f \left[\begin{array}{l} \text{타율, 출루율, 장타율, 출장경기, 타석, 타수, 득점,} \\ \text{안타, 1루타, 2루타, 3루타, 홈런, 총루타수, 타점,} \\ \text{도루, 도루사, 볼넷, 사구, 고의사구, 삼진, 병살타,} \\ \text{희생타, 희생플라이, 년차, FA여부 ...} \end{array} \right]$$


원인변수(설명변수, 독립변수): X
: 각 변수의 결과에의 영향도(중요도)는 서로 다르다.

확률 분포(確率 分布, probability distribution)는
확률 변수가 특정한 값을 가질 확률을 나타내는 함수를 의미한다.

(예) 동전 던지기의 확률 분포




(예) 주사위 던지기의 확률 분포



정규분포(Normal Distribution) – 가우스 분포

관심 특성 : 좌우대칭과 종형의 형태를 갖는 연속형 측정값
분포의 모수 : 평균(μ), 분산(σ^2)




정규분포는 자연현상의 기본적인 원리로 발견된다. 즉, 자연계에 존재하는 대부분의 특성치는 정규분포를 한다.
따라서 정규분포는 하는 것이 정상(Normal)이라고 할 수 있다.


(Carl Friedrich Gauss – 독일)




독일 10Mark 화폐



Big Data, Complex Data → Simple, Visual & Prediction




“목적이 모든 과정을 지배한다”



목적

- ✓ 과제는 정한 시간이 되어서 끝나는 것이 아니라, 목적을 달성하고 종료된다.
- ✓ 모든 과제가 예측모델을 개발해야 하는 것은 아니며, 따라서 과제의 실행 절차는 과제의 목적에 따라 서로 다를 수 밖에 없다.



알고 있는 세상으로 알고 싶은 세상을 합리적으로 추정하여 미래 구간에서 활용

표본
(표본을 측정하여 확인한 사실)

모집단
(지식의 일반화, 미래의 예측)

오차를 감안한 의사결정

일반화, 예측

