


데이터 수집

Data 수집의 기본 관점을 이해함



“목적이 모든 과정을 지배한다”







양보다는 질이 먼저 중요하다 !!!

Quantity vs. Quality


	Big Volume	Small Size
High Quality		
Low Quality		



데이터 공학 (Data engineering) 은
대규모의 데이터를 효율적으로 관리하고 처리하며 가공을 통해
분석에 적합한 형태 혹은 데이터과학자가 사용할 수 있는 형태로 만드는 것과 관련이 있습니다.
분산 시스템을 활용하며 대용량의 데이터를 저장합니다
이와 같이 데이터를 저장하고 필요할 때 추출해서 처리하기 위한 방법론을 데이터 공학이라고 이야기합니다.



수집방법이 분석 결과의 유용성을 결정한다.



- 실험이 가장 비용과 시간이 많이 소요되나, 고품질의 데이터를 얻을 수 있다.
- Data를 수집하기 위한 비용/시간 등은 소급연구가 가장 적게 든다.
- 직접 데이터를 수집하는 것 뿐만 아니라, 외부에서 데이터를 구매할 수도 있다.

1차 Data와 2차 데이터

1차 데이터는 분석가가 분석 목적에 맞추어 직접 측정하거나 조사한 데이터를 말합니다. 반면 2차 데이터는 다른 사람/부서/기관이 자신의 목적에 맞춰 수집해 놓은 Data를 말합니다.


1차 데이터는 현재의 분석 목적에 적합하게 수집하였으므로, 즉시 활용 가능하다는 장점이 있지만, 수집을 위해 시간과 노력 그리고 돈이 많이 들어간다는 어려움이 있습니다.

반면, 2차 데이터는 데이터 수집에 비용과 노력이 적게 들어간다는 장점이 있지만, 애초에 다른 목적으로 수집된 데이터이기 때문에 바로 사용하기는 어려울 수 있습니다.


그래서 통상 데이터를 수집할 때에는 먼저 사용할만한 적합한 2차 데이터가 있는지를 확인하고, 부족한 부분은 1차 데이터로 보완하는 것이 추천됩니다.

Historical Data는 기본적으로 2차 데이터입니다. 따라서, 데이터 수집에서 일반적으로 추천되는 순서는 먼저 내부의 Historical Data를 고려하고, 두 번째로 외부의 2차 데이터를 구매 등을 통해 수집하는 것이며, 마지막으로 돈과 시간을 들여 내가 직접 데이터를 생성시키는 것이라고 할 수 있습니다.


[예] 식습관이 체중에 미치는 영향에 대한 연구



[예] 식습관이 체중에 미치는 영향에 대한 연구



[예] 식습관이 체중에 미치는 영향에 대한 연구



비즈니스 질문을 제대로 검증하려면, 체계적인 데이터 수집이 필요

계획 없는 실행이 빠질 수 있는 함정...



목적
(비즈니스 질문)

- 데이터 분석을 통해서 알고 싶거나 증명하고 싶은 것

가설


- Data 분석을 통해 얻을 수 있는 잠정적 결론

수집 계획

- 결론을 증명할 수 있는 데이터 세트를 얼마나, 어떻게 수집할 것인가에 관한 것

Data 수집 계획에 포함될 사항


- 누 가(who) : 수집하는 사람 등
- 언 제(when) : 데이터를 취할 기간
- 어디서(where) : 데이터 소스
- 무엇일(what) : 제품, 명칭, 특성 등
- 어떻게(how) : 수집 데이터의 크기, 간격, 관련 계측기 등
- 왜(why) Data 수집 목적



[가상 데이터] 전국 노래자랑 시청률 조사

Wide Data 형식

개최 차수	경쟁	초대가수	서울 시청률	인천 시청률	수원 시청률
#1회	XX	A	11	15	19
#2회	00	A	12	16	20
#3회	000	B	13	17	21
#4회	XXX	B	14	18	22



Long Data 형식

시청률	시청 지역	개최차수	경쟁	초대가수
11	서울	#1회	XX	A
12	서울	#2회	00	A
13	서울	#3회	000	B
14	서울	#4회	XXX	B
15	인천	#1회	XX	A
16	인천	#2회	00	A
17	인천	#3회	000	B
18	인천	#4회	XXX	B
19	수원	#1회	XX	A
20	수원	#2회	00	A
21	수원	#3회	000	B
22	수원	#4회	XXX	B

THE DATABERG
THE DARK DATA THAT LIES
BENEATH

12%
OF DATA IS BUSINESS CRITICAL

23%
REDUNDANT, OBSOLETE AND
TRIVIAL (ROT) - COST TO GLOBAL
INDUSTRY: \$3.3 TRILLION BY 2020

65%
DARK DATA HIDDEN WITHIN
NETWORKS, PEOPLE AND
MACHINES

DARK DATA REASONS

85%
No tool to
capture and
unlock Dark Data

39%
Too much data,
not enough
analytics

25%
Can only access
Structured Data

66%
Data is missing or
incomplete

Dark Data

기업이 정보를 수집한 후, 저장만 하고 분석에 활용하고 있지 않은 데이터

Data Lake

가공되지 않은 다양한 종류의 데이터를 한 곳에 모아둔 저장소의 집합.
데이터를 효율적으로 분석/사용하고자 다양한 영역의 Raw 데이터(가공되지 않은 데이터)를
한 곳에 모아서 관리하고자 하는 것

Data Warehouse

데이터 기반 의사 결정을 돕는 Data 분석이 가능하도록 데이터를 모아둔 저장소.
데이터는 여러 소스로부터 수집하여 분석이 용이하도록 구조화가 완료

Database

트랜잭션 시스템과 같이 단일 소스에 있는 그대로 캡처한 데이터.
고도로 구조화되어 있으며, 일반적으로 지속적인 쓰기 작업에 최적화 됨

Data Mart

특정 운영 부서의 요구를 충족하도록 설계된 데이터 저장소.
Data Warehouse는 Data Mart는 집합에 해당.
예를 들어 Data Warehouse 가 도서관이라면
Data Mart는 특정 주제에 관한 책을 모아둔 도서관의 특정 섹션에 해당한다.

- Data는 양보다 질이 더 중요하다. (물론 둘 다 중요하지만...)
- 과거 데이터를 모으는 것은 경제적으로는 유리하는 품질 측면에서 불리하다.
실험은 매우 고단한 과정이나, 고품질의 데이터를 얻을 수 있다.
- 데이터를 올바르게 수집하려면, 데이터 수집 계획을 고려해야 한다.