



Data 품질

데이터 품질의 기본 요소를 이해함



“목적이 모든 과정을 지배한다”





양보다는 질이 먼저 중요하다 !!!

Quantity vs. Quality

	Big Volume	Small Size
High Quality		
Low Quality		

사실을 담아내는 데이터 만이 의미가 있습니다.
품질이 낮은 데이터는 사용하지 말아야 합니다.
고품질의 데이터를 얻으려면, 기술 뿐만 아니라 정성도 필요합니다.

데이터 품질 요소

- 타당성 알고 싶은 사실이 담겨야 한다.
- 적시성 필요 할 때, Data를 얻을 수 있어야 한다.
- 일관성 Data의 의미와 기준이 시간과 공간에 관계없이 유지되어야 한다.
- 대표성 수집된 샘플이 모집단을 대표해야 한다.
- 정확성 데이터는 가능한 참값에 가까워야 한다.
- 정밀성 누가 측정 및 수집하던, 몇 번을 반복하던 똑같은 값이어야 한다.
- 기타 완전성, 충분성, 보안성, 접근성 등



알고 싶은 사실을 담고 있어야 한다.

알고 싶은 것은 대부분의 경우 개념이다. 개념을 충분히 담아내는 항목이어야 한다.

[예]

■ 알고 싶은 것 “조직의 경쟁력”

■ 가능한 항목들


- 매출액
- 시장점유율
- 영업이익
- 종업원 수
- 품질 수준
- 제품 가격
- 제품 특성
- 일일 생산수
- UPPH
- 가동일수
-
-

어떤 항목이 타당한가?

하나의 개념에 하나의 항목으로 측정하는 것이 최상이나, 하나의 항목으로 개념 전체에 대한 Coverage가 부족하다면, Data 수집(측정) 항목을 추가한다.





데이터 수집 대상(표본)이 알고 싶은 세상(모집단)을 대표해야 한다.
우리가 만나는 거의 모든 데이터는 샘플(표본)을 측정한 것이다.
Big Data는 단지 표본이 많은 것 뿐이다.




- 리터러리 다이제스트(Literary Digest) (잡지사)
- 1936년에도 1,000만 명 모의투표
- 공화당의 랜던 후보의 승리 예측
그러나 민주당 루스벨트 대통령 후보가 압도적 승리 (61%)
➔ 부유층만 조사

과거 Data를 수집하는 경우 현업에서 자주 만나는 문제




필요할 때, 데이터를 얻을 수 있어야 한다.
Data를 얻기 까지 시간 지연이 과도한 경우, 바람직하지 않다.




Data의 의미와 기준이 시간과 공간에 관계없이 유지되어야 한다.

[예 1]



[예 2]






기준, 단위, 측정방법 등이 일치해야 한다.

데이터는 가능한 참값에 가까워야 한다.




자(一尺)의 길이

- 손가락 길이에서 유래
- 고대 중국에선 15~16cm
- 당나라 때 30cm
- 금나라에선 43cm
- ➔ 세금을 더 많이 징수



누가 측정 및 수집하던, 몇 번을 반복하던 똑같은 값이어야 한다.



Data 값의 범위가 적절해야 하며, 누락이 없어야 한다.


① 중요 인자의 누락이 없어야 한다.

구분	X1	X2	X3	X5	Xp	Y
#1						
#2				이상치		이상치
#3						
#4					결측치	결측치
#5						
#n						

② 결측치나 이상치가 과도하게 많으면 안 된다.

충분한 양을 확보해야 한다.

① 오차의 관점




데이터 Size가 커지면
표본오차는 줄어드나,
비표본오차 (특히 측정오차)는
늘어날 수 있다.

*비표본오차는 정확성과
정밀성으로 확인

② 데이터 차원 관점

차원=변수의 수



- (예) 1차원에서 10개의 데이터 필요하다면 ($=10^1$)
- 2차원에서 100개 데이터 ($=10^2$)
- 3차원에서 1000개 데이터 ($=10^3$)
- p차원이라면 10^p 개의 데이터 고려

③ 특정 변수에서, 각 범주의 발생을 관점

예를 들어,
평소의 고객 불만 발생율이 0.1%라면,
→ 100명의 고객을 조사하면
불만 데이터는 수집되지 않을 수 있다.
→ 1000명의 고객을 조사해도
불만 데이터는 극히 소수가 수집될 것이다.

➔ 분석 의도를 만족시킬 수 있을 정도의
Data Size를 고려해야 한다.

Data는 기업의 고유 자산이므로, 내부 및 외부 요인으로 부터 데이터를 보호해야 한다.
특히, 개인 정보는 법적인 책임이 따를 수 있으므로, 유의해야 한다.

개인정보·가명정보·익명정보는		
	예시	특징
개인정보	 홍길동 990909-1234567 010-1234-5678 서울 도봉구 방학로4길 google@gmail.com 통신요금 7만6500원 기관지염	정보주체의 이익, 안전조치(암호화) 여부 등에 따라 동의 없이 활용 가능
가명정보	 홍** 99년생, 남자 010-****-**** 서울 도봉구 ****@gmail.com 통신요금 7만6500원 기관지염	통계작성, 과학 적 연구, 공익적 기록보존 등에 동의 없이 활용 가능
익명정보	 - 20대, 남자 서울 통신요금 7만6500원 기관지염	언제든 동의 없이 활용 가능

개인정보는 그 사람이 누구인지 특정할 수 있는 데이터로
사전에 구체적으로 동의를 받은 범위 내에서만 활용이 가능

가명정보는 **추가 정보** 없이는 개인을 특정할 수 없게 처리한 것으로,
데이터3법 개정에 따라 다음 목적으로 활용 가능

- ① 통계 작성 (상업적 목적 포함)
- ② 연구 (산업적 연구 포함)
- ③ 공익적 기록 보존 목적 등

익명정보는 개인정보가 아니기 때문에 아무 제한 없이 자유롭게 활용이 가능

데이터 3법 개정에 따른 데이터 활용 비교

개정 전	개정 후
가명 조치한 개인정보	가명정보 개념 도입
사전에 구체적 동의 얻은 범위 내 활용	특정 목적 하 정보주체 동의없이 활용 가능
목적 달성 후 지체없이 (5일 이내) 파기	온라인 및 금융업, 복합 분야에서 빅데이터 활용

데이터3법 개정의 핵심 중의 하나가 가명정보의 개념을 도입한 것임.
즉, 개인정보를 가명화하여 빅데이터의 활용 범위를 확장할 수 있도록 함.

하지만 **추가 정보**라는 것이 현실에서는 얼마든지 가능하므로,
실질적으로는 개인정보와 다를 것 없다는 견해도 있음.

☞ **Data Profiling** : **비식별 정보를 합쳐서, 식별 정보를 만드는 것**

- 타당성
- 적시성
- 일관성
- 대표성
- 정확성
- 정밀성
- 완전성
- 충분성
- 보안성

번호	X1	X2	X3	X4	Y1(길이)	Y2(만족도)
#1	3	11	6	5	15	3
#2	2	22	2	2	17	5
#3	4	11	4	2		
#4	4	24	8	8	56	43

Missing Value

Outlier

통상적이지 않은 값 오타


Data Quality Report

구분	X1	X2	X3	X4	Y1	Y2
데이터 유형	time	연속	이산	정수	문자	
데이터 Size						
결측치 수						
이상치 수						
일관성...등						
평균						
표준편차						
중앙값						

기술적 분석

“분석 목적이 모든 과정을 지배한다.”

올바른 분석 결과를 위한 필요 조건



데이터 품질 요소

- **타당성** 알고 싶은 사실이 담겨야 한다.
- **적시성** 필요 할 때, Data를 얻을 수 있어야 한다.
- **일관성** Data의 의미와 기준이 시간과 공간에 관계없이 유지되어야 한다.
- **대표성** 수집된 샘플이 모집단을 대표해야 한다.
- **정확성** 데이터는 가능한 참값에 가까워야 한다.
- **정밀성** 누가 측정 및 수집하던, 몇 번을 반복하던 똑같은 값이어야 한다.
- **완전성** 필요한 모든 인자에 대한 데이터가 수집되어야 한다.
- **기타** 충분성, 보안성, 접근성 등

적용을 위한 분석 결과의 올바른 해석

- **기술적 해석** 모든 데이터 분석은 기술적 해석을 요구한다. 특히, 상관관계와 인과관계를 구분한다.
- **실무적 적용** 실제 업무에 적용함으로써 분석은 완성된다.

실무 적용 후 변화 관리 Change Management

- **Concept Drift** 분석 결과의 수명은 유한하다.