


## 데이터 전처리 (Data Preprocessing)

데이터 전처리가 무엇이며, 왜 필요한가를 개념적으로 이해함



“목적이 모든 과정을 지배한다”





Quantity vs. Quality


|              | Big Volume | Small Size |
|--------------|------------|------------|
| High Quality |            |            |
| Low Quality  |            |            |

# 데이터 전처리의 정의


Data 전처리란, 수집된 Data를 즉시 분석할 수 있도록 정리, 정돈하는 것.  
데이터 준비가 전체 프로젝트 기간의 80%를 점유하며, 결과의 80%를 지배한다

수집된 데이터가 모두 즉시 사용 가능한 것은 아닙니다.  
센서를 통해 자동으로 수집된 데이터도 센서의 이상, 대상물의 부정확한 포지셔닝, 통신 장애 등으로  
이상치(outlier)와 결측치(missing value)가 발생하는 것은 일반적입니다.  
이런 상태로 분석을 그냥 진행해서는 좋은 결과를 얻기 힘듭니다.  
또한 1차 데이터(Raw data)를 그냥 사용하는 것 보다는 적절하게 가공하여 (integration and/or transformation) 더 좋은 결과를 얻을 수도 있습니다.  
그리고, 계산 용량의 감축 등을 위하여 수집한 전체 데이터 중에서 일부를 샘플링하여 분석을 진행할 수도 있습니다.  
이와 같이, 분석 전 Data-set를 분석 가능한 상태로 만드는 것을  
데이터 전처리 Data Preprocessing이라 합니다.

1 Data Cleaning




2 Data Integration



3 Data Transformation



4 Data Selection



결측치란, 해당 필드에 데이터가 없는 경우를 말합니다. 결측치에 대응하는 방법은...

1. 결측치를 NA라는 데이터 값으로 가정하고 분석

| No | X1 | X2 | X3 | X4 | X5 | Y  |
|----|----|----|----|----|----|----|
| 1  | NA | NA | NA | NA | 41 | 양품 |
| 2  | NA | 10 | 20 | 30 | 42 | 양품 |
| 3  | NA | 11 | 22 | 33 | 43 | 양품 |
| 4  | NA | 13 | 34 | 36 | 44 | 불량 |
| 5  | NA | 14 | 26 | 39 | 45 | NA |
| 6  | 20 | 25 | 38 | 40 | NA | 양품 |

| No | X1 | X2 | X3 | X4 | X5 | Y  |
|----|----|----|----|----|----|----|
| 1  | 19 | 13 | 24 | 36 | 41 | 양품 |
| 2  | 19 | 10 | 20 | 30 | 42 | 양품 |
| 3  | 19 | 11 | 22 | 33 | 43 | 양품 |
| 4  | 19 | 13 | 24 | 36 | 44 | 불량 |
| 5  | 19 | 14 | 26 | 39 | 45 | 양품 |
| 6  | 20 | 25 | 38 | 40 | 43 | 양품 |

2. 삭제(제거)

3. 대체

- (1) 임의의 값으로 대체
- (2) 통계적 대체
  - 평균
  - 중앙값 (연속형)
  - 최빈값 (이산형)
  - 회귀분석


| No | X1 | X2 | X3 | X4 | X5 | Y  |
|----|----|----|----|----|----|----|
| 1  | NA | NA | NA | NA | 41 | 양품 |
| 2  | NA | 10 | 20 | 30 | 42 | 양품 |
| 3  | NA | 11 | 22 | 33 | 43 | 양품 |
| 4  | NA | 13 | 34 | 36 | 44 | 불량 |
| 5  | NA | 14 | 26 | 39 | 45 | NA |
| 6  | 20 | 25 | 38 | 40 | NA | 양품 |

| No | X1 | X2 | X3 | X4 | X5 | Y  |
|----|----|----|----|----|----|----|
| 1  | 19 | 13 | 24 | 36 | 41 | 양품 |
| 2  | 19 | 10 | 20 | 30 | 42 | 양품 |
| 3  | 19 | 11 | 22 | 33 | 43 | 양품 |
| 4  | 19 | 13 | 24 | 36 | 44 | 불량 |
| 5  | 19 | 14 | 26 | 39 | 45 | 양품 |
| 6  | 20 | 25 | 38 | 40 | 43 | 양품 |

※ NA가 다수를 차지하는 행과 열까지 모두 대체하는 것은 비합리적.  
5% 이상의 결측 비율이면, 삭제하는 것이 좋다는 사람도 있지만, 절대적인 기준은 없습니다.  
특히, 변수의 삭제는 신중할 필요가 있습니다.  
결측치는 삭제와 대체 등을 적절히 조합하여 대응하는 것이 적합할 것입니다.  
가장 좋은 방법은 한 땀 한 땀 들여보며 어떻게 처리할 것인지를 의사결정을 하는 것입니다.  
특히 데이터 수가 얼마 안될 때에는 이런 수고를 기꺼이 감내해야 합니다.

기술적 관점에서 19로 임의 지정      최빈값으로 대체

이상치란, 무리에서 떨어져 있는 데이터를 말합니다.



1 비합리적 이상치


명백한 오류.  
예를들어, 5점법 측정에서 55점이 기록된 경우.  
결측치에 준해서 처리한다.

2 합리적 이상치

오류가 아니나, 통상의 데이터 무리에서 벗어난 데이터.  
예를 들어 고졸, 대학 중퇴, 대졸, 대학원졸 순으로 소득과의 관계를 분석하는 경우, 만약 빌 게이츠나 스티브 잡스가 포함된다면, 이들의 데이터는 통상의 범위에서 벗어난 것으로 이상치라고 할 수 있다.

이러한 데이터를 분석에 포함시킬 것인가 혹은 적절히 조치를 위한 것인가는 분석의 목적에 따라 판단해야 한다.

※ 합리적 이상치는 탐색의 대상이 되며, insight의 재료가 된다.



이상치 탐지는 **Anomaly Detection**이란 주제로 Big Data 분석에서 중요한 분야 중의 하나입니다. 이는 전통적인 통계적 기법을 활용할 수도 있고, 머신러닝을 활용할 수도 있습니다. .

통계적 방법은 오른 쪽 그림과 같이 다양한 방법이 존재하며, 머신러닝을 활용하는 방법으로도 Supervised, Unsupervised, Semi-supervised 방법론 등 다양합니다.

탐지 방법보다 더 중요한 것은 이상치를 어떻게 정의할 것인가 하는 것입니다.

데이터 결합이란, 여러 데이터 소스로 부터 수집한 데이터를 하나의 Data-set으로 만드는 것을 말합니다.

Partner A

| Part ID | Material | Lead Time (weeks) | Price (dollars) |
|---------|----------|-------------------|-----------------|
| 10010   | Fe       | 2                 | 40              |
| 10011   | Cu       | 3                 | 55              |
| 10013   | Alloy    | 4                 | 67              |

Partner B

| Part ID | Material | Price(dollars) |
|---------|----------|----------------|
| 10010   | Fe       | 40.30          |
| 10012   | Cu       | 54.80          |
| 10013   | Alloy    | 67.47          |

Integrated database

| Part ID | Material | Price (dollars) | Lead Time (days) |
|---------|----------|-----------------|------------------|
| 10010   | Fe       | 40.30           | [8, 14]          |
| 10011   | Cu       | [54.50, 55.49]  | [15, 21]         |
| 10012   | CU       | 54.8            | φ                |
| 10013   | Alloy    | 67.47           | [22, 28]         |

몇 일로 추정?

데이터 선택이란, 수집한 Data-set에서, 분석 대상 Data-set을 추출하는 것을 말합니다.

Feature (attribute)

| 구분 | y1 | y2 | yn | x1 | x2 | Y | Side effect |
|----|----|----|----|----|----|---|-------------|
| #1 |    |    |    |    |    |   |             |
| #2 |    |    |    |    |    |   |             |
| #3 |    |    |    |    |    |   |             |
|    |    |    |    |    |    |   |             |
| #n |    |    |    |    |    |   |             |

instances

Record(instance) Selection

- 전체 모집단에서 대표하는 subsample을 만들어 분석.  
시계열 데이터에서 많이 사용하며, Validation을 목적으로 사용하는 경우가 많음.  
subsample size가 관심사항.
- 적시 (Timeliness)**: 미래를 위해 결론을 도출하기 원한다면, 과거의 데이터보다 최근의 것을 우선적으로 사용하는 것이 좋다.
  - 대표성 (Representativeness)**: 때때로 관심 있는 모집단이 우리가 가용 가능한 모집단과 다를 경우가 있다. 많은 샘플보다는 빈번하게 적은 샘플을 취하는 것이 샘플의 대표성을 좋게 한다.
  - 드문 사건 (Rear events)**: 거의 발생하지 않는 사건에 대해 예측을 원한다면, 샘플링 수를 늘려 event는 발생하지 않을 것이라는 확률로 판단하면 아주 좋은 성능 (performance)이 발생된다. (로지스틱 회귀분석)


참조1] 불균형 Data의 Over-sampling과 Under-sampling  
예를 들어, 남자 100명, 여자 900명으로 이루어진 모집단 1000명이 있다면  
남녀 비율은 50: 50이 일반적이므로,  
소수집단(남자)에서 Over-sampling 혹은 다수 집단(여자)에서 Under-sampling  
참조2] Bootstrapping sample

Feature Selection

- (1)Filter Method (2)Wrapper Method (3)Embedded Method

Feature Selection이란,  
수집된 데이터 세트에서 불필요한 특징들(변수들)을 제거하는 것을 말하며, 3가지 방법이 있습니다.

1 Filter Method 통계적 검정을 통한 유의한 인자 선택




| Y\X | 연속형   | 이산형        |
|-----|-------|------------|
| 연속형 | 상관분석  | 선형판별분석     |
| 이산형 | ANOVA | Chi-Square |

| Feature (attribute) |    |    |    |    |    |   |             |
|---------------------|----|----|----|----|----|---|-------------|
| 구분                  | y1 | y2 | yn | x1 | x2 | Y | Side effect |
| #1                  |    |    |    |    |    |   |             |
| #2                  |    |    |    |    |    |   |             |
| #3                  |    |    |    |    |    |   |             |
| #n                  |    |    |    |    |    |   |             |


instances

2 Wrapper Method 변수를 삭제하며 모델을 구축



Forward selection,  
Backward elimination,  
Greedy Algorithm

3 Embedded Method 스스로 평가하여 모델을 최적화



Ridge regression, LASSO,  
Deep Learning

Data 변환이란, 원 데이터를 수학 함수를 이용하여 새 값으로 바꾸는 것을 말합니다.  
이는 분석과 해석의 용이성을 도모하기 위해서 진행합니다.

[예시] Data 변환



일반적인 Data의 변환

- Scale 변경
- Power Transformation(거듭제곱, log, 제곱근 ...)
- Box-Cox Transformation
- etc.
- Logit 변환 이산형 변수를 연속형으로 변환
  - $0 \leq \text{확률 } (p) \leq 1$
  - $0 \leq \text{Odds} = \text{성공확률}/\text{실패확률} = p/(1-p) \leq +\infty$
  - $-\infty \leq \log(\text{Odds}) = \log(p/(1-p)) \leq +\infty$

표준화(Normalization)

Data를 변환하는 또 다른 이유는 변수의 영향도나 중요성을 객관적으로 상호비교 하기 위한 것입니다. 일반적으로 집단의 유사성은 거리(distance)로 측정하는데, 이는 사용된 척도(scaling)에 따라 달라집니다. 이와 같이 Scale에 무관한 무차원 데이터로 만들기 위하여 표준화(Normalization)을 실시합니다. 대표적인 방법들로 최대최소 표준화(min-max normalization)와 z값 표준화(z-score normalization)가 있습니다.

- min-max normalization

$$n : \text{dom } X \rightarrow [0, 1], \quad x \mapsto \frac{x - \min_X}{\max_X - \min_X}.$$

- z-score normalization

$$s : \text{dom } X \rightarrow \mathbb{R}, \quad x \mapsto \frac{x - \hat{\mu}_X}{\hat{\sigma}_X}.$$

- robust z-score standardization : 평균과 표준편차가 이상점에 영향을 많이 받을 경우

$$s : \text{dom } X \rightarrow \mathbb{R}, \quad x \mapsto \frac{x - \tilde{x}}{IQR_X}.$$

- decimal scaling : s는 log10 (x의 최대값) 보다 큰 최소의 정수. X의 소수점을 이동시켜 정규화 함.


$$d : \text{dom } X \rightarrow [0, 1], \quad x \mapsto \frac{x}{10^s}.$$

이산화(discretization)

모델링 알고리즘을 사용할 때, 모델링 도구에 맞도록 data 속성으로 변환해야 합니다.  
전형적인 해법은 명목, 순서형을 이진 속성으로 변환하는 것입니다.

이산화(discretization)를 통해 구간을 나누는 방법은 여러 가지가 있다.  
등폭(equi-width) 이산화(discretization)는 같은 폭으로 모든 구간을 나누는 것을 의미합니다.  
등빈도(equi-frequency) 이산화(discretization)는 모든 구간들이 같은 데이터 수를 포함하는 것을 말합니다.

- <예시>
- Data : 0, 4, 12, 16, 16, 18, 24, 26, 28
  - Equal width
    - Bin 1: 0, 4                    [-,10)
    - Bin 2: 12, 16, 16, 18        [10,20)
    - Bin 3: 24, 26, 28            [20,+)
  - Equal frequency
    - Bin 1: 0, 4, 12                [-, 14)
    - Bin 2: 16, 16, 18            [14, 21)
    - Bin 3: 24, 26, 28            [21,+)



문제 재구성 (Problem Reformulation)

변환(Transformation)은 적용할 수 있는 기술의 범위를 키우기 위해서 문제를 재구성하는데 도움이 됩니다.  
어떤 분류(classification) 기법은 복합적인 범주(multiclass)의 속성을 변환하여 두 개의 변수(binary class)로 다룰 수 있습니다.  
ex. 이산데이터의 Logit, Profit 모형으로의 변환으로 관계의 추정

특징추출(Feature Extraction)


원본 특징들의 조합으로 새로운 특징을 조합 및 생성하는 것으로, 주성분분석이 대표적인 방법입니다.




체질량 지수(body mass index, BMI)는 인간의 비만도를 나타내는 지수로, 체중과 키의 관계로 계산 (= 몸무게 ÷ 키<sup>2</sup>), 여기서 몸무게는 Kg, 키는 m 단위임

- Data는 양보다 질 (Garbage in, Garbage out)
- 데이터 준비가 전체 프로젝트 기간의 80%를 점유하며, 결과의 80%를 지배합니다.
- 결측치와 이상치의 처리는 세심한 주의가 필요합니다.


## ① Data Cleaning



## ② Data Integration



## ③ Data Transformation



## ④ Data Selection

