



기술적 분석 (Descriptive Data Analysis)


DDA의 개념과 방법에 대해서 이해






목적

- ✓ 과제는 정한 시간이 되어서 끝나는 것이 아니라, 목적을 달성하고 종료된다.
- ✓ 모든 과제가 예측모델을 개발해야 하는 것은 아니며, 따라서 과제의 실행 절차는 과제의 목적에 따라 서로 다를 수 밖에 없다.



기술(記述)적 분석


대상이나 과정의 내용과 특징을
있는 그대로 열거하거나 기록하여 서술함




601.6	602.8	598.4	598.2	600.8	600.8	600.4	598.2	599.4	601.2	602.2	601.6	599.8	603.8	600.8	598.0	601.6	602.4	601.4	601.2
600.4	600.8	599.6	602.0	598.6	597.2	598.2	599.4	598.0	599.0	599.8	600.2	602.8	603.6	600.2	598.4	603.4	602.2	599.2	604.2
598.4	603.6	603.4	599.4	600.0	600.4	598.6	599.4	597.6	600.4	599.8	601.8	600.0	601.8	600.4	600.8	597.0	600.6	601.6	600.2
600.0	604.2	600.6	599.4	600.4	599.8	599.6	600.2	598.0	600.6	601.0	601.2	599.6	602.0	600.2	602.8	599.8	596.2	600.4	600.0
596.8	602.4	598.4	600.8	600.8	596.4	599.0	599.0	597.6	599.0	601.6	597.6	602.2	603.6	602.2	597.6	597.8	602.4	598.0	596.8

기술적 분석이란, 수집된 데이터 전체를 한 두 개의 값으로 요약하여 표현하는 것

우리의 관심 사항은 변수며, 변수는 패턴과 확률로 표현한다.  중심위치, 산포, 모양




모든 원은
중심점과 반지름만 알면 그려낼 수 있다.



모든 Data은
중심위치와 산포를 알면 그려낼 수 있다.

*모양에 관해서는 탐색적 분석에서 확인함



➡ 중심위치와 산포로 요약한다.

● Data의 **중심위치**를 나타내는 특성 값

1) (산술) 평균(Average, mean)

- 모든 연속형 Data에 적용할 수 있다.
- Data의 수와 상관없이 항상 유일한 값을 가진다.
- 확장성이 좋다.
- 극단값의 영향을 많이 받는다.

Xbar

$$\bar{X} = \frac{\text{Data의 합}}{\text{Data의 수}} = \frac{X_1 + X_2 + X_3 + \dots + X_n}{n}$$

2) 중앙값(Median)

- 순서를 부여할 수 있는 연속형 Data에 적용 가능하다.
- Data의 수와 상관없이 항상 유일한 값을 가진다.
- 평균에 비해 극단값의 영향을 덜 받는다.
- 확장성이 없다.

오름차순으로 나열된 데 Data의 50%에 해당하는 값

- n이 홀수 : (n+1)/2 번째 값
- n이 짝수 : (n/2) 번째 값과 (n/2)+1 번째 값의 평균

3) 최빈값(Mode)

- 연속형, 이산형 Data에 모두 적용 가능하다.
- 극단값의 영향을 받지 않는다.
- 하나 이상의 최빈값이 가능하고, 존재하지 않을 수도 있다.
- 확장성이 없다.

수집된 Data의 값들 중에서 가장 빈도가 높은 값


예제] 다음 Data의 평균, 중앙값, 최빈값은? [6.5 , 9.0 , 9.0 , 9.1 , 9.2 , 9.3 , 9.6 , 10.0]

중심위치는...



연속형 데이터에서는 **평균**을 가장 많이 사용한다.

그러나, 치우침이 있을 때에는 **중앙값(중위수)**를 사용하는 경우가 많다.

이산형 데이터인 경우는 평균과 중앙값은 사용하지 않는다.



소득 분포를 요약할 때, 흔히 **중위수**를 사용합니다.
이것은 치우침(불균형)을 반영하기 위함입니다.



이산형 데이터는 평균이나 중위수를 사용하지 않고, 최빈값을 사용합니다.

[예] 리커트 순서 척도인 경우



5명 조사 결과 Data :2점, 3점, 5점, 5점, 5점

평균 만족도 = 4점

☞ 순서척도를 구간척도 취급한 것.
기준값 간의 간격이 동일하다고 가정할 수 있을 때, 사용 가능

최빈값 = 5점

☞ '매우만족'하는 사람이 가장 많다.

5점 비율 60%

이산형 데이터는 평균이나 중위수 보다는, **최빈값**을 사용합니다.

[예] 등간으로 볼 수 없는 순서 척도의 경우



메달 집계 순위

2월 22일(목) 08:00 기준

순위	국가	금	은	동	계
6	프랑스	5	4	5	14
7	스웨덴	4	4	0	8
8	대한민국	4	3	2	9
9	오스트리아	4	2	4	10
10	일본	3	5	3	11

어떤 운동 선수가...
1회 대회: 동 메달
2회 대회: 은 메달
3회 대회: 금 메달
4회 대회: 금 메달
5회 대회: 금 메달




평균 2.4 메달 (금이 조금 섞인 은메달?)
중앙값: 금메달

금메달을 가장 많이 획득했다.
금메달의 점유율이 60%다.

이산형 데이터는 평균이나 중위수를 사용하지 않고, **최빈값**을 사용합니다.

[예] 명목 척도인 경우



남성, 여성과 같은 명목척도도
Data 분석 시에는 숫자로 Coding합니다.
예를 들어,
남자는 2, 여자는 1로 바꾸는 식입니다.

그런데...

어떤 모임에
남성 30명
여성 20명이 참가했다면...



참가자의 평균 성별은 1.6입니다?

*1.6으로 남성이 더 많이 참가했다는 정보를
추정할 수 있지만, 이런 식으로 표현하지 않습니다.



● Data 의 흩어짐 정도를 나타내는 특성 값

1) 분산(variance) 과 표준 편차(standard deviation)

총변동(Sum of Square)

$$SS = \sum_{i=1}^n (\bar{X} - X_i)^2$$

(대문자)

표본분산

$$s^2 = \frac{\sum_{i=1}^n (\bar{X} - X_i)^2}{n-1}$$

(소문자)


표준편차

$$s = \sqrt{\frac{\sum_{i=1}^n (\bar{X} - X_i)^2}{n-1}}$$



2) 범위 (R : Range) : Data의 최대값과 최소값의 차이

3) IQR(Inter Quartile Range) = Q₃ - Q₁




Excel
Minitab
Tableau
JMP
SPSS
SAS
Orange
...

R
Python
MATLAB
C++
...




“모두가 컴퓨터 프로그래밍을
배워야합니다.
왜냐하면 생각하는 방법을
가르쳐주니까요”


- 故 스티브 잡스 (Apple 창업자)




1 R 공식 사이트 접속
<http://www.cran.r-project.org/>




2 Mirror Site 목록에서
Korea Mirror Site 중 선택



3 자신의 OS에 맞는
다운로드 링크를 클릭



4 Base 선택



5 회색 박스로 둘러싸인 Download R 4.0.2 for Windows 클릭 후 R 설치 파일을 내려 받기




If you want to double-check that the package you have downloaded matches the package distributed by CRAN, you can compare the [md5sum](#) of the .exe to the [fingerprint](#) on the master server. You will need a version of md5sum for windows: both [graphical](#) and [command line versions](#) are available.


Frequently asked questions

- [Does R run under my version of Windows?](#)
- [How do I update packages in my previous version of R?](#)
- [Should I run 32-bit or 64-bit R?](#)



6



7 설치 완료 후 실행한 화면



1 R studio Site 접속
<https://www.rstudio.com/>




4

RStudio 데스크톱 1.3.959 - 출시 노트

- 1. R을 설치하십시오. RStudio에는 R 3.0.1+가 필요합니다.
- 2. RStudio Desktop을 다운로드하십시오. 시스템에 권장:



5 설치 완료 후 실행 화면



[실습1] R을 이용하여, 평균, 중앙값, 표준편차, 범위, IQR 구하기
☞ 이러한 기초통계량은 Excel에서 손쉽게 구할 수 있습니다.

실습 Data File : 실습data.xlsx (sheet=1)

length
6.5
9
9
9.1
9.2
9.3
10

RStudio

File Edit Code View Plots Session Build Debug Profile Tools Help

Go to file/function Addins

lec1_2(2019).R

Source on Save Run Source

```
1
2
3 #실습 1
4
5 install.packages("readxl")
6 library(readxl)
7 setwd("D:/ODX전략W1.CoEW교육과정개발DX기본과정WR실습")
8
9 ex1 <- read_excel("실습data.xlsx", sheet=1)
10 ex1
11
12 mean(ex1$length)
13 median(ex1$length)
14 mode(ex1$length)
15
16 sd(ex1$length)
17 IQR(ex1$length)
18
19 range= max(ex1$length) - min(ex1$length)
20 range
21
```

21:1 (Top Level) R Script

Console Terminal Jobs

D:/ODX전략W1.CoEW교육과정개발DX기본과정WR실습/

Environment History Connections Tutorial

Global Environment

Data

ex1 7 obs. of 1 variable

Values

range 3.5

Files Plots Packages Help Viewer

Install Update

read

	Name	Description	Vers...
☒	readxl	Read Excel Files	1.3.1
☐	cellranger	Translate Spreadsheet Cell Ranges to Rows and Columns	1.1.0
☐	foreign	Read Data Stored by 'Minitab', 'S', 'SAS', 'SPSS', 'Stata', 'Systat', 'Weka', 'dBase', ...	0.8-80
☐	prettyunits	Pretty, Human Readable Formatting of Quantities	1.1.1

- ①윈도우 탐색기에서 폴더 주소 복사
- D:\W0DX전략W1.CoEW교육과정개발DX기본과정WR실습
- ②붙여 넣기를 한 후, 역 슬래시를 슬래시로 변경
- D:\W0DX전략W1.CoEW교육과정개발DX기본과정WR실습

[실습1] R을 이용하여, 평균, 중앙값, 표준편차, 범위, IQR 구하기

`install.packages("readxl")` 엑셀에서 data를 읽어오기 위해서 필요한 패키지 설치

`library(readxl)` 엑셀에서 data를 읽어오는 패키지 준비

`setwd("D:/0DX전략/1.CoE/교육과정개발/DX기본과정/R실습")` 작업이 진행되는 working directory (data file이 있는 곳)

변수명
`ex1 <- read_excel("실습data.xlsx", sheet=1)` : 실습data의 1번 sheet에 있는 데이터를 불러와서 ex1으로 저장
Data file 이름 1번 sheet
`ex1`

`mean(ex1$length)` ex1에 있는 length항의 데이터의 평균을 구하라

`median(ex1$length)` ex1에 있는 length항의 중앙값을 구하라

`sd(ex1$length)` 표준편차 구하기

`IQR(ex1$length)` IQR 구하기
대문자 주의~

`range = max(ex1$length) - min(ex1$length)` 범위를 구하는 내장함수가 없으므로, 최대값-최소값으로
범위를 구함.

`range`

☞ 최빈값을 구하는 내장함수도 없습니다.

[실습2] R을 이용하여, 평균, 중앙값, 표준편차, 범위, IQR 구하기
☞ 이러한 기초통계량은 Excel에서 손쉽게 구할 수 있습니다.

실습 Data File : 실습data.xlsx (sheet=2)

data1	data2	Data 3
98	98	99
98	97	94
99	99	86
99	100	90
100	98	94
100	99	93
101	98	99
101	97	100
102	98	91
102	101	94

#실습 2

실습1을 하면서 이미 지정되었으므로, 또 지정할 필요는 없습니다.
명령어 앞에 #표기를 하면, 해당 라인은 동작하지 않습니다.

#install.packages("readxl")
#library(readxl)
#setwd("D:/0DX전략/1.CoE/교육과정개발/DX기본과정/R실습")

ex2 <- read_excel("실습data.xlsx", sheet=2)
ex2

mean(ex2\$data1)
mean(ex2\$)

◆ data1
◆ data2
◆ Data 3

R은 대소문자 및 띄어쓰기를 모두 인식합니다.


[실습2] R을 이용하여, 평균, 중앙값, 표준편차, 범위, IQR 구하기

```
ex2 <- read_excel("실습data.xlsx", sheet=2)  
ex2
```

```
mean(ex2$data1)  
mean(ex2$data2)  
mean(ex2$`Data 3`)
```

```
mean(ex2$data1) ; mean(ex2$data2) ; mean(ex2$`Data 3`)  
sd(ex2$data1);sd(ex2$data2);sd(ex2$`Data 3`)
```

```
apply(ex2, 2, mean) Ex2 데이터를 종방향으로 평균을 구하라  
apply(ex2, 2, sd)
```



모든 통계 패키지는 요약 통계량을 제공하는 함수를 가지고 있다.



statistical summary in r

전체

이미지

동영상

뉴스

쇼핑

더보기

검색결과 약 833,000,000개 (0.45초)

www.statmethods.net > stats > descriptives

Descriptive Statistics - Quick-R

R provides a wide range of functions for obtaining **summary statistics**. One method of obtaining descriptive **statistics** is to use the `sapply()` function with a specified summary statistic. Possible functions used in `sapply` include mean, sd, var, min, max, ...

www.statsandr.com > blog > descriptive-statistics-in-r

Descriptive statistics in R - Stats and R

2020. 1. 22. — Data frame **summaries** with `dfSummary()`. The `dfSummary()` function returns a **summary** table with **statistics**, frequencies and graphs for all ...

47

48

49

summary(ex2)

35:19 (Top Level) ⬆

Console

Terminal x

Jobs x

D:/ODX전략/1.CoE/교육과정개발/DX기본과정/R실습/ ↗

> summary(ex2)

data1		data2		Data 3	
Min.	: 98	Min.	: 97.0	Min.	: 86.00
1st Qu.	: 99	1st Qu.	: 98.0	1st Qu.	: 91.50
Median	:100	Median	: 98.0	Median	: 94.00
Mean	:100	Mean	: 98.5	Mean	: 94.00
3rd Qu.	:101	3rd Qu.	: 99.0	3rd Qu.	: 97.75
Max.	:102	Max.	:101.0	Max.	:100.00

Descriptive Statistics

R provides a wide range of functions for obtaining summary statistics. One method of obtaining descriptive statistics is to use the `sapply()` function with a specified summary statistic.

```
# get means for variables in data frame mydata
# excluding missing values
sapply(mydata, mean, na.rm=TRUE)
```

Possible functions used in `sapply` include **mean, sd, var, min, max, median, range, and quantile**.

There are also numerous R functions designed to provide a range of descriptive statistics at once. For example

```
# mean, median, 25th and 75th quartiles, min, max
summary(mydata)

# Tukey min, lower-hinge, median, upper-hinge, max
fivenum(x)
```



basic statistics in r

 전체

 동영상

 이미지

 뉴스

검색결과 약 1,430,000,000개 (0.46초)

www.statmethods.net > stats > descriptives ▾

Descriptive Statistics - Quick-R

R provides a wide range of functions for obtaining **descriptive statistics** is to use the `summary()` function. Possible functions used in `summary()` include mean, sd, range, etc.

bookdown.org > mikemahoney218 > LectureBook > 15 Basic Statistics (Using R) | Introduction

15 Basic Statistics (Using R) | Introduction

This isn't a **statistics** book. However, **R** is a **statistical** programming language. The **summary()** functions built into **R** are designed for **statistical** purposes.

www.statsandr.com > blog > descriptive-statistics-in-r

Descriptive statistics in R - Stats and R

2020. 1. 22. — **Descriptive statistics** is often the first step in **statistical** analysis. It allows to check the quality of data.

www.sthda.com > R software > R Basic Statistics

R Basic Statistics

This page contains a list of R functions for descriptive statistics. It is organized by function type: summary statistics, measures of central tendency, measures of dispersion, etc.

Antoine Soetewey · 2020-01-22 · 32 minute read · R · Statistics · E

- Coefficient of variation

The coefficient of variation can be found with `stat.desc()` (see the line manually (remember that the coefficient of variation is the standard deviation

```
sd(dat$Sepal.Length) / mean(dat$Sepal.Length)
```

```
## [1] 0.1417113
```

Mode

To my knowledge there is no function to find the mode of a variable. However,

`table()` and `sort()` :

```
tab <- table(dat$Sepal.Length) # number of occurrences for each u
sort(tab, decreasing = TRUE) # sort highest to lowest
```

```
##
## 5 5.1 6.3 5.7 6.7 5.5 5.8 6.4 4.9 5.4 5.6 6 6.1 4.8 6.5 4.
## 10 9 9 8 8 7 7 7 6 6 6 6 6 5 5
## 4.4 5.9 6.8 7.2 4.7 6.6 4.3 4.5 5.3 7 7.1 7.3 7.4 7.6 7.9
## 3 3 3 3 2 2 1 1 1 1 1 1 1 1 1
```

[실습3] R을 이용하여, 평균, 중앙값, 표준편차, 범위, IQR 구하기

실습 Data File : 실습data.xlsx (sheet=3)

MC#1	MC#2
13.3	103.3
11.8	101.8
11.5	101.5
10.9	100.9
10.6	100.6
13.9	103.9
12.6	102.6
12.9	102.9
11.8	101.8
12.4	102.4
9.9	99.9
10	100
12	102
10.7	
7.8	
11.47333	101.8154

엑셀로 구한 평균

```
59 apply(ex3, 2, mean)
60
61 apply(ex3, 2, mean, na.rm=TRUE)
62
```

59:20 (Top Level) ⚡

Console	Terminal ×	Jobs ×
D:\0DX전략\1.CoE\교육과정개발\DX기본과정\R실습/ ↗		
# A tibble: 15 × 2		
`MC#1` `MC#2`		
<dbl> <dbl>		
1	13.3	103.
2	11.8	102.
3	11.5	102.
4	10.9	101.
5	10.6	101.
6	13.9	104.
7	12.6	103.
8	12.9	103.
9	11.8	102.
10	12.4	102.
11	9.9	99.9
12	10	100
13	12	102
14	10.7	NA
15	7.8	NA

```
> apply(ex3, 2, mean)
  MC#1      MC#2
11.47333      NA
> apply(ex3, 2, mean, na.rm=TRUE)
  MC#1      MC#2
11.47333 101.81538
```

NA를 제거하고
평균을 구함

```
52 ex3 <- read_excel("실습data.xlsx", sheet=3)
53 ex3
54 summary(ex3)
55
56
```


35:19 (Top Level) ⚡

Console	Terminal ×	Jobs ×
D:\0DX전략\1.CoE\교육과정개발\DX기본과정\R실습/ ↗		
# A tibble: 15 × 2		
`MC#1` `MC#2`		
<dbl> <dbl>		
1	13.3	103.
2	11.8	102.
3	11.5	102.
4	10.9	101.
5	10.6	101.
6	13.9	104.
7	12.6	103.
8	12.9	103.
9	11.8	102.
10	12.4	102.
11	9.9	99.9
12	10	100
13	12	102
14	10.7	NA
15	7.8	NA

```
> summary(ex3)
      MC#1      MC#2
Min.   : 7.80   Min.   : 99.9
1st Qu.:10.65   1st Qu.:100.9
Median :11.80   Median :101.8
Mean   :11.47   Mean   :101.8
3rd Qu.:12.50   3rd Qu.:102.6
Max.   :13.90   Max.   :103.9
NA's    :2
```

정규분포(Normal Distribution) – 가우스 분포

관심 특성 : 좌우대칭과 종형의 형태를 갖는 연속형 측정값
분포의 모수 : 평균(μ), 분산(σ^2)



정규분포는 자연현상의 기본적인 원리로 발견된다. 즉, 자연계에 존재하는 대부분의 특성치는 정규분포를 한다.
따라서 정규분포는 하는 것이 정상(Normal)이라고 할 수 있다.

(Carl Friedrich Gauss – 독일)



독일 10Mark 화폐

[예제]
제품 배달 시간이 정규분포를 따르고,
배달 시간 실적을 조사했더니 평균은 50 그리고 표준편차는 5였다.
(1) 배달 시간이 55분 이상 걸릴 확률은 얼마인가?
(2) 배달 시간이 45분 이하 걸릴 확률은 얼마인가?

```
70
71 pnorm(q=c(55), mean=50, sd=5, lower.tail=FALSE)
72 pnorm(q=c(45), mean=50, sd=5, lower.tail=TRUE)
73
74 pnorm(q=c(60), mean=50, sd=5, lower.tail=FALSE)
75 pnorm(q=c(35), mean=50, sd=5, lower.tail=TRUE)
76 |
77
```

76:1 (Top Level) ⚡

Console

Terminal ×

Jobs ×

D:/0DX전략/1.CoE/교육과정개발/DX기본과정/R실습/ ↗

> pnorm(q=c(55), mean=50, sd=5, lower.tail=FALSE)
[1] 0.1586553 55분 이상 걸릴 확률 15.87%
> pnorm(q=c(45), mean=50, sd=5, lower.tail=TRUE)
[1] 0.1586553 45분 이하 걸릴 확률 15.87%
> pnorm(q=c(60), mean=50, sd=5, lower.tail=FALSE)
[1] 0.02275013 60분 이상 걸릴 확률 2.28%
> pnorm(q=c(35), mean=50, sd=5, lower.tail=TRUE)
[1] 0.001349898 35분 이하 걸릴 확률 0.13%
~ |

The figure shows a normal distribution curve centered at 50. A vertical dashed line marks the mean at 50. Two vertical solid lines are drawn at 45 and 55, which are one standard deviation (5) away from the mean. The area under the curve to the right of 55 is shaded and labeled with a red arrow as 15.87%. Similarly, the area to the left of 45 is shaded and labeled with a red arrow as 15.87%. The x-axis is labeled '배달시간' (Delivery Time) with tick marks at 45, 50, and 55.

EDA에서 분석

우리의 관심 사항은 변수 **variable**며, 변수는 패턴으로 표현한다. ➡ 중심위치, 산포, 분포의 모양
기술적 분석이란 수집된 데이터 전체를 한 두 개의 값으로 **요약**하여 표현하는 것

