



탐색적 분석 (Exploratory Data Analysis)

- EDA의 필요성과 데이터 분석에서의 위치 이해
- EDA의 절차와 해석 방법에 대한 개념적 이해



목적

- ✓ 과제는 정한 시간이 되어서 끝나는 것이 아니라, 목적을 달성하고 종료된다.
- ✓ 모든 과제가 예측모델을 개발해야 하는 것은 아니며, 따라서 과제의 실행 절차는 과제의 목적에 따라 서로 다를 수 밖에 없다.



EDA (Exploratory data analysis, 탐색적 자료 분석)은

- 존 튜키(미국의 통계학자)가 창안한 자료 분석 방법론
- 수집한 데이터를 다양한 각도에서 관찰하고 이해하는 과정이며, 이를 통해 새로운 패턴이나 가설을 발견할 수 있다.
- 특히 주목하는 것은, 이상점(outlier), 패턴과 추이(Trend), 인자 간의 비교(Comparison)와 관계(Relationship) 등이다.

“EDA는 우리가 존재한다고 믿는 것들은 물론이고, 존재하지 않는다고 믿는 것들을 발견하려는 태도, 유연성, 그리고 자발성이다.” (존 튜키)



EDA는 철저히, 살살히, 하나 하나 분석하는 끈질김이 필요합니다. 때문에 상당히 고단한 작업입니다.
주어진 변수의 실수 값 Data를 이용하여 분석하며,
데이터의 변환, 변수 결합 등을 통해 훨씬 풍성하고, 많은 분석을 할 수 있다.

EDA (Exploratory data analysis, 탐색적 자료 분석)에서는
특히 이상점 **outlier**, 패턴과 추이 **Trend**, 인자 간의 비교 **Comparison**와 관계 **Relationship**에 주목한다.

정해진 절차가 있는 것은 아니나, 다음과 같은 순서를 따를 것을 추천

순서1. 단변량의 분포	중심위치, 산포, 모양, 이상점, 패턴	} 적합한 데이터가 있을 때
순서2. 변수 간 비교	이상점, 패턴	
순서3. 변수 간 관계	이상점, 패턴	
순서4. 시계열 변화	이상점, 패턴, 추이	
순서5. 공간 분포	이상점, 패턴, 추이	



다양한 데이터 시각화 유형의 예 (출처: datavizcatalogue.com)


“EDA는 우리가 존재한다고 믿는 것들은 물론이고,
존재하지 않는다고 믿는 것들을 발견하려는 태도, 유연성, 그리고 자발성이다.”

-존 튜키

▪ 단변량의 분포 / 이산형 데이터로 측정된 개별 X나 Y의 범주 별 비중

- 명목형 : 양품/불량, 남/녀, 10대/20대/30대 등
 - 순서형 : 금메달/은메달/동메달, 상/중/하, 매우 만족/만족/보통/불만족/매우 불만족 등
- 구간척도로 취급하는 경우도 있음

❖ Phi Chart



❖ Pareto diagram(chart)




☞ 집중화 경향, 범주별 비중의 특이 사항 등 : 기술적 해석이 중요 !!! Graph만 외롭게 두지 말 것!


[참고] 파레토 법칙과 롱테일의 법칙

파레토 법칙

20%의 원인이 80%의 결과를 지배한다.


롱테일^{long tail} 법칙

인터넷과 새로운 물류기술의 발달로 롱테일도 경제적으로 의미가 있다.




■ 단변량의 분포 / 연속형 데이터로 측정된 개별 X나 Y의 분포

❖ 히스토그램(histogram)





❖ Density Plot



☞ 중심위치, 산포를 볼 수 있으나, 특히 모양에 집중.
정규분포 Normal Distribution을 정상으로 보고, 이것에서 어긋나는 경우 그 이유를 탐색
좌우 대칭, 종 모양(Bell-Shaped)

✓ 자동화의 맹신...



■ 비교 Comparison/ 이산형 X에 따른 Y 혹은 다른 X의 값이나 범주 비중의 비교

☞ Y는 default, X는 option



❖ 막대 그래프 (Bar Plot)

No	X1	Y1	Y2
1	A	17	합격
2	A	23	불합격
3	A	19	합격
4	A	21	합격
5	B	15	합격
6	B	15	불합격
7	B	16	불합격
8	B	16	불합격

2개 범주

연속형 Y

이산형 Y




■ 비교 Comparison / 이산형 X에 따른 Y 혹은 다른 X의 값이나 범주 비중의 비교


✓ 평균 비교의 함정... 누가 더 우수한가?

- COD 농도 (1회/일 측정 관리)
- 규격 10 mg/l 이하 (망소 특성)
- 제반 조건은 동일한 것으로 가정




지난 1개월 간의 측정 결과 평균



A 사업장




B 사업장



■ 비교 Comparison / 이산형 X에 따른 Y 혹은 다른 X의 값이나 범주 비중의 비교


✓ 빈도 비교의 함정...

이슈 발생건수 비교




구분	A	B
검토 대상	500	100
이슈 건수	100	50
불만을	20%	50%

이슈 발생율 비교



✓ 비율 비교의 함정...

합격을 비교







구분	A	B
검토 대상	3	100
합격수	3	80
합격율	100%	80%

기준점의 과도한 차이는
비교 자체를 의미없게 만듭니다.

관계 그래프의 해석


- 관계Relationship/ 연속형 X와 Y의 관계 혹은 연속형 X들 간의 관계

❖ Scatter Plot과 Matrix Plot




관계Relationship/ 연속형 X와 Y의 관계 혹은 연속형 X들 간의 관계

✓ 상관관계




상관성이 높다




상관성이 낮다


✓ 이상치Outlier




이상치 때문에 관계가 없는 것이
관계가 있는 것처럼 보일 수 있습니다.



✓ 시선 유도






상관관계가 없어 보이는 것도
상관관계가 있는 것처럼
시선유도가 일어날 수 있습니다.



관계Relationship/ 연속형 X와 Y의 관계 혹은 연속형 X들 간의 관계



상관관계와 인과관계



관계 그래프의 해석

■ **관계**Relationship/ 연속형 X와 Y의 관계 혹은 연속형 X들 간의 관계

✓ 상관관계와 인과관계



인과 관계를 확인할 수 있는 두 가지 방법

- ① 이미 알고 있는 지식으로 판단
- ② 실험 (Experiment)을 통한 규명

✓ 흥미도 : 우연과 당연

Data 분석을 통해 확인된 상관관계가 모두 인과관계는 아니다.

우연하게 나타난 현상이라 인과관계가 없는 것도 있지만

인과관계라도 흥미롭지 않은 당연한 관계는 관심의 대상이 되기 어렵다.

우연하지만 필연적이지 않다.



필연적이지만 당연해서 흥미롭지 않다.



관계 그래프의 해석

✓ Practically Reasonable : 현장의 제약 조건을 고려



모든 데이터 분석은 항상 기술적으로 해석해야 한다.

데이터 분석 결과는 정보며, 그 정보가 기술적으로 해석될 때, 지식이 된다.

기술적으로 해석된다 함은, 실무적으로 그럴듯 해야 한다.









이는 세상의 제약 조건을 함께 고려하여 생각하는 것을 말한다.

Practically Reasonable (예시)





- 분포 Distribution
- 구성비 Composition
- 비교 Comparison
- 관계 Relationship
- 시간 추이 Time Series
- 공간 분포 Spatial



- 분석의 목적이 모든 과정을 지배한다.
- EDA는 사례중심의 귀납적 접근으로, 선입견을 배제한 개방적 논증으로 새로운 해석의 가능성을 추구한다.
 - “EDA는 우리가 존재한다고 믿는 것들은 물론이고, 존재하지 않는다고 믿는 것들을 발견하려는 태도, 유연성, 그리고 자발성이다.” (존 튜키)
 - DA는 철저히, 살살히, 하나 하나 분석하는 끈질김이 필요하다.
- EDA의 결과 발견된 사실이 모두 흥미로운 것은 아니다.
 - 발견된 사실의 80%는 이미 알고 있는 사실을 확인하는 수준일 수 있다.
 - EDA 결과는 검증하거나, 올바르게 해석하여 insight를 찾아야 한다.