

확인적 분석

- CDA의 필요성과 데이터 분석에서의 위치 이해
- CDA의 절차와 해석 방법에 대한 개념적 이해





알고 있는 세상으로 알고 싶은 세상을 합리적으로 추정하는 것이 데이터 분석이다.

표본
(표본을 측정하여 확인한 사실)


모집단
(지식의 일반화, 미래의 예측)

오차를 감안한 의사결정






“목적이 모든 과정을 지배한다”




준비




수집된 데이터의 전체 모습을 확인하고,
데이터 품질 평가와 데이터 전처리의 방향 수립


분석



적용

데이터 분석은
반복적 과정







확인적 분석(CDA)는 소수의 Data로 비교 평가하여, 모호한 상황에서 의사결정을 돕는 것

(샘플 집단에서의 차이가 모집단에도 적용되는가를 확인하는 통계적 추론)

- 2집단의 평균 비교 : 2 sample t – test
- 3개 이상 집단의 평균 비교 : ANOVA
- 2집단의 비율 비교 : 2 proportion – test
- 3개 이상 집단의 비율 비교 : Chi-square test
- 집단 간 산포 비교 : variance – test
- 연속형 변수 간 관계의 강도 : 상관계수


확인 사항 (1) 데이터 수 (2) p-value

✓ 기계적 의사결정 vs. 합리적 의사결정




통계적 가설 검정 : **p값의 확인**

- p값은 통계적 의사결정이 틀릴 확률을 의미한다.
- 의사결정의 경중에 따라, 기준은 달라질 수 있다.
- 1%(0.01), 5%(0.05), 10%(0.1)을 사용할 수 있으며, 전형적으로 5%를 사용한다.
- 그렇다면, 극단적인 사례로서 p값이 0.051인 경우 혹은 0.049인 경우 어떤 의사결정이 합리적이라 할 수 있을까?



의사결정은 통계가 해주는 것이 아니라, 분석 결과를 해석하는 사람의 몫이다.


✓ Big Data와 확인적 분석 Big Data 분석은 많은 경우 통계적 추론을 목적으로 하지 않는다.



A 무한모집단인 공정에서 생산된 제품을 Lot를 구성하여 유한 모집단을 만듭니다.

Lot에서 일부를 샘플링하여, Data를 취한 후 통계량을 구합니다.
이렇게 구한 통계량으로 모수를 추정하여, 의사결정을 하게 됩니다.
이때 오차를 감안한 의사 결정을 하게 됩니다.

B 기술의 발달과 더불어 이것이 가능해졌습니다.
공정에서 생산되는 모든 제품을 검사(측정)하여 빅데이터를 수집할 수 있습니다.
이때, 전수 데이터에서 구한 통계량은 유한모집단인 Lot의 모수와 일치합니다.
즉, 통계적 추론(CDA)를 사용할 필요가 없습니다.
하지만 무한모집의 모수는 통계적 추정을 해야 합니다.




우리 홈 페이지를 방문하는 고객 Data를가 왼쪽 그림과 같다면...
즉, 일부의 고객 만이 우리 홈 페이지를 방문하고, 그 중 일부만 디지털 흔적을 남겨서,
그것을 우리가 데이터로 수집한 것이라면,

그렇게 수집된 데이터를 분석하여, 모든 소비자로 일반화 할 수 있을까요?

✓ p-Hacking (Data Snooping)

2차 세계대전 당시 미군 전투기가 격추되는 것을 줄이기 위해 전장에서 돌아온 전투기들의 외상을 분석하여 취약 부분을 보강하는 계획을 세웠다고 합니다. 오른쪽 그림의 붉은 색 점은 총탄의 위치를 의미합니다. 이 부분을 보강할 계획을 세웠는데, 이는 살아 돌아 오는 비행기가 손상된 비행기의 전체를 대표한다고 암시 적으로 가정했기 때문입니다. 그러나 Abraham Wald가 이끄는 데이터 분석팀은 손상되지 않은 곳을 강화할 것을 권장했습니다. 돌아 오는 비행기는 돌아오지 못한 비행기가 빠진 편향된 표본이란 것을 인식했기 때문입니다.


[예시] 선택편향 (생존자 편향)



선택편향 : 데이터를 잘못 선택함으로써 발생하는 데이터 분석의 왜곡 문제.

데이터 수집 과정 중 선택 편향이 존재한다면, 아무리 데이터 양이 많더라도 그런 데이터를 분석하여 얻은 결과는 적합성과 유용성이 크게 상처를 받게 됩니다. 모르고 데이터를 수집했다면 안타까운 일이고 알고도 그렇게 수집했다면 **Data를 이용한 사기**가 될 것입니다.

Historical Big Data를 이용한 소급연구에서는 이와 같은 선택 편향이 발생할 우려가 항상 존재합니다. 환경을 비롯한 제반 조건이 과거와 현재 그리고 미래가 똑같을 수 없기 때문입니다. 또한 데이터 수집 영역에 따라 난이도 등이 다른 경우에도 선택 편향이 발생할 수 있습니다. 데이터 수집이 어려우면 피하고 싶고, 돈이 너무 많이 들면 불가능할 수도 있습니다.




선택 편향을 완전히 제거한다는 것은 불가능합니다. 아무리 작은 양이라고 해도, 표본오차는 존재하기 마련이며, 무엇보다도 모든 데이터 분석과 그 결과의 해석에는 분석가의 관점이 반영될 수 밖에 없기 때문입니다. 즉, 의도하지 않더라도 부지불식간에 자신의 생각을 지지하는 데이터나 분석 결과를 선택적으로 취하는 사람의 심리가 존재합니다.

✓ p-Hacking (Data Snooping)

확증 편향 Confirmation bias 은 원래 가지고 있는 생각이나 신념을 확인하려는 경향성을 말합니다.

흔히 하는 말로 “사람은 보고 싶은 것만 본다”와 같은 것이 바로 확증 편향입니다.
사람들은 자신이 원하는 결과를 간절히 바랄 때,
또는 어떤 사건을 접하고 감정이 앞설 때,
그리고 저 마다의 뿌리 깊은 신념을 지키고자 할 때 확증 편향을 보입니다.

확증 편향은 원하는 정보만 선택적으로 모으거나,
어떤 것을 설명하거나 주장할 때 편향된 방법을 동원합니다.
사람들은 원하는 결과가 있을 때 소망적 사고에 따라
자신의 관찰과 경험을 편향적으로 재해석하고자 합니다.



확증편향은 대표적인 인지편향Cognitive bias 의 하나 입니다. 인지편향이란 경험에 의한 비논리적 추론으로 잘못된 판단을 하는 것을 말합니다.
입력된 인식으로부터 사람들이 자신만의 "주체적인 현실"을 창조하기 때문에 발생한다고 할 수 있습니다.

인지 편향은 여러 차원에서 구분될 수 있습니다.

- 개인적 차원에서의 인지 편향과 대조되는, 집단 차원에서 발생하는 인지 편향 (예: 집단 극화)
- 선택의 만족도를 판단할 때 발생할 수 있는 인지 편향 (예: 매몰비용 오류)
- 인과관계의 오류
- 일반화의 오류
- 긍정적인 자아 형성을 향한 욕구와,
논리적 충돌을 회피하고자 하는 욕구에서 비롯된 의도적 합리화(Motivated reasoning)



시스템 1 : 직관적인 빠른 사고

- 고속으로 자동적으로 행하여 멈출 수 없음
- 생각해야하는 노력이 거의 불필요
- 인상을 바로 느끼거나 연상이 가능
- 편견이 있음



시스템 2 : 논리적으로 느린 사고


- 시스템 1에서 답이 없을 때 행함
- 생각하는데 주의력이 필요
- 논리적 / 통계적 사고 가능
- 최종 결정권은 시스템 2가 가짐

✓ p-Hacking (Data Snooping)

분석가들이 저도 모르게 혹은 일부러 p-값을 슬쩍 조작하는 것

Snoop이란 '기웃거리다, 엿듣다'라는 뜻을 가지고 있습니다.
즉, 데이터 스누핑이란, 데이터를 엿듣하여 자신이 원하는 결과를 이끌어내는 것을 말합니다.
다음 용어들은 모두 같은 의미로 사용됩니다.

Data fishing, data dredging, data butchery, significance chasing, significance questing, selective inference, p-hacking




가설검정에서 p값p-value는 통계적 유의성을 결정하는 기준 값으로, 0.05(=5%)가 흔히 사용됩니다. 예를 들어, 광고비 지출이 매출액에 영향을 미치는가를 데이터로 확인하고자 할 때, p값이 0.05 미만이 나오면 광고비 지출은 매출액에 영향을 미친다고 판정합니다.


문제는 어떻게 하면 p값을 0.05 미만으로 만들 수 있는 가를 너무도 잘 알고 있다는 것입니다.

어떤 데이터를 수집하면 그런 값이 나올 것인지를 잘 알며,
또한 데이터 수집 후에도 데이터를 몇 개 제거하거나 추가하여 p값을 0.05 미만으로 만들어낼 수 있습니다.
또한 데이터를 미리 수집해두고, p값이 0.05 미만이 나오는 것을 거꾸로 논리를 끼워 맞추다거나
혹은 p값이 0.05 미만이 나올 때 까지 데이터를 변환하거나 결합하는 것입니다.
예를 들어, X1, X2는 유의하지 않으나, X1X2X3 혹은 log(X1X2X3)은 유의할 수 있습니다.
데이터를 무한히 변환하면 어디선가는 p값 0.05 미만을 찾아낼 수 있습니다.

이를 '피-해킹'(p-hacking)이라고 합니다.
이는 결코 데이터를 조작하는 것은 아니지만, 데이터를 이용한 사기일 뿐입니다.




✓ Big Data와 확인적 분석 Big Data 분석은 많은 경우 통계적 추론을 목적으로 하지 않는다.




빅 데이터는 표본의 크기가 엄청 크므로 오차가 작아질 것이라는 기대가 있으며, 따라서 의사 결정의 모호성이 사라질 수 있다는 장점을 누릴 수 있습니다. 즉, Big Data 분석에서는 굳이 확인적 분석을 하지 않아도 될 수 있습니다.

하지만, 편의가 심하다면, 더 큰 오류를 생산하는 위험도 있습니다. 즉, 모든 데이터 기반 의사결정에서는 일반화의 오류를 경계해야 하지만 Big Data에서는 그 정도가 심해질 수도 있습니다.



표본 추출에서 우연히 발생하는 오차는 표본 크기를 키우면 감소하고, 편의(bias)에 의한 오차는 표본추출 방법을 올바르게 적용하여 축소시킬 수 있습니다.

	표본조사 데이터	빅데이터
편향	Bias = 0	Bias ≠ 0
분산	Variance = K/n	Variance ≅ 0



- ④ 사례중심의 귀납적 접근으로,
선입견을 배제한 개방적 논증으로 새로운 해석의 가능성을 높여준다.


Diagram illustrating the difference between Induction (귀납) and Deduction (연역):

- 귀납 (Induction):** Specific instances (a pink triangle, a light blue pentagon, a purple square, and a light pink hexagon) are used to derive a general principle (일반적 원리).
- 연역 (Deduction):** A general principle (일반적 원리) is used to derive specific instances (a pink triangle, a purple square, a light blue pentagon, and a light pink hexagon).

✓ 공짜 점심은 없다.
만능은 없다.
어떤 것을 얻으려면 반드시 상응하는 대가를 치러야 한다.

Big Data는
자료 수집 비용을 절약하지만
자료 분석 비용의 증가를 초래한다.
즉, 공짜 점심은 없다.

- 빅데이터의 **희망** (기회요인)
 - 자료 수집 비용을 절약
 - 풍부하고, 다양하고, 빠른 정보
 - 세부 도메인에 대한 정보를 제공 (소지역 추정)
- 빅데이터의 **절망** (위험요인)
 - 편향 존재 (선택 편향, 정보 편향)
 - 대수의 법칙이 성립하지 않음



미국의 경제학자 밀턴 프리드먼이 속담처럼 즐겨 쓰던 표현입니다.
공짜 점심'은 미국 서부 개척시대에서 유래되었다고 합니다.
당시 어느 술집에서는 술을 일정 한도 이상 마시면
점심식사를 공짜로 제공했다고 합니다.
이는 술깃한 공짜 서비스처럼 들리지만 실상은 달랐습니다.
막상 공짜로 점심밥을 먹으려면 그만큼 술을 많이 마셔야 하고
당연히 술값을 많이 내야 했기 때문입니다.
결국 술집이 제공하는 점심식사의 값이 술값에 포함되는 셈입니다.
여기서 유래한 것이 공짜 점심의 법칙 No Free Lunch Theorem입니다.

알고 싶은 세상

전체 유권자
42,479,710명

1,030명이 전체 유권자를 대변?

No....표본 오차

전국 성인남녀
1,030명

오차를 감안한 의사결정

±3.1%포인트


- 문재인 = 33.4~40.1%
- 안철수 = 23.3~29.5%

- 문재인 : 37.5%
- 안철수 : 26.4%

알고 있는 세상

목적

- ✓ 과제는 정한 시간이 되어서 끝나는 것이 아니라, 목적을 달성하고 종료된다.
- ✓ 모든 과제가 예측모델을 개발해야 하는 것은 아니며, 따라서 과제의 실행 절차는 과제의 목적에 따라 서로 다를 수 밖에 없다.



- 분석의 목적이 모든 과정을 지배한다.
- 확인적 분석은 모호한 상황에서 합리적 의사 결정을 돕는다.
 - 데이터 기반 의사결정이란 오차를 감안한 의사결정을 말한다.
 - Data 개수가 많아질 수록 (표본)오차는 줄어든다.
 - 의사결정은 통계가 내리는 것이 아니라, 사람의 몫이다.