



예측적 분석

PDA의 개념을 이해하고, 활용 시 주의 사항을 확인






“목적이 모든 과정을 지배한다”




준비




수집된 데이터의 전체 모습을 확인하고,
데이터 품질 평가와 데이터 전처리의 방향 수립

분석



적용

데이터 분석은
반복적 과정



목적/목표

결과에 영향을 미치는 인자들

$$Y = \underline{f}(X_1, X_2, X_3, \dots)$$

(예측)함수



= f(출전 경기수, 타율, 타점, 홈런, 수비율, 팬심, 리더십, 훈련 태도

X(원인/인자)들의 조건으로 Y(결과)를 예측한다...

회귀 분석 (Regression Analysis)	독립변수 값이 주어졌을 때, 결과변수 값 추정 (Y가 연속형인 Labeled Data를 이용한 지도학습)	Linear Regression, Non-linear Regression, Regularized Regression(Ridge, LASSO, Elastic), Generalized Regression(Logistic Regression, Poisson Regression)
분류 분석 (Classification Analysis)	대상 개체를 사전에 정해진 범주 중의 하나로 할당하는 것 (Y가 이산형인 Labeled Data를 이용한 지도학습)	1R(1 rule), Naïve Bayesian, k-NN(k-Nearest Neighborhood), Regression, Logistic Regress, Discriminant Analysis, Decision Tree, Ensemble Method, SVM(Support Vector Machine) Neural Network
군집 분석 (Cluster Analysis)	주어진 Data의 구조를 파악하기 위하여 유용한 그룹으로 나누는 것 (unlabeled Data를 이용한 자율학습)	연결 기반 군집분석(계층적 군집분석) 중심 기반 군집분석(K-means, K-Medoids) 분포 기반 군집분석, 밀도 기반 군집분석, 그래프 기반 군집분석
시계열분석 (Time Series Analysis)	시계열 데이터에 바탕을 둔 분석으로, 회귀분석의 특수한 경우	AR(Auto-Regression), MA(Moving Average), ARMA, ARIMA(Auto-Regressive Integrated Moving Average)
연관 규칙 분석 (Association Rule Analysis)	동시발생 관계가 있는 사건이나 활동을 발견(반복 가능한 규칙을 확률로 표현)	Collaborative Filtering, Contents-based Filtering, Knowledge-based Filtering, Hybrid Filtering

$y=f(x)$ 를 구하는 이유는 **설명(Explanation)**과 **예측(Prediction)**이다.

▪ 설명의 관심 사항

- (1) 어떤 설명변수(X)들이 반응변수(Y)와 관련되어 있는가?
- (2) Y에의 영향도가 어떤 설명변수가 다른 설명변수들 보다 얼마나 큰가?
- (3) 반응변수와 설명변수 간의 상관관계는 무엇인가?


▪ 예측의 관심 사항

- (1) 미래를 예측한다.
 - (2) Y값을 예측한다.
- X들의 특정 값이 주어졌을 때, Y값을 예측.


정확한 예측을 제공한다면, 그것의 형태에는 신경 쓰지 않고 Black Box로 취급한다.

White Box vs. Black Box


✓ 예측 모형의 성능 평가: 반드시 Test-Set으로 성능 평가



✓ [예시] 예측 모형의 성능 평가



회귀모형의 성능지표



✓ ① 설명력(기여율) : R^2 $R^2 = 1 - \frac{SS_{RES}}{SS_{TOT}} = 1 - \frac{\sum_i (\overset{\text{실제값}}{y_i} - \overset{\text{예측값}}{\hat{y}_i})^2}{\sum_i (\underset{\text{y값 평균}}{y_i} - \bar{y})^2}$

② 평균제곱예측오차 MSE(mean squared error) $MSE = \frac{1}{N} \sum_{i=1}^N (\overset{\text{실제값}}{y_i} - \overset{\text{예측값}}{\hat{y}_i})^2$

③ RMSE root mean squared error $RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$


④ 평균절대예측오차 MAE(mean absolute error) $MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|$

⑤ 평균절대백분위예측오차 MAPE(mean absolute percentage prediction error) $MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{\overset{\text{실제값}}{y_i} - \overset{\text{예측값}}{\hat{f}(x_i)}}{y_i} \right|$

회귀모형의 성능지표

✓ 「1-MAPE평균절대백분위예측오차」를 예측정확도라고 표현하고, 활용하는 경우 백분율(%)로 표현되므로, 직관적이라는 장점이 있습니다만....

[예시] 판매량 예측 문제




과다 예측 : 시간이 지날수록 재고 증가

$MAPE = \frac{1}{4}(10+11.1+10+11.1) = 21.1$
1- MAPE = 78.9%

☞ 실제 값이 크면 클 수록 유리

$R^2 = 1 - \frac{SS_{RES}}{SS_{TOT}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$

$R^2 = 1 - \frac{400}{100} = 0 \%$




과다 예측 : 시간이 지날수록 Back Order 증가

$MAPE = \frac{1}{4}(9.1+10+9.1+10) = 9.6$
1- MAPE = 93.4%

☞ 과소 예측이 과다 예측 보다 유리

$R^2 = 1 - \frac{400}{100} = 0 \%$



시간이 지나면서 수요-공급 균형

$MAPE = \frac{1}{4}(9.1+10+9.1+10) = 9.6$
1- MAPE = 93.4%

$R^2 = 1 - \frac{400}{100} = 0 \%$

회귀모형의 성능지표


회귀모형의 성능지표

✓ 설명력(기여율, 결정계수) : R^2


“ Test R^2 , Not Training R^2 ”

$$R^2 = 1 - \frac{SS_{RES}}{SS_{TOT}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

실제값 예측값
 y값 평균



- 0 ~ 1 (0%~100%) 사이의 값을 가진다.
1에 가까울 수록 좋은 회귀모형이 구해졌다는 의미




- 절대적인 판정기준은 없으나, 일반적으로....
 - 70% 이상이면 괜찮은 모형
 - 80% 이상이면 우수한 모형
 - 90% 이상이면 탁월한 모형으로 본다.
- ➔ 80% 이상을 추구한다.

회귀모형의 성능지표

✓ R²가 낮게 나온다면...

① 모형 선택이 잘못된 경우




② 중요한 인자(X, 독립변수)가 누락된 경우

- (예) $Y = a + bX_1$ -----> $R^2 = 50.0\%$
- $Y = a + bX_1 + cX_2$ -----> $R^2 = 70.0\%$
- $Y = a + bX_1 + cX_2 + dX_3$ -----> $R^2 = 70.1\%$

인자 수가 늘어날 수록 모형의 설명력은 커진다. 그러나 인자 수가 늘어나면, 데이터를 더 많이 수집해야 하고, 모형이 복잡해서 해석하기 어렵다.

③ Data Size와 품질 문제

특히, 이상치, 서로 다른 집단의 혼합 등 품질 문제 확인 필요



R²가 높아도 문제를 발생시키는 다중공선성

아들의 키 = f(아버지의 키, 몸무게)
아들의 키를 아버지의 키와 몸무게로 예측하고자 할 때, 아버지의 키와 몸무게는 상관성이 높을 것입니다.

이와 같이 독립변수들간의 상관관계가 매우 높을 때, 하나의 독립변수의 변화가 다른 독립변수에 영향을 미쳐, 결과적으로 예측모델의 안정성이 크게 떨어지는 현상을 말합니다.

특히, 설명(예측)문제에는 심각한 영향을 미쳐서, 어떤 인자가 더 중요한지 확인하기 어렵게 됩니다.

예측 문제에서도 오버피팅을 유발할 수 있으므로, 모형 개발 시에는 큰 문제를 느끼지 못할 수 있으나, 실무 적용 시에는 예측력에 문제를 일으킬 수 있습니다.

분류모형의 성능지표

Confusion Matrix

Actual Class		Predicted Class		
		Positive	Negative	
		True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$
Positive				민감도 혹은 재현율(recall)
Negative		False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$ 정밀도	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$ 예측 정확도

예시

	Predicted class POSITIVE (spam 📧)	Predicted class NEGATIVE (normal 📧)	
Actual class POSITIVE (spam 📧)	TRUE POSITIVE (TP) 📧 📧 320	FALSE NEGATIVE (FN) 📧 📧 43	$Sensitivity$ $\frac{TP}{TP + FN}$ $= \frac{320}{320 + 43} = 0.882$
Actual class NEGATIVE (normal 📧)	FALSE POSITIVE (FP) 📧 📧 20	TRUE NEGATIVE (TN) 📧 📧 538	
			$Specificity$ $\frac{TN}{FP + TN}$ $= \frac{538}{20 + 538} = 0.964$

예측정확도 = (320+538)/(320+43+20+538) = 93.5%

	Predicted class POSITIVE (spam 📧)	Predicted class NEGATIVE (normal 📧)	
Actual class POSITIVE (spam 📧)	TRUE POSITIVE (TP) 📧 📧 320	FALSE NEGATIVE (FN) 📧 📧 43	$Recall$ $\frac{TP}{TP + FN}$ $= \frac{320}{320 + 43} = 0.882$
Actual class NEGATIVE (normal 📧)	FALSE POSITIVE (FP) 📧 📧 20	TRUE NEGATIVE (TN) 📧 📧 538	
	$Precision$ $\frac{TP}{TP + FP}$ $= \frac{320}{320 + 20} = 0.941$		

F - measure = 2 * $\frac{recall * precision}{recall + precision}$ = 2 * $\frac{0.882 * 0.941}{0.882 + 0.941}$ = 0.910

$F_1measure = \frac{2}{\frac{1}{precision} + \frac{1}{recall}} = 2 * \frac{precision * recall}{precision + recall}$

* 이 외에도 여러 가지 성능 지표가 있습니다.

분류모형의 성능지표

✓ 예측정확도는 낮은 성능을 숨길 수 있다.
특히, Test-Set 데이터가 불균형한 경우는 유의해야 합니다.

[예시] 이탈 10, 잔류 90

모형 1

구분		예측	
		잔류	이탈
실제	잔류	90	0
	이탈	9	1

예측정확도
= 92/100
= 92%

잔류를 잔류로 예측한 비율과
이탈을 이탈로 예측한 비율의 평균

평균 예측 정확도

산술평균 $(100\% + 10\%)/2 = 55\%$

조화평균 $\frac{1}{\frac{1}{2} \left(\frac{1}{1.0} + \frac{1}{0.1} \right)} = \frac{1}{5.5} = 18.2\%$

모형 2

구분		예측	
		잔류	이탈
실제	잔류	70	20
	이탈	2	8

= 78/100
= 78%

산술평균 $(77.8\% + 80\%)/2 = 83.9\%$

조화평균 $\frac{1}{\frac{1}{2} \left(\frac{1}{0.778} + \frac{1}{0.800} \right)} = \frac{1}{1.268} = 78.873\%$

$$\text{average class accuracy} = \frac{1}{|levels(t)|} \sum_{l \in levels(t)} recall_l$$

산술평균보다 조화평균을 사용하는 경우가 더 많다.


$$\text{average class accuracy}_{HM} = \frac{1}{\frac{1}{|levels(t)|} \sum_{l \in levels(t)} \frac{1}{recall_l}}$$

- 다른 분류분석의 성능지표들
- 수익과 손실 추정
 - 예측 점수
 - ROC (Receiver Operating Characteristic) Curve
 - 지니 계수
 - 콜모고로프-스미로노프 통계량 (K-S Statistics)
 - 이득(gain)과 상승(lift)

분류모형의 성능지표

✓예측정확도가 낮게 나온다면...

① 알고리즘 선택이 잘못된 경우




② 중요한 인자(X, 독립변수)가 누락된 경우

- (예) $Y = f(X_1)$ -----> 예측 정확도 50%
- $Y = f(X_1, X_2)$ -----> 예측 정확도 70%
- $Y = f(X_1, X_2, X_3)$ -----> 예측 정확도 69%

인자 수가 늘어날 수록 모형의 설명력은 커진다. 그러나 인자 수가 늘어나면, 데이터를 더 많이 수집해야 하고, 모형이 복잡해서 해석하기 어렵다.

③ Data Size와 품질 문제

특히, 이상치, 서로 다른 집단의 혼합 등 품질 문제 확인 필요



네모와 세모를 분류하는 문제라면, 초록색 집단과 붉은 색 집단을 분리하면, 훨씬 간단하게 분류할 수 있다.


④ 하이퍼 파라미터 최적화 문제

예측정확도 향상 전략

올바른 예측 모형의 개발하기 위해

1. 처음부터 필요충분한 Data 수집
2. 모형을 활용하면서 추가 수집
3. 여러 알고리즘의 비교 평가
4. 모형을 활용하면서 추가 학습

* Data 모델링은 반복적인 과정이다.




하이퍼 파라미터Hyper parameter는 초매개변수로 번역됩니다.
하이퍼 파라미터는 Data에 의해서 계산되는 것이 아니라, 분석하는 사람이 결정하는, 모델 외적 요소입니다.
하이퍼 파라미터는...
▪ 모델의 파라미터를 추정하기 위해 알고리즘 구형 과정에서 사용합니다.
▪ 알고리즘 사용자가 모델링할 때 직접 세팅해 주는 값입니다.
▪ 정해진 최적의 값이 없습니다.
휴리스틱한 방법이나 경험 법칙(rules of thumb)에 의해 결정하는 경우가 많습니다.

대표적인 하이퍼 파라미터는 다음과 같은 것들입니다.

- 인공신경망에서 learning rate, batch size, epoch
- kNN에서 k값
- Random Forest에서 ntree, mtry...

나무를 몇 그루 심어서
숲을 만들 것인가?



하이퍼 파라미터를 어떻게 잘 세팅하는가에 따라 모델의 성능이 달라집니다.
그래서 하이퍼 파라미터 세팅 실력이 모델링 실력과 비례한다고 합니다.

일반적으로 알고리즘 라이브러리가 제공하는 default 값을 사용하여 초기 모델링을 하고, 그 후에 미세 조정을 합니다.

요즘은 베이지안 옵티마이제이션과 같이 자동으로 하이퍼 파라미터를 선택해주는 알고리즘을 사용하기도 합니다.

분류모형의 성능지표

- ✓ 예측정확도가 99.9%라도 사용할 수 없는 경우가 있으며, 반대로, 예측정확도가 50%라도 사용할 수 있는 경우가 있다.
- ☞ 예측정확도가 얼마가 되어야 한다는 절대적 기준이 존재하는 것이 아니다. 실무적 상황에 따라 의사결정 해야한다.

[상황 1]

		실제	
		양품	불량
예측	양품	980	10
	불량	0	10

- **예측정확도 = $990/1000 = 99.9\%$**
매우 우수한 듯이 보이지만, 불량률을 올바르게 예측하는 비율은 50%에 불과함. 따라서, 만약 이러한 예측 정확도를 가진 모델로 자동 검사를 적용하게 된다면 50%의 불량률만 검출할 수 없으므로, 적용할 수가 없을 것이다.

*통상 발생율이 0.1% 나오는 문제를 예측할 때, 문제가 전혀 없다고 예측해도 예측정확도는 99.9%가 나온다.

[상황 2]

		실제	
		양품	불량
예측	양품	400	0
	불량	500	100

- **예측정확도 = $500/1000 = 50\%$**
예측정확도는 50%에 불과하므로, 매우 불안정한 모델임. 원인은 양품을 불량품으로 판정하는 비율이 높아서임. 그러나 불량품은 완벽하게 걸러내고 있음. 예측모델로 자동검사를 1차 실시하고, 불량품에 대해서만 사람이 검사함으로써 40% 검사 Load를 줄일 수 있었음. (이전 1000개 검사, 개선 600개 검사)

✓과도한 예측정확도 집착의 함정 : Data Snooping in PDA

예측 정확도에 대한 과도한 집착이 data snooping 편이의 원인이 될 수 있습니다.

너무 많은 변수를 사용하여 모델을 구하는 경우 이런 문제가 발생할 수 있습니다.
변수가 많아질 수록 설명력이 증가하는 현상을 회귀분석에서 경험했을 것입니다.
이는 모든 모델링에서도 똑같이 적용됩니다.

과도하게 복잡한 모형으로 적합 시키는 경우도 문제가 될 수 있습니다.
또한 X2, X3, log 함수 등 변환된 변수를 과도하게 추가하는 경우는 data snooping 편의를 더욱 심화시킬 수도 있습니다.
데이터에는 우연과 필연이 뒤섞여 있습니다.
올바른 분석이란 우연을 제거하고 필연만 건져 올리는 것이어야 합니다.
하지만 모든 변수를, 거기다가 변수 결합이나 변환을 통해 경우의 수를 늘리면 우연히 재미있는(?) 패턴이 발견될 확률도 높아집니다.
데이터 분석이 주사위 놀이가 되어서는 안될 것입니다.


이를 방대한 검색 효과vast search effect를 경계하라는 말로 표현하기도 합니다.
뭔가 흥미로운 것이 나올 때까지 데이터를 너무 살살이 뒤지거나 빅데이터를 이리 저리 반복적으로 만지는 것이
항상 좋은 결과를 보장하지는 않는다는 의미로 이해됩니다.

모델링 과정 중 범하는 대표적인 data snooping 편이가 발생하는 원인 중 하나는 자신이 원하는 결론을 이끌어내기 위하여
중요한 모형을 부당하게 배제하는 것입니다.
분석가가 고의로 이런 일을 저지른 경우 문제점을 찾아내기 매우 어렵습니다. 부지불식간에 저지른 경우에도 찾아내기 어렵긴 마찬가지 입니다.
모델링 과정은 복잡하고, 또한 일반인이 이해하기 어려운 영역도 분명히 존재하기 때문입니다.
분석가의 선의를 일단 믿어야겠지만... 또 한편으로는 분석 기술의 민주화, 속의 민주주의 등이 강조되는 이유라 하겠습니다.

모델링에서 data snooping 편의를 피하기 위한 적용하는 가장 대표적인 방법이 데이터를 training set와 test set로 나누어
활용하는 것입니다. 많은 전문가들은 모든 데이터를 훈련에만 사용한 모형은 데이터 스누핑 편의를 의심하라고 단언하기도 합니다.

$$Y = f(X_1, X_2, X_3, X_4, \dots X_p)$$

어떤 변수가 Y에 영향을 더 많이 미치는가?



산사태를 일으키는 요인들의 영향도 순위

(출처 : <https://www.koreascience.or.kr/article/JAKO202030060641301.pdf>)

개념 변질 대응을 위한 모니터링

Process는 개선 등의 이유로 시간이 지나면서 변한다. 따라서, Data는 유한한 수명을 가진다.
이런 현상을 **개념 변질(Concept Drift)**이라고 한다.
즉, 거의 모든 예측 모델은 언젠가는 정체되어, 사용 중인 예측 모델이 더 이상 유효하지 않은 순간이 온다는 것을 의미한다.
따라서, 예측 모델이 정체되기 시작하는 시점을 포착할 수 있게 모니터링 해야 한다.
이를 **상시 모델 검증(on-going model validation)**이라고 한다.

상시 모델 검증을 위한 가능한 모니터링 대상

- ① 예측 모델의 적절한 성능 지표 (예, 예측정확도)
- ② 예측 모델의 예측결과 값 분포
- ③ 예측 모델에 입력되는 설명변수(X)들의 분포



① 성능지표 모니터링

- 개념 변질 발생 신호를 포착하는 가장 명확한 방법
- 그러나, 이 방법은 예측 결과와 실제 결과를 비교할 수 있어야 가능하다.
하지만 일상의 업무에서 실제 Y값을 측정할 수 없거나, 측정/수집하지 않는 경우
혹은 시간 지연으로 인해 개념 변질의 발생 시점 후에나 확인되는 경우도 있다.
즉, 성능 지표를 모니터링하는 것이 불가능한 경우가 있다.

개념 변질 대응을 위한 모니터링

② 예측 결과 값 분포 모니터링

- 예측 모델로 생성한 예측 결과 값의 분포의 변화로 개념 변질의 신호를 포착할 수 있다.
예를 들어, 통상 80%의 positive 예측 비율이 20%로 급격히 변동되었다면, 개념 변질의 가능성을 진단해 보아야 할 것이다
- 분포의 변화 여부는 예측 모델 개발 시의 예측 값 분포와 예측 모델 적용 후의 일정한 기간 동안 수집된 예측 값 분포의 차이를 확인한다.
- 이 경우, 가장 많이 사용하는 것이 **안정성 지표(stability index)**다.

$$\text{stability index} = \sum_{l \in \text{levels}(t)} \left(\left(\frac{|A_{t=l}|}{|A|} - \frac{|B_{t=l}|}{|B|} \right) \times \log_e \left(\frac{|A_{t=l}|}{|A|} / \frac{|B_{t=l}|}{|B|} \right) \right)$$

- |A| 예측 모델 개발 시의 전체 집합의 크기
- |A_{t=l}| 예측 모델 개발 시 범주 l로 예측한 집합의 크기
- |B| 예측 모델 적용 후 수집한 전체 집합의 크기
- |A_{t=l}| 예측 모델 적용 후 범주 l로 예측한 집합의 크기

- ✓ 안정성 지표 값이 0.1보다 작으면, 신규 Data-set에서의 분포는 test-set에서의 분포와 동일하다.
- ✓ 안정성 지표 값이 0.1~0.25 사이면, 어떤 변화가 발생한 것이며, 추가 조사가 필요하다.
- ✓ 안정성 지표 값이 0.25보다 크다면, 중대한 변화를 암시하며, 수정 작업이 필요하다.


- 안정성 지표는 범주형 변수와 연속형 변수 모두에 적용할 수 있다.
단, 연속형 변수를 예측하는 모델인 경우는 예측 값의 범위를 구간으로 나누고, 각 구간의 분포를 이용하여 지표를 계산한다. 이때, 범주화는 통상 10분위를 사용한다.
- 안정성 지표는 분포의 차이를 확인하는 여러 방법 중 하나에 해당하며, 범주형 변수의 경우에 Chi-sq. 검정, 연속형 변수의 경우에는 K-S 통계량도 사용할 수 있다.
- 안정성 지표의 변화는 모집단의 변화로 인해 발생할 수 있다. 즉, 개념 변질 없이도 발생할 수 있다.

개념 변질 대응을 위한 모니터링

③ 예측 모델에 입력되는 설명변수(X)들의 분포 변화 모니터링

- X들의 분포 변화에 대해서도 동일한 방법을 적용할 수 있다.
즉, 안정성 지표, Chi-sq. 통계량, K-S 통계량 등을 활용하여, 분포의 변화를 확인할 수 있다.
- 모델에 적용된 X들의 개수가 아주 적을 때(일반적으로 10개 이하 일 때)에만 적용을 추천한다.


예측 모델은
가까운 미래를 예측할 수 있을 뿐이다.



“데이터 분석은 골방 프로젝트가 아니다.”


예측적 분석 프로젝트에서 예측 모델을 만드는 것은 오히려 쉬운 과정일 수 있다.
올바른 예측 모델을 이끌어 내기 위해서는 프로젝트의 전 과정에서
경험과 직관, 시험과 실험을 적절히 활용해야 한다.
특히, 예측적 분석 프로젝트의 전 과정에서 올바른 결정을 내리려면 아래 사항을 갖춰야 한다.

- 상황적 능숙함으로 해당 분야의 기술 전문가와 대화할 수 있어야 한다.
- 데이터를 올바르게 이해하기 위해서 탐색해야 한다.
- 데이터 정리에 시간을 할애해야 한다.
- 변수를 표현하는 가장 좋은 방법을 고민해야 한다.
- 평가 과정을 올바르게 설계하기 위해 시간을 할애해야 한다.



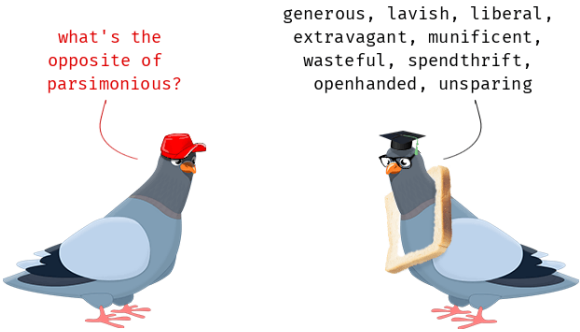
① Best Fitting

장기간의 예측품질이 확보되도록
최적 모형을 개발해야 함.




② Most Parsimonious

경제성의 원칙
: 가능한 적은 수의 인자로, 가능한 간단한 모형으로
예측모형을 구해야 해석과 활용이 용이함.



③ Practically Reasonable

실무적으로 납득할 수 있어야,
실무 적용 방법 설계가 용이하며,
실무 적용 후 변화관리가 튼튼해짐



이론적 최고가 아닌
실무적 최적화

- ① 다양한 머신러닝 알고리즘을 비교 평가했는가?

만능은 없으며, 모형은 단순할 수록 활용에 유리합니다.
(1)Best Fitting (2)Most Parsimonious
여러 가지를 적용했다면, 왜 알고리즘을 선택했는지 물어보면 됩니다.
- ② Test-Set으로 모형의 성능척도를 평가했는가?

Training-Set으로 평가된 것이라면, Data Snooping을 의심합니다.
회귀분석은 R²를, 분류분석은 Confusion Matrix를 검토합니다.
- ③ 예측모형의 성능(회귀분석의 R², 분류분석의 예측정확도)의 하한 목표는?

예측성능은 높으면 높을 수록 좋겠지만, 하한 목표는 절대적 기준은 없습니다. 실무적 적합성으로 판단해야 합니다.
- ④ 예측 모형의 성능을 추가 향상 방안은?

대부분의 경우 Data Size와 품질 문제. 하이퍼 파라미터로는 크게 움직이지 않습니다.
- ⑤ 실무적용 시 Risk 헤지 방안?


R²와 예측정확도에는 항상 에러가 존재하고, 특히, 자동화의 경우 통신 장애등은 언제든지 발생할 수 있습니다.
- ⑥ 모형의 실무적 해석은?

실무적으로 해석할 수 있어야 지식이 됩니다.
- ⑦ 인자 중요도?

모든 인자들이 동등하게 중요하지 않습니다.
Pareto 법칙(원인의 20%가 결과의 80%를 지배한다)은 일반적인 현상입니다.
인자들의 결과(Y)에 대한 영향도의 순위를 확인할 수 있습니다.
- ⑧ 개념 변질에 대한 모니터링 방법은?

개념 변질은 필연적입니다.
자동화를 과신하면, 체계적으로 오류에 빠질 위험이 있습니다.
- ⑨ Ad-hoc에 대한 유연성은?

실무에서는 갑자기 기준이나 정책이 바뀔 수도 있습니다.
이에 대한 유연성은 미리 검토해야 합니다.



- 분석의 목적이 모든 과정을 지배한다.
- Data는 양보다 질이 중요하다.
- 다양한 예측 모형을 고려하고, 그 중 가장 적합한 것을 선택한다.
같은 값이면 간단한 모형을 선택한다.
- 예측정확도만이 유일한 판단 기준은 아니다.
실무적 적용성과 함께 생각해야 한다.
- Machine Learning을 통한 예측은 가까운 미래만 예측할 수 있을 뿐이다.
Data의 수명은 유한하며, 따라서 Concept Drift를 모니터링 해야한다.