

2. 데이터 분석 절차와 관련 용어

L1 과정에서 다루었던 내용을 재확인합니다.

모든 관심 특성은 **변수 Variable**다.

상황이나 조건에 따라 값이 변한다.


상수 Constant가 관심 대상이 되는 경우는 드물다.

관심주실게요~!



변수 Variables





개와 고양이의 차이




1. 고양이는 움직임이 얇전하나, 개는 활동적이다.
2. 고양이는 실내에서 지내는 것을 더 좋아하나, 개는 산책을 좋아한다.
3. 개와 고양이는 물 마시는 방법도 다르다.
4. 개는 굶으면 지방을 태워 에너지로 쓰나, 고양이는 그런 능력이 없다.
5. 개의 기억력은 5분, 고양이는 16시간
6. 개는 꼬리를 치며 주인을 따르나, 고양이는 도도하다.
7. 개는 먹이가 도망가기 전에 재빠르게 달려가 낚아채는 방식으로 먹이를 획득한다. 반면 고양이는 먹이가 눈치채지 않게 살금살금 다가간다.
8. 고양이는 발톱을 숨길 수 있는 능력이 있는 반면, 개에게는 그럴 수 없다.
9. 개는 틈만 나면 주인의 스킨십을 받고 싶어하지만, 고양이는 주인과 거의 스킨십을 하지 않는다.
10. 개보다도 2배나 좋다고 한다.
11. 개는 잡식성으로 풀도 먹을 수 있으나, 고양이는 고기를 먹어야 한다.
12. 개는 훈련시키기 쉬우나, 고양이는 어렵다.
13. 개의 이빨은 42개이고, 고양이는 30개이다.
14. 고양이는 즉시 대소변을 가리나, 개는 영원히 못 가리는 경우도 있다.
15. 고양이는 밤에 움직이나, 개는 낮에 움직인다.
16. 고양이가 강아지보다 시력이 좋다.
17. etc.

Feature (특징)

ID	Name	AGE	SEX
01	KIM	32	M
02	LEE	26	F
03	PARK	72	F
04	CHOI	15	M


structured data

정형 데이터란 정의된 스키마가 있는 데이터를 말합니다.
쉽게 말해서 엑셀과 같이 정해진 형식과 구조가 있는 데이터



semi-structured data

정형 데이터와 같이 테이블의 행과 열로 구조화되어 있지는 않으나, 데이터의 구조 정보를 함께 제공되므로, 데이터의 형식과 구조를 쉽게 변경할 수 있는 것을 말합니다.
주로 XML, HTML, JSON 등의 파일 형태로 저장됩니다




unstructured data

정의된 구조가 없는 데이터로서, 정형 데이터가 아닌 모든 데이터는 비정형 데이터로 분류될 수 있습니다
동영상 파일, 오디오 파일, 사진, 보고서, 메일 본문 등이 해당하며, 빅데이터의 80%는 비정형 데이터라고 합니다.

[출처] TTA 정보통신 용어 사전

데이터 생성

일정한 기준에 근거하여, 관심 사항을 기록



- 측정, 관찰, 조사, 실험, 검사 등의 결과
- 데이터 생성 과정에 오차 발생

VS.

데이터 수집

여러 데이터 소스로부터 필요한 데이터 획득



- Zero Party Data : 고객이 자발적으로 제공
- 1st Party Data 자사 데이터
- 2nd Party Data 파트너/제휴사 등의 데이터
- 3rd Party Data 외부 제3자 데이터

명목 척도 (Nominal Scale)

- ✓ **단순 구분 Data** : 순서나 차이를 말할 수 없음
예) [남자와 여자], [업체 1, 2, 3], [변경 전과 후], [20대 고객과 30대 고객], ...

순서 척도 (Ordinal Scale)

- ✓ **등급 분류 Data** : 순서는 말할 수 있으나 차이를 정의할 수는 없음.
예) [금메달, 은메달, 동메달], [상, 중, 하], [한도 건본 등급] → 주로 홀수를 사용

※ (금메달과 은메달의 간격) = (은메달과 동메달의 간격) ???

구간 척도 (Interval Scale)


- ✓ **등간격 자료**로써 절대적 원점이 없는 Data :
구간으로 나누어져 있으나 구간 사이에는 무수히 포갤 수 있음.
예) 온도(20℃는 10℃보다 2배 뜨거운 것이 아니다), 특정지수(생산성, 공정능력) 등

※ 리커트 척도로 측정된 만족도 등은 구간척도로 취급하여 분석할 수 있다.

비율 척도 (Ratio Scale)

- ✓ **비율이 존재하는 Data** : 시간, 길이, 무게 등으로 원점인 0이 존재 함.
예) 2m는 4m의 2배이다., 1 inch = 2.54cm 이다.

측정 척도는 측정해야 할 정보의 양을 결정하고, Data의 유형은 분석 방법을 결정한다.



* 연속형 데이터가 가장 많은 정보량을 갖고 가장 많은 분석 방법의 적용이 가능하다.


* 연속형 데이터는 정보량이 많으므로, 이산형 데이터에 비해 적은 수의 데이터로도 질 높은 분석이 가능하다.

측정 척도와 데이터의 유형

2. Data 분석 절차와 관련 용어의 이해

(실습) 측정 척도와 데이터의 유형을 구분해 봅시다.

데이터	측정 척도(명목/순서/구간/비율)	유형(연속형/ 범주형)
아파트 평수		
아파트 동 호수		
학교 등수		
학교 점수		
버스 번호		
출퇴근 소요 시간		
자동차 연비		
축구 선수의 백 넘버		
근무 기간		
고객만족도 (1,2,3,4,5점)		




모든 간격이 동일한가?




올림픽 메달처럼
가치를 서로 다르게
취급한다면
등간(구간)척도로
취급할 수 없다.

“목적이 모든 과정을 지배한다”



가설과 Data 수집 계획

2. Data 분석 절차와 관련 용어의 이해



현상 분석

요즘 “전국노래자랑” 시청률이 떨어진 것 **같다**.

근본원인 분석

왜 시청률이 떨어졌는가를 알고 싶다.

대응안 설계

어떻게 “놀면 뭐하니?” 수준의 시청률을 달성할 수 있을까?

가설

- 작년 대비 시청률의 큰 변화 없는데 계절별 시청률 등락으로 그렇게 보인다.
- 시청률에 영향을 미치는 요인은...
 1. 동시간 경쟁 프로그램
 2. 시청자들의 취향 변화
 3. 경연 노래의 장르 다양성
 4. 초대가수 화제성
 5. etc.
- 놀면 뭐하니 시청률이 높은 이유는...
 1. MC들의 화제성
 2. 프로그램의 신선도
 3. 유튜브와의 연계
 4. etc.

수집 항목 선정

- 1년치 이상의 시청률 (회차별, 녹화날짜, 방송날짜)
- 1. 경쟁 프로그램의 유형, 시청률
- 2. 성별, 시청자 연령층
- 3. 노래 장르 분포(트로트, 발라드 등)
- 4. 초대 가수, 초대 가수 노래
- 5. etc.
- 1. MC에 따른 시청률
- 2. 프로그램의 신선도별 시청율
- 3. 유튜브 조회수
- 4. etc.


수집 계획 수립

- 가설을 확인할 수 있는 데이터를 누가, 얼마나, 어떻게 수집할 것인가에 관한 것

Data 수집 계획에 포함될 사항

- 누가(who) : 수집하는 사람 등
- 언제(when) : 데이터를 취할 기간
- 어디서(where) : 데이터 소스
- 무엇을(what) : 제품, 명칭, 특성 등
- 어떻게(how) : 데이터의 크기, 간격, 관련 계측기 등
- 왜(why) Data 수집 목적

비즈니스 질문에 대한 잠정적 결론
→ X(원인)과 Y(결과)의 식별



Dark Data

기업이 정보를 수집한 후, 저장만 하고 분석에 활용하고 있지 않은 데이터

Data Lake

가공되지 않은 다양한 종류의 데이터를 한 곳에 모아둔 저장소의 집합.
데이터를 효율적으로 분석/사용하고자 다양한 영역의 Raw 데이터(가공되지 않은 데이터)를 한 곳에 모아서 관리하고자 하는 것

Data Warehouse

데이터 기반 의사 결정을 돕는 Data 분석이 가능하도록 데이터를 모아둔 저장소.
데이터는 여러 소스로부터 수집하여 분석이 용이하도록 구조화가 완료

Database

트랜잭션 시스템과 같이 단일 소스에 있는 그대로 캡처한 데이터.
고도로 구조화되어 있으며, 일반적으로 지속적인 쓰기 작업에 최적화 됨

Data Mart

특정 운영 부서의 요구를 충족하도록 설계된 데이터 저장소.
Data Warehouse는 Data Mart는 집합에 해당.
예를 들어 Data Warehouse 가 도서관이라면
Data Mart는 특정 주제에 관한 책을 모아둔 도서관의 특정 섹션에 해당한다.

관계형 데이터베이스

생산 데이터

생산 Line	생산품종	Serial No.	공정 조건	성능특성...

attribute / feature

관계


Sales 데이터

판매 일자	판매 지역	판매 모델	Serial No.	고객특성...

고유한 Key 값을 기준으로
하나의 테이블로 합칠 수 있다.


Data Warehouse

정형 데이터, 관계형 DB



Data Lake

정형 + 비정형 + Streaming데이터, 적재




Data Warehouse/ Data Lake...



중앙집중의 장점과 한계 보유
특히, 현장에서는
ETL의 Lead Time을 지적

Data Mesh

근래 관심
분산형



모집단과 표본

문제

sepal(꽃받침)의 폭과 길이
petal(꽃잎)의 폭과 길이를 가지고
품종(species)을 분류(예측)

문제 정의

Y : species (3종 : setosa, versicolor, virginica)

X : petal_length
petal_width
sepal_length
sepal_width




petal sepal




petal sepal



petal sepal



“알고 싶은 대상에 대한 데이터 수집”







내가 수집한 Data는
내가 알고 싶은 세상을
대표하는가???

표본오차

모집단과 표본집단의 불일치로 인한 오차

측정오차

Data 생성 중 발생하는 오차 (측정도구, 측정자)

**선택편향**표본을 잘못
선택하는 경우(a) 편향 없음
모든 발생 가능성을 포함(b) 편향 발생
일부 발생 영역만 포함

수집된 데이터의 구조

문제

sepal(꽃받침)의 폭과 길이
petal(꽃잎)의 폭과 길이를 가지고
품종(species)을 분류(예측)

문제 정의

Y : species (3종 : setosa, versicolor, virginica)

X : petal_length
petal_width
sepal_length
sepal_width



petal sepal



petal sepal



petal sepal

Feature, 독립 변수(X)

종속 변수(Y)

Instance

#	sepal_length	sepal_width	petal_length	petal_width	species
#1	5.1	3.5	1.4	0.2	setosa
#2	4.9	3	1.4	0.2	setosa
#3	4.7	3.2	1.3	0.2	setosa
#4	7	3.2	4.7	1.4	versicolor
#5	6.4	3.2	4.5	1.5	versicolor
#6	6.9	3.1	4.9	1.5	versicolor
#7	6.3	3.3	6	2.5	virginica
#8	5.8	2.7	5.1	1.9	virginica
#9	7.1	3	5.9	2.1	virginica

Data Size

연속형 Data

범주형 Data

Data 전처리란, 수집된 Data를 즉시 분석할 수 있도록 정리, 정돈하는 것.
 데이터 준비가 전체 프로젝트 기간의 80%를 점유하며, 결과의 80%를 지배한다

수집된 데이터가 모두 즉시 사용 가능한 것은 아닙니다.

센서를 통해 자동으로 수집된 데이터도 센서의 이상, 대상물의 부정확한 포지셔닝, 통신 장애 등으로

이상치 outlier와 **결측치** missing value가 발생하는 것은 일반적입니다.


이런 상태로 분석을 그냥 진행해서는 좋은 결과를 얻기 힘듭니다.

또한 원시 데이터(Raw data)를 그냥 사용하는 것 보다는 적절하게 가공하여 (integration and/or transformation) 더 좋은 결과를 얻을 수도 있습니다.


그리고, 계산 용량의 감축 등을 위하여 수집한 전체 데이터 중에서 일부를 샘플링하여 분석을 진행할 수도 있습니다.

이와 같이, 분석 전 Data-set를 분석 가능한 상태로 만드는 것을 **데이터 전처리** Data Preprocessing이라 합니다.

① Data Cleaning




② Data Integration



③ Data Transformation



④ Data Selection




Data는 양보다는 질이 먼저 중요하다 !!!

데이터 품질 요소

	Big Volume	Small Size
High Quality		
Low Quality		

- **타당성** 알고 싶은 사실이 담겨야 한다.
- **적시성** 필요 할 때, Data를 얻을 수 있어야 한다.
- **일관성** Data의 의미와 기준이 시간과 공간에 관계없이 유지되어야 한다.
- **대표성** 수집된 표본이 알고 싶은 세상(모집단)을 대표해야 한다.
- **정확성** 데이터는 가능한 참값에 가까워야 한다.
- **정밀성** 누가 측정 혹은 수집하던, 몇 번을 반복하던 똑같은 값이어야 한다.
- **기타** 완전성, 충분성, 보안성, 접근성 등

데이터 분석 유형




DDA

Descriptive Data Analysis

기술(記述)적 분석

기술 記述

대상이나 과정의 내용과 특징을
있는 그대로 열거하거나 기록하여 서술함




원시 데이터 Raw Data

601.6	602.8	598.4	598.2	600.8	600.8	600.4	598.2	599.4	601.2	602.2	601.6	599.8	603.8	600.8	598.0	601.6	602.4	601.4	601.2
600.4	600.8	599.6	602.0	598.6	597.2	598.2	599.4	598.0	599.0	599.8	600.2	602.8	603.6	600.2	598.4	603.4	602.2	599.2	604.2
598.4	603.6	603.4	599.4	600.0	600.4	598.6	599.4	597.6	600.4	599.8	601.8	600.0	601.8	600.4	600.8	597.0	600.6	601.6	600.2
600.0	604.2	600.6	599.4	600.4	599.8	599.6	600.2	598.0	600.6	601.0	601.2	599.6	602.0	600.2	602.8	599.8	596.2	600.4	600.0
596.8	602.4	598.4	600.8	600.8	596.4	599.0	599.0	597.6	599.0	601.6	597.6	602.2	603.6	602.2	597.6	597.8	602.4	598.0	596.8


☞ 원시 데이터에서 '무엇'인가를 직접 알아낸다는 것은 매우 어려운 일이다.

기술적 분석이란, 수집된 데이터 전체를 요약하고, 전체적인 현황을 서술하는 것

우리의 관심 사항은 변수며, 변수는 패턴과 확률로 표현한다. 📖 **모양, 중심경향, 산포**



모든 원은
중심점과 반지름만 알면 그려낼 수 있다.



모든 Data은
중심경향과 산포를 알면 그려낼 수 있다.

● Data의 중심경향을 나타내는 특성 값

1) (산술) 평균(Average, mean)

Xbar

$$\bar{X} = \frac{\text{Data의 합}}{\text{Data의 수}} = \frac{X_1 + X_2 + X_3 + \dots + X_n}{n}$$

[6.5 , 9.0 , 9.0 , 9.1 , 9.2 , 9.3 , 9.6 , 10.0]

합계 = 6.5+9.0+9.0+9.1+9.2+9.3+9.6+10.0 = 71.7

평균 = 71.7 / 8 = 8.96

2) 중앙값(Median)

오름차순으로 나열된 데 Data의 50%에 해당하는 값

- n이 홀수 : (n+1)/2 번째 값
- n이 짝수 : (n/2) 번째 값과 (n/2)+1 번째 값의 평균

가장 작은 값에서 네 번째 ← → 가장 큰 값에서 네 번째

[6.5 , 9.0 , 9.0 , 9.1 , 9.2 , 9.3 , 9.6 , 10.0]

중앙값 = (9.1+9.2) / 2 = 9.15

3) 최빈값(Mode)

수집된 Data의 값들 중에서 가장 빈도가 높은 값

[6.5 , 9.0 , 9.0 , 9.1 , 9.2 , 9.3 , 9.6 , 10.0]

최빈값 = 9.0

9.0은 두번 나타났으나,
나머지는 한번씩만 나타났음

1) (산술) 평균(Average, mean)


- 모든 연속형 Data에 적용할 수 있다.
- Data의 수와 상관없이 항상 유일한 값을 가진다.
- 확장성이 좋다.
- 극단값의 영향을 많이 받는다.

2) 중앙값(Median)

- 모든 연속형 Data에 적용 가능하다.
- Data의 수와 상관없이 항상 유일한 값을 가진다.
- 평균에 비해 극단값의 영향을 덜 받는다.
- 확장성이 없다.

3) 최빈값(Mode)

- 연속형, 이산형 Data에 모두 적용 가능하다.
- 극단값의 영향을 받지 않는다.
- 하나 이상의 최빈값이 가능하고, 존재하지 않을 수도 있다.
- 확장성이 없다.



● Data 의 흠어짐 정도를 나타내는 특성 값

1) 분산(variance) 과 표준 편차(standard deviation)

표본분산

$$s^2 = \frac{SS}{n-1}$$

(소문자)

표본표준편차

$$s = \sqrt{\text{분산}}$$

총변동(Sum of Square)


$$SS = \sum_{i=1}^n (\bar{X} - X_i)^2$$

(대문자)




2) 범위 (R : Range) : Data의 최대값과 최소값의 차이

3) IQR(Inter Quartile Range) = $Q_3 - Q_1$



$$R = 81 - 62 = 19$$

기술적 분석은 수집된 데이터 전체를 요약하고, 지금까지의 현황을 서술하는 것입니다.
즉, 중심 경향과 산포로 데이터를 요약하고, 이들 간의 조합으로 관심 사항을 표현합니다.



부분에서 성립하던 성질이 부분을 합한 전체에선 성립하지 않는 것을
 심슨의 역설(Simpson's Paradox)라고 합니다.
 요약 통계량을 사용할 때에는 주의해야 합니다.

전체	지원자	합격자	합격률
남학생	1150	815	71%
여학생	820	185	23%

48%의 차이 → 여성 차별 ???

문학부	지원자	합격자	합격률
남학생	150	15	10%
여학생	700	85	12%
공학부	지원자	합격자	합격률
남학생	1000	800	80%
여학생	120	100	83%


오히려 여학생의
합격율이 높았음

탐색적 분석 (EDA, Exploratory Data Analysis)

2. Data 분석 절차와 관련 용어의 이해


EDA (Exploratory Data Analysis, 탐색적 자료 분석)은

- 존 튜키(미국의 통계학자)가 창안한 자료 분석 방법론
- 수집한 데이터를 다양한 각도에서 관찰하고 이해하는 과정이며, 이를 통해 새로운 패턴이나 가설을 발견할 수 있다.
- 특히 주목하는 것은, 이상점(outlier), 패턴과 추이(Trend), 비교(Comparison)와 인자 간의 관계(Relationship) 등이다.




**Data Visualization과
Exploratory Data
Analysis는
모두 Graph를 사용하지만
목적하는 바가 다르다.**

Data 시각화
커뮤니케이션의 효과성




vs.

탐색적 분석
숨겨진 패턴 발견의 유용성



확인적 분석 (CDA, Confirmatory Data Analysis)

2. Data 분석 절차와 관련 용어의 이해



이번 조사는 지난 21일~22일까지 이틀간 전국 성인남녀 **1030명**을 대상으로 실시했다.

유선전화(45%) 및 휴대전화(55%) RDD(임의 번호 걸기) 방식을 사용했고

표본 오차는 95% 신뢰 수준에서 **±3.1%포인트**, 응답률은 16.0%다.

자세한 내용은 중앙선거여론조사 공정심의위원회 홈페이지를 참조하면 된다

알고 싶은 세상

전체 유권자
42,479,710명

1,030명이 전체 유권자를 대변?

No....표본 오차

전국 성인남녀
1,030명

오차를 감안한 의사결정

 $\pm 3.1\%$ 포인트

- A후보 = 33.4~40.1% (37.5 ± 3.1)
- B후보 = 23.3~29.5% (26.4 ± 3.1)

- A후보 : 37.5%
- B후보 : 26.4%

알고 있는 세상

PDA (Predictive data analysis, **예측적 자료 분석**)은 $Y=f(X)$ 를 구하는 것

(1) 설명

- 그런 결과가 나타난 원인을 설명하는 것.
- 원인 별 결과에의 영향의 정도를 설명하는 것

(2) 예측

- 알려지지 않는 결과의 가능성을 파악하는 것
- 미래의 불확실한 사실을 사전에 예측하는 것

$$Y = \underline{f}(X_1, X_2, X_3, \dots)$$

(예측)함수



$$= \text{Flour} + \text{Salt} + \text{Yeast} + \text{Oven} + \text{Chef} + \dots$$



$$= f(\text{출전 경기수, 타율, 타점, 홈런, 수비율, 팬심, 리더십, 훈련 태도})$$

인공지능을 구현하기 위한 구체적인 접근 방식이 머신 러닝입니다. 즉, 머신 러닝은 말 그대로 컴퓨터가 스스로 학습하여 인간과 닮은 학습능력, 추론능력, 지각능력, 자연언어의 이해능력 등을 실현하는 모든 기술을 의미합니다.

'스스로 학습'한다는 것이 핵심이라고 할 수 있습니다. 즉, 프로그래머가 구체적인 규칙을 코딩하는 것이 아니라 알고리즘을 통해 컴퓨터가 '학습'을 하고, 그를 통해 원하는 결과를 만들어내는 것입니다.

AI Artificial Intelligence, 인공지능 인간의 지능과 유사한 특성을 가진 복잡한 컴퓨터 제작을 목표 (1956~)

- Expert System 예) DGMS
- 규칙기반 시스템
- etc. 예) DfM 시스템
규칙기반 RPA

<if – then>

인간의 사고와 행동 규칙을 정의하고,
그것을 기계가 따라 하도록 함

Machine Learning 인공지능을 구현하기 위한 구체적인 접근 방식

- Random Forest
- Support Vector Machine
- etc.

**Deep
Learning**

동물의 신경망을 응용한 학습 알고리즘



▶ 지도학습 용 데이터 : Labeled Data

키	무게	색깔	분류
3300	6000	회색	코끼리
580	800	점박이	기린

▶ 비지도학습 용 데이터 : Unlabeled Data

키	무게	색깔	분류
3300	6000	회색	
580	800	점박이	


▶ 데이터 없이도 스스로 학습



[개념적] 머신러닝 모형의 훈련

2. Data 분석 절차와 관련 용어의 이해

번호	X	Y
#1	1	1
#2	2	3
#3	3	2
#4	4	4

[직선 모형] $Y = \beta_0 + \beta_1 X$


- 학습(훈련)이란 총 오차가 최소화 되는 함수의 계수 β_0 와 β_1 을 구하는 것

- 총 오차의 크기 Loss Function


$$= \sum (Y_i - \hat{Y}_i)^2 = \sum (Y_i - \beta_0 - \beta_1 X_i)^2$$

실제값 예측값

→ 이것을 최소화


[곡선 모형] $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \dots$ 

경사하강법




예측 모형의 오차

2. Data 분석 절차와 관련 용어의 이해




번호	X	Y
#1	1	1
#2	2	3
#3	3	2
#4	4	4

1. 모형 선택의 오차




2. 모형 적합의 오차




데이터 분석을 통해 정보가 발견되고, 이를 해석하면 지식이 됩니다.
 모든 데이터 분석 결과는 실무적 의미를 해석해야 합니다.

Practical Reasonable?!



목적

- ✓ 과제는 정한 시간이 되어서 끝나는 것이 아니라, 목적을 달성하고 종료된다.
- ✓ 모든 과제가 예측모델을 개발해야 하는 것은 아니며,
따라서 과제의 실행 절차는 과제의 목적에 따라 서로 다를 수 밖에 없다.



Question or Comment ?!

고객도
모르는
고객을
알자



배운다
배운 걸
지우고
다시 배운다

