





2. Data Handling




Gurbage In



***Garbage
in the head***



Bad Decisions



- munging = mash until no good에서 파생된 단어
- **전처리, 파싱(Parsing), 필터링(Filtering)**과 같이 데이터를 핸들링 한다는 것을 뜻함.
- Raw Data를 **깔끔한 데이터 (tidy data)**로 정비함
- Data 분석 Process 중 80%가 데이터 핸들링이 차지함

데이터 랭글링 Data Wrangling 혹은 데이터 먼징 Data Munging은 원자료 raw data를 보다 쉽게 접근하고 분석할 수 있도록 데이터를 정리하고 통합하는 과정.

Data Munging과 Data Wrangling이라는 용어는 같은 의미로 사용되지만, 미묘한 차이를 구분하기도 합니다.

Data Munging은 원시 데이터를 정리하고 보다 유용한 형식으로 변환하는 프로세스를 의미합니다. 여기에는 오류 제거, 누락된 값 채우기 및 데이터 유형 변환과 같은 작업이 포함됩니다.

반면 Data Wrangling은 원시 데이터를 분석에 적합한 형식으로 변환하는 것과 관련된 모든 단계를 포함하는 더 넓은 의미로 사용됩니다. 여기에는 데이터 정리 작업이 포함되지만 데이터 탐색, 데이터 집계 및 데이터 시각화와 같은 다른 단계도 포함됩니다.

깔끔한 데이터 (Tidy Data)

깔끔한 데이터는 특정한 구조를 가진다.

- 변수 **variables** 는 열 **column**에 배열하고,
- 관측점 **observations** 은 행 **row**에 배열하며,
- 행과 열이 교차하는 셀에 값 **value**이 위치하며,
- 관측단위에 대한 형태는 테이블로 구성된다

#	sepal_length	sepal_width	petal_length	petal_width	species
#1	5.1	3.5	1.4	0.2	setosa
#2	4.9	3	1.4	0.2	setosa
#3	4.7	3.2	1.3	0.2	setosa
#4	7	3.2	4.7	1.4	versicolor
#5	6.4	3.2	4.5	1.5	versicolor
#6	6.9	3.1	4.9	1.5	versicolor
#7	6.3	3.3	6	2.5	virginica
#8	5.8	2.7	5.1	1.9	virginica
#9	7.1	3	5.9	2.1	virginica

깔끔한 데이터 (Tidy Data)

1. 각 변수가 칼럼이 된다.
2. 각 관측점은 행이 된다.
3. 각 셀은 값이 된다.
4. 관측 단위에 대한 형태가 테이블을 구성한다.

wide data

id	x	y
1	22.19	24.05
2	19.82	22.91
3	19.81	21.19
4	17.49	18.59
5	19.44	19.85

long data

id	변수	값
1	x	22.19
2	x	19.82
3	x	19.81
4	x	17.49
5	x	19.44
1	y	24.05
2	y	22.91
3	y	21.19
4	y	18.59
5	y	19.85

깔끔한 데이터 (Tidy Data)

깔끔하기 전 데이터


종교		\$10- <\$10k	\$20- 20k	\$30- 30k	\$40- 40k	\$50- 50k
Agnostic	27	34	60	81	76	
Atheist	12	27	37	52	35	
Buddhist	27	21	30	34	33	
Catholic	418	617	732	670	638	
모름/거절	15	14	15	11	10	
Evangel	575	869	1064	982	881	
Hindu	1	9	7	9	11	
Black Prot	228	244	236	238	197	
여호와 의 증인	20	27	24	24	21	
Jewish	19	19	25	25	30	

깔끔하게 만든 후 데이터

religion	income	freq
Agnostic	< \$10k	27
Agnostic	\$10-20k	34
Agnostic	\$20-30k	60
Agnostic	\$30-40k	81
Agnostic	\$40-50k	76
Agnostic	\$50-75k	137
Agnostic	\$75-100k	122
Agnostic	\$100-150k	109
Agnostic	>\$150k	84
Agnostic	모름/거절	96




(출처 : https://r2bit.com/book_viz/tidy-data.html)




1. Discovering : 보유한 데이터의 정보 이해하고, 분석의 방향 판단
2. Structuring : 필요없는 행/컬럼 삭제 및 분석 가능한 형태로 구조화하는 단계
3. Cleaning : 데이터의 문제점을 식별하고 수정
4. Enriching : 부가적인 데이터를 추가하여 데이터의 효용성 증대
5. Validating : 데이터의 분포, 일관성, 품질 등을 확인
6. Publishing : 데이터를 분석 모델에 인풋하고, 재사용할 수 있도록 저장

일반적으로 데이터 랭글링은 data scientist 또는 data engineer가 담당하며 데이터 랭글링을 전문적으로 수행하는 사람을 data wrangler라 부른다. 이를 돕는 오픈 소스 소프트웨어가 여럿 있다.


Data Handling in Orange





1 데이터가 읽어 오기


데이터가 저장된
폴더를 찾아가서 선택





◀데이터에 대한 기본 정보


◀데이터 유형 확인

2 불러온 데이터 확인






1 데이터에 관한 정보





기초 통계량 계산




데이터 이름 바꾸기

Edit Domain widget으로 Dataset 의 Feature Name, Type, Value, Label 변경 및 생성이 가능







- Name : Feature 이름 지정
- Type : Feature 유형 (Categorical / Numeric / Text / Time)
- Values : Up , Down , Append , Delete , Rename , Merge infrequent items



- Label : Key / Value 지정

	ameter narrowin	age	gender Binary	chest pain	rest SBP
label1					
1	0	63	M	typical ang	145
2	1	67	M	asymptomatic	160
3	1	67	M	asymptomatic	120
4	0	37	M	non-anginal	130
5	0	41	F	atypical ang	130
6	0	56	M	typical ang	120
7	1	62	F	asymptomatic	140
8	0	57	F	asymptomatic	120
9	1	63	M	asymptomatic	130

데이터 저장하기



통계량 저장하기

Untitled * - Orange
File Edit View Widget Options Help

Data

- File
- CSV File Import
- Datasets
- SQL Table
- Data Table
- Paint Data
- Data Info
- Rank
- Edit Domain
- Color
- Feature Statistics
- Save Data

Transform

Visualize

Model

Evaluate

Unsupervised




Image Analytics


a Text Mining

Save Data

Save data to an output file.


[more...](#)






Data Preprocessing의 4가지 주제

Preprocess 위젯은 결측치 처리, 정규화, 차원축소 등 다양한 data 전처리 기능을 모아두고 있다.



◆ List of preprocessors



※ 필요한 전처리 기능을 우측으로 가져와 세부조건을 선택한다.

1. Discretize of continuous values : 연속형의 범주화
2. Continuize of discrete values : 범주형의 연속형 변환
3. Impute missing values : 결측값의 대체
4. Select relevant features : 상위 Rank 변수 선택
5. Select random features : 임의의 변수 선택
6. Normalize adjusts values : 정규화
7. Randomize instances. : 랜덤 데이터 선택
8. Remove sparse features : 희소 변수 제거
9. Principal component analysis : PCA 이용한 차원축소
10. CUR matrix decomposition : SVD 이용한 차원축소

Singular Value Decomposition

Data Preprocessing의 4가지 주제 ① Data Cleansing

데이터의 문제점을 식별하고 처리

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결

결측값 처리

이상값 처리

노이즈 처리

↓
깔끔한 데이터



Data Preprocessing의 4가지 주제 ① Data Cleansing

2. Data Handling

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결

결측값 처리

이상값 처리

노이즈 처리

깔끔한 데이터


데이터의 유형^{type}

- **categorical** : 범주형 혹은 이산형 데이터
- **numeric** : 연속형 변수
- **text** : 고유 값을 가지는 문자 데이터
예, 제품 Serial No. 고객 ID, 이름, 주소 등
- **datetime** : 시간 데이터


변수의 역할^{role}

- **meta** : 데이터 세트에 대한 추가적인 정보를
정보를 제공하지만 분석에는 반영되지 않는다.
text는 meta 취급한다. categorical 혹은 numeric
변수도 meta로 지정하면 분석에 반영되지 않는다.
예를 들어, 군집분석을 실행하는데 고객의 나이를
meta로 지정하면, 군집 형성 인자로 반영되지 않는다.
- **target** : 결과(독립) 변수
- **skip** : 데이터 세트에서 제거

<file 위젯>



<edit domain 위젯>



데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결

결측값 처리


이상값 처리

노이즈 처리

깔끔한 데이터

1 알고 싶은 것(분석 질문, 분석 목적)과 관계 없는 데이터 제거


- (1) 변수가 아닌 경우 예, 데이터 번호
- (2) 인과 관계가 없는 경우
- (3) 상관 관계가 없는 경우
- (4) 영향도가 없는(작은) 경우



x와 y는 상관성은 높으나
x는 y에 영향을 미치지 못한다.

2 상수 Constant 제거

- (1) 범주형 변수 : 오직 하나의 범주만 가진다.
- (2) 연속형 변수 : 오직 하나의 숫자 값만 가진다.




x가 y에 미치는 영향을
전혀 가늠할 수 없다.

3 희귀 변수 sparse features, Near Zero Variance 제거 검토

[예 1] 1,000명을 남녀 구분,
999명 남자, 1명 여자

[예 2] 1,000명 고객 설문,
999명 만족, 1명 불만족

※ 희귀 데이터는 기본적으로 제거.
알고 싶은 것(분석 질문, 분석 목적)을
기준으로 제거 여부 결정



Data Preprocessing의 4가지 주제 ① Data Cleansing

2. Data Handling

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결



결측값 처리

이상값 처리

노이즈 처리

깔끔한 데이터

Unique 위젯을 활용하여 중복을 탐색하고 제거



중복 검색할 기준 변수 선정

중복된 값 중에서 남겨둘 행 지정

→ First : 첫 번째 중복 데이터를 남긴다.

data no	name	height	weight
1	Lim	185	108
2	Lim	185	108
3	Hwang	168	48
4	Yang	160	60
5	Lee	168	66

	name	height	weight
1	Lim	185	108
2	Hwang	168	48
3	Yang	160	60
4	Lee	168	66



Syntax issue 해결

스펠링 실수나 누락, 약어, 대소문자, 양식의 변화 등은 분석에 문제가 될 수 있다..
이와 같은 Noise를 수정하고, 적절한 표준화 필요

- 모든 문자를 대문자로 변환하여 대 소문자 구분.
- 공백 및 불명확한 문자를 제거
- 숫자, 날짜 및 시간 형식을 통일 (소수 점, 기호, 통화 기호 포함).
- 혼합 정보는 두 개의 개별 특성으로 전달하는 필드로 분할. 이것을 field overloading 이라 함.
- 맞춤법 검사기 또는 형태소 분석을 사용해서 스펠링을 표준화.
- 약어의 제거
- 제목, 이름, 성의 순서를 무시하고 주소 및 이름의 작성을 표준화.
- 숫자는 표준화된 unit으로 변환
- 속성의 모든 가능한 value를 포함하는 단어들을 사용

[유의 사항]

사람이 noise를 수정할 수는 있지만, 문제는 변종이 많아서 자동으로 완전한 수정은 어렵다.
그러므로 필터링이나 변환을 위한 규칙이나 패턴을 만들어 정의하는 것이 대단히 유용하다.

Data Preprocessing의 4가지 주제 ① Data Cleansing

2. Data Handling

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결


결측값 처리

이상값 처리

노이즈 처리

깔끔한 데이터


edit domain을 활용할 수 있다.



➤ Name : Feature 이름 지정

➤ Type : Feature 유형 (Categorical / Numeric / Text / Time)

➤ Values : Up , Down , Append , Delete ,
 Rename , Merge infrequent items



➤ Label : Key / Value 지정

label1	ameter narrowin	age	gender Binary	chest pain	rest SBP
1	0	63	M	typical ang	145
2	1	67	M	asymptomatic	160
3	1	67	M	asymptomatic	120
4	0	37	M	non-anginal	130
5	0	41	F	atypical ang	130
6	0	56	M	atypical ang	120
7	1	62	F	asymptomatic	140
8	0	57	F	asymptomatic	120
9	1	63	M	asymptomatic	130

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결

결측값 처리

이상값 처리

노이즈 처리

깔끔한 데이터

결측치란, 해당 필드에 데이터가 없는 경우를 말한다.
결측치는 데이터 분석에서 큰 방해물이므로, 적절하게 조치를 취한다.

① Missing Value를 NA라는 데이터로 간주하고 분석한다.

② 누락이 포함된 행이나 열을 모두 제거한다.

No	X1	X2	X3	X4	X5	Y
1	NA	NA	NA	NA	41	양품
2	NA	10	20	30	42	양품
3	NA	11	22	33	43	양품
4	NA	13	34	36	44	불량
5	NA	14	26	39	45	NA
6	20	25	38	40	NA	양품

제거

No	X1	X2	X3	X4	X5	Y
1	NA	NA	NA	NA	41	양품
2	NA	10	20	30	42	양품
3	NA	11	22	33	43	양품
4	NA	13	34	36	44	불량
5	NA	14	26	39	45	NA
6	20	25	38	40	NA	양품

일부만
분석에
활용

→ 과도한 제거는 정보의 손실을 초래한다.

Data Preprocessing의 4가지 주제 ① Data Cleansing



3 분석가가 들여다 보면서 임의의 값으로 대체

4 중심 경향으로 대체 : 평균, 중앙값, 최빈값

연속형 변수는 중앙값으로,
이산형 변수는 최빈값으로
대체하는 경우가 가장 많다.

중앙값으로 대체

No	X1	X2	X3	X4	X5	Y
1	19	13	24	36	41	양품
2	19	10	20	30	42	양품
3	19	11	22	33	43	양품
4	19	13	24	36	44	불량
5	19	14	26	39	45	양품
6	20	25	38	40	43	양품

실무적 관점에서
19로 임의 지정

최빈값으로 대체

5 데이터 모델링을 통한 대체

다른 인자와의 회귀분석이나
기타의 모델링 기법을 활용하여
대체할 수 있다.

Data Preprocessing의 4가지 주제 ① Data Cleansing

2. Data Handling

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결



결측값 처리

이상값 처리

노이즈 처리


깔끔한 데이터

preprocess 위젯을 활용한 Missing Value의 대체



1 파일 : IRIS_전처리 실습

2 각 변수마다
3개의 Missing이 있다는
것을 확인할 수 있다.



Data Preprocessing의 4가지 주제 ① Data Cleansing

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결


결측값 처리

이상값 처리


노이즈 처리

깔끔한 데이터

impute 위젯을 활용한 Missing Value의 대체



파일 : IRIS_전처리 실습



Data Preprocessing의 4가지 주제 ① Data Cleansing

2. Data Handling



- 결측치를 잘못 대체하면 데이터에서 편향이 생길 수 있다.
- 결측치 처리에 분석가의 견해가 많이 반영되고, 분석결과가 달라질 수 있다.

중앙값으로 대체

No	X1	X2	X3	X4	X5	Y
1	19	13	24	36	41	양품
2	19	10	20	30	42	양품
3	19	11	22	33	43	양품
4	19	13	24	36	44	불량
5	19	14	26	39	45	양품
6	20	25	38	40	43	양품

실무적 관점에서
19로 임의 지정

최빈값으로 대체

vs.

No	X1	X2	X3	X4	X5	Y
1	19	13	24	36	41	양품
2	19	10	20	30	42	양품
3	19	11	22	33	43	양품
4	19	13	24	36	44	불량
5	19	14	26	39	45	양품
6	20	25	38	40	43	양품

- ※ NA가 다수를 차지하는 행과 열까지 모두 대체하는 것은 비합리적.
 5% 이상의 결측 비율이면, 삭제하는 것이 좋다는 사람도 있지만, 절대적인 기준은 없습니다.
 특히, 변수의 삭제는 신중할 필요가 있습니다.
 결측치는 삭제와 대체 등을 적절히 조합하여 대응하는 것이 적합할 것입니다.
 가장 좋은 방법은 한 땀 한 땀 들여보며 어떻게 처리할 것인지를 의사결정을 하는 것입니다.
 특히 데이터 수가 얼마 안될 때에는 이런 수고를 기꺼이 감내해야 합니다.

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결

결측값 처리

이상값 처리

노이즈 처리

깔끔한 데이터

이상값(극단값, Outlier)란, 무리에서 떨어져 있는 데이터를 말한다.
이상치도 데이터 분석에서 큰 방해물이므로, 적절하게 조치를 취해야 한다.



1 비합리적 이상치

명백한 오류.

예를들어, 5점법 측정에서 55점이 기록된 경우.

결측치에 준해서 처리한다.

2 합리적 이상치


오류가 아니나, 통상의 데이터 무리에서 벗어난 데이터.

예를 들어 고졸, 대학 중퇴, 대졸, 대학원졸 순으로 소득과의 관계를 분석하는 경우, 만약 빌 게이츠나 스티브 잡스가 포함된다면, 이들의 데이터는 통상의 범위에서 벗어난 것으로 이상치라고 할 수 있다.

이러한 데이터를 분석에 포함시킬 것인가 혹은 적절히 조치를 취할 것인가는 분석의 목적에 따라 판단해야 한다.

※ 합리적 이상치는 탐색의 대상이 되며, insight의 재료가 된다.

※ 이상치를 반드시 처리해야 하는 알고리즘도 있다.



데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결

결측값 처리

이상값 처리

노이즈 처리


깔끔한 데이터

이상치 탐지는 **Anomaly Detection**이란 주제와 더불어 Big Data 분석에서는 중요한 분야 중의 하나입니다. 이는 전통적인 통계적 기법을 활용할 수도 있고, 머신러닝을 활용할 수도 있습니다.

통계적 방법은 다양한 방법이 존재하며, 머신러닝을 활용하는 방법으로도 Supervised, Unsupervised, Semi-supervised 방법론 등 다양합니다.

탐지 방법보다 더 중요한 것은 이상치를 어떻게 정의할 것인가 하는 것입니다.

이상치를 탐지할 수 있는 통계적 기법



Supervised Anomaly Detection



학습 시, Labeling이 된 정상/비정상 데이터를 모두 사용한 경우
- 모델 성능 평가가 직관적임.
- Class Imbalanced Problem 해결이 필요

Semi-Supervised Anomaly Detection



학습 시, Labeling이 된 정상 데이터만을 사용한 경우
- 정상 데이터만 확보되는 상황에서, 시도해보기 좋음

Unsupervised Anomaly Detection



학습 시, 데이터가 대부분 정성으로 이루어져 있다고 가정
- 데이터에 확실한 Labeling이 없을 때, 용이함
- 모델 학습 후, 정상/비정상 데이터의 구분에 대한 임계치 설정이 필요할 수 있음

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결

결측값 처리


이상값 처리

노이즈 처리

깔끔한 데이터

표준화 점수의 활용

“한국 남자 청소년의 평균 키는 176Cm, 표준편차(σ)는 6Cm”




☞ 3σ 를 벗어날 확률은 0.135%에 불과하다. 즉, 이를 벗어나는 것은 아주 드문 경우이므로, 이것을 기준으로 이상값을 판단한다.

꼭 3σ 만 사용해야 하는 것은 아니다. 실무적 상황에 따라 다른 기준을 적용할 수 있다.



Tukey's Fence



☞ k 값으로는 1~3이 사용되며, $k=3$ 인 경우를 극단 이상값(Far Outlier)라 한다.
 $k=1.5$ 가 가장 많이 사용된다.

정규분포라면 $k=1.5$ 를 벗어날 확률은 0.7%에 불과하므로, 꽤 안정적으로 이상값을 식별할 수 있다.

IQR : Inter Quartile Range

Data Preprocessing의 4가지 주제 ① Data Cleansing

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거


구조적 문제 해결

결측값 처리


이상값 처리

노이즈 처리

깔끔한 데이터



1 파일 : example_outliers1



3

	Selected	ds	y
1	y ≥ 4000	2009-01-07	5264
2	y ≥ 4000	2009-01-08	5657
3	y ≥ 4000	2014-07-26	4731
4	y ≥ 4000	2014-12-06	7537
5	y ≥ 4000	2015-01-27	4142
6	y ≥ 4000	2015-04-29	8583

5

	ds	y
1	2009-01-07	5264
2	2009-01-08	5657
3	2014-07-26	4731
4	2014-12-06	7537
5	2015-04-29	8583

Data Preprocessing의 4가지 주제 ① Data Cleansing

2. Data Handling

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거


구조적 문제 해결

결측값 처리


이상값 처리

노이즈 처리

깔끔한 데이터



1 파일 : example_outliers1



3 Select Rows - Orange

Conditions

y is greater than 4900.75

$$2415.5 + 1.5 * (2415.5 - 757) = 4900.75$$

Add Condition Add All Variables Remove All

☐ Remove unused values and constant features

☐ Remove unused classes

☒ Send Automatically

2863 4 | 2859 | 2863

4

	ds	y
1	2009-01-07	5264
2	2009-01-08	5657
3	2014-12-06	7537
4	2015-04-29	8583

Data Preprocessing의 4가지 주제 ① Data Cleansing

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거


구조적 문제 해결

결측값 처리


이상값 처리

노이즈 처리

깔끔한 데이터



① 파일 : example_outliers1



※ 전통적인 통계적 기법과 결과가 아주 다르게 나왔다?
어느 것을 믿어야 하는 건가??

Data Preprocessing의 4가지 주제 ① Data Cleansing



이상값은 표준을 훨씬 벗어나 분석을 특정 방향으로 왜곡할 수 있는 데이터 포인트입니다.

① Outliers가 포함된 행이나 열을 모두 제거한다.

② Outliers를 있는 그대로 포함한 채 분석을 진행한다.

숫자가 분석 중인 다른 숫자보다 훨씬 작거나 크다고 해서 궁극적인 분석이 부정확하다는 의미는 아니다.
이상값이 존재한다고 해서 고려해서는 안 된다는 의미는 아닙니다.

실행 중인 분석의 종류와 이상값을 제거하거나 유지하는 것이 결과에 어떤 영향을 미칠지 고려해야 합니다.

③ Outliers를 Data 변환을 통한 Inliers로 만든 후 분석을 진행한다.

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결

결측값 처리

이상값 처리

노이즈 처리

깔끔한 데이터

4 Data를 이산화(discretization)한 후 분석을 진행한다.

이산화(discretization)

연속형 변수를 구간을 설정하여 이산형 변수로 바꾸는 것.

이산화를 통해 구간을 나누는 방법은 여러 가지가 있다.

등폭(equi-width) 이산화는 같은 폭으로 모든 구간을 나누는 것을 의미한다.

등빈도(equi-frequency) 이산화는 모든 구간들이 같은 데이터 수를 포함하는 것을 의미한다.

<예시>



• Data : 0, 4, 12, 16, 16, 18, 24, 26, 28

• Equal width

- Bin 1: 0, 4 [-, 10)
- Bin 2: 12, 16, 16, 18 [10, 20)
- Bin 3: 24, 26, 28 [20, +)

• Equal frequency

- Bin 1: 0, 4, 12 [-, 14)
- Bin 2: 16, 16, 18 [14, 21)
- Bin 3: 24, 26, 28 [21, +)



Data Preprocessing의 4가지 주제 ① Data Cleansing

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결



결측값 처리

이상값 처리

노이즈 처리

깔끔한 데이터

4 Data를 이산화(discretization)한 후 분석을 진행한다.



1. Equal-frequency discretization : 동일한 빈도로 구간을 구분
2. Equal-width discretization : 구간폭을 동일하게 나누어줌
3. Leave numeric variables : 수치형 변수 그대로 사용
4. Entropy-MDL discretization : Information gain을 최대화 하는 최적의 구간 산출
5. Remove numeric variables : 변수열을 제거
6. Manual : 분석자가 직접 구간정보를 입력

데이터의 유형과 역할
확인 및 수정

불필요하거나
의미 없는 정보 제거

데이터 중복 제거

구조적 문제 해결


결측값 처리

이상값 처리



노이즈 처리

깔끔한 데이터

1 평활화(smoothing)을 통한 노이즈의 처리



2 회귀분석을 통한 노이즈의 처리



데이터 결합이란, 여러 데이터 소스로부터 수집한 데이터를 하나의 Data-set으로 만드는 것



분석적 합리성을 토대로 데이터 결합

Partner A

Part ID	Material	Lead Time (weeks)	Price (dollars)
10010	Fe	2	40
10011	Cu	3	55
10013	Alloy	4	67

Partner B

Part ID	Material	Price(dollars)
10010	Fe	40.30
10012	Cu	54.80
10013	Alloy	67.47

Integrated database

Part ID	Material	Price (dollars)	Lead Time (days)
10010	Fe	40.30	[8, 14]
10011	Cu	[54.50, 55.49]	[15, 21]
10012	CU	54.8	φ
10013	Alloy	67.47	[22, 28]

결측

Data Join

Table 1 ●

1		
2		

Table 2 ●

1		
3		
4		

Outer Join ●●

1				
2				
3				
4				

Inner Join ●●

1				
---	--	--	--	--

Left Join ●●

1				
2				

Union ●+●

1		
2		
1		
3		
4		

Cross Join ●●●●


1			1		
1			3		
1			4		
2			1		
2			3		
2			4		

Data Preprocessing의 4가지 주제 ② Data Integration

2. Data Handling





Merge Data 위젯은 Dataset 을 수평으로 통합




	name	sex	height
1	Lim	male	185
2	Seong	female	162

	name	height	weight
1	Lim	185	108
2	Hwang	168	48
3	Yang	160	60
4	Lee	168	66



Concatenate 위젯은 동일한 변수 명을 가진 두 개 이상의 Dataset 을 수직으로 통합하는데 유용



data no	name	height	weight
1	A	185	108
2	B	168	48
3	C	160	60
4	D	168	66

data no	name	height	weight
1	E	155	44
2	F	177	75



	name	height	weight
1	A	185	108
2	B	168	48
3	C	160	60
4	D	168	66
5	E	155	44
6	F	177	75

➤ 선형 변환

$$L(x) = ax + b, \text{ 여기서 } a > 0$$

선형 변환은 해석의 용이성을 위한 단위 또는 척도를 변환할 때 유용하지만 분포의 형태 또는 관계의 형태를 변경하지는 못한다.

$$z = \frac{x_i - \mu}{\sigma}$$

➤ 비선형 변환 (역승변환)

$$P_p(x) = \begin{cases} x^p & p \neq 0 \\ \log(x) & p = 0 \end{cases}$$

$$T_p(x) = \begin{cases} (x^p - 1) / p & p \neq 0 \\ \log(x) & p = 0 \end{cases}$$

비선형 변환(역승 변환, power transformation)은 단일 또는 다수 집단의 분포의 모양(shape) 또는 2개 이상의 변수들 간의 함수 관계의 형태를 변경 시킬 수 있다.

[선형 변환] 데이터의 표준화

변수의 영향도나 중요성을 객관적으로 상호비교 하기 위한 것이다.

일반적으로 집단의 유사성은 거리(distance)로 측정하는데, 이는 사용된 척도(scaling)에 따라 달라진다.

이와 같이 Scale에 무관한 무차원 데이터로 만들기 위하여 표준화(Normalization)을 실시한다.

min-max normalization

$$n : \text{dom } X \rightarrow [0, 1]$$

$$X \mapsto \frac{X - \min_x}{\max_x - \min_x}$$

z-score normalization

$$n : \text{dom } X \rightarrow \mathbb{R}$$

$$X \mapsto \frac{X - \mu_x}{\sigma_x}$$

robust z-score
standardization

$$n : \text{dom } X \rightarrow \mathbb{R}$$

$$X \mapsto \frac{X - \text{중앙값}}{\text{IQR}_x}$$

decimal scaling

$$n : \text{dom } X \rightarrow [0, 1]$$


$$X \mapsto \frac{X}{10^s}$$

Preprocess 위젯을 활용한 Z값으로 변환




1 파일 : example_outliers1

2




Min-Max Transformation의 수동 생성




1 파일 : example_outliers1

2



Data Preprocessing의 4가지 주제 ④ Data Selection



1 instance Selection

X1	X2	X3	X5	X5	X6	Y


2 Feature Selection

[illegible]

3 Dimension Reduction


[illegible]

1 instance Selection



- 데이터 축소의 수단. 특히, 예비 분석은 일부 데이터로 진행할 수 있다.
- 머신러닝을 위한 Training Set과 Test Set로의 분할

※ Sampling의 가장 기본적인 방법은 무작위 Random Sampling.
Random이라 함은 각 요소가 뽑힐 확률이 동일하다는 의미임.



Data Preprocessing의 4가지 주제 ④ Data Selection

1 instance Selection

확률표본추출 방법 : 모집단의 모든 구성요소가 표본으로 선정될 확률이 동일한 표본추출방법

단순임의추출법 (Simple Random Sampling)

모든 가능한 원소들이 추출될 가능성이 동일하도록 추출 하는 방법 (랜덤 샘플링)

층화임의추출법 (Stratified Random Sampling)


모집단이 서로 이질적인 원소들로 구성되어 있을 때, 각 층에서 단순임의 추출법을 시행하여 표본을 추출하는 방법

계통추출법 (Systematic Sampling)

표본을 추출하고자 하는 모집단이 너무 커서 단순임의 추출법을 시행하기 곤란한 경우, 모집단의 구성이 랜덤함을 가정하고, 일정 간격으로 표본을 추출하는 방법

집락추출법 (Cluster Sampling)


모집단이 여러 개의 집단이 결합된 형태로 구성되어 있는 경우, 각 집단(집락, Cluster)을 임의로 추출하여 전수조사하거나, 추출된 집단으로부터 일정 수의 원소를 임의로 추출



[예시] IRIS data-set에서

- 150개 중 임의로(random하게) 50개의 instance를 뽑아서 분석했다.
- 각 품종 별 20개씩 추출하여 총 60개의 데이터를 분석했다.
- 150개 데이터를 일련 번호를 부여하고, 5의 배수에 해당하는 instance를 뽑아서 분석했다.
- setosa 품종의 데이터를 뽑아서 그것만 분석했다.


1 instance Selection : data sampler 위젯을 활용한 확률 표본 추출



Data Preprocessing의 4가지 주제 ④ Data Selection

2. Data Handling

1 instance Selection : Select Row 위젯을 활용한 비확률표본추출



1

Select Rows - Orange

Conditions

species is setosa

품종 setosa만 선택

2

Edit Links - Orange

setosa를 제외한 데이터 선택

Matching Data ☐

Unmatched Data ☒ → Data

Data ☐

Select Rows **Data Table (1)**

OK Cancel

Select Rows - Orange

Conditions

sepal_length is greater than 5.0

sepal_length가 5.0보다 큰 데이터만 선택


Add Condition Add All Variables Remove All

☐ Remove unused features
☐ Remove unused classes
☒ Send Automatically

118 | 32 | 150


2 Feature Selection : 원본 데이터에서 불필요한 특징들(변수들)을 제거하는 것

1. Filter Method 통계 분석을 통해 중요한 Feature를 선정




Y\X	연속형	이산형
연속형	상관분석	선형판별분석
이산형	ANOVA	Chi-Square

2. Wrapper Method 변수를 추가 혹은 삭제하면서 모델을 구축하고, 성능을 평가하여 최적의 Feature 조합을 선택



Forward selection,
Backward elimination,
Greedy Algorithm

3. Embedded Method 스스로 평가하여 모델을 최적화



Ridge regression, LASSO,
Deep Learning

Data Preprocessing의 4가지 주제 ④ Data Selection

2. Data Handling

2 Feature Selection : preprocess 위젯을 활용



1 데이터 : IRIS

File - Orange

Source

File: IRIS.csv

File Type

Automatically detect type

Info

150 instances
5 features (no missing values)
Data has no target variable,
0 meta attributes

Columns (Double click to edit)

Name	Type	Role	Values
1 sepal_length	numeric	feature	
2 sepal_width	numeric	feature	
3 petal_length	numeric	feature	
4 petal_width	numeric	feature	
5 species	categorical	target	setosa, versicolor, virginica

target으로 변경

Reset Apply

Browse documentation datasets

2

Preprocess - Orange

Preprocessors

- Discretize Continuous Variables
- Continuize Discrete Variables
- Impute Missing Values
- Select Relevant Features
- Select Random Features
- Normalize Features
- Randomize
- Remove Sparse Features
- Principal Component Analysis
- CUR Matrix Decomposition

Select Relevant Features

Score

Information Gain

Number of features

Fixed: 3


Proportion: 75,00%

information Gain을 활용하여
전체 feature중
target에 영향을 미치는 중요도에 따라
75%를 선택


Apply Automatically

150 - | 150

2 Feature Selection : Select Row 위젯을 활용하여 임의로 Feature의 삭제 혹은 선택




두 개의 feature를
삭제함



2. Data Handling

3 Dimension Reduction : 원 Feature들을 결합하여, 전체 feature의 개수 축소



1. 주성분 분석 (PCA) Principle Component Analysis

$$PC1 = aX1 + bX2 + cX3$$

$$PC2 = \alpha X5 + \beta X6$$

➡ 같은 유형의 변수들을 선형 결합

2. Domain Knowledge를 활용한 Feature Extraction

[illegible]

Data Preprocessing의 4가지 주제 ④ Data Selection

2. Data Handling

3 Dimension Reduction : Rank 위젯을 활용한 중요 변수의 선별



Rank - Orange

Scoring Methods

- ☒ Information Gain
- ☒ Information Gain Ratio
- ☒ Gini Decrease
- ☐ ANOVA
- ☐ χ^2
- ☐ ReliefF
- ☐ FCBF


Select Attributes

- ☐ None
- ☐ All
- ☐ Manual
- ☒ Best ranked: 2

☒ Send Automatically

	#	Info. gain	Gain ratio	Gini
1	petal length	1.086	0.544	0.423
2	petal width	1.059	0.532	0.407
3	sepal length	0.624	0.313	0.247
4	sepal width	0.361	0.183	0.154

← 전체 변수 중 Rank 순으로 2개 선택



Data Table - Orange

Info

150 instances (no missing data)
2 features
Target with 3 values
No meta attributes

Variables

- ☒ Show variable labels (if present)
- ☐ Visualize numeric values
- ☒ Color by instance classes

Selection

- ☒ Select full rows

	iris	petal length	petal width
1	Iris-setosa	1.4	0.2
2	Iris-setosa	1.4	0.2
3	Iris-setosa	1.3	0.2
4	Iris-setosa	1.5	0.2
5	Iris-setosa	1.4	0.2
6	Iris-setosa	1.7	0.4
7	Iris-setosa	1.4	0.3
8	Iris-setosa	1.5	0.2
9	Iris-setosa	1.4	0.2
10	Iris-setosa	1.5	0.1
11	Iris-setosa	1.5	0.2
12	Iris-setosa	1.6	0.2
13	Iris-setosa	1.4	0.1
14	Iris-setosa	1.1	0.1
15	Iris-setosa	1.2	0.2
16	Iris-setosa	1.5	0.4
17	Iris-setosa	1.3	0.4
18	Iris-setosa	1.4	0.3
19	Iris-setosa	1.7	0.3
20	Iris-setosa	1.5	0.3
21	Iris-setosa	1.7	0.2

Restore Original Order

☒ Send Automatically

※ Scoring Methods

- Information Gain – 엔트로피 감소량
- Information Gain Ratio – Information Gain 비율
- Gini Decrease – 도수 분포 값 간의 불평등
- ANOVA – 전체 평균과 feature 평균간 차이
- Chi2 – feature 와 class 간 종속성에 대한 χ^2 검정
- ReliefF – 유사 데이터 내에서 Class 구별력
- FCBF – 엔트로피 & 상관분석을 활용

3 Dimension Reduction : preprocess 위젯을 활용한 PCA



1 데이터 : IRIS

File - Orange

Source

File: IRIS.csv

File Type

Automatically detect type

Info

150 instances
5 features (no missing values)
Data has no target variable,
0 meta attributes

Columns (Double click to edit)

Name	Type	Role	Values
1 sepal_length	numeric	feature	
2 sepal_width	numeric	feature	
3 petal_length	numeric	feature	
4 petal_width	numeric	feature	
5 species	categorical	target	setosa, versicolor, virginica

target으로 변경

Reset Apply

Browse documentation datasets

2

Preprocess - Orange

Preprocessors

- Continuize Discrete Variables
- Impute Missing Values
- Select Relevant Features
- Select Random Features
- Normalize Features
- Randomize
- Remove Sparse Features
- Principal Component Analysis
- CUR Matrix Decomposition

Principal Component Analysis



Components: 2

두 개의 주성분으로 데이터를 재구성

Apply Automatically

3 Dimension Reduction : Domain Knowledge를 활용한 Feature Extraction

[예시] 체질량지수(BMI) Body Mass Index는 몸무게(kg)를 키의 제곱(m)으로 나눈 값



① 데이터 : data merge 21

2 Feature Constructor - Orange

Variable Definitions

New BMI $\text{weight}/((\text{height}/100)**2)$

Remove ☐ Meta attribute Select Feature Select Function

BMI := $\text{weight}/((\text{height}/100)**2)$


키는 Cm 단위이므로, 100을 나눠주고 제곱함.

3

	name	height	weight	BMI
1	Lim	185	108	31.5559
2	Hwang	168	48	17.0068
3	Yang	160	60	23.4375
4	Lee	168	66	23.3844

[참조] Data Table 위젯

여러 Dataset을 엑셀처럼 Sheet 단위로 볼 수 있고, 일부 행을 선택하여 전달할 수 있다.



Data Table (2) - Orange

Info
10 instances (no missing data)
4 features
Target with 3 values
No meta attributes

Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection
☒ Select full rows

Restore Original Order
☒ Send Automatically

	iris	sepal length	sepal width	petal length	petal width
1	Iris-setosa	5.1	3.5	1.4	0.2
2	Iris-setosa	4.9	3.0	1.4	0.2
3	Iris-setosa	4.7	3.2	1.3	0.2
4	Iris-setosa	4.6	3.1	1.5	0.2
5	Iris-setosa	5.0	3.6	1.4	0.2
6	Iris-setosa	5.4	3.9	1.7	0.4
7	Iris-setosa	4.6	3.4	1.4	0.3
8	Iris-setosa	5.0	3.4	1.5	0.2
9	Iris-setosa	4.4	2.9	1.4	0.2
10	Iris-setosa	4.9	3.1	1.5	0.1

앞 단계 Data Table 에서 선택된 행으로 구성된 새로운 Data Table

ZOO Dataset

ZOO - Orange

Source
File: zoo.tab
URL:

Info
Zoo dataset
This dataset consists of 101 animals with various traits to describe them.
101 instance(s)
16 feature(s) (no missing values)
Classification: categorical class with 7 values (no missing values)
1 meta attribute(s)

Columns (Double click to edit)

Name	Type	Role	Values
legs	categorical	feature	0, 4, 5, 6, 8
tail	categorical	feature	0, 1
domestic	categorical	feature	0, 1
catsize	categorical	feature	0, 1
type	categorical	target	amphibian, bird, fish, insect, invertebrate, mammal, reptile
name	text	meta	

Reset Apply

Browse documentation datasets

IRIS Dataset

IRIS - Orange

Source
File: iris.tab
URL:

Info
Iris flower dataset
Classical dataset with 150 instances of Iris setosa, Iris virginica and Iris versicolor.
150 instance(s)
4 feature(s) (no missing values)
Classification: categorical class with 3 values (no missing values)
0 meta attribute(s)

Columns (Double click to edit)

Name	Type	Role	Values
sepal length	numeric	feature	
sepal width	numeric	feature	
petal length	numeric	feature	
petal width	numeric	feature	
iris	categorical	target	Iris-setosa, Iris-versicolor, Iris-virginica

Reset Apply

Browse documentation datasets

&

Data Table (1) - Orange

Info
150 instances (no missing data)
4 features
Target with 3 values
No meta attributes

Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection
☐ Select full rows

Restore Original Order
☒ Send Automatically



	iris	sepal length	sepal width	petal length
1	Iris-setosa	5.1	3.5	
2	Iris-setosa	4.9	3.0	
3	Iris-setosa	4.7	3.2	
4	Iris-setosa	4.6	3.1	
5	Iris-setosa	5.0	3.6	
6	Iris-setosa	5.4	3.9	
7	Iris-setosa	4.6	3.4	
8	Iris-setosa	5.0	3.4	
9	Iris-setosa	4.4	2.9	
10	Iris-setosa	4.9	3.1	
11	Iris-setosa	5.4	3.7	
12	Iris-setosa	4.8	3.4	
13	Iris-setosa	4.8	3.0	

IRIS 에서
10행 선택

두 Dataset 이 각각의 sheet 로 구성되며, 전체 행 정보를 확인 가능

[참조] Aggregate Columns 위젯

기존 변수의 간단한 통계량을 계산하여 새로운 열에 저장





②

	iris	sepal length	sepal width	petal length	petal width	sepal_sum
1	Iris-setosa	5.1	3.5	1.4	0.2	8.6
2	Iris-setosa	4.9	3.0	1.4	0.2	7.9
3	Iris-setosa	4.7	3.2	1.3	0.2	7.9
4	Iris-setosa	4.6	3.1	1.5	0.2	7.7
5	Iris-setosa	5.0	3.6	1.4	0.2	8.6
6	Iris-setosa	5.4	3.9	1.7	0.4	9.3
7	Iris-setosa	4.6	3.4	1.4	0.3	8
8	Iris-setosa	5.0	3.4	1.5	0.2	8.4
9	Iris-setosa	4.4	2.9	1.4	0.2	7.3
10	Iris-setosa	4.9	3.1	1.5	0.1	8
11	Iris-setosa	5.4	3.7	1.5	0.2	9.1
12	Iris-setosa	4.8	3.4	1.6	0.2	8.2
13	Iris-setosa	4.8	3.0	1.4	0.1	7.8
14	Iris-setosa	4.3	3.0	1.1	0.1	7.3
15	Iris-setosa	5.8	4.0	1.2	0.2	9.8

[참조] Feature Constructor 위젯

Feature Constructor widget은 기존 변수와 python 표현식을 사용하여 새로운 변수열을 생성하는데 사용한다.



Variable Definitions


1. 변수 속성 선택
2. 변수명 입력
3. Python Expression 으로 입력
4. (Option) 기존의 변수열 사용
5. (Option) 저장된 함수 사용(로그, 삼각함수, ...)
6. (Option) Category Level 지정 (콤마로 구분)
7. Expression 확인
8. Expression 제거
9. Expression 적용

	iris	sepal length	sepal width	petal length	petal width	petal length square	sepal length class
1	Iris-setosa	5.1	3.5	1.4	0.2	1.96	low
2	Iris-setosa	4.9	3.0	1.4	0.2	1.96	low
3	Iris-setosa	4.7	3.2	1.3	0.2	1.69	low
4	Iris-setosa	4.6	3.1	1.5	0.2	2.25	low
5	Iris-setosa	5.0	3.6	1.4	0.2	1.96	low

← 두개의 변수열이 생성되었다.

[참조] Group by 위젯

Group 별 선택한 변수에 대한 기초통계량을 계산



Group by - Orange

Filter...

- ☒ iris
- ☐ sepal length
- ☐ sepal width
- ☐ petal length
- ☐ petal width

기준변수 선택

	Attributes	Aggregations
1	☒ sepal length	Mean
2	☒ sepal width	Mean
3	☒ petal length	Mean
4	☒ petal width	Mean
5	☒ iris	

변수와 통계량을 선택

Aggregations

- ☒ Mean
- ☐ Median
- ☐ Mode
- ☐ Standard deviation
- ☐ Variance
- ☐ Sum
- ☐ Concatenate
- ☐ Min. value
- ☐ Max. value
- ☐ Span
- ☐ First value
- ☐ Last value
- ☐ Random value
- ☐ Count defined
- ☐ Count
- ☐ Proportion defined

☒ Send Automatically

150 3

Data Table (8) - Orange

Info

- 3 instances (no missing data)
- 4 features
- No target variable.
- 1 meta attribute

Variables

- ☒ Show variable labels (if present)
- ☐ Visualize numeric values
- ☒ Color by instance classes

Restore Original Order

☒ Send Automatically

	iris	sepal length - Mean	sepal width - Mean	petal length - Mean	petal width - Mean
1	Iris-setosa	5.006	3.418	1.464	0.244
2	Iris-versicolor	5.936	2.77	4.26	1.326
3	Iris-virginica	6.588	2.974	5.552	2.026

3 3 | 3

[참조] Pivot Table 위젯

행과 열의 2 x 2 Cross Table 을 만들 수 있으며, 간단한 통계량도 지원

untitled * - Orange

File Edit View Widget Window Options Help

Data

Transform

Data Sampler Select Columns Select Rows Transpose

Merge Data Concatenate Select by Data Index Unique

Aggregate Columns Group by **Pivot Table** Apply Domain

Preprocess Impute Continuity Discretize

Randomize Purge Domain Melt Feature Constructor

Create Class Create Instance Python Script

Visualize

Model

Evaluate

titanic data에서 train

File Data Pivot Table

pivot table 생성

Pivot Table - Orange

File View Window Help

Rows

☒ Survived

Columns

☒ Sex

Values

(None)

Aggregations

☒ Count

☐ Count defined

☐ Sum ☐ Mode

☐ Mean ☐ Min

☐ Var ☐ Max

☐ Median

☐ Majority

Count

		Sex		
		female	male	Total
Survived	0	81.0	468.0	549.0
	1	233.0	109.0	342.0
	Total	314.0	577.0	891.0

통계량 계산

Pivot Table - Orange

File View Window Help

Rows

☒ Survived

Columns

☒ Sex

Values

☒ Age

Aggregations

☐ Count

☒ Count defined

☐ Sum ☐ Mode

☒ Mean ☐ Min

☐ Var ☐ Max

☒ Median

☐ Majority

Apply Automatically

		Sex			
		female	male	Total	
Survived	0	Mean	25.047	31.618	30.626
		Median	24.5	29.0	28.0
	1	Mean	28.848	27.276	28.344
	Median	28.0	28.0	28.0	
Total	Mean	27.916	30.727	29.699	
	Median	27.0	29.0	28.0	

생존-사망, 남-녀의 나이 평균과 중앙값

전처리, 파싱(Parsing), 필터링(Filtering)과 같이 데이터를 핸들링하여
깔끔한 데이터 (tidy data)로 정비하는 것. Data 분석 중 80%의 노력과 시간 소비

1. 분석 목적이 모든 과정을 지배한다.
2. 데이터는 양보다 질이다.
3. 데이터에 대한 올바른 이해가 중요하다. (탐색적 분석)
4. 올바른 데이터 정제 프로세스를 만들고 일관되게 적용한다.
5. 적절한 도구를 탐색하고 활용한다.
6. 오류에 주의를 기울이고 깔끔하지 않은 데이터의 출처를 추적한다.
7. 재주만이 아니라 성의가 필요한 작업이다.



Question or Comment ?!

고객도
모르는
고객을
알자



배운다
배운 걸
지우고
다시 배운다

