



4. 분류분석 (Classification Analysis)

분류 Classification 와 회귀 Regression


Input X를 활용해서
Output Y를 정해진 범주로
분류하는 함수를 찾는 것



Input X와 output Y 사이의
관계식(함수)을 찾는 것.
값을 예측하는 문제에 적용




머신러닝 Machine Learning



Classification (분류)

분류 알고리즘

Logistic Regression
Discriminant Analysis
K-nearest neighborhood
Decision Tree
Random Forest
Gradient Boosting
Support Vector Machine
Deep Learning



[예] 분류 알고리즘은 환자 정보를 이용하여 당뇨병 유무를 예측할 수 있다.

혼동 행렬 (Confusion matrix)

		Predicted	
		Negative	Positive
Actual	Negative	True Negative(TN)	False Positive(FP)
	Positive	False Negative(FN)	True Positive(TP)

$$\text{정확도(Accuracy)} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$


$$\text{정밀도(Precision)} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

$$\text{재현율(Recall)} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$




$$\text{F1} = 2 * \frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}}$$


ROC (Receiver Operating Characteristic)



Threshold



AUC (Area Under Curve)




- ✓ True Positive Rate(Y축) : Positive 를 Positive 로 올바르게 예측 (재현율 , 민감도)
- ✓ False Positive Rate(X축) : Negative를 Positive로 잘못 예측 (1종 오류, 1-특이도)

kNN(K-nearest neighborhood)


k개 최근접 이웃을 기준으로 분류하는 알고리즘

[예] $k = 1, 3, 9$ 일때 $\oplus$ 의 kNN 분류 결과



로지스틱 회귀분석, 판별분석


로지스틱 회귀분석 (Logistic regression analysis)




$$\ln \frac{p}{1-p} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_i X_i$$

$$\text{Probability}(Y=1) = \ln \frac{e^{\beta_0 + \beta_1 X_1 + \dots + \beta_i X_i}}{1 + e^{\beta_0 + \beta_1 X_1 + \dots + \beta_i X_i}}$$

판별분석 (Discriminant Analysis)



(a) 선형판별분석




(b) 이차판별분석

$$Z = W_1 X_1 + W_2 X_2 + \dots + W_n X_n$$

(Z : 판별점수, W_i : 판별계수, X_i : 독립변수)

의사결정 규칙을 Tree 구조로 나타내어
소집단으로 분할하거나 예측하는 알고리즘



재귀적 분할 (Recursive Partitioning)

하나의 입력 변수를 선택하여 데이터를 두 공간으로 나눌 수 있는 후보값들을 정의한다.

각 후보값 별로 데이터를 두 공간으로 분할하여 Impurity(불순도)¹⁾, Information Gain²⁾을 계산한다.

가장 데이터 불순도가 낮은 후보값을 그 입력 변수의 분기 기준값으로 선정한다.

여러 입력 변수와 분기 기준값 중 가장 데이터 불순도가 낮아지는 방법으로 데이터를 분할한다.

¹⁾ Impurity(불순도) : 무질서한 정도를 정량화 한 값으로, 낮을수록 순수도가 높으며, Gini index 또는 Entropy 가 주로 사용된다.

²⁾ Information Gain(정보 이득) : 데이터를 잘 구분하는지 평가하는 지표로써, 클수록 변별력이 좋다. 상위노드 Entropy - 하위노드 Entropy

Decision Tree(의사결정나무)

불순도(Impurity)는 무질서 정도의 정량값


불순도가 크다.

강아지 10 마리
고양이 10 마리


불순도가 없다.

강아지
10마리고양이
10마리

- Entrophy : $H(D_j) = -\sum P(c_i|D_j) \log_2 P(c_i|D_j)$
- Gini index : $G(D_j) = 1 - \sum P(c_i|D_j)^2$

 $P(c_i|D_j)$: 훈련집합 D_j 내에 c_i 가 나타날 확률

information gain = 분할 전 엔트로피 - 분할 후 엔트로피



Gini index

$$G_{\text{Base}} = 1 - \left(\frac{10}{15}\right)^2 - \left(\frac{5}{15}\right)^2 = 0.444$$

$$Gini = 1 - \sum_{i=1}^C (p_i)^2$$

$$G_{\text{New}} = \frac{11}{15} \left\{ 1 - \left(\frac{10}{11}\right)^2 - \left(\frac{1}{11}\right)^2 \right\} + \frac{4}{15} \left\{ 1 - \left(\frac{1}{4}\right)^2 \right\} = 0.371$$

$$\text{Information Gain} = G_{\text{Base}} - G_{\text{New}} = 0.073$$

Entropy

$$H_{\text{Base}} = -\frac{10}{15} \log_2 \left(\frac{10}{15}\right) - \frac{5}{15} \log_2 \left(\frac{5}{15}\right) = 0.444$$

$$H(X) = -\sum_{i=1}^n p_i \log_2 p_i$$

$$H_{\text{New}} = \frac{11}{15} \left\{ -\frac{10}{11} \log_2 \left(\frac{10}{11}\right) - \frac{1}{11} \log_2 \left(\frac{1}{11}\right) \right\} + \frac{4}{15} \left\{ -\frac{4}{4} \log_2 \left(\frac{4}{4}\right) \right\} = 0.406$$

$$\text{Information Gain} = H_{\text{Base}} - H_{\text{New}} = 0.038$$



Decision Tree(의사결정나무)

[예]세가지 입력변수와 범주형 출력변수로 구성된 데이터를 이용하여
의사결정 모델을 학습한 후 채무불이행자를 분류하여 보자.

ID	집 소유	결혼	연소득(K)	채무 불이행
1	Yes	미혼	125	No
2	No	기혼	100	No
3	No	미혼	70	No
4	Yes	기혼	120	No
5	No	이혼	95	Yes
6	No	기혼	60	No
7	Yes	이혼	220	No
8	No	미혼	85	Yes
9	No	기혼	75	No
10	No	미혼	90	Yes


Decision Tree(의사결정나무)

재귀적 분기를 통한 의사결정나무 생성



Decision Tree(의사결정나무)


새로운 데이터의 결과 예측



ID	집 소유	결혼	연소득(K)	채무 불이행	예측 클래스
11	No	미혼	55	?	No
12	Yes	기혼	80	?	No
13	Yes	미혼	110	?	No
14	No	기혼	95	?	No
15	No	이혼	300	?	Yes

Decision Tree(의사결정나무)

Cut-off value




$$P(\text{채무불이행}=\text{Yes}) = 3/4 = 0.75$$

$$P(\text{채무 이행}=\text{No}) = 1/4 = 0.25$$

“채무불이행=Yes” 인 terminal node 로 변경

Decision Tree(의사결정나무)


Cut-off value = 0.5



- If 결혼='기혼', then 채무불이행 = No
- If 결혼='미혼 or 이혼' and 집소유여부=No, then 채무불이행 = YES
- If 결혼='미혼 or 이혼' and 집소유여부=Yes, then 채무불이행 = No

앙상블 Ensemble, 여러 개의 나무 조합

Decision Tree를 여러 개 만들고, 다수결 원칙 적용



1. 전체 데이터 세트에서 다수의 훈련 세트를 추출
2. 각 훈련 셋에서 Tree 생성 및 예측
3. 예측 결과 통합 : 다수결 혹은 평균

→ 예측 정확도는 향상되지만, 해석은 어려워진다.

앙상블 모형 (Ensemble Model)

예측력을 향상시키기 위해

여러 개의 예측 모형을 결합하여 사용하는 것.

앙상블의 작동 원리는 대중의 지혜 Wisdom of Crowd

다수의 보통 사람들이 모여서 내놓은 답이

한 분야의 전문가의 답보다 항상 더 정확하다.

앙상블 Ensemble, 여러 개의 나무 조합

Random Forest 는 Decision Tree 의 병렬조합

Gradient Boosting 은 Decision Tree 의 직렬 조합





Variance
Reduction

Gradient Boosted Trees



Bias
Reduction




✓ High bias & Low variance Model (underfitting): 로지스틱 회귀분석, 판별분석

✓ Low bias & high variance Model (overfitting) : 의사결정나무, 서포트벡터머신

SVM (Support Vector Machine)

마진을 최대화하는 선형경계선으로 분리




➤ 1차원에서는 어떻게 분류해도 오분류 발생



분류 함수를 어디에 가져다 놓아도 오차 발생

2차원으로
데이터 변환

➤ 2차원에서는 오분류를 최소화하여 분류 가능



✓ Kernel 함수를 적용하여 고차원의 평면(hyper plane)으로 분리

[실습 1] Heart Disease Data

Heart Disease Data 는 가슴통증으로 내원한 303명의 환자의 심장 건강상태에 대한 정보가 기록되어 있다.

심장 혈관의 직경이 좁아짐에 대한 결과가 기록된 변수는 diameter narrowing 이다. (1 : 협소화, 0 : 정상)



File

File - Orange

Source
File: heart_disease.tab
URL:
File Type
Automatically detect type

Info
Heart Disease dataset
Data on the presence of heart disease in patients.
303 Instance(s)
13 feature(s) (0.2% missing values)
Classification: categorical class with 2 values (no missing values)
0 meta attribute(s)

Columns (Double click to edit)

Name	Type	Role	Values
1 age	numeric	feature	
2 gender	categorical	feature	female, male
3 chest pain	categorical	feature	asymptomatic, atypical ang., non-anginal, typical ang.
4 rest SBP	numeric	feature	
5 cholesterol	numeric	feature	
6 fasting blood sugar > 120	categorical	feature	0, 1
7 rest ECG	categorical	feature	normal, left vent hypertrophy, ST-T abnormal
8 max HR	numeric	feature	
9 exerc ind ang	categorical	feature	0, 1
10 ST by exercise	numeric	feature	
11 slope peak exc ST	categorical	feature	upsloping, flat, downsloping
12 major vessels colored	numeric	feature	
13 thal	categorical	feature	normal, reversable defect, fixed defect
14 diameter narrowing	categorical	target	0, 1

Reset Apply

Browse documentation datasets

```
#age - 나이
#sex - (1 = 남성; 0 = 여성)
#cp - 가슴 통증 유형(0, 1, 2, 3, 4)
#trestbps - 안정 혈압(병원 입원시 mm Hg)
#chol - 혈청 콜레스테롤(mg/dl)
#fbs - (공복 혈당 > 120 mg/dl)(1 = true; 0 = false)
#restecg - 안정 심전도 결과(0, 1, 2)
#thalach - 최대 심박동수
#exang - 협심증 유발 운동(1 = yes; 0 = no)
#oldpeak - 비교적 안정되기까지 운동으로 유발되는 ST depression
#slope - 최대 운동 ST segment의 기울기
#ca - 형광 투시된 주요 혈관의 수(0-3)
#thal - (3 = 보통; 6 = 해결된 결함; 7 = 해결가능한 결함)
#target - 심장병 진단(1 = true; 0 = false)
```

Open...


« Orange » Lib » site-packages » Orange » datasets datasets 검색

구성	새 폴더	이름	수정된 날짜	유형	크기
★ Orange		brown-selected.tab	2022-10-04 오전 12:05	TAB 파일	96KB
★ Q bank		heart_disease.tab	2022-10-04 오전 12:05	TAB 파일	24KB
보고서		housing.tab	2022-10-04 오전 12:05	TAB 파일	34KB
내 PC		iris.tab	2022-10-04 오전 12:05	TAB 파일	5KB
3D 개체		titanic.tab	2022-10-04 오전 12:05	TAB 파일	45KB
Local Disk (C: on CHRRD)		zoo.tab	2022-10-04 오전 12:05	TAB 파일	5KB
Local Disk (D: on CHRRD)					

File 위젯의 드롭다운 메뉴에서 heart_disease.tab 데이터 세트를 불러온다.

[실습 1] Heart Disease Data

Heart Disease Dataset을 8 : 2로 분할하여 각각 학습과 평가에 사용하고, 앞에서 살펴본 5가지 분류 알고리즘을 활용하여 모형의 성능을 평가지표를 통하여 평가한다.



Random Forest 의 성능지표가 전체적으로 높게 나타났다.


문제

sepal(꽃받침)의 폭과 길이
petal(꽃잎)의 폭과 길이를 가지고
품종(species)을 분류(예측)

문제 정의

Y : species (3종 : setosa, versicolor, virginica)

X : petal_length
petal_width
sepal_length
sepal_width



Training / test data

Features				Labels
Sepal length	Sepal width	Petal length	Petal width	Species
5.1	3.5	1.4	0.2	Iris setosa
4.9	3.0	1.4	0.2	Iris setosa
7.0	3.2	4.7	1.4	Iris versicolor
6.4	3.2	4.5	1.5	Iris versicolor
6.3	3.3	6.0	2.5	Iris virginica
5.8	3.3	6.0	2.5	Iris virginica

iris setosa



petal sepal

iris versicolor



petal sepal

iris virginica




petal sepal

[실습 2] 예측에 활용

개발한 모델을 활용하여, 꽃잎과 꽃받침의 데이터만 측정하여 품종 예측하기

파일 : IRIS예측



Test and Score - Orange

☐ Cross validation
 Number of folds: 2
☒ Stratified

☐ Cross validation by feature

☐ Random sampling
 Repeat train/test: 10
 Training set size: 70 %
☒ Stratified

☐ Leave one out

☐ Test on train data

☒ Test on test data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Precision	Recall
SVM	1.000	0.978	0.978	0.979	0.978
Random Forest	0.998	0.978	0.978	0.979	0.978

Compare models by: Area under ROC curve ☐ Negligible

Random Forest와 SVM의 예측 결과 확인

File (1) - Orange

Source
☒ File: IRIS예측.xlsx
☐ URL:
 File Type
 Automatically detect type

Info
 3 Instance(s)
 4 feature(s) (no missing values)
 Data has no target variable.
 0 meta attribute(s)

Columns (Double click to edit)

Name	Type	Role	Values
1 sepal_length	numeric	feature	
2 sepal_width	numeric	feature	
3 petal_length	numeric	feature	
4 petal_width	numeric	feature	

Reset Apply

Browse documentation datasets

Predictions - Orange

Show probabilities for: Classes known to the model

Restore Original Order

	Random Forest	SVM	sepal_length	sepal_width	petal_length	petal_width
1	0.50 : 0.25 : 0.25 → set...	0.08 : 0.83 : 0.10 → versic...	6.4	2.8	1.9	2.1
2	0.50 : 0.25 : 0.25 → set...	0.30 : 0.32 : 0.37 → setosa	2.5	3.0	2.3	3.3
3	1.00 : 0.00 : 0.00 → set...	0.98 : 0.01 : 0.01 → setosa	4.7	3.2	1.3	0.2

[참고] 하이퍼 파라미터 Hyper-Parameter

Random Forest - Orange

Name: Random Forest

Basic Properties

Number of trees: 10

☐ Number of attributes considered at each split: 5

☐ Replicable training

☐ Balance class distribution

Growth Control

☐ Limit depth of individual trees: 3

☒ Do not split subsets smaller than: 5

☒ Apply Automatically



Test and Score - Orange

☐ Cross validation
Number of folds: 5
☒ Stratified

☐ Cross validation by feature

☐ Random sampling
Repeat train/test: 10
Training set size: 70 %
☒ Stratified

☐ Leave one out

☒ Test on train data

☐ Test on test data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Precision	Recall
kNN	0.996	0.971	0.971	0.972	0.971
SVM	0.998	0.962	0.962	0.963	0.962
Random Forest	1.000	0.981	0.981	0.982	0.981
Gradient Boosting	1.000	1.000	1.000	1.000	1.000

Compare models by: Area under ROC curve ☐ Negligible diff.: 0.1

	kNN	SVM	Random Forest	Gradient Boosting
kNN				
SVM				
Random Forest				
Gradient Boosting				

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Random Forest에서
Tree의 개수를 달리하면
성능이 달라진다

Random Forest - Orange

Name: Random Forest

Basic Properties

Number of trees: 25

☐ Number of attributes considered at each split: 5

☐ Replicable training

☐ Balance class distribution

Growth Control

☐ Limit depth of individual trees: 3

☒ Do not split subsets smaller than: 5

☒ Apply Automatically



Test and Score - Orange

☐ Cross validation
Number of folds: 5
☒ Stratified

☐ Cross validation by feature

☐ Random sampling
Repeat train/test: 10
Training set size: 70 %
☒ Stratified

☐ Leave one out

☒ Test on train data

☐ Test on test data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Precision	Recall
kNN	0.996	0.971	0.971	0.972	0.971
SVM	0.998	0.962	0.962	0.963	0.962
Random Forest	0.999	0.962	0.962	0.963	0.962
Gradient Boosting	1.000	1.000	1.000	1.000	1.000

Compare models by: Area under ROC curve ☐ Negligible diff.: 0.1

	kNN	SVM	Random Forest	Gradient Boosting
kNN				
SVM				
Random Forest				
Gradient Boosting				

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

[참고] 하이퍼 파라미터 Hyper-Parameter

하이퍼 파라미터(Hyper parameter)는 초매개변수로 번역됩니다.

하이퍼 파라미터는 Data에 의해서 계산되는 것이 아니라, 분석하는 사람이 결정하는, 모델 외적 요소입니다.

하이퍼 파라미터는...


- 모델의 파라미터를 추정하기 위해 알고리즘 구현 과정에서 사용합니다.
- 알고리즘 사용자가 모델링할 때 직접 세팅해 주는 값입니다.
- 정해진 최적의 값이 없습니다.

휴리스틱한 방법이나 경험 법칙(rules of thumb)에 의해 결정하는 경우가 많습니다.

대표적인 하이퍼 파라미터는 다음과 같은 것들입니다.

- 인공신경망에서 learning rate, batch size, epoch
- kNN에서 k값
- Random Forest에서 number of tree...

나무를 몇 그루 심어서
숲을 만들 것인가?



하이퍼 파라미터를 어떻게 잘 세팅하는가에 따라 모델의 성능이 달라집니다.

그래서 하이퍼 파라미터 세팅 실력이 모델링 실력과 비례한다고 합니다.

일반적으로 알고리즘 라이브러리가 제공하는 default 값을 사용하여 초기 모델링을 하고, 그 후에 미세 조정을 합니다.

요즘은 베이지안 오토 엠엘(Auto-ML)과 같이 자동으로 하이퍼 파라미터를 선택해주는 알고리즘을 사용하기도 합니다.

고객도
모르는
고객을
알자



생각을 모으자. 행동을 바꾸자
REINVENT
LG전자

배운다
배운 걸
지우고
다시 배운다



생각을 모으자. 행동을 바꾸자
REINVENT
LG전자