



5. 회귀분석 (Regression Analysis)

분류 Classification 와 회귀 Regression


주어진 점(point, 데이터)들로부터
Input X를 정해진 범주로
분류하는 함수를 찾는 것




주어진 점(point, 데이터)들로부터
Input X와 output Y 사이의
관계식(함수)을 찾는 것




머신러닝 Machine Learning



프랜시스 골턴 경 Sir Francis Galton	
FRS ⁽¹⁾ FRAI ⁽²⁾	
	
국적	 영국
출생	1822년 2월 16일  잉글랜드, 웨스트 미들랜즈, 버밍엄
사망	1911년 1월 17일 (향년 88세)  잉글랜드, 서리, 하슬미어
연구분야	인류학, 기상학, 유전학, 통계학, 심리학, 사회학, 지리학
소속	기상위원회 (Meteorological Council) 왕립지리학회 (Royal Geographical Society)

회귀 回歸, regress의 원래 의미는 옛날 상태로 돌아가는 것을 의미.
영국의 유전학자 프랜시스 골턴은 부모의 키와 아이들의 키 사이의 연관 관계를 연구하면서 부모와 자녀의 키 사이에는 **선형적인 관계**가 있고, 키가 커지거나 작아지는 것보다는 **전체 평균으로 돌아가려는 경향**이 있다는 가설을 세웠으며, 이를 분석하는 방법을 "회귀분석"이라고 하였다. 이러한 경험적 연구 이후, 칼 피어슨은 아버지와 아들의 키 Data로 함수 관계를 도출하여 회귀분석 이론을 수학적으로 정립하였다. (위키백과)

키가 큰 아버지의 아이들은 아버지 보다는 키가 작으나, 전체 평균보다는 크고.
키가 작은 아버지의 아이들은 아버지 보다는 키가 크나 전체 평균보다는 작다.
➔ **평균으로 회귀**



회귀분석이란?

Y가 연속형 변수인 경우, 원인 변수 X들과의 함수 관계를 찾는 것

하나, 연속된 값
(예)길이, 무게, 온도, 시간, 금액...

$$y = f(X's)$$

한 개 혹은 여러 개
연속형 + 범주형

머신러닝 알고리즘

➤ 통계 기반

- Simple Linear Regression
- Multiple Linear Regression
- General Linear Model
- Regularized Linear Regression
- Generalized Addictive Models
- Regression Tree
- Principle Component Regression
- Partial Least Square
- polynomial regression
- step function / basis function
- regression splines
- smoothing splines
- Local Regression
- Support Vector Machine







➤ 정보 기반

- Regression Tree
- Random Forest
- Gradient Boosting...

➤ 인공지능망


- Deep Learning

[예시] 회귀분석




$$\text{오차의 크기} = \sum (y_i - \hat{y}_i)^2$$

실제 관측값 회귀함수로 추정한 값



오차가 크다.
모형이 단순하다.




오차가 작다.
모형이 복잡하다.

분산-편향 트레이드 오프

모형이 복잡할 수록


모형을 만들 때는 잘 들어맞는 것 같으나, 실사용 환경에서는 예측력이 떨어지는 경향이 있다.



같은 성능이면....


Simple is Best

성능은 반드시 모형을 만들 때
사용하지 않은 데이터로 평가




모형의 성능 평가

성능은 반드시 모형을 만들 때 사용하지 않은 데이터로 평가



✓ [예시] 예측 모델의 성능 평가를 위한 데이터 셋 구성



✓ ① 설명력(기여율) : R^2

$$R^2 = 1 - \frac{SS_{RES}}{SS_{TOT}} = 1 - \frac{\sum_i (\overset{\text{실제값}}{y_i} - \overset{\text{예측값}}{\hat{y}_i})^2}{\sum_i (\underset{\text{y값 평균}}{y_i} - \bar{y})^2}$$

② 평균제곱예측오차
MSE(mean squared error)

$$MSE = \frac{1}{N} \sum_{i=1}^N (\overset{\text{실제값}}{y_i} - \overset{\text{예측값}}{\hat{y}_i})^2$$

③ RMSE
root mean squared error


$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

④ 평균절대예측오차
MAE(mean absolute error)

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|$$

✓ ⑤ 평균절대백분위예측오차 MAPE(mean absolute percentage prediction error)

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{\overset{\text{실제값}}{y_i} - \overset{\text{예측값}}{\hat{f}(x_i)}}{y_i} \right|$$



✓ **MAPE** 평균절대백분위예측오차는 **백분율(%)**로 표현되므로, 직관적이라는 장점이 있습니다.

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{\overset{\text{실제값}}{y_i} - \overset{\text{예측값}}{\hat{f}(x_i)}}{y_i} \right|$$

실제값 10, 예측값 20이면,

$$MAPE = (20-10) / 10 = 100\%$$

실제값 20, 예측값 10이면,

$$MAPE = (20-10) / 20 = 50\%$$

전체 MAPE

평균값 = 75%

회귀모형의 성능지표

✓ 「1-MAPE 평균절대백분위예측오차」를 예측정확도라고 표현하고, 활용하는 경우 백분율(%)로 표현되므로, 직관적이라는 장점이 있습니다만....

[예시] 판매량 예측 문제

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{f}(x_i)}{y_i} \right|$$

$$R^2 = 1 - \frac{SS_{RES}}{SS_{TOT}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

① 과다 예측 항상 예측량이 많은 경우

구분	1월	2월	3월	4월	평균	계
예측값	110	100	110	100	105	420
실제값	100	90	100	90	95	380
오차	10	10	10	10	10	0
오차율	10.0%	11.1%	10.0%	11.1%	10.6%	

예측한 만큼 생산을 하면,
고객 수요가 부족하여, 재고 발생

1- MAPE = 89.4%

실제 값이 클수록 오차율이 적게 나타남

$$R^2 = 1 - \frac{400}{100} = 0 \%$$

② 과소 예측 항상 예측량이 적은 경우

구분	1월	2월	3월	4월	평균	계
예측값	100	90	100	90	95	380
실제값	110	100	110	100	105	420
오차	10	10	10	10	10	40
오차율	9.1%	10.0%	9.1%	10.0%	9.5%	

예측한 만큼 생산을 하면,
고객 수요가 많아서, Back Order 발생

1- MAPE = 90.5%

과다 예측보다 성능이 우수한 것으로 나타남

$$R^2 = 1 - \frac{400}{100} = 0 \%$$

회귀모형의 성능지표

✓ 「1-MAPE 평균절대백분위예측오차」를 예측정확도라고 표현하고, 활용하는 경우 백분율(%)로 표현되므로, 직관적이라는 장점이 있습니다만....

[예시] 판매량 예측 문제

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{f}(x_i)}{y_i} \right|$$

$$R^2 = 1 - \frac{SS_{RES}}{SS_{TOT}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$

실제값 예측값
y값 평균

③ 균형 예측 1 과다예측과 과소예측이 번갈아 발생

구분	1월	2월	3월	4월	평균	계
예측값	100	110	100	110	105	420
실제값	110	100	110	100	105	420
오차	10	10	10	10	10	0
오차율	9.1%	10.0%	9.1%	10.0%	9.5%	

예측한 만큼 생산을 하면,
시간이 지나면서 수요 공급이 일치

$$1 - MAPE = 90.5\%$$

$$R^2 = 1 - \frac{400}{100} = 0\%$$

③ 균형 예측 2 과다예측과 과소예측이 번갈아 발생

구분	1월	2월	3월	4월	평균	계
예측값	100	90	100	90	95	380
실제값	90	100	90	100	95	380
오차	10	10	10	10	10	0
오차율	11.1%	10.0%	11.1%	10.0%	10.6%	

$$1 - MAPE = 89.4\%$$

$$R^2 = 1 - \frac{400}{100} = 0\%$$

실제 값이 작으면, 오차율이 크게 나타남

회귀모형의 성능지표

✓ 「1-MAPE 평균절대백분위예측오차」를 예측정확도라고 표현하고, 활용하는 경우

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{\overset{\text{실제값}}{y_i} - \overset{\text{예측값}}{\hat{f}(x_i)}}{\underset{\text{실제값}}{y_i}} \right|$$

같은 크기의 오차가 발생하더라도
실제 값이 크면 오차율이 적어진다.
즉, 과소 예측이 유리 (Back order)

$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{\overset{\text{실제값}}{y_i} - \overset{\text{예측값}}{\hat{f}(x_i)}}{\underset{\text{예측값}}{\hat{f}(x_i)}} \right|$$


같은 크기의 오차가 발생하더라도
예측 값이 크면 오차율이 적어진다.
즉, 과다 예측이 유리 (재고)

회귀모형의 성능지표


✓ 설명력(기여율, 결정계수) : R^2

“ Test R^2 , Not Training R^2 ”

$$R^2 = 1 - \frac{SS_{RES}}{SS_{TOT}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$$




- 0 ~ 1 (0%~100%) 사이의 값을 가진다.
- 1에 가까울 수록 좋은 회귀모형이 구해졌다는 의미



- 절대적인 판정기준은 없으나, 일반적으로....
 - 70% 이상이면 괜찮은 모형
 - 80% 이상이면 우수한 모형
 - 90% 이상이면 탁월한 모형으로 본다.
- ➔ 80% 이상을 추구한다.

✓ 회귀모형의 성능이 낮게 나오는 경우...

① 모형 선택이 잘못된 경우



② 중요한 인자(X, 독립변수)가 누락된 경우

(예) $Y = a + bX_1$	$\longrightarrow$	$R^2 = 50.0\%$
$Y = a + bX_1 + cX_2$	$\longrightarrow$	$R^2 = 70.0\%$
$Y = a + bX_1 + cX_2 + dX_3$	$\longrightarrow$	$R^2 = 70.1\%$


인자 수가 늘어날 수록
모형의 설명력은 커진다.
그러나 인자 수가 늘어나면,
데이터를 더 많이 수집해야 하고,
모형이 복잡해서 해석하기 어렵다.

회귀모형의 성능지표

✓ 회귀모형의 성능이 낮게 나오는 경우...

③ Data Size와 품질 문제

특히, 이상치,
서로 다른 집단의 혼합 등
품질 문제 확인 필요



R^2 가 높아도 문제를 발생시키는 다중공선성

아들의 키 = f (아버지의 키, 몸무게)
아들의 키를 아버지의 키와 몸무게로 예측하고자 할 때, 아버지의 키와 몸무게는 상관성이 높을 것입니다.


이와 같이
독립변수들간의 상관관계가 매우 높을 때, 하나의 독립변수의 변화가 다른 독립변수에 영향을 미쳐, 결과적으로 예측모델의 안정성이 크게 떨어지는 현상을 말합니다.

특히, 설명(예측)문제에는 심각한 영향을 미쳐서, 어떤 인자가 더 중요한지 확인하기 어렵게 됩니다.

예측 문제에서도 오버피팅을 유발할 수 있으므로, 모형 개발 시에는 큰 문제를 느끼지 못할 수 있으나, 실무 적용 시에는 예측력에 문제를 일으킬 수 있습니다.

④ 하이퍼 파라미터 최적화 문제

이 점들을 모델링 해봅시다



통계적 회귀모형


상수(절편)

$$Y = aX + b \text{ (Linear fit)}$$


계수(기울기)



$$Y = aE^{bx} \text{ (Exponential fit)}$$



$$Y = aX^b \text{ (Power fit)}$$




통계적 회귀모형

$$Y = aE^{bx} \xrightarrow{\text{log 변환}} \log Y = \overset{\text{상수(절편)}}{\log a} + \overset{\text{계수(기울기)}}{b} X$$

$$Y = aX^b \xrightarrow{\text{log 변환}} \log Y = \log a + b \log X$$

단순 선형 회귀

$$\bullet Y = \overset{\text{계수(기울기)}}{a} X + \overset{\text{상수(절편)}}{b} \text{ (Linear fit)}$$



다중 선형 회귀 (Multiple linear regression)

Y를 여러 개의 X들의 선형조합으로 표현하는 식을 도출하는 것

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon$$


intercept
(절편)

coefficients
(계수)

error (오차)

[예시] 집 가격 예측 모형

학군	방의개수	거리	가격
1	1	1분	\$
4	5	20분	\$
8	3	15분	\$
8	2	9분	\$
6	4	30분	\$
4	3	17분	\$
3	6	21분	\$







➔ Random Forest 등 앙상블 모형으로 예측 정확도를 높일 수 있다.

[실습 및 검토] $Y=f(X)$ vs. $X=f(Y)$

Data file : 회귀실습1

X	y
1	1
2	3
3	2
4	6




3 회귀계수 확인

	name	coef
1	Intercept	-0.5
2	x	1.4

회귀식

$$Y = -0.5 + 0.14X$$

회귀식



2

Test and Score (1) - Orange

☐ Cross validation

Number of folds: 2

☒ Stratified

☐ Cross validation by feature

☐ Random sampling

Repeat train/test: 10

Training set size: 70 %

☒ Stratified

☐ Leave one out

☒ Test on train data

Model	MSE	RMSE	MAE	R2
Linear Regression (1)	0.375	0.612	0.500	0.700

Compare models by: Mean square error

3

	name	coef
1	Intercept	1
2	y	0.5

[실습 및 검토] $Y=f(X)$ vs. $X=f(Y)$

Data-set

x	y
1	1
2	3
3	2
4	6

Y를 target으로 설정한 경우

Model	MSE	RMSE	MAE	R2
Linear Regression	1.050	1.025	0.850	0.700

$$Y = -0.5 + 0.14X$$

X를 target으로 설정한 경우

Model	MSE	RMSE	MAE	R2
Linear Regression (1)	0.375	0.612	0.500	0.700

$$X = 1 + 0.5Y$$

↓
될까?


----- 다르다!!! -----

$$Y = 2 + 0.5X$$


- **Y(결과, target)와 X(원인, feature)를 올바르게 설정 !!!**
- **$Y=f(X)$ 를 구하고, $X=f(Y)$ 로 사용하는 것은 오류 !!!**

$Y=f(X)$ vs. $X=f(Y)$

$Y=f(X)$ 를 구하고, $X=f(Y)$ 로 사용하는 것은 오류 !!!



Y의 목표 범위가 1~3이므로
X를 1~3의 범위로 관리한다.




X가 3이면, Y는 95%의 확률로
2에서 4 사이의 값을 가진다.


X를 1~3의 범위로 관리하면,
Y는 0~4 사이에 위치한다.

$Y=f(X)$ vs. $X=f(Y)$

X와 Y의 구분이 만만하지 않은 경우가 많다.



범죄가 많아지니
동네 집 값이 내린다.



집 값이 급격히 하락하면서
범죄가 많은 슬럼가가 되었다.

(행복해서 많이 웃는다 vs. 많이 웃으면 행복해진다)

[실습] 보스턴 집 값 예측

<https://www.kaggle.com/c/boston-housing>

파일명


bostonHousePrice.xlsx

변수명	설명
CRIM	도시(town) 별 1인당 범죄 비율
ZN	25,000 평방 피트를 초과하는 거주지역의 비율
INDUS	비소매상업지역이 점유하고 있는 토지의 비율
CHAS	찰스강과의 가까움 여부(강의 경계에 위치한 경우는 1, 아니면 0)
NOX	10ppm 당 농축 일산화질소
RM	주택 1가구당 평균 방의 개수
AGE	1940년 이전에 건축된 소유주택의 비율
DIS	5개의 보스턴 직업센터까지의 접근성 지수
RAD	방사형 도로까지의 접근성 지수
TAX	10,000 달러 당 재산세율
PTRATIO	도시(town)별 학생/교사 비율
B	$1000(Bk-0.63)^2$, 여기서 Bk는 자치시별 흑인의 비율을 말함.
LSTAT	모집단의 하위계층의 비율(%)
MEDV	본인 소유의 주택가격(중앙값) (단위: \$1,000)

X

Y

[실습] 보스턴 집 값 예측



2 Data 확인

Info	
506 instances (no missing data)	
14 features	
No target variable.	
No meta attributes	
Variables	
☒ Show variable labels (if present)	
☐ Visualize numeric values	
☒ Color by instance classes	
Selection	
☒ Select full rows	

	CRIM	ZN
1	0.00632	18.0
2	0.02731	0.0
3	0.02729	0.0
4	0.03237	0.0
5	0.06905	0.0
6	0.02985	0.0
7	0.08829	12.5
8	0.14455	12.5
9	0.21124	12.5
10	0.17004	12.5
11	0.22489	12.5
12	0.11747	12.5

3 Error

1 Data Loading

File - Orange

Source

☒ File: bostonHousePrice.csv

File Type

Automatically detect type

Info

506 instance(s)
14 feature(s) (no missing values)
Data has no target variable,
0 meta attribute(s)

Columns (Double click to edit)

	Name	Type	Role	Values
8	DIS	numeric	feature	
9	RAD	numeric	feature	
10	TAX	numeric	feature	
11	PTATIO	numeric	feature	
12	B	numeric	feature	
13	LSTAT	numeric	feature	
14	MEDV	numeric	feature	

Reset Apply

Browse documentation datasets

506

Test and Score - Orange

☐ Cross validation

Number of folds: 2

☒ Stratified

☐ Cross validation by feature

☐ Random sampling

Repeat train/test: 10

Training set size: 70 %

☒ Stratified

☐ Leave one out

☐ Test on train data

☒ Test on test data

Evaluation results for target

Model

Compare models by:




Negligible diff.: 0.1

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

Target 지정이 안됨


Train data input requires a target variable

[실습] 보스턴 집 값 예측

**2 Training용과 Test용 데이터 구분 지정****3 성능 확인**

[실습] 보스턴 집 값 예측

내가 사고 싶은 집 값 예측



내가사고싶은집.xlsx

1

Predictions - Orange

Restore Original Order

	Linear Regression	Random Forest	SVM	CRIM	ZN
1	21.0	21.0	2...	0.0001	0

2

Data Table (1) - Orange

Info

1 instances
14 features (7.1 % missing data)
No target variable.
3 meta attributes

Variables

☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes


Selection

☒ Select full rows

	Linear Regression	Random Forest	SVM
1	20.9599	21.0201	22.0107

[생각해 보기] 예측

[질문] 보스톤 집 값 예측 사례에서,
예측된 집 값은 현재의 가격인가 6개월 후의 가격인가?



고객도
모르는
고객을
알자



생각을 모으자. 행동을 바꾸자
REINVENT
LG전자

배운다
배운 걸
지우고
다시 배운다



생각을 모으자. 행동을 바꾸자
REINVENT
LG전자