

6. 주성분 분석 (Principal Component Analysis)

다변량 분석 vs. 단변량 분석

다변량분석(Multivariate analysis)이란

여러 현상이나 사건에 대한 측정치를 개별적으로 분석하지 않고
동시에 한번에 분석하는 통계적 기법을 말한다.

즉 여러 변량들 간의 관계성을 동시에 고려해 그 효과를 밝히는 것이다.

#	X1	X2	X3	X4	Xn	Y1	Y2	Y3	Y4
#1									
#2									
#3									

다변량 분석의 유형

(1) 변수들간의 인과관계 (causal relationship) :


회귀분석, 분산분석

(2) 변수들간의 상관관계 를 이용하여
데이터의 차원을 축소


: 주성분분석, 요인분석

(3) 개체들의 유사성에 의해 개체를 분류


: 판별분석, 군집분석



주성분 분석과 군집 분석



주성분 분석(Principal Component Analysis, PCA)은 가장 널리 사용되는 차원 축소 기법 중 하나로, 원 데이터의 분포를 최대한 보존하면서 고차원 공간의 데이터들을 저차원 공간으로 변환한다.



주성분의 개수 선택


p개의 변수를 주성분분석을 통해서 p개의 주성분을 생성시킬 수 있다.
 이때, 주성분이 전체 분산에 대한 **기여율**을 고려하여 주성분의 개수를 선택한다.

[예]

4개 변수(X_1, X_2, X_3, X_4)	→	PC1 = $a_{11}X_1 + a_{12}X_2 + a_{13}X_3 + a_{14}X_4$	기여율 60%	누적 기여율 60%
		PC2 = $a_{21}X_1 + a_{22}X_2 + a_{23}X_3 + a_{24}X_4$	30%	90%
		PC3 = $a_{31}X_1 + a_{32}X_2 + a_{33}X_3 + a_{34}X_4$	8%	98%
		PC4 = $a_{41}X_1 + a_{42}X_2 + a_{43}X_3 + a_{44}X_4$	2%	100%

80%
이상을
추천

Scree Plot



<참고>

주성분 적재값 $|a_{ij}| \leq 1$

0에 가까울 수록
중요도가 낮아진다는
의미로 해석할 수 있다.

주성분 분석의 활용 (1)탐색적 분석

변수(feature)를 결합함으로써, 새로운 관점에서 데이터를 탐색할 수 있다.

(예) 학생들의 역량을 확인하기 위하여 수학, 영어, 국어, 과학 4개 과목 시험 실시.
이것을 주성분 분석한 결과가 아래와 같다면....

#	수학	과학	국어	영어	누적 기여율	변수의 재정의
#1					주성분 1 = 0.9 수학 + 0.7 과학 - 0.1 영어 - 0.15 국어 45%	주성분1= 논리영역
#2					주성분 2 = 0.1 수학 - 0.05 과학 + 0.8 영어 + 0.9 국어 85%	주성분1= 언어영역
#3					주성분 3 = 0.08 수학 + 0.17 과학 - 0.07 영어 - 0.05 국어 90%	※ 변수의 재정의는 실무적 관점에서 Domain Knowledge에 근거
#4					주성분 2 = 0.1 수학 - 0.05 과학 + 0.18 영어 + 0.19 국어 100%	
#5						
#n						



주성분 분석의 활용 (2)머신러닝에 활용

머신러닝을 통해 개발한 예측 모형은
기본적으로 변수의 개수 보다 Data Size가 더 커야, 안정적인 성능을 보인다.
만약, Data Size가 변수의 개수보다 적다면, 주성분 분석을 한 후
주성분 결과값을 가지고 머신러닝 알고리즘을 훈련시킨다.

p차원 Data
Data size = n
 $p \gg n$ 인 경우
불안정 모형 개발

주성분 분석

m차원 Data
Data size = n
 $M \ll n$ 으로
안정적 모형 개발




또한 계산 용량의 감축, 해석의 용이성 등을 위해서도
주성분 분석 결과를 활용하여 머신러닝 모형을 개발할 수 있다.

[실습 1] IRIS 데이터를 활용한 주성분 분석 실습


6. 주성분 분석

① <file> 위젯 활성화




② <iris> 데이터 불러오기


여기서 데이터 파일 선택



③ PCA 위젯을 활성화하고, 데이터와 연결



④ Scree Plot 확인



[실습 1] IRIS 데이터를 활용한 주성분 분석 실습

6. 주성분 분석

⑤ PCA 결과 데이터 확인

The screenshot shows the Orange3 interface with a workflow consisting of three widgets: File, PCA, and Data Table. A red arrow points from the Data Table widget to a detailed view of the widget's data table. The data table displays the results of the PCA analysis, including the original features (species, sepal_length, sepal_wid) and the principal components (PC1, PC2).

Data Table - Orange

Info
150 instances (no missing data)
4 features
Target with 3 values
2 meta attributes


Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection
☒ Select full rows

Restore Original Order
☒ Send Automatically

variance	species	PC1 0.729624	PC2 0.228508	sepal_length	sepal_wid
1	setosa	-2.2647	0.480027	5.1	
2	setosa	-2.08096	-0.674134	4.9	
3	setosa	-2.36423	-0.341908	4.7	
4	setosa	-2.29938	-0.597395	4.6	
5	setosa	-2.38984	0.646835	5.0	
6	setosa	-2.07563	1.48918	5.4	
7	setosa	-2.44403	0.0476442	4.6	
8	setosa	-2.23285	0.223148	5.0	
9	setosa	-2.33464	-1.11533	4.4	
10	setosa	-2.18433	-0.469014	4.9	
11	setosa	-2.16631	1.04369	5.4	
12	setosa	-2.32613	0.133078	4.8	
13	setosa	-2.21845	-0.728676	4.8	
14	setosa	-2.6331	-0.961507	4.3	
15	setosa	-2.19874	1.86006	5.8	
16	setosa	-2.26221	2.68628	5.7	
17	setosa	-2.20759	1.48361	5.4	
18	setosa	-2.19035	0.488838	5.1	
19	setosa	-1.89857	1.40502	5.7	
20	setosa	-2.34337	1.12785	5.1	

⑥ 주성분으로 그래프 그려보기



더블 클릭





👉 2개의 주성분으로 분류가 잘 될 것 같음.

[실습 1] IRIS 데이터를 활용한 주성분 분석 실습

6. 주성분 분석

⑦ 주성분 값만 데이터 테이블로 확인



Data Table (1) - Orange

Info
150 instances (no missing data)
2 features
Target with 3 values
No meta attributes

Variables
☒ Show variable labels (if present)
☐ Visualize numeric values
☒ Color by instance classes

Selection
☒ Select full rows

Restore Original Order
☒ Send Automatically

varianr	species	PC1 0.729624	PC2 0.228508
1	setosa	-2.2647	0.480027
2	setosa	-2.08096	-0.674134
3	setosa	-2.36423	-0.341908
4	setosa	-2.29938	-0.597395
5	setosa	-2.38984	0.646835
6	setosa	-2.07563	1.48918
7	setosa	-2.44403	0.0476442
8	setosa	-2.23285	0.223148
9	setosa	-2.33464	-1.11533
10	setosa	-2.18433	-0.469014
11	setosa	-2.16631	1.04369
12	setosa	-2.32613	0.133078
13	setosa	-2.21845	-0.728676
14	setosa	-2.6331	-0.961507
15	setosa	-2.19874	1.86006
16	setosa	-2.26221	2.68628
17	setosa	-2.20759	1.48361
18	setosa	-2.19035	0.488838
19	setosa	-1.89857	1.40502
20	setosa	-2.34337	1.12785
21	setosa	-1.91432	0.408856

[실습 1] IRIS 데이터를 활용한 주성분 분석 실습

6. 주성분 분석

⑦ 주성분 값만 데이터 테이블로 확인

The image shows the Orange3 software interface with a workflow for PCA analysis. The workflow consists of the following steps:

- File** widget connected to **Data**.
- Data** widget connected to **PCA**.
- PCA** widget connected to **Data Table (1)**, **Scatter Plot**, and **Data Table (2)**.
- Scatter Plot** widget connected to **Data Table (1)**.


The **Edit Links - Orange** dialog box is open, showing the connections for the **PCA** widget. The **Data** link is selected, and the **Data Table (2)** widget is chosen as the destination.

The **Data Table (2) - Orange** window displays the following data:

	components	variance	sepal.Length	sepal.width	petal.Length	pe
1	PC1	0.729624	0.521066	-0.269347	0.580413	
2	PC2	0.228508	0.377418	0.923296	0.0244916	

👉 기여율과 각 적재값을 볼 수 있음

⑧ 주성분 분석 결과를 활용한 모형 개발



Test and Score - Orange

☐ Cross validation
Number of folds: 5
☒ Stratified

☐ Cross validation by feature
☒ Selected

☐ Random sampling
Repeat train/test: 10
Training set size: 70 %
☒ Stratified

☐ Leave one out
☒ Test on train data
☐ Test on test data

Evaluation results for target (None, show average over classes)

Model	AUC	CA	F1	Precision	Recall
kNN	0.991	0.947	0.947	0.948	0.947
Random Forest	0.997	0.973	0.973	0.974	0.973

Compare models by: Area under ROC curve ☐ Negligible diff.: 0,1

	kNN	Random Fo...
kNN		
Random Forest		

Table shows probabilities that the score for the model in the row is higher than that of the model in the column. Small numbers show the probability that the difference is negligible.

[실습2] 설문 문항의 개념화

[예시] DX 활동에 대한 사원 의식 조사

[데이터 파일] 주성분분석실습2

주성분 분석을 실행하고, 해석

- A. 회사의 경쟁력 확보와 변화 대응을 위해서 DX가 필요하다고 생각한다.
- B. 우리 회사는 지속적으로 DX활동을 추진해야 한다.
- C. 나는 DX관련 정보나 지식을 기회 닿는 대로 습득하고 있다.
- D. 나는 DX에 대해서 관심이 많다.
- E. 나는 DX활동을 위한 새로운 아이디어를 개발하려고 노력한다.
- F. 나는 DX활동을 위해 외부의 자료나 새로운 방법을 적용한다.
- G. 나는 주위 동료들이 DX활동을 실행할 수 있도록 돕는다.
- H. 나는 동료들이 제안하는 SDX실행 방법을 잘 다듬어 유용하게 활용한다.
- I. 나는 DX활동을 수행하는데 있어 적절한 계획과 일정을 수립한다.
- J. 나는 DX활동을 실행하는데 있어서 필요한 자원을 요청하고 확보한다.
- K. 나는 DX를 잘 활용하고 있다고 생각한다.
- L. 나는 앞으로도 회사에서 추진하는 DX활동에 계속 참여할 것이다.
- M. DX활동으로 인해 스트레스를 받은 적이 있다.
- N. 나는 DX활동으로 인해 좋지 않은 감정을 가지고 있다.
- O. 나는 우리 회사의 DX활동으로 인해 두려움을 종종 느끼는 편이다.
- P. 나는 우리 회사의 DX활동에 대해 상급자에게 이의를 제기하였다.
- Q. 나는 우리 회사의 DX활동에 대해 경영진이나 관리자에게 반대 의견을 제시하였다.
- R. 나는 우리 회사의 DX프로그램에 대해 막아 볼 방안을 찾아 보았다.

리커트 5점 척도

- 1점 : 전혀 그렇지 않다.
- 2점 : 그렇지 않다.
- 3점 : 보통이다.
- 4점 : 그렇다.
- 5점 : 완전히 그렇다.



[실습2] 설문 문항의 개념화

실습파일 : 주성분분석실습2

File

CSV File Import

Datasets

SQL Table

Data Table

Paint Data

Data Info

Rank

File

Data

PCA

Data Table

Transformed Data

Data

Components

PCA

Clear All

OK

Cancel

File - Orange

Source

File: 주성분분석실습2.xlsx

Sheet: raw data

URL:

File Type

Automatically detect type

Info

243 instance(s)

19 feature(s) (no missing values)

Data has no target variable

0 meta attribute(s)

Columns (Double click to edit)

Name	Type	Role	Values
1 no	numeric	skip	
2 A	numeric	feature	
3 B	numeric	feature	
4 C	numeric	feature	
5 D	numeric	feature	
6 E	numeric	feature	

Reset

Apply

Browse documentation datasets

243

components variance A B C D E F G H I J K L M N

1 PC1	0.510559	-0.248291	-0.266054	-0.274876	-0.260090	-0.281198	-0.274306	-0.272162	-0.276108	-0.267048	-0.267698	-0.275958	-0.28505	0.105502	0.188511
2 PC2	0.152513	-0.00048428	-0.0345328	0.0524948	0.0379121	0.134983	0.140961	0.122085	0.143621	0.0981896	0.127252	0.102589	0.0060208	0.174588	0.285384
3 PC3	0.060593	-0.183382	-0.180245	-0.00020418	-0.0734807	0.0307859	0.0404385	-0.009452	-0.0414814	-0.0173711	-0.0402458	0.0086705	-0.00354816	-0.073448	-0.334918

어떻게 해석할 것인가?

[실습3] 22년 프로야구 정기리그 데이터

6. 주성분 분석

실습파일 : 주성분분석실습3_프로야구팀data

www.koreanbaseball.com에서
Data 추출

선수기록

팀기록

기록용어 ?

타자

투수

수비

주루

2022

KBO 정규시즌

팀기록(타자)

기록보기

순위	팀명	AVG	G	PA	AB	R	H	2B	3B	HR	TB	RBI	SAC	SF
1	KIA	0.272	144	5703	5000	720	1361	250	19	113	1988	677	61	36
2	삼성	0.270	144	5647	5023	663	1358	241	19	103	1946	627	83	41
3	LG	0.269	144	5627	4927	715	1325	208	33	118	1953	674	49	46
4	롯데	0.267	144	5534	4948	605	1320	227	16	106	1897	570	73	42
5	NC	0.257	144	5585	4899	646	1260	230	15	105	1835	613	50	47
6	두산	0.255	144	5510	4891	638	1249	210	12	101	1786	592	53	45
7	SSG	0.254	144	5642	4893	720	1245	242	18	138	1937	682	77	47
8	KT	0.254	144	5547	4864	631	1237	192	19	119	1824	588	70	44
9	키움	0.252	144	5655	4953	621	1250	203	33	94	1801	578	49	34
10	한화	0.245	144	5513	4878	564	1196	217	19	88	1715	520	45	40
합계		0.260	720	55963	49276	6523	12801	2220	203	1085	18682	6121	610	422

[생각해 보기] 머니볼

오클랜드 어슬레틱스 (스몰 마켓 구단)

2001년 구단 운영 금액 400억원

vs.

뉴욕 양키즈 (빅 마켓 구단)

1145억원

믿음


- 타율, 타점, 홈런이 많은 선수는 비싸지만...승리의 보증 수표다.
- 번트, 도루, 히트 앤드 런 등 작전으로 승리한다.

Data

머니볼의 성공

“야구를 이기게 하는 중요한 통계가 뭔지 찾아내고, 거기에 집중 투자”

1. 저평가 받는 출루율, 장타율 등의 통계를 중시한다.
2. 지나치게 고평가된 수비나 주루는 과감히 배제한다.
3. 유망주의 가치는 지나치게 저평가 되어 있다.
스타 플레이어를 팔아서 좋은 유망주를 얻을 수 있으면 과감히 판매한다.
4. 5툴 선수의 가치가 지나치게 고평가 되어 있기 때문에
5툴이 아니라도 확실한 툴이 있으면 그 선수를 싸게 영입한다.
5. 잠재력 있는 고졸 선수의 가치가 고평가 되어 있기 때문에
상대적으로 잠재력은 낮아도 현재 능력이 좋은 대졸 선수를 드래프트한다.
6. 이전까지 기본적인 통계 활용에 그쳤던 것에서 벗어나
세이버메트릭스를 구단 운영에 도입한다.




세이버메트릭스(Sabermetrics)는 1971년 8월 밥 데이비스가 창시한 SABR(The Society for American Baseball Research)라는 모임에서 만들어진, 야구를 통계학적/수학적으로 분석하는 방법론이다.

Data 분석 절차와 DX 과제

목적

- ✓ 과제는 정한 시간이 되어서 끝나는 것이 아니라, 목적을 달성하고 종료된다.
- ✓ 모든 과제가 예측모델을 개발해야 하는 것은 아니며,
따라서 과제의 실행 절차는 과제의 목적에 따라 서로 다를 수 밖에 없다.



고객도
모르는
고객을
알자



생각을 모으자. 행동을 바꾸자
REINVENT
LG전자

배운다
배운 걸
지우고
다시 배운다



생각을 모으자. 행동을 바꾸자
REINVENT
LG전자