


7. 군집분석 (Clustering Analysis)

군집분석



지도학습 vs. 비지도 학습

고객 ID	성별	나이	소득	...	고객분류(Y)
#1	남	27	200	...	단골고객
#2	여	46	300	...	일반고객
#3	여	18	30	...	경쟁사 고객
#4					
#5					

머신러닝 학습
분류함수 $Y=f(X)$

이런 특징을 가진 사람은?

고객 ID	성별	나이	소득	...
New #1	남	21	120	
New #2	여	35	180	

New #1 = 단골고객으로 **예측**

New #2 = 일반고객으로 **예측**

고객 ID	성별	나이	소득	...
#1	남	27	200	...
#2	여	46	300	...
#3	여	18	30	...
#4				
#5				

머신러닝 학습
유사성 기반 군집화
(군집 #1, #2) = $f(X)$

이런 특징을 가진 사람은?

고객 ID	성별	나이	소득	...
New #1	남	21	120	
New #2	여	35	180	

New #1 = 군집 1로 **예측**

New #2 = 군집 2로 **예측**


유사성 Similarity = 거리 Distance

거리가 가까우면 유사하고, 거리가 멀면 유사하지 않다.

Data-set

#	X1	X2
#1	X11	X21
#2	X12	X22

[예] #1 관측값과 #2 관측값의 유사성




✓ ① 유클리드 거리 Euclidean Distance

$$= \sqrt{(X11-X12)^2 + (X21-X22)^2}$$

② 맨하탄 거리 Manhattan Distance

$$= |X11-X12| + |X21-X22|$$

③ 마할라노비스 거리 Mahalanobis distance




$$d(x, y) = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}$$

where $x = (x_1, x_2, \dots, x_n)$, $y = (y_1, y_2, \dots, y_n)$

$$\Sigma = \begin{pmatrix} \text{Cov}(X_1, X_1) & \cdots & \text{Cov}(X_1, X_n) \\ \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \cdots & \text{Cov}(X_n, X_n) \end{pmatrix}$$

유사성 Similarity = 각도



$$\text{sim}(x, y) = \frac{\langle x, y \rangle}{\|x\| \|y\|}$$

where $x = (x_1, x_2, \dots, x_n), y = (y_1, y_2, \dots, y_n)$

$$\|x\| = \sqrt{\sum_{i=1}^n (x_i)^2}, \langle x, y \rangle = \sum_{i=1}^n x_i y_i$$

- 벡터의 크기에 영향을 받지 않는다.
- -1~ 1의 값을 가진다.
- 1에 가까울 수록 더 유사하다.

[참고] 범주형 자료의 유사성 척도

범주형 자료(이분형, 서열형, 명목형)의 유사성 척도
(Similarity Measures for Categorical Data)이분형 변수
(binary variable)

	x_j	
	1	0
x_i	1	a
	0	c

- Hamming distance (Simple Matching)

$$\text{dist}(x_i, x_j) = \frac{1}{p} \sum_{k=1}^p \text{dist}(X_{ki}, X_{kj}) = \frac{b+c}{a+b+c+d}$$

- Jaccard Co-efficient (Asymmetric Binary Attributes)

$$\text{dist}(x_i, x_j) = \frac{b+c}{a+b+c} \Rightarrow \text{sim}(x_i, x_j) = \frac{a}{a+b+c}$$

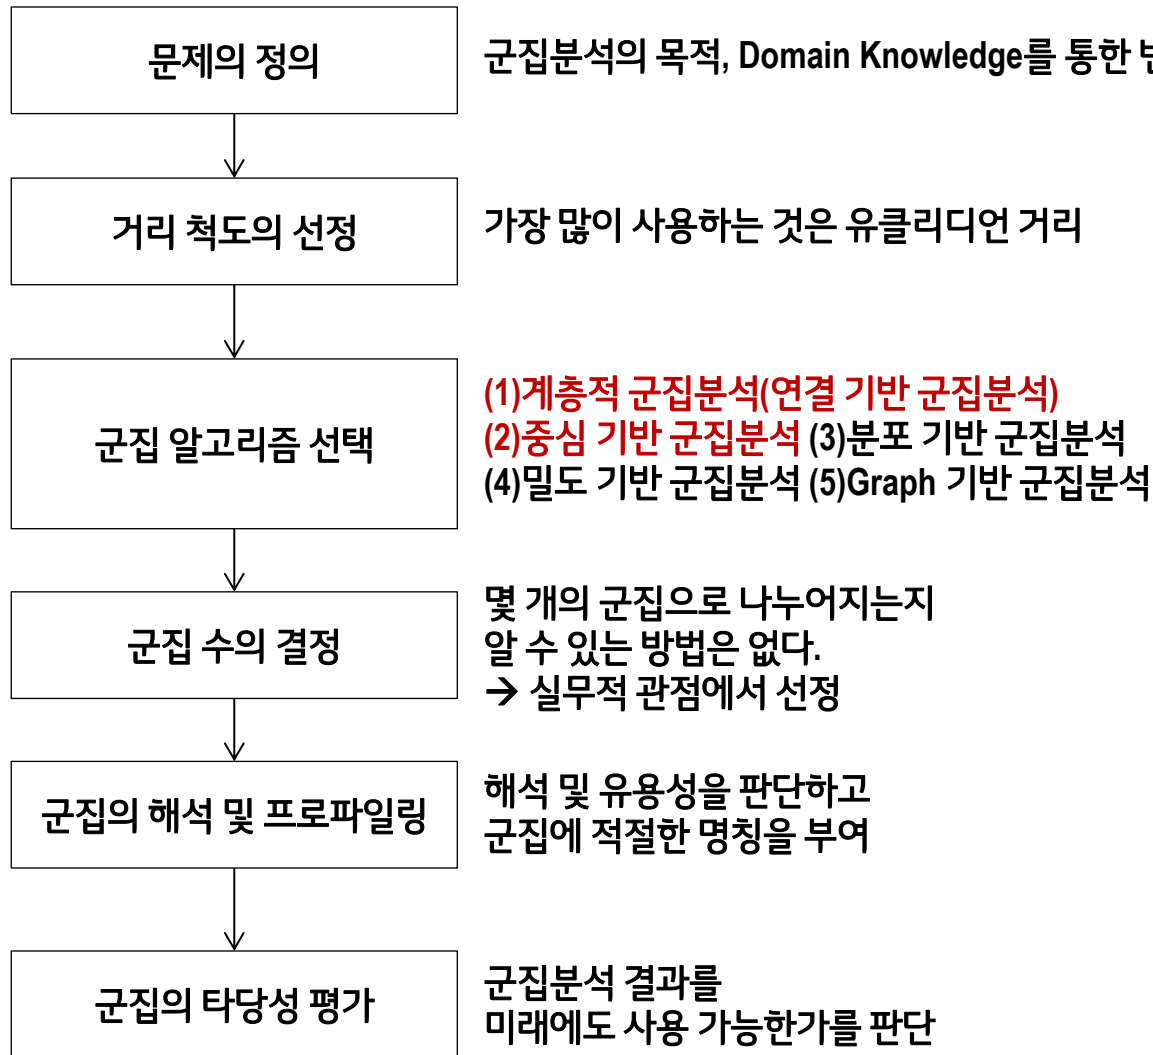
서열형 변수
(ordinal variable)객체의 k 번째 변수가 서열형이고 $1, 2, \dots, M_k$ 중 한 값을 갖는다고 할 때,

$$\text{dist}(x_i, x_j) = \sum_{k=1}^p \text{dist}(X_{ki}, X_{kj}) = \sum_{k=1}^p \frac{|X_{ki} - X_{kj}|}{M_k - 1} \Rightarrow \text{sim}(X_{ki}, X_{kj}) = 1 - \text{dist}(X_{ki}, X_{kj})$$

명목형 변수
(nominal variable)두 객체에 대한 k 번째 변수가 명목형인 경우,


$$\text{sim}(X_{ki}, X_{kj}) = \begin{cases} 1 & \text{if } X_{ki} = X_{kj} \\ 0 & \text{if } X_{ki} \neq X_{kj} \end{cases}$$

군집분석의 절차



1. 대용량 처리 가능성
2. 고차원 자료 처리 가능성
3. 연속형, 범주형 자료 동시 처리 가능성
4. 임의의 형태를 가지는 군집을 식별할 수 있는 능력
5. 잡음이나 이상치에 대한 강건성
6. 입력 자료의 순서에 영향을 받지 않는 알고리즘
7. 입력 자료의 배경 지식에 대한 의존성이 낮은 것
8. 사용자의 제약조건을 반영할 수 있는 능력
9. 해석 및 사용 용이성

동일한 자료로도 다양한 군집 분석 가능



군집분석을 하는 목적이
무엇인가를 기준으로 선택.
즉, 군집분석은
상당히 주관적이다.

군집 방법 ① 계층적 군집분석

7. 군집분석

계층적 군집분석은 가장 오래된 군집분석 방법이지만 아직도 유용하게 활용.


- (1) 집괴법(Agglomerative method : bottom-up)
- (2) 분할법(Divisive Method : top-down)

Data-set


#	X1	X2
#1	X11	X21
#2	X12	X22
#3	X13	X23
#4	X14	X24

- ① 4개 원소간의 거리를 모두 구해서 비교한다.
- ② 가장 가까운 2개를 grouping
예, #1과 #2가 상대적으로 가장 가까웠다면
이것이 하나의 집단이 됨.
- ③ 위에서 만든 집단과 나머지 두 개의 원소 간의
거리를 모두 구해서 비교한다.
이때, 집단과의 연결 방법은 오른쪽 참조
- ④ 가장 가까운 2개를 grouping
예, #1과 #2가 묶인 집단과 #4가
상대적으로 가장 가까웠다면...

연결 방법




덴드로그램



군집 방법 ① 계층적 군집분석

7. 군집분석

계층적 군집분석은 결과를 덴드로그램으로 표현해주므로 이해하기 쉽고, 군집간의 크기가 달라도 적용가능한 장점이 있습니다.




계층적 군집분석의 단점은...

1. 데이터가 클 수록 계산 횟수가 급격히 증가한다.
2. 이상치가 존재하는 경우, 생성된 군집의 질에 문제 있다.
3. 군집의 분할 및 병합은 비가역적이다.
4. 안정성이 낮다. 즉, 데이터를 재정렬하거나 일부 데이터를 제거할 경우 완전히 다른 결과가 나올 수 있다.
5. 사용하는 거리 척도에 따라 다른 결과가 나올 수 있다.

군집 방법 ② 중심기반 군집분석

각 군집을 대표하는 데이터 포인트가 존재한다고 가정하고 각 관측치를 가장 가까운 대표성을 갖는 데이터 포인트로 할당하는 것. 이는 계층적 군집분석과는 달리 한번 분할하여 K개의 군집을 생성하는데, 생성된 군집의 중심점을 재 계산한 후 관측치의 재할당 작업을 반복하여 최종 군집을 찾아간다.

평균을 이용하는
K-means가
가장 많이 활용된다.



군집 방법 ② 중심기반 군집분석


7. 군집분석

• 장점

- 계산이 쉬움: 다른 군집화 알고리즘에 비해 복잡도가 낮음.
- 구현이 쉽고 다양한 언어와 플랫폼에서 제공되는 알고리즘

• 단점

- 노이즈에 매우 민감함.
- 군집의 개수를 사전에 정의해야 함.
- 몇 가지 상황에서는 최적의 군집 구조를 찾기 어려움.



K-means 알고리즘 사용 시의 주의 사항

(1) 지역최적점을 찾아주는 것에 불과하므로, 더 좋은 군집을 찾기 위해서는 군집의 수, 초기 중심점을 변화시켜가면서 K-Means 알고리즘을 여러 번 수행한 후 선택하는 것이 바람직하다.

(2) 초기 중심점 선정 문제 : 초기 중심점을 최대한 거리를 유지하라고 권고하지만, 이상점의 영향을 무시할 수 없다. 이러한 문제점을 해결하기 위하여 중심점을 변화시키면서 여러 번 수행할 것을 권고한다.

(3) 군집 수 K 선정 문제 : 직관에 의존하는 경우가 많지만, ①계층적 군집분석의 선행 실시 ②주성분 분석 등을 실행하여 선정할 수도 있다.

(4) 이상치의 영향 : 이상치를 제거 후 실행

(5) 빈 군집이 발생 : 어떤 관측치도 할당되지 않는 경우가 발생하면 중심점을 교체해야 한다.


Data-set의 전체 구조를 파악하고, 탐색과 요약을 돕습니다.

가장 대표적인 사례가 데이터 기반 고객 segmentation이라 할 수 있습니다.

과거의 고객 segmentation은
성별, 나이, 소득 등
인구통학적 특성에 따라
유사성의 그룹을 나눈 것이었으며,
마케터의 선입견이 개입될 여지가
매우 컸습니다.

하지만, 디지털 시대에는
보다 풍성한 고객의
특성이 반영된 데이터를
기반으로
정교한 세그멘테이션을
진행할 수 있게 되었습니다.

물론, 디지털 마케팅에서는
마이크로 세그멘테이션을 넘어
1:1 개인화 마케팅을 추구 중입니다.



군집 분석의 활용 ② 데이터의 축소

Instance Selection에 응용할 수 있습니다.


#	X1	X2	X3	X4	X5
#1					
#2					
#3					
#4					
#5					
#6					

Diagram illustrating Instance Selection for Clustering:

The table shows 6 instances (#1 to #6) across 5 features (X1 to X5). Arrows indicate the selection of specific instances for two clusters:

- 군집1 (Cluster 1):** Includes instances #1, #2, and #3.
- 군집2 (Cluster 2):** Includes instances #4, #5, and #6.

1. 군집만 뽑아서 상세하게 분석한다.
2. 군집 간의 차이 비교, 관계를 탐색한다.




군집 분석의 활용 ② 데이터의 축소

창원시 소비 활동, 개인 소득 분석

활용 데이터: 지역거주자의 사업장, 지역근로자, 지역사업장활동, 지역 관외 소비내역, 지역이동량, 기업신용정보, 주민등록인구, 지역 전출입 데이터, 사망출생

인구 군집

[인구 - 군집 선정 결과]



[인구 - 군집 중심값]

군집 번호	총인구수 전년대비 증감률	가업이성대비 출생자수비율	순전입인구수 비율	경제활동 유동인구수비율 전년대비증감률
1	2.485	1.085	4.866	0.351
2	-0.465	-0.485	-0.271	-0.556
3	0.402	0.514	-0.053	0.713

※ 각 군집의 중심을 기준으로 Euclidean distance를 측정하여 군집 선정

- > 1번 군집과 2번 군집의 경우 순 전입 인구수 비율의 중심값이 가장 큰 값이 나타남
- > 3번 군집의 경우 경제활동 유동인구수비율 전년대비 증감률이 가장 크게 나타남


[인구 - 군집 평균값]

군집 번호	총인구수 전년대비 증감률	가업이성대비 출생자수비율	순전입인구수 비율	경제활동 유동인구수비율 전년대비증감률
1	-1.438	0.217	-2.114	0.361
2	28.283	0.404	1.705	-0.389
3	-5.414	0.137	-2.326	0.713

- 군집특성**
- > A그룹: 인구증가
 - > B그룹: 인구감소
 - > C그룹: 인구감소/유동인구감소

소비 군집

[소비 - 군집 선정 결과]



[소비 - 군집 중심값]

군집 번호	인구1인당 평균소비액 전년대비증감률	경제활동인구 1인당평균소비액 전년대비증감률	시군구외유출 소비액수비율 전년대비증감률	시군구외유출 소비액수비율 전년대비증감률
1	1.641268	1.575579	-2.56325	-2.3264
2	-1.20065	-1.13234	0.891236	0.909743
3	-0.26142	-0.30249	-0.10246	-0.15536
4	0.679978	0.892152	-0.08104	-0.03546

※ 각 군집의 중심을 기준으로 Euclidean distance를 측정하여 군집 선정

- > 1번 군집의 경우 인구1인당 평균소비액수 전년대비 증감률, 2번 군집의 경우 시군구외 유출 오프라인 소비액수 비율 전년대비 증감률이 가장 높게 나타남
- > 3번 군집은 시군구의 유출 소비액수 비율 전년대비 증감률, 4번 군집은 경제활동인구 1인당 평균 소비액수 전년대비 증감률이 가장 크게 나타남


[소비 - 군집 평균값]

군집 번호	인구1인당 평균소비액 전년대비증감률	경제활동인구 1인당평균소비액 전년대비증감률	시군구외유출 소비액수비율 전년대비증감률	시군구외유출 소비액수비율 전년대비증감률
1	-8.408	-7.36	18.087	15.15
2	9.015	9.907	7.424	4.654
3	-0.538	-0.262	7.189	3.317
4	15.399	15.735	-13.799	-23.111

- 군집특성**
- > A그룹: 소비증가/관외소비증가
 - > B그룹: 소비증가/관외소비증가
 - > C그룹: 소비 유지/관외소비증가
 - > D그룹: 소비감소/관외소비증가

산업 군집

[산업 - 군집 선정 결과]



[산업 - 군집 중심값]

군집 번호	순가업사업장수 전년대비증감률	순가업사업장 종사자수비율 전년대비증감률	유틸리티사업장 종사자수비율 전년대비증감률	가업장평균 종교소득금액 전년대비증감률
1	-0.895	-1.154	-0.137	-1.249
2	0.260	-0.025	-1.415	0.375
3	1.165	1.235	0.552	1.352
4	-0.137	0.079	0.577	0.321

※ 각 군집의 중심을 기준으로 Euclidean distance를 측정하여 군집 선정

- > 1번 군집과 4번 군집의 경우 유틸리티사업장 종사자수비율 전년대비 증감률이 가장 큰 값이 나타남
- > 2번 군집은 순가업 사업장수 전년대비증감률, 3번 군집은 가업장 평균 종교소득금액 전년대비증감률이 가장 크게 나타남

[산업 - 군집 평균값]

군집 번호	순가업사업장수 전년대비증감률	순가업사업장 종사자수비율 전년대비증감률	유틸리티사업장 종사자수비율 전년대비증감률	가업장평균 종교소득금액 전년대비증감률
1	0.077	0.25	6.596	0.681
2	-0.812	-0.817	14.105	-0.457
3	1.425	1.251	6.776	1.514
4	0.488	0.159	27.699	0.731

- 군집특성**
- > A그룹: 사업장/가업자 증가
 - > B그룹: 사업장유지/가업자증가
 - > C그룹: 사업장/유틸리티종사자 증가
 - > D그룹: 사업장/가업자 감소

군집 분석의 활용 ③ 맞춤형 대응

[예시] 어떤 사람의 인맥 관리

성명	나이	학력	직위	성격	...
#1					
#2					
#3					
#4					
#5					
#6					
#n					

군
집
분
석

군집1 매일 안부 전화 걸기

군집2 일주일 한번 카톡 메시지 보내기

군집3 한달에 한번 식사 약속 잡기

군집4 6개월 한번 메일로 인사 하기

-
- 새로운 사람이 추가되면,
기 개발된 군집분석 알고리즘에 따라 분류
 - 1년에 한번 데이터 재검토 및 수정 후
군집분석 재학습 실행

군집이 잘 형성되었는가를 판단하는 아래와 같은 척도가 존재합니다만,
잘 사용되지는 않습니다. 분석의 목적 달성 여부 등 정성적 해석이 더 중요하기 때문입니다.

외부 평가척도

군집에 대한 사전 지식 혹은 전문가의 지식을 이용한 평가. 즉, Data에 내재되지 않은 정보를 이용.
 K개의 군집이 존재한다는 것을 미리 안다면, 이를 근거로 성능을 평가한다.

- 군집 단위 관점 : 순수도, 엔트로피, F척도
- 개별 관측치 관점
 1. 자카드 계수 = $TP / (TP + FN + FP)$
 2. 랜드 지수 = $(TP + TN) / GS$
 3. Forkes-Meloows 척도
 - 정밀도 = $TP / (TP + FP)$
 - 재현율 = $TP / (TP + FN)$
 - FM 기하평균 = $(정밀도 * 재현율)^{1/2}$

		예측		
		true	false	계
실제	true	TP	FN	AT
	false	FP	TN	AF
	계	PT	PF	GS

내부 평가척도

군집 분석에 사용한 데이터만을 사용한 평가로서 대부분의 현실 상황에 적용된다.
 → 군집 내 유사도는 크고, 군집 간 유사도는 작아야 한다는 관점에서 ...
 응집도(cohesion) 분리도(separation)

1. Dunn 지표 = (군집간 거리 중 가장 작은 값) / (군집간 거리 중 가장 큰 값)
2. CI지표 = (전체 중심과 군집 중심으로 계산한 분리도) / (군집 중심과 관측치 사이의 응집도)
3. DB 지표 = 응집도/분리도
4. Brock 지표
5. 실루엣 지수 : 1에 가까울 수록 군집이 잘 되었다고 본다.

[참고] 실루엣 지수

군집의 수는 기본적으로 실무적으로 결정한다.


군집의 수를 바꾸어 가면서 실무적으로 가장 의미있는 개수를 선정한다.

그러나, 실루엣 지수를 활용할 수도 있다.

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

$a(i)$: average distance between i and all other data assigned the same cluster
(**mean intra-cluster distance**)


$b(i)$: average distance of i to all points in the nearest cluster that i is not a part of
(**mean nearest-cluster distance**)




$$-1 \leq s(i) \leq 1$$

실루엣 지수가 1에 가까우면 군집이 잘 되었다고 본다.


[실습 1] IRIS 데이터를 활용한 K-means 분석 실습




species를 skip



① 2개로 clustering이 제일 확실






② 두개 군집이 어느 정도 가능하지 확인




[실습 1] IRIS 데이터를 활용한 Hierarchical Clustering 분석 실습

군집 별 상세 분석을 위한 데이터 세트 분할



[실습 1] IRIS 데이터를 활용한 Hierarchical Clustering 분석 실습

군집 별 비교



1 Group by

기준 변수

요약값

Group by - Orange

Filter...

Attributes

Attributes	Aggregations
1 ☒ sepal_length	Mean, Median, Min. value and 1 more
2 ☒ sepal_width	Mean, Median, Min. value and 1 more
3 ☒ petal_length	Mean, Median, Min. value and 1 more
4 ☒ petal_width	Mean, Median, Min. value and 1 more
5 ☒ species	Count
6 ☒ Cluster	Count
7 ☒ Silhouette	Mean

Aggregations

☒ Mean ☐ Sum ☐ First value

☒ Median ☐ Concatenate ☐ Last value

☐ Mode ☒ Min. value ☐ Random value

☐ Standard deviation ☒ Max. value ☐ Count defined

☐ Variance ☐ Span ☐ Count

☐ Proportion defined


☒ Send Automatically

150 2


2

Cluster	sepal_length - Mean	sepal_length - Median	sepal_length - Min
C1	5.006	5	
C2	6.262	6.3	


[실습 1] IRIS 데이터를 활용한 K-means 분석 실습






① 3개라는 것을 알고 있다?!



② 3 개 군집이 어느 정도 가능하지 확인



[실습 1] IRIS 데이터를 활용한 Hierarchical Clustering 분석 실습



Clustering은 해석의 문제지
분석의 문제는 아닌 것 같은데...

[실습 2] marathon 데이터를 활용한 실습



File - Orange

Source

☒ File:

☐ URL:

File Type

Automatically detect type

Info

108 instance(s)
2 feature(s) (no missing values)
Data has no target variable.
0 meta attribute(s)

Columns (Double click to edit)

	Name	Type	Role	Values
1	age	categorical	skip	
2	time	numeric	feature	

108

k-Means - Orange

Number of Clusters

☐ Fixed:

☒ From: to

Preprocessing

☒ Normalize columns

Initialization

Initialize with KMeans++

Re-runs:


Maximum iterations:

☒ Apply Automatically

Silhouette Scores

2	0.579
3	0.605
4	0.623
5	0.575
6	0.600
7	0.597
8	0.574


108



Data 분석 절차와 DX 과제

목적

- ✓ 과제는 정한 시간이 되어서 끝나는 것이 아니라, 목적을 달성하고 종료된다.
- ✓ 모든 과제가 예측모델을 개발해야 하는 것은 아니며,
따라서 과제의 실행 절차는 과제의 목적에 따라 서로 다를 수 밖에 없다.



고객도
모르는
고객을
알자



생각을 모으자. 행동을 바꾸자
REINVENT
LG전자

배운다
배운 걸
지우고
다시 배운다



생각을 모으자. 행동을 바꾸자
REINVENT
LG전자