


9. Text Mining

Text Mining과 NLP

자연어처리(NLP, Natural Language Processing)는 인간의 언어인 자연어(Natural Language)를 인공지능이 인식하고 표현할 수 있도록 하는 것에 중점을 두는 분야인 반면, 텍스트 마이닝(Text mining)은 NLP를 통해 추출된 단어나 문장 속에서 유의미한 인사이트를 찾아내는 작업을 칭한다. 텍스트 마이닝에는 NLP 뿐만 아니라 데이터 마이닝과 데이터베이스(Database) 등 다양한 방면의 지식과 스킬이 필요하다.



NLP는 인공지능이 자연어를 알아듣도록(Natural Language Understanding)하고, 그럴듯하게 생성(Natural Language Generation)해 낼 수 있도록 통계학과 다양한 딥러닝 기술들을 적용하여 연구하는 분야다. 반면에 텍스트마이닝(Text-mining)은 자연어처리(NLP)의 결과물인 언어모델(Language Model) 혹은 토큰(Token)과 말뭉치(Corpus) 등을 활용하여 텍스트 형태로된 데이터에서 고객의 경향성이나 선호도 등 유의미한 정보를 얻어내기 위한 분석 기법들인 것이다.

- 단어 빈도 분석 : 워드클라우드(주요 키워드의 추출), 단어 트렌드 분석
- 주제 분석 (Topic Modeling)
- 감성 분석 (Sentiment Analysis)
- 네트워크분석 (연관 단어의 추출과 단어 네트워크 분석)
- 군집분석 (유사 단어들 또는 문서들 간의 군집 분석)
- 이상치 분석 (Anomaly Detection :예, 스팸 메일 탐지)
- 표절 분석 : 문서의 유사도 계산
- 문서 분류(classification): 문서를 미리 정해진 주제에 할당



- 토큰화
- 전처리
- 임베딩



말뭉치

말뭉치 또는 코퍼스는

자연어 연구를 위해 특정한 목적을 가지고 언어의 표본을 추출한 집합.
쉽게 말해서, 연구와 분석을 위해서 수집한 Text Sample을 의미함.

영어 말뭉치

- 구글의 엔그램 말뭉치
155,000,000,000 단어 수로 구성된 가장 큰 영어 말뭉치.
- 미국 국립 코퍼스 (American National Corpus)
- Bank of English
- British National Corpus
- 법학 말뭉치 (Corpus Juris Secundum)

한국어 말뭉치

- 모두의 말뭉치 (<https://corpus.korean.go.kr/>, 국립국어원)
- 대규모 웹데이터 기반 한국어 말뭉치 데이터(<https://aihub.or.kr/>, AI Hub)
- 연세 말뭉치 (연세대학교 언어정보연구원)



자연어의 토큰화 Tokenization

주어진 코퍼스에서 토큰(token)이라 불리는 단위로 나누는 작업을 **토큰화**라고 합니다. 토큰의 단위가 상황에 따라 다르지만, 보통 의미있는 단위로 토큰을 정의합니다.

1. 단어 토큰화(Word Tokenization)

단어(word)를 기준으로 토큰화하는 것을 말합니다.

단, 여기서 단어는 단어 단위 외에도 단어구, 의미를 갖는 문자열로도 간주되기도 합니다.

[예시]

It's so funny !!!

"Its" "so" "funny"

구두점(punctuation)을 제외한 단어 토큰화

구두점 : 마침표(.), 쉼표(,), 물음표(?), 세미콜론(;), 느낌표(!) 등과 같은 기호

- *1. 영어는 띄어쓰기 단위로 자르면 대체로 단어 토큰이 구분되나 한국어는 다르다.
- *2. 구두점 등 특수문자를 전부 제거하면 의미를 상실할 수 있다. (예, It's vs. Its vs. It is)
- *3. 대소 문자를 다르게 인식할 수 있으므로 모두 소문자로 변경하는 것이 좋겠다.

2. 문장 토큰화(Sentence Tokenization)

토큰의 단위를 문장(sentence)으로 하는 경우, 문장 분류(sentence segmentation)라고도 합니다. 보유한 코퍼스가 문장 단위로 구분되어 있지 않는 경우, 이를 활용할 수도 있습니다.



토큰(token)은 본래 '징표', '형식물'이라는 뜻에서 유래하여 상품권이나 서비스의 교환권을 뜻하는 영단어로, 화폐의 기능을 대신하는 유가증권의 일종이다. 실물로 주조될 경우 대개 화폐와 비슷한 모양으로 발급되며 재질은 동전부터 종이피의 형태까지 다양하다. 카지노 등지에서는 '칩(chip)'이라는 용어를 쓰기도 한다.

한국어의 토큰화의 어려움

영어는 띄어쓰기(whitespace)를 기준으로 하는 토큰화를 진행하면 단어 토큰화가 대체로 잘 작동합니다.
(단, New York과 같은 합성어나 he's 와 같이 줄임말에 대한 예외 처리 필요).
하지만 한국어는 영어와는 달리 띄어쓰기만으로는 토큰화를 하기에 부족합니다.

1) 교착어의 특성

<한국어는> <한국어가> <한국어를>
이들을 다른 단어로 인식하므로, 형태소 단위로 분리 필요.

철수는 학교에 갔다.

- 띄어쓰기 단위 토큰화 : 철수는, 학교에, 갔다.
- 자립 형태소 : 철수, 학교
- 의존 형태소 : -는, -에, 갔-, -다

2) 한국어는 띄어쓰기가 잘 지켜지지 않는다.
띄어쓰기가 틀려도 의미를 이해하는데 크게 지장이 없기 때문이다.

상용화된 많은 형태소 분석기가 있다.
형태소 분석기에서 기본적으로 품사 태깅과 띄어쓰기를 제공한다.
(예, Python 라이브러리의 KoNLPy, 카카오의 Khaiii 등)

교착어란 어근과 접사에 의해 단어의 기능이 결정되는 언어의 형태. 즉, 조사, 어미 등을 붙여서 말을 만들어 낸다.
한국어·터키어·일본어·핀란드어 등.

형태소(morpheme)
의미를 가질 수 있는 가장 작은 말의 단위

1. 자립 형태소 : 접사, 어미, 조사와 상관없이 자립하여 사용할 수 있는 형태소. 그 자체로 단어가 된다. 명사, 대명사, 수사, 관형사, 부사, 감탄사 등
2. 의존 형태소 : 다른 형태소와 결합하여 사용되는 형태소. 접사, 어미, 조사, 어간을 말한다.

품사 태깅 Part-of-speech tagging


표기는 같지만 품사에 따라서 의미가 달라지는 것을 구분하기 위하여, 해당 단어가 어떤 품사로 쓰였는지 구분하는 것.

코퍼스 데이터를 목적에 맞게 정리, 정돈하는 작업

Orange에 반영된 Text 전처리

- Transformation
- Tokenization
- Normalization
- Filtering
- N-gram Range
- POS Tagger

- ✓ 분석가의 실력은 전처리에 있다!
- 전처리를 실행하면서 지속적 갱신
 - 결국 원문을 들여다 봐야하는 수고?!



1. Transformation

- **Lowercase**는 모든 텍스트를 소문자로 바꿉니다.
- **Remove accents**는 텍스트의 모든 발음 구별 부호/악센트를 제거합니다. (naïve → naive)
- **Parse html**은 html 태그를 감지하고 텍스트만 구문 분석합니다. (<a href...>transform text → transform text)
- **Remove urls**은 텍스트에서 URL을 제거합니다. This is a http://orange.biolab.si/ url. → This is a url.

2. Tokenization

- **Word & Punctuation**은 텍스트를 단어 별로 나누고 구두점 기호를 유지합니다.
(예) This example. → (This), (example), (.)
- **Whitespace**는 공백만으로 텍스트를 분할합니다.
(예) This example. → (This), (example.)
- **Sentence**는 전체 문장만 유지하면서 텍스트를 마침표로 분할합니다.
(예) This example. Another example. → (This example.), (Another example.)
- **Regexp**는 제공된 정규식으로 텍스트를 분할합니다.
기본적으로 구두점을 생략하고 단어로만 구분합니다.
- **Tweet** 은 해시태그, 이모티콘 및 기타 특수 기호를 유지하는
미리 훈련된 트위터 모델로 텍스트를 분할합니다.
(예) This example. :-) #simple → (This), (example), (.), (: -)), (#simple)

3. Normalization

- 정규화는 단어에 형태소 분석 및 원형 복원을 적용합니다.
(예) I've always loved cats. → I have always love cat.)
- 이를 돕는 다양한 모델이 있습니다.
: Porter Stemmer, Snowball Stemmer, WordNet Lemmatizer, UDPipe, Lemmagen

정규화는 코퍼스로부터 복잡성을 줄이기 위해 적용됩니다.
어간 추출(stemming)과 표제어 추출(lemmatization)이 가장 대표적으로 적용되는 것입니다.

1. Stemming : 어간(stem)만 남겨두고 접사(affix) 제거
예) cats → cat

2. 표제어 추출(Lemmatization)
예) ex. am, are, is는 서로 다른 스펠링이지만 그 뿌리 단어인 be는 이 단어들의 표제어라고 할 수 있습니다.

4. Filtering

자연어가 아니면서 아무 의미도 갖지 않는 글자들(특수 문자 등) 뿐만 아니라 분석하고자 하는 목적에 맞지 않는 불필요 단어들(등장 빈도가 적은 단어 포함)은 노이즈라 할 수 있습니다.

- **Stopwords**는 텍스트에서 불용어를 제거합니다(예: 'and', 'or', 'in'... 제거)
- **Lexicon**은 파일에 제공된 단어만 보관합니다.
- **Regexp**는 Regular Expression과 일치하는 단어를 제거합니다.
- **Document frequency**는 지정된 문서 수/백분율 이상에 나타나는 토큰을 유지합니다.
- **Most frequency**는 지정된 개수의 가장 자주 사용되는 토큰만 유지합니다.

영어는 길이가 2~3 이하인 단어를 제거하는 것만으로도 크게 의미를 갖지 못하는 단어를 줄이는 효과를 갖고 있지만, 한국어 단어는 한자어가 많고, 한 글자만으로도 이미 의미를 가진 경우가 많아 이를 직접 적용할 수 없습니다. 따라서 결국에는 사용자가 직접 불용어 사전을 만들게 되는 경우가 많습니다.

5. n-gram range

n-gram은 자연어 처리, 정보 검색 등에서 활용이 되는 시퀀스 데이터 표현 방식입니다. ngram에서 n은 연속된 단어의 개수를 의미합니다.

여기서 각 단어는 토큰(token)이라 하며 토큰 개수(n)에 따라 다음과 같이 부릅니다.

n=1 : 1-gram(unigram)

n=2 : 2-gram(bigram)

n=3: 3-gram(trigram)

n=4 : 4-gram

예) An adorable little boy is spreading smiles

unigrams : an, adorable, little, boy, is, spreading, smiles

bigrams : an adorable, adorable little, little boy, boy is, is spreading, spreading smiles

trigrams : an adorable little, adorable little boy, little boy is, boy is spreading, is spreading smiles

4-grams : an adorable little boy, adorable little boy is, little boy is spreading, boy is spreading smiles

6. POS tagging

토큰에 품사를 태깅합니다.

이는 문장의 문맥과 이웃 단어들과의 관계를 고려하여 부여되며



이를 통해 단어의 모호함을 해소 것이 주 목적입니다.

Document Embedding

[참고] 임베딩 Embedding

사람이 사용하는 언어나 이미지를 컴퓨터가 이해할 수 있도록 고차원 공간의 벡터로 표현하는 것.

- **이미지 임베딩**은 저차원 공간에서 이미지를 표현하는 데 사용됩니다. 이러한 임베딩은 색상 및 질감과 같은 이미지의 시각적 특징을 캡처하여 머신러닝 모델이 이미지 분류나 객체 감지와 같은 작업을 수행할 수 있도록 합니다.
- **워드 임베딩**은 단어를 저차원 공간에서 벡터로 표현하는 데 사용됩니다. 이러한 임베딩은 단어 간의 의미와 관계를 포착하여 머신러닝 모델이 자연어를 더 잘 이해하고 처리할 수 있도록 합니다.
- **그래프 임베딩**은 서로 연결된 노드들의 네트워크인 그래프를 저차원 공간에서 벡터로 표현하는 데 사용됩니다. 이러한 임베딩은 그래프에서 노드 간의 관계를 포착하여 머신러닝 모델이 노드 분류 및 링크 예측 작업을 수행할 수 있도록 합니다.



임베딩의 활용 분야

- **데이터 품질 개선** : 노이즈를 줄이고, 이상값(outlier)을 제거하며, 의미 관계를 포착하여 데이터 품질을 개선하는 데 도움이 될 수 있습니다.
- **수동 데이터 라벨링의 필요성 감소** : AI 임베딩은 임베딩 표현을 기반으로 데이터에 자동으로 라벨을 지정할 수 있습니다.
- **연산량 감소** : 임베딩은 고차원 데이터를 저차원 공간에 표현하기 때문에 연산량을 줄이는 데 유용합니다.
- **향상된 자연어 처리(NLP)**
- **추천 시스템 개선** : 추천 시스템의 일종인 협업 필터링은 사용자 및 아이템 임베딩을 사용하여 개인화된 추천을 제공합니다.
- **이미지 및 비디오 처리 향상** : 객체 감지, 인식 및 분류에서 이미지 및 비디오 임베딩을 사용할 수 있습니다.

[참고] Text와 범주형 변수의 인코딩 encoding

일반적으로 인코딩이란 정보의 형태나 형식을 변환하는 것을 말합니다.

범주형 변수의 인코딩은 데이터를 기계가 이해할 수 있도록 숫자로 변환해 주는 것을 말합니다.

① Label Encoding (혹은 정수 인코딩)

Text(범주형 변수)에 0 ~ n-1 (n은 범주의 개수)의 정수를 부여하는 것을 말합니다.

(예) 사과, 수박, 자두, 포도 → 사과 = 0, 수박 = 1, 자두 = 2, 포도 = 3

*인코딩된 숫자를 가지고 차이나 비율을 논의할 수 없습니다.

따라서 3개 이상일 때에는 특히 주의해야 합니다.

단, Tree 기반 방법은 3개 이상도 효과적으로 처리합니다.

품목	구매수량
사과	25
수박	33
자두	45
포도	62

품목	구매수량
0	25
0	33
2	45
3	62

② One-hot Encoding

n개의 범주형 데이터를 n개의 비트(0,1) 벡터로 표현합니다.

원핫 인코딩은 여러 범주형 변수를 한 번에 인코딩할 수 있습니다.

그러나 범주의 수 만큼 차원이 확대되는 단점이 있습니다.

(예) 사과, 배, 자두, 포도

→ 사과 = [1, 0, 0, 0]

수박 = [0, 1, 0, 0]

자두 = [0, 0, 1, 0]

포도 = [0, 0, 0, 1]

사과	수박	자두	포도	수량
1	0	0	0	25
0	1	0	0	33
0	0	1	0	45
0	0	0	1	62

[참고] 단어 임베딩 Word Embedding

워드 임베딩(Word Embedding)은 단어를 벡터로 표현하는 방법으로, LSA, Word2Vec, FastText, Glove 등이 있습니다.

1. 희소 표현 Sparse Representation

벡터 또는 행렬의 값이 대부분이 0으로 표현되기에 희소 표현이라고 합니다.
즉, 원-핫 인코딩을 통해 만들어진 벡터는 희소 벡터(sparse vector)입니다.
희소 벡터의 문제점은 단어의 개수가 늘어나면 벡터의 차원이 확장되고,
또한 단어의 의미 또는 단어 간 유사도를 담지 못한다는 단점이 있습니다.

2. 밀집 표현 Dense Representation

밀집 표현은 벡터의 차원을 단어 집합의 크기로 상정하지 않고,
사용자가 설정한 값으로 모든 단어의 벡터 표현의 차원을 맞춥니다.
따라서 0과 1만의 값이 아니라 실수값을 가지게 됩니다.
벡터의 차원이 조밀해졌다고 하여 밀집 벡터(dense vector)라고 합니다.


3. 분산 표현 Distributed Representation

단어의 의미 또는 단어 간 유사도를 담아내지 못하는 원-핫 벡터의 단점을
개선하고자 고안된 방법입니다. 이는 기본적으로 분포 가설에 기반하여
단어의 의미를 여러 차원에 분산하여 표현합니다.
따라서 단어 사이의 유사도를 계산할 수 있으며
가장 대표적인 방법이 구글에서 2013년 Google에서 발표한 Word2vec 입니다.

분포 가설 : '비슷한 위치에서 등장하는 단어들은 비슷한 의미를 가진다'

예를 들어, 강아지란 단어는 귀엽다, 예쁘다, 애교 등의 단어가 주로 함께 등장하는데

분포 가설에 따라서 이런 내용을 가진 텍스트를 벡터화한다면 이런 단어들은 의미적으로 가까운 단어가 됩니다.



Word Cloud

단어의 빈도를 시각적으로 나타내는 시각화 방법 (빈도 기반)



Word cloud는
문서의 주요 키워드나 중요도를
직관적으로 파악할 수 있습니다.
그러나
단어 간의 관계를 표현할 수 없고
정보가 편향될 수 있습니다.

[예시] 고객 불만 녹취

- 음향 버튼이 이상해요.
- 음향 조작하는데, 화면이 번쩍거렸어요.
- 음향을 맞추다가 문득 음질은 좋은데, 화질이 부족해서...



'음향' 품질에 고객이 불만을 가지고 있다?!



Word Cloud

http://wordcloud.kr/

워드클라우드 생성기 3.6

워드클라우드 생성기

갤러리

무료폰트

영어버전

일본어버전

글자색

rainbow

폰트


나눔고딕

I 폰트미리보기

배경색



마스크



크기

직접입력

500px

x

500px

단어수

300개

키워드

텍스트


우리에게는 민족 중흥의 역사적 사명이 있다.
 민족 중흥은 좋은 것이다
 역사는 민족을 배반하지 않는다.

입력

입력 후 클릭



워드클라우드 만들기



내가 만든 워드클라우드 다운로드

다운로드

갤러리공개

Topic Modeling

문서 집합의 추상적인 "주제"를 발견하기 위한 통계적 모델.

텍스트의 핵심 주제를 찾아 비슷한 내용끼리 분류하는 분석 방법으로, 다량의 텍스트를 분석할 때 유용

특정 주제에 관한 문서에서는 그 주제에 관한 단어가 다른 단어들에 비해 더 자주 등장할 것이라는 가정에 기반한다. 단어의 순서에는 신경쓰지 않는다.

함께 자주 등장하는 단어들은 대개 유사한 의미를 지니게 되는데 이를 잠재적인 "주제"로 정의할 수 있다.

예를 들어

개에 대한 문서에서는 "개"와 "뼈다귀"라는 단어가 더 자주 등장


고양이에 대한 문서에서는 "고양이"와 "야옹"이 더 자주 등장

→ "개"와 "뼈다귀"를 하나의 주제로 묶고,

"고양이"와 "야옹"을 또 다른 주제로 묶는 모형

대표적인 알고리즘으로
잠재 디리클레 할당(LDA)이 있다.

Latent Dirichlet Allocation



설명출처 : 위키백과

Topic Modeling

잠재 디리클레 할당 Latent Dirichlet Allocation


- 각 문서에 어떤 주제들이 존재하는지를 서술하는 확률적 토픽 모델 기법 중 하나입니다.
- 미리 알고 있는 주제별 단어 수 분포를 바탕으로, 주어진 문서에서 발견된 단어 수 분포를 분석함으로써 해당 문서가 어떤 주제들을 함께 다루고 있을지를 예측할 수 있습니다.
- LDA는 문서 집합에서 토픽이 몇 개가 존재할지 가정하는 것을 하이퍼 파라미터로 취급합니다.

LDA는 다음과 같은 가정 하에 알고리즘을 수행합니다.

- 빈도수 기반의 표현 방법이며, 단어의 순서는 토픽에 기여하지 않는다.
- 토픽은 여러 단어의 혼합으로 구성된다
- 하나의 문서는 복수의 토픽으로 이루어져 있다.

여러 단어가 혼합된 Topic의 이름은 Domain Knowledge를 기반으로 분석가가 정합니다.

영화 기생충 아카데미상 수상 기사 댓글 토픽
토픽별 주요 단어 Top 10



감성분석(Sentiment Analysis)

감성 분석은 '오피니언 마이닝(Opinion Mining)'으로 도 불리는데,
이는 텍스트에 나타난 사람들의 태도, 의견, 성향과 같은 주관적인 감성을 분석하기 위한 것.

감성분석은 감성과 심리를 파악하려 하므로, '오늘 스마트폰을 새로 샀다'와 같이 사실 만을
진술하는 문장은 가치판단이 전혀 개입되지 않았으므로, 감성 분석에서는 제외된다.

감성 분석 3단계



단어의 감성점수가 모여서 문서의 감성점수가 되고, 이를 통해 글쓴이의 의견이 긍정인지 부정인지를 판단

[참고] 감성분석에는 3가지 접근법이 있습니다.

- ① **규칙 기반** 규칙 기반 접근 방식은 미리 결정된 어휘를 기반으로 특정 키워드를 식별, 분류 및 평가합니다. 이때 다양한 표현의 감정적 가중치를 반영하기 위해 긍정적 어휘와 부정적인 어휘에 감정 점수를 할당합니다. 문장이 긍정적인지, 부정적인지, 중립적인지는 전체 감정 점수를 합산하고, 이를 감정 경계와 비교합니다. 규칙 기반 감정 분석은 설정이 간단하지만 조정하기는 어렵습니다. 즉, 새로운 키워드를 발견하면 어휘를 계속 확장해야 합니다. 또한 이 접근 방식은 다른 문화의 영향을 받는 문장을 처리할 때 정확하지 않을 수 있습니다.
- ② **머신러닝** 감정 분류 알고리즘을 학습시킵니다. 이는 알 수 없는 데이터의 감정을 높은 정확도로 추측할 수 있도록 감정 분석 모델을 만들고 알려진 데이터에 대해 반복적으로 훈련시키는 과정이 포함됩니다. ML 감정 분석은 광범위한 텍스트 정보를 정확하게 처리하므로 효과적입니다. 하지만 훈련된 ML 모델은 하나의 비즈니스 영역에서만 유효합니다. 즉, 마케팅 데이터로 학습된 감정 분석 소프트웨어는 재훈련 없이는 소셜 미디어 모니터링에 사용할 수 없습니다.
- ③ **하이브리드** 하이브리드 감정 분석은 ML 시스템과 규칙 기반 시스템을 결합하여 작동합니다.

자연어 처리(NLP) 기술의 발전에도 불구하고 인간의 언어를 이해하는 것은 기계에게 어려운 일입니다. 비꼬는 것이나 반어적 표현 그리고 이중 부정의 처리는 자주 잘못된 분류의 원인이 됩니다. <화질은 만족스러운데 음질이 마음에 안 들어요>와 같이 긍부정이 겹쳐 있을 수 있습니다. 따라서 감정을 보다 잘 이해하기 위해서는 아래와 같은 다른 방법들과 함께 사용하는 것이 일반적입니다.

- **세분화된 채점** 세분화된 감정 분석은 텍스트 의도를 여러 수준의 감정으로 분류하는 것을 말합니다. 일반적으로 이 방법에는 0~100의 척도나 리커트 척도를 사용하여 감정을 평가합니다.
- **측면 기반** 측면 기반 분석은 제품 또는 서비스의 특정 측면에 중점을 둡니다. 예를 들어, 디자인, 사운드, 그래픽 등으로 나누고, 각각에 대한 고객 경험을 설문 조사를 통해서 수집할 수 있습니다.
- **의도 기반** 의도를 추가적으로 반영함으로써, 글쓴이의 감정을 더 잘 이해할 수 있습니다.
- **정서적 감지** 정서적 감지에는 텍스트를 쓸 때 사람의 심리적 상태를 분석하는 것이 포함됩니다. 감정 감지는 단순히 범주로 분류하는 것보다 더 심층적인 감정 분석 분야입니다. 이 접근 방식에서 감정 분석 모델은 사람의 단어 선택을 통해 기쁨, 분노, 슬픔, 후회와 같은 다양한 감정을 해석하려고 시도합니다.


한국어 감정 분석이 다른 언어에 비해 어렵다는 많은 연구 결과가 존재합니다. 한국어는 같은 단어라도 문맥상 해석이 달라질 수 있어 알고리즘으로 구현되기 어려운 언어라는 것입니다. 한국어 감정 분석이 어려운 이유는 크게 두 가지가 있습니다. 첫째로는 상황에 따라 문장의 감정이 달라질 수 있는 경우이고, 둘째로는 모호한 감정 표현들이 사용된 경우입니다.

상황 지배적	'만사가 귀찮아요' '참 재미있는 일이 없어서 큰일입니다' '퇴근했어요. 배고파서 어지러워요'
모호한 표현	'정년퇴직을 하게 되니 시원섭섭합니다' '내일 딸 결혼식이라 마음이 싱숭생숭합니다.' '상견례를 하는데 마음이 몽글했어요'

이재아, 박구만(2022), "라디오 청취자 문자 사연을 활용한 한국어 다중 감정 분석용 데이터셋 연구", 방송공학회논문지 제27권 제6호

특정 키워드의 활용 빈도가 시간의 흐름에 따라 어떤 추이를 보이는지를 표현하는 기법

검색 빈도, 클릭 빈도, 등장 빈도 등 다양한 측면의 활용 빈도를 활용
데이터 사이언티스트가 직접 수집한 데이터에서의 빈도 변화를 파악할 수 있지만,
구글 트렌드나 네이버 데이터랩 서비스, 썸트렌드 등을 활용할 수도 있다.




개별 키워드에 대한 자체적인 정보 뿐 아니라
키워드들의 연관 관계를 살펴봄으로써 인사이트를 얻을 수도 있다.
네트워크 분석이 가장 널리 쓰인다.



[실습 1] 썸트렌드로 분석해보기

트렌드 분석



[실습 1] 썸트렌드로 분석해보기

연관어 분석

Sometrend 분석센터

lg전자

시작일 2022.11.30 - 종료일 2022.12.29 1개월 3개월 6개월 12개월

커뮤니티 OFF 인스타 OFF 블로그 ON 뉴스 ON 트위터 ON 리트윗제기

소셜 분석

연관어 분석

경제/사회 > 경제

분석단어와 많이 언급된 카테고리

lg전자 연관어 TOP1

냉장고

순위변화가 가장 큰 연관어

카테고리

전체

인물

정지/교육/예술인

연예인

스포츠인

기타

단체

정부조직

비즈니스

기관/단체

기타

장소

관광지/숙박

식당/카페

적용하기

연관어 ?

차트수정

분석데이터

sk

삼성

글로벌

ultra pc

시스템

ces

고객

공기

다오스

유리케어

오브제컬렉션

시장

설치

엘지

현대

기업

가능

tv

노트북

냉장고

서비스

lg

경험

제품

출시

국내

사업

모델

Powered by Sometrend

lg전자

2022.11.30 - 2022.12.29

LG렌탈정수기는 베스트렌탈샵에서

LG전자 공식인증점, LG전자 공식판매점으로 리퍼 제품 아닌 새로 생산된 정품 배송으로 신뢰할 수 있는 렌탈 업체입니다.

삼성 비스포크·LG 시그니처 신제품 CES서 첫 선(종합)

CES2023에 알뜰 내일 새가전 삼성전자와 LG전자가 다음달 5일(현지시간)부터 나흘간 미국 라스베이거스에서 열리는 세계 최대가전·IT 전시회 CES2023...

LG전자 <https://twitter.com/bagjuny40297593/status/16...>

LG전자 <https://twitter.com/bagjuny40297593/status/160847158717044...>

LG렌탈은 LG베스트몰

400여가지의 상품들과 현금이 준비되어있으니 꼭 LG전자 베스트몰을 이용해보세요

자세히 보기

연관어순위변화 ?

주별 월별


분석데이터

전체순위 ?


2022.11.30 - 2022.12.29

[실습 1] 썸트렌드로 분석해보기

긍부정 분석



[실습 2] 구글 트렌드 분석해보기



[생각해 보기] 단어의 빈도 기반이 가진 한계

현재까지 다룬 Text 분석 기법은 특정 단어들의 출현 빈도를 기반으로 추이, 패턴, 경향 등을 확인하고, 여기서 insight를 추출하고자 합니다.


- 단어는 문장을 대신하지 못한다.
- 정확도/적확도가 불충분하다.
- 되는 것 몇 개 빼고는 전부 안 된다.
- 분석 결과물 자체를 그대로 비즈니스에 적용할 수 없다.

사용 목적과 방법이
그 한계의 크기를 결정한다.

평가용 vs. **개선용**
누가 누가 잘했나? 개선기회는 어디에?

Insight는 분석의 결과가 아니라 해석의 결과이다.


[실습 3] 오렌지를 활용한 워드 클라우드 실습



Data 분석 절차와 DX 과제

목적

- ✓ 과제는 정한 시간이 되어서 끝나는 것이 아니라, 목적을 달성하고 종료된다.
- ✓ 모든 과제가 예측모델을 개발해야 하는 것은 아니며,
따라서 과제의 실행 절차는 과제의 목적에 따라 서로 다를 수 밖에 없다.



고객도
모르는
고객을
알자



생각을 모으자. 행동을 바꾸자
REINVENT
LG전자

배운다
배운 걸
지우고
다시 배운다



생각을 모으자. 행동을 바꾸자
REINVENT
LG전자