


13. Closing

“올바른 과정이 좋은 결과를 약속한다”

Trial and Error

VS.

Trial and Success



데이터 분석은 골방 프로젝트가 아니다 !!!

예측적 분석 프로젝트에서 예측 모델을 만드는 것은 오히려 쉬운 과정일 수 있다.

올바른 예측 모델을 이끌어 내기 위해서는 프로젝트의 전 과정에서

경험과 직관, 시험과 실험을 적절히 활용해야 한다.


특히, 분석 프로젝트의 전 과정에서 올바른 결정을 내리려면 아래 사항을 갖춰야 한다.

- **상황적 능숙함**으로 해당 분야의 기술 전문가와 대화할 수 있어야 한다.
- 데이터를 올바르게 이해하기 위해서 **탐색**해야 한다.
- **데이터 정리**에 시간을 할애해야 한다.
- **변수를 표현**하는 가장 좋은 방법을 고민해야 한다.
- **평가** 과정을 올바르게 설계하기 위해 시간을 할애해야 한다.



“목적이 모든 과정을 지배한다”

동의 없이 일 잘하는 방법 없다. 가치에 동의를 얻어라!



혁신적 목표



- 목표는 정량적 숫자로 표현하지 못하면 목표가 아니다.
- 목표는 KPI, not KAI KPI는 (내부/외부) 고객의 Benefit.
 무엇을 했다 안했다는 목표가 아니다.
 (예) Data Mart 구축 1건 : 목표가 아니다.
 → 일정, 성과를 포함하는 정량화
- 목표는 성공의 판정 기준 목표는 합의 되어야 한다.
- 목표는 혁신적 Aggressive but Realistic



목적이 뛰는 방향을 결정하고, 목표가 뛰는 속도를 결정한다.



“데이터의 수량과 품질은 모두 중요하지만, 품질이 더 중요하다.”

데이터 품질을 입증하는 Data Quality Report를 확인하라!

Data Collection	webRTS Test Data	Data Frame	Raw Data: 2017.1~2018.5.15 (967MB, CSV 기준)		알고 싶은 세상에 적합한 Data가 수집되었는가? : 수집 Data의 대표성 *Big Data는 편향이 위험
	Jira Defect Data		- No. of Features: 109 (ID 제외)		
	개발 Data 외		- No. of Instances: 1,279,411		
		- Model List 기준 Unique Model : 167 (Model Name : 255)			
Data Feasibility	Qualitative (정성적)	타당도	- TE 업무 활동에 기여하는 업무 환경 검토 및 현상 진단		
			- TE 업무 결과와 밀접한 관련 변수 검토 : 연관된 변수군 선택 및 기술적 검토 : 109개 변수 선택		
	Quantitative (정량적)	정확도	- 변수 별 입력 값/범주 정확성 검토 및 확인 (Data 수정 : 93.8%) : Data Preprocessing: (1) Data 정리 (2) Data 통합 (3) Data 감소(4) Data 변환		
			- 입력 오류 제거, 관련 DB 내용/수기 정보 확인을 통한 데이터 보완/수정		
		정밀도	- 변수 별 값/범주의 범위/규모 확인 필요한 경우 Query/수작업을 통한 값/범주 재정의 - 데이터 값/범주의 시점 별 반복성 확인 : Model, Chip Info 등 상황 별 입력 범주 구분과 반복성		
Data PST	Preprocessing	Syntax	1) 대소문자 혼재 2) 빈 칸 (범주의 앞, 뒤, 내) 3) 수기 입력으로 인한 오타자 4) 특수기호 혼재 5) 같은 뜻이나 다르게 표현	- Data 범주 내 빈칸(space) 사용 금지 - 모든 범주의 앞/뒤 빈칸 포함 여부 확인 - 범주 내 사용되는 대소문자 통일 - 범주 내 사용되는 특수 기호 통일 (예) 괄호 ({} [] 등) - 범주 내 2개 이상의 정보를 포함하는 경우 입력 순서, 글자 수 통일	
	Standardization				
		Transformation	Semantic	1) 범주의 정당성 없음 2) MECE한 범주가 아님 3) 같은 뜻이나 다르게 표현 4) NA값이 많아 사용 불가 5) 하나의 Feature에 다양한 의미가 있음	- 중복 Features 및 상/하위 Feature 구조 파악을 통한 특징 고찰 - 의미 별 표준 용어 정의 및 사전 List 작성 및 준수 - 예외적 상황은 새로운 Feature로 정의하고 범주 구분 - 각 Feature별 단일 활동/특징 부여 - 실무적 이유로 2개 이상의 정보를 포함하는 경우 표준 순서 정의 및 준수

실무적 해석

“능숙한 데이터 분석보다, 섬세한 해석이 더 중요하다.”
모든 분석은 실무적으로 해석하고, 이론적 최고 보다는 실무적 최적을 추구한다!



닭이 먼저일까, 달걀이 먼저일까??

닭이 먼저인가, 달걀이 먼저인가는 우선 달걀을 어떻게 정의하느냐에 따라 달라질 수 있습니다. 즉, 달걀을 '닭이 낳은 알' 정의할 것인가 혹은 '닭이 될 알'로 정의할 것인가에 따라 달라 집니다.

닭이 낳은 알이라면 당연히 닭이 먼저지만, 닭이 될 알이라면 달걀이 먼저가 되어야 합니다. 국어대사전에 의하면, 달걀은 닭이 낳은 알로 설명되어 있습니다. 즉, **국어대사전에 의하면 닭이 먼저입니다.**

핑 대신에 닭이란 말이 있습니다. 닭은 핑에서 진화해왔다고 합니다. 그렇다면 핑이 나온 알 중에서 닭으로 돌연변이가 발생했다고 봐야 할 것입니다.


이런 관점에서 본다면, **진화생물학은 달걀이 먼저**라고 이야기해주고 있습니다.

매년의 달걀의 총수와 닭의 총수를 집계해서,

그랜저 상관관계를 분석할 수 있습니다.

분석 결과에 의하면, 달걀의 수로는 닭의 수를 예측할 수 있지만, 닭의 수로는 달걀의 수를 예측할 수 없다고 합니다.

따라서 **통계학은 달걀이 먼저**라고 이야기해줍니다.




“모형을 만드는 것보다 데이터 탐색에서 더 많이 얻는다.”
탐색 결과의 요약본을 확인하고, 질문하라 !

No	분석을 통해 얻은 사실	실무적 해석
#1	▪ 모든 분석 결과를 한 페이지로 요약 ▪ 개별 사실들 간의 관계를 추가 탐색 ➔ 전체상을 가지고 insight를 추구	
#2		
#3		
#n		

Key Question (1) 그 밖에 없는가?
 (2) 실무적으로 합리적인가?

예측 모형에 대한 질문

- ① 다양한 머신러닝 알고리즘을 비교 평가했는가? 만능은 없으며, 모형은 단순할 수록 활용에 유리합니다.
(1)Best Fitting (2)Most Parsimonious
여러 가지를 적용했다면, 왜 알고리즘을 선택했는지 물어보면 됩니다.
- ② Test-Set으로 모형의 성능척도를 평가했는가? Training-Set으로 평가된 것이라면, Data Snooping을 의심합니다.
회귀분석은 R^2 를, 분류분석은 Confusion Matrix를 검토합니다.
- ③ 예측모형의 성능(회귀분석의 R^2 , 분류분석의 예측정확도)의 하한 목표는? 예측성능은 높으면 높을 수록 좋겠지만, 하한 목표는 절대적 기준은 없습니다.
실무적 적합성으로 판단해야 합니다.
- ④ 예측 모형의 성능을 추가 향상 방안은? 대부분의 경우 Data Size와 품질 문제. 하이퍼 파라미터로는 크게 움직이지 않습니다. 얼마 이상 되어야 한다는 일방적 지시는 Data Snooping을 유혹하는 것과 같습니다.
분석가는 어떻게든 만들어 낼 것입니다.
질문을 통한 넋지적 접근이 권고되는 이유입니다.
- ⑤ 실무적용 시 Risk 헤지 방안? R^2 와 예측정확도에는 항상 에러가 존재하고, 특히, 자동화의 경우 통신 장애등은 언제든지 발생할 수 있습니다.
- ⑥ 모형의 실무적 해석은? 실무적으로 해석할 수 있어야 지식이 됩니다.
예측정확도 만이 아니라, 설명가능성을 확인한다.
- ⑦ 인자 중요도? 모든 인자들이 동등하게 중요하지 않습니다.
Pareto 법칙(원인의 20%가 결과의 80%를 지배한다)은 일반적인 현상입니다.
인자들의 결과(Y)에 대한 영향도의 순위를 확인할 수 있습니다.
- ⑧ 개념 변질에 대한 모니터링 방법은? 개념 변질은 필연적입니다.
자동화를 과신하면, 체계적으로 오류에 빠질 위험이 있습니다.
- ⑨ Ad-hoc에 대한 유연성은? 실무에서는 갑자기 기준이나 정책이 바뀔 수도 있습니다.
이에 대한 유연성은 미리 검토해야 합니다.




모든 사고방식의 원점

모든 의사결정의 마디에서 두 가지 질문을 한다.

모든 올바른 의사결정의 근본

발산 : 모든 가능성의 탐색



수렴 : 실현 가능한 최적의 선택

핵심 요소

리더의 질문

발산 어떻게 가능성을 **충분히** 고려할 것인가?


“그 밖에 없는가?”

수렴 여러 가능성 중에서 어떻게 **합리적**으로 최종안을 선택할 것인가?

“근거는 무엇인가?”

* 발산과 수렴 단계를 섞지 않는 것이 중요.
수렴을 미래 생각하는 발산은 스스로 창조성의 장벽을 치는 것임.

Half Science, Half Art



Question or Comment ?!

고객도
모르는
고객을
알자



배운다
배운 걸
지우고
다시 배운다

