




# C-D-P\* Handbook vol. 5.0

고객가치혁신담당

\* C-D-P : CX-DX 시너지를 통해 고객 중심의 성과(Performance) 창출하는 LG전자만의 일하는 방식  
CX (Customer eXperience) - DX (Digital Transformation) - Performance 의 약자로 '-'로 구분하여 표기함

## 1. 그룹의 고객 가치 혁신 방향


## ★ ★ 연도별 키워드 속지

'19년 부터 연도별 키워드를 통하여 지속적 고객가치 혁신 방향성 수립 / 실천

'25년은 '도전과 변화의 DNA'를 기반으로 'LG만의 차별적 미래가치' 창출



★★★★ 고객 경험 5가지 요소 암기



## ★ 전자의 비전과 전략 방향 3가지

LG전자 비전 ‘**스마트 라이프 솔루션 기업**’으로 도약을 위해 집중해야 할 전략 방향

**1 포트폴리오 고도화**

- Where to Play ( Non-HW 사업모델 혁신, B2B 성장 가속, New to LGE 조기 성과 가시화)
- CPM (Corporate Portfolio Management) 관리 체계 고도화

**2 C-D-P 가속화를 통한 경영 성과 창출**

- 고객중심 일하는 방식 C-D-P (CX-DX-Performance) 가속화
- CX경영관리 체계 고도화
- 전사 Data 플랫폼의 활용과 글로벌 확산체계 정비/실행

**3 미래 준비 역량 강화**

- 기존 사업의 Full Potential 지원
- 기술 Pipeline 강화 / R&D 건전성 제고
- 전 세대가 공감하는 사랑 받는 브랜드 지향
- 경험 플랫폼으로서의 OBS 혁신



★ 운영 체계의 3가지 구성요소와 각각 세부 내용 이해

고객중심 기업으로 변화하기 위한 'LG만의 일하는  
방식/경영체계'

목표

CX 지향점


일하는 방식

C-D-P 일하는 방식

경영체계

고객중심 경영체계

★★ 전사 고객가치혁신 활동이  
추구해야 하는 절대적인 목표지점



CX-DX간 시너지를 통해 고객 중심의 성과를  
창출하는 LG만의 일하는 방식




고객 중심 회사로 전환을 위한  
핵심 경영 요소 재설계



## 2. C-D-P 운영 체계\_목표 체계

★★★★★ CX 지향점에서 FUN과 QCD 각각의 개념과 핵심 키워드 암기



고객에게 제공하는 궁극적의 목표

‘내 일상의 따뜻한 감동,  
더 나은 삶을 위한 즐거운 변화’

고객 감동을 위해 제공해야 할 핵심 가치

**First** 기대를 넘어선, 최고의  
**Unique** 삶을 바꾸는, 차별화된  
**New** 기존에 누리지 못한, 세상에 없던 경험

절대 훼손되면 안 되는 고객의 기본 가치

**Quality** 기본 품질을 넘어 감성품질까지  
**Cost** 기대를 뛰어넘는 합리적 교환가치  
**Delivery** 전체경험여정에서 고객과 신뢰  
속적

고객 감동을 위해 제공해야 할 **핵심 가치**

**First** 최고  
이



**기대를 넘어선, 최고의**

- No.1 디자인 / 성능 / 품질
- Touch Point별 최고의 고객 감동

**Unique** 차별화  
되



**삶을 바꾸는, 차별화된**

- 남들과 다른 폼팩터, 사용성
- 쉽고 편리한 삶으로 이끄는 서비스 경험

**New** 세상에 없던



**기존에 누리지 못한, 세상에 없던**

- 새로운 제품 카테고리 / 콘텐츠 / 서비스
- 업종 내 최초로 접목하는 혁신적 사업 모델

- 최고의 화질 OLED TV
- 초프리미엄 가전 'LG SIGNATURE'

- 이동하며 즐기는 프라이빗 스크린:스탠바 이미
- 세탁 건조를 하나로,; 워시콤보

- 매일 씻어입는 의류관리기 : 스타일러
- 나에게 맞춤 진화하는 가전 플랫폼 : 업가전

★★★★★ FUN과 QCD각각의 개념과 핵심 키워드 암기

절대 훼손되면 안 되는 **고객의 기본 가치**

**Quality**



**Cost**



**Delivery**



기본 품질을 넘어 감성품질까지 관리 기대를 뛰어넘는 합리적 교환가치 전체 경험여정에서 고객과 신뢰 축적

고객이 제품 구입 시  
가장 고려하는 품질은 무엇인가?

- 잔고장은 없을까?
- 제품, 기기연결 등 사용상 어려움은 없는가?
- 우리집에 잘 어울릴까?

고객이 생각하는  
합리적인 가격은 무엇인가?

- 원하는/사용한 만큼만 지불할 수 있을 때
- 항상 최상의 상태로 사용할 수 있을 때
- 많이 구입할 수록 확실히 더 좋아질 때

고객은 제품을 어떻게 만나고  
그 기분을 유지하고 싶어하나?

- 구매: 원하는 시간에 체험/구매 가능한가?
- 배송: 원하는 날 받을 수 있고, 변경 시 친절히 안내 하는가?

## 2. CX 성과관리 체계\_R-NPS

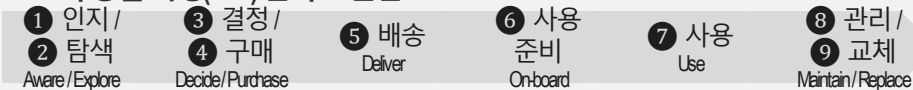
### ★★★ R-NPS 계산 방식 이해

#### LG R-NPS(Relationship NPS) 정의 및 계산 방식

자사제품 구매고객을 대상으로 CEJ 단계별 추천 의향을 조사하여 각 단계별 NPS를 조사하고 각 단계별 NPS 값의 산술평균으로 전체 R-NPS를 집계 한다.


$$R-NPS = \frac{\sum \left( \begin{array}{c} \text{인지/} \\ \text{탐색} \\ \text{R-NPS} \end{array} + \begin{array}{c} \text{결정/} \\ \text{구매} \\ \text{R-NPS} \end{array} + \begin{array}{c} \text{배송} \\ \text{R-NPS} \end{array} + \begin{array}{c} \text{설치} \\ \text{R-NPS} \end{array} + \begin{array}{c} \text{사용} \\ \text{R-NPS} \end{array} + \begin{array}{c} \text{관리/} \\ \text{교체} \\ \text{R-NPS} \end{array} \right)}{N(=6 \text{ CEJ})}$$

#### ※고객 경험 여정(CEJ) 전사표준안



\*LGR-NPS에서는 인지와 탐색, 결정과 구매, 그리고 관리와 교체 단계를 각각 한 단계로 묶어 총 6개의 여정으로 구분하여 측정

- 추천 의향 문항을 11점(0~10점) 척도로 측정하여 '추천고객 비율(Promoters %)'에서 '비추천고객비율(Detractors %)'을 빼서 NPS를 산출
- '추천 의향'이라는 단 하나의 문항으로 고객의 서비스 로열티를 측정
- 이론적으로 점수 범위는 -100점부터 +100점까지



Q. 100명의 고객을 대상으로 '순추천지수(NPS)'를 조사한 결과에서 NPS%를 구하시오.

구분    0점   1점   2점   3점   4점   5점   6점   7점   8점   9점   10점  
 인원수   3명   7명   5명   5명   5명   10명   10명   20명   25명   7명   3명  
 비추천자  
 추천자 비율(9~10) = (7 + 3) / 100 = 10 / 100  
 비율(0~6) = (3 + 7 + 5 + 5 + 5 + 10 + 10) / 100 = 45 / 100


NPS(%) = (추천자 비율 - 비추천자 비율) \* 100 = (10/100 - 45/100) \* 100 = -35%



★★ R-NPS, T-NPS 차이 이해

Competitive-NPS


• 최근 출시 상품의 상세 사용 경험을 경쟁 상품과 비교 / 평가(상품별 특화된 상세 설문 조사)



고객과 기업(브랜드)간의 현재 상태 및 전반적인 관계 파악을(진단)위해 측정되며, 주로 성과에 대한 주요 평가 지표로

|             |                            |
|-------------|----------------------------|
| 측정 대상       | 고객과 브랜드 간의 여정별 추천 의향       |
| 측정 주기       | 일정 기간 동안의 고객 경험 (1년~2년 이내) |
| 현황('24년 기준) | 7개 제품 대상 21개 국가            |

- NPS의 장점**
- 1. 간단하여 실행하기 쉽다는 것입니다.
  - 2. 기업성장과의 연관성이 깊다는 것입니다.
  - 3. 피드백의 적시성을 들고 있습니다.



제품이나 채널, 매장에서 고객 불만 사항 즉각 대응 및 현장 개선을 위해 측정되며, 주로 현장 개선을 위한 관리 지표로

|       |                            |
|-------|----------------------------|
| 측정 대상 | 특정 제품이나 채널, 경험 등에 대한 추천 의향 |
| 측정 주기 | 특정 거래 또는 상호작용 직후 (1개월 이내)  |
| 현황    | 상품 T-NPS, 접점T-NPS, 닷컴T-NPS |

- NPS 적용의 이슈**
- 1. 모든 산업에 적용할 수 없다.  
독점적 산업, 공급자가 주도권을 가진 사업 분야, 한번의 이벤트 성 사업 등에는 적용할 수 없다.
  - 2. 척도의 문제 : 사람이 11단계로 나누어 생각할 수 있는가의 문제
  - 3. 추천, 중립, 비추천의 기준 점수의 문제  
국가나 문화에 따라서, 기준 점수가 달라질 수 있다.

★★★★★ 3C2S의 항목과 정의, TAT(CDP내 DX 역할)

[CX기획단계]

### 5대 집중 고객경험 (3C 2S)

자사 사업을 통해 고객이 무엇을 경험하게 할 것인가?

고객의 마음과 상황을 알아서 맞춰주고,  
환경과 사회를 더 좋게 만드는 고객경험

**Connectivity** | 교차 / 융합

기기/환경/활동이 교차되어도  
매끄러운 고객경험

**Care** | 관리 / 돌봄

고객/가족/반려 대상의 건강과  
공간/환경/보안까지 세심히 돌보는 경험

**Customization** | 맞춤 / 최적


고객 개인의 경제/취향/상황에 따라  
최적화 되는 경험

**Servitization** | 구독 / 콘텐츠

필요한 상품을 필요한 만큼  
사용하고 지불하는 경험

**Sustainability** | ESG / 지속

깨끗하고 따뜻한 환경과 사회를  
지속하는 경험



- 1 Trigger**

Data 기반 고객을 더 깊이 이해하고 Insight 발굴

  - (내부)기기 사용 Data, VoC 분석
  - 페르소나 기반 Data 분석
- 2 Accelerator**

Digital 기술 기반 CX 구현에 필요한 솔루션 제공

Digital 기술을 통하여 고객 경험 구현

  - Data 분석 로직 / 시스템 개발
- 3 Tracker**

Data기반 고개경험 전달 모니터링

  - Data 수집 항목 및 방안 수립 구축
  - CX 및 성과 관리

| 집중 고객경험                    | 고객맥락                  | 고객니즈                            | 고객경험                |
|----------------------------|-----------------------|---------------------------------|---------------------|
| Connectivity<br>(교차/융합)    | 고객이 어떤 환경에서<br>무엇을 하든 | 기기/환경/활동이<br>교차되어도 문제없도록        | 매끄럽게<br>연결되는 경험     |
| Care<br>(관리/돌봄)            | 고객/가족/반려대상에<br>이르기까지  | 고객의 신체/정신/환경이<br>안전하고 건강할 수 있도록 | 세심히<br>돌보는 경험       |
| Customization<br>(맞춤/최적)   | 고객이 어떤 것을<br>선호하더라도   | 고객 개인의 경제/취향/상황에<br>꼭 맞을 수 있도록  | 맞춤화<br>되는 경험        |
| Servitization<br>(구독/컨텐츠)  | 고객의 경제상황과<br>필요에 따라   | 솔루션과 지불방식을<br>유연하게 선택할 수 있는     | 최적의 서비스를<br>제공받는 경험 |
| Sustainability<br>(ESG/지속) | 고객이 원하는<br>더 나은 삶을 위해 | 깨끗하고 따뜻한 환경과<br>사회를 만들어주는       | 지속가능한<br>소비 경험      |

★ 디지털 기술을(DX) 통한 새롭게 구현 가능한 가치 5가지 암기 필요

디지털 기술을 활용하여 새로운 가치의 구현....



① Personalization

개인화, 개성화, 개별화



② Agility

민첩성



③ Prediction

예측



④ Self-Organization

자기 조직화, 지능화



⑤ Platform

플랫폼, 참여시스템

# 1. 고객가치/경험/만족

★ OX 문제 출제 가능성 있음

**고객가치** Customer Value = 인지된 고객 혜택 Perceived Customer Benefits



거래에 대한 인식에 근거한 상품의 유용성  
Utility를

고객이 전반적으로 평가한 것.

즉, 고객의 특성에 따라 어떤 고객은 양,  
다른 고객은 품질이나 성능을, 또 다른 고객  
은  
편리함이나 친밀감 등 혜택을 느끼는 것이  
상이함.

- **총 고객 비용** Total Customer Cost

단지 금전적인 비용 뿐만 아니라  
혜택을 얻기 위해서 투입한 시간이나 노력  
등의

시리저 비용까지 포함하는 개념으로 확대됨.

대표적인 고객 가치의 유형

- 경제적 가치 제품/서비스의 성능, 품질, 가격, 시간 등
- 관계적/지원적 가치 고객과 기업 사이의 사회적 유대
- 기술적 가치 기업의 기술력에 대한 믿음
- 사회적 가치 사용자 집단에서의 유대 관계
- 정서적 가치 재미나 미학적 즐거움 등

**고객경험** CX, Customer Experience

: 고객이 되기 이전 단계인 상품과 서비스의 인지부터 사용 및 폐기 단계를 포함하는  
**고객 여정** Customer Journey의 모든 단계에서 인지적, 정서적, 감각적, 행동적 고객 반응의 총체.

: 고객이 직접 혹은 간접적으로 접한 기업 활동으로부터 느끼는 개인적이고 주관적  
고객의 직접 경험 뿐만 아니라,  
가족, 친구 등에 의한 간접 경험의 영향에도 관심  
CRM이 고객의 이성적 행동에 초점을 맞추었다  
CEM은 고객의 감정에 중점을 두어  
장기적 고객 관계 추구

고객은 **고객 여정** Customer Journey 속에서 기업의 직원, 제품, 절차 등을 만나면서 다양한 경험

**고객 여정** Customer Journey이란, 고객이 되기 이전 단계인 상품과 서비스의 인지부터  
궁극적으로 고객 충성에까지 이르는 일련의 과정을 말합니다.

고객 경험 관리의 중점 영역

- **제품** 제품 기능의 고객별 적합성
- **커뮤니케이션** 광고 등을 통한 지속적인 상호작용
- **커뮤니케이션 채널** 기업에 대한 접근 용이성
- **프로세스** 구매 여정의 편리성
- **가격** 가성비

## 2. CX 성과관리 체계\_R-NPS

★ OX 문제 출제 가능성 있음

### 고객만족 CS, Customer Satisfaction

: 상품과 서비스에 대한 고객의 기대와 실제 경험한 결과의 차이. 인지적 요소와 감성적 요소를 모두 포함

고객만족 = 거래특성적 만족 + 누적적 만족

· 거래 특성적 만족 : 특정한 상품거래, 사건, 서비스 접점 등 거래과정에서의 경험적 만족

· 누적적 만족 : 과거, 현재, 미래의 실행에 대해 만족

1단계 고객서비스(Customer Service)

고객에게 다양한 서비스를 제공

2단계 고객만족(Customer Satisfaction)

고객에게 기본서비스 외에 추가적인 서비스를 제공

3단계 고객감동(Customer Surprise)

감동적인 서비스에 깜짝 놀라게 만드는 단계.

### 고객충성 Customer Loyalty = 기존 고객의 재구매 + 입 소문을 통한 신규 고객 유입

고객 이탈 방지, 곧 기존 고객의 유지가 고객충성의 기본 모습입니다.

즉, 고객 충성이란 선호하는 상품이나 서비스를 향후에도 지속적으로 재구매하려는 의도나 행동을 말합니다.

여기에는 몇 가지 조건을 내포하고 있습니다. '일정 기간'과 '두 번 이상의 구매'를 말합니다.

또한, 경쟁사의 마케팅 노력에도 불구하고, 같은 브랜드 또는 같은 브랜드 묶음을 구매하고, 주변 사람들에게 해당 브랜드를 추천하여 긍정적 입소문을 퍼트리기도 합니다.

1. 산업 포화기에 고객충성은 생존전략이다.

- 신규 고객의 유치가 기존고객 유지보다 6배의 비용이 더 들어간다.
- 5%의 고객 유지율이 늘어나면 25%~100%의 수익이 증가한다.



2. 관계품질relationship quality 확보가 필요

<성능/품질→가치→만족> 뿐만 아니라, 장기적이고도 관계 지향적인 몰입commitment과 신뢰trust 구축 필요




## 2. 고객 충성도 측정 7가지 방법

1

### 설문조사에 의한 방법

타당도 높은 설문 문항을 개발이 중요

1. 나는 LG전자의 제품을 계속 사용할 것이다.
2. 나는 전자제품에 대해서는 LG전자를 우선적으로 선택할 것이다.
3. 앞으로 LG전자의 다른 제품도 더 많이 이용할 것이다.
4. 주위 사람들에게 LG전자 제품을 긍정적으로 이야기한다.
5. 주위 사람들에게 LG전자 제품의 좋은 점을 이야기한다.
6. LG전자 제품을 이용하는 주위 사람들에게 계속 사용하는 것을 지지한다.
7. 나는 주위 사람들에게 현재 LG전자 제품을 추천하고 싶다.
8. 나는 주위사람들이 LG전자 제품에 대해 물어오면 적극적으로 설명할 것이다.
9. 추가비용을 지불하게 되더라도 LG전자 제품을 구매할 용의가 있다.



2

### NPS Net Promotor Score, 순수 고객 추천지수

회사, 제품 또는 서비스를 친구나 동료에게 추천할 가능성을 평가

$$NPS(\%) = \frac{(\text{추천자수} - \text{비추천자수})}{(\text{전체 응답수})} * 100$$



### NPS의 장점

1. 간단하여 실행하기 쉽다는 것입니다.
2. 기업성장과의 연관성이 깊다는 것입니다.
3. 피드백의 적시성을 들고 있습니다.

### NPS 적용의 이슈

1. 모든 산업에 적용할 수 없다.  
독점적 산업, 공급자가 주도권을 가진 사업 분야, 한번의 이벤트 성 사업 등에는 적용할 수 없다.
2. 척도의 문제 : 사람이 11단계로 나누어 생각할 수 있는가의 문제
3. 추천, 중립, 비추천의 기준 점수의 문제  
국가나 문화에 따라서, 기준 점수가 달라질 수 있다.



## 2. 고객 충성도 측정 7가지 방법

### 3 반복구매율 Repeat purchase rate는

내부 데이터로서 파악 가능한 고객충성도 지표입니다.  
계산식은 아래와 같이 매우 간단합니다.

[반복 구매율 = 1년간 반복 구매 고객 수 / 1년간 총 고객 수]

이 지표가 의미를 가지는 것은...

Adobe의 미국 시장에 대한 조사에 의하면

전체 수익의 40%가 반복 구매를 통해 얻는 것으로 나타났는데,  
이는 재구매율은 8%로 달성한 성과라고 합니다.

유럽 시장에서도 역시 전체 수익의 38%가

10%의 반복구매율을 통해 얻는 것으로 나타났다고 합니다.

### 4 고객 평생 가치 Customer lifetime value (CLV)는

전자 상거래에 대한 고객 충성도의 지표로 많이 사용한다고 합니다.

이는 고객과의 관계 품질을 특히 고려한 것으로 보면 되겠습니다.

고객 평생 가치를 계산하는 방법은 여러 가지가 있지만  
아래와 같은 간단한 공식을 사용하여 계산할 수 있습니다.

CLV가 높을수록 충성도가 높은 것으로 판단합니다.

**고객 평생 가치 = (고객 당 연간 수익 \* 고객 유지 년수) - 고객획득 비용**

### 5 Upsell Ratio

= (제품을 한 종류 이상을 구매한 고객 수) / (제품 한 종류만 구매한 고객 수)

이는 신제품 구매 시의 고객 충성도를 측정하고자 할 때 사용.

일반적으로는 더 비싼 제품을 판매하는 Upselling과

보완재 등을 추가 판매하는 Cross-selling은 다른 것이지만

Upsell Ratio를 계산할 때에는 함께 포함시킨다



### 6

### 고객 관여 점수 Customer Engagement Score

사용빈도, 사용 수준, 서비스 사용 시간,  
핵심 기능 사용 빈도 등 다양한 변수를 조합

자신에게 적합한 지표를 만들어서 사용한다

이 지표는 전통 산업보다는 디지털 흔적이 남

온라인 사업에서 추적하기 용이합니다.

또한 이 지표는 고객 개인의 점수를 확인할 수 있으므로,  
고객 Segmentation의 기준으로 활용할 수도 있습니다.



### 7

### 고객충성도 지수 Customer Loyalty Index (CLI)

- 친구나 친지에게 추천하겠습니까?
- 미래에 다시 구매하겠습니까?
- 다른 제품도 사용해 보겠습니까?

위와 같은 질문으로 6점 척도로 고객의 응답을 구합니다.

이때 1은 [확실히 예]를, 6은 [확실히 아니오]를 나타냅니다.

그리고 이를 100점으로 환산합니다.

즉, 1=100, 2=80, 3=60, 4=40, 5=20, 6=0

그리고 모든 응답의 평균 점수를 취하여 CLI를 계산합니다.


기출 문제 연관  
L1/L2/L3 주요 이론

| 1단계 : Digital Starter                                                                                                                                                                                                                                                                                              | 2단계 : Digital Literate                                                                                                                                                                                                                                                                                   | 3단계 : Digital Performer                                                                                                                                                                                                                                                                                                                           | 4단계 : Digital Leader                                                                                                                                                                                                                                                                                                                                                     |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <div></div> <div>Digital Starter</div> <div><ul style="list-style-type: none"><li>▪ <u>모호한 디지털 비전</u></li><li>▪ 사업부서와 IT부서는 상황 별 필요에 따라 디지털 과제를 수행하며 공동 프로젝트 이외의 협력은 이루어지지 않음</li><li>▪ <u>조직의 디지털 역량이 현저하게 부족</u></li></ul></div> | <div></div> <div>Digital Literate</div> <div><ul style="list-style-type: none"><li>▪ <u>디지털 전략의 필요성을 인식하고 있으며 디지털 역량확보를 위한 로드맵이 구상됨</u></li><li>▪ <u>프로세스 디지털화를 추진 중</u>이며 사업부, 부서 단위에서 개별적인 디지털 과제를 수행</li></ul></div> | <div></div> <div>Digital Performer</div> <div><ul style="list-style-type: none"><li>▪ <u>높은 수준의 디지털 / Agile 문화보유</u></li><li>▪ 사업부서와 IT부서가 모든 영역에서 공동역량을 구축, 디지털 과제를 통합 관리하며 <u>성공적으로 개발 / 상용화 하고 있음</u></li><li>▪ 혁신적(disruptive) 사업과제를 일부 출범</li></ul></div> | <div></div> <div>Digital Leader</div> <div><ul style="list-style-type: none"><li>▪ <u>디지털 전략이 혁신, 가치전달, 기술 및 운영 전반에 걸쳐 내재화</u> 되어 있으며 주요 디지털 지표에서 경쟁사보다 우위에있음</li><li>▪ 디지털을 주요한 전사적 가치로 여기며 <u>디지털 전략과 로드맵이 정의됨</u></li><li>▪ 디지털 과제는 확실한 부가가치 창출을 통해 기업전략 추진에 기여 중임</li></ul></div> |

사전적 정의



데이터란 양적 혹은 질적 **변수들의 값의 집합**이다. 즉, 데이터는 개별 정보를 가진다. 데이터는 현존하는 정보나 지식을 더 잘 활용하거나 처리할 수 있도록 대변하거나 부호화된 것이다. 데이터, **정보, 지식과 지혜**를 매우 밀접한 관계에 있다. 하지만 이들은 서로간의 관계에서 고유한 역할을 하며, 각 용어는 고유한 의미를 가진다. **데이터를 수집하고 분석함으로써 의사 결정에 적합한 정보가 된다.**




실무적 정의 ★★★ OX 문제 대비

: Data란, 현장의 사실을 측정하여 숫자나 문자로 나타낸 것

- 현장이란 일이 이루어지는 모든 물리적, 정보적 공간을 포함한다
- 『숫자』가 모두 『Data』는 아니다
- 『Data』는 『현장/프로세스』의 『사실』을 『의도적』으로 『측정/관찰/조사/검사/실험』한 결과이다. 수명은 유한하다.

★★ 각 오차의 정의와 차이점 이해



오차를 줄일 수 있는 방법은 무엇인가?  
표본 오차 : 샘플링 방법 합리화

관련된 OX문제  
: 데이터의 양을 늘리면 표본 오차는 줄어든다.(O)  
: 데이터의 양을 늘리면 비표본 오차는 줄어든다.(X)

표본오차 : 모집단에서 샘플을 취하면서 어쩔 수 없이 발생하는 오차  
비표본오차 : 표본오차를 제외한 오차. 수집이나 측정단계에서 부주의로 알 수 없는 원인으로 발생하는 오차임.  
측정오차가 이에 해당 됨.

[대표적 측정 오차]




표본 추출에서 우연히 발생하는 (표본)오차는 표본 크기를 키우면 감소하고, 편의(bias)에 의한 (비표본 or 측정)오차는 표본추출 방법을 올바르게 적용하여 축소시킬 수 있습니다.

★★★ 변수 선택의 3가지 방법을 적고 설명하기


Feature Selection이란,  
수집된 데이터 세트에서 불필요한 특징들(변수들)을 제거하는 것을 말하며, 3가지 방법이 있습니다.

1 Filter Method 통계적 검정을 통한 유의한 인자 선택




| Y \ X | 연속형   | 이산형        |
|-------|-------|------------|
| 연속형   | 상관분석  | 선형 판별분석    |
| 이산형   | ANOVA | Chi-Square |

2 Wrapper Method 변수를 삭제하며 모델을 구축



Forward selection,  
Backward elimination,  
Stepwise Selection

3 Embedded Method 스스로 평가하여 모델을 최적화



Ridge regression, LASSO,  
Deep Learning

★★ 품질 요소 항목별 정의 암기 (5개이상 적으시오 문제 출제)

사실을 담아내는 데이터 만이 의미가 있습니다.

품질이 낮은 데이터는 사용하지 말아야 합니다.

고품질의 데이터를 얻으려면, 기술 뿐만 아니라 정성도 필요합니다.

### 데이터 품질 요소

- 타당성 알고 싶은 사실이 담겨야 한다.
- 적시성 필요 할 때, Data를 얻을 수 있어야 한다.
- 일관성 Data의 의미와 기준이 시간과 공간에 관계없이 유지되어야 한다.
- 대표성 수집된 샘플이 모집단을 대표해야 한다.
- 정확성 데이터는 가능한 참값에 가까워야 한다.
- 정밀성 누가 측정 및 수집하던, 몇 번을 반복하던 똑같은 값이어야 한다.
- 기타 완전성, 충분성, 보안성, 접근성 등

익명정보는 개인정보가 아니기 때문에 아무 제한 없이 자유롭게 활용이 가

능

★OX 문제 출제 가능성 있음 : 익명 정보라도 ~~~ 자유롭게 활용할 수 없다.



**Dark Data**

기업이 정보를 수집한 후, 저장만 하고 분석에 활용하고 있지 않은 데이터

**Data Lake**

가공되지 않은 다양한 종류의 데이터를 한 곳에 모아둔 저장소의 집합. 데이터를 효율적으로 분석/사용하고자 다양한 영역의 Raw 데이터 (가공되지 않은 데이터)를 한 곳에 모아서 관리하고자 하는 것

데이터  
가공  
전

**Data Warehouse**

데이터 기반 의사 결정을 돕는 Data 분석이 가능하도록 데이터를 모아둔 저장소.

데이터는 여러 소스로부터 수집하여 분석이 용이하도록 구조화가 완료

**Data Mart**

특정 운영 부서의 요구를 충족하도록 설계된 데이터 저장소.

Data Warehouse는 Data Mart는 집합에 해당.

예를 들어 Data Warehouse 가 도서관이라면

Data Mart는 특정 주제에 관한 책을 모아둔 도서관의 특정 섹션에 해당한다.

데이터  
가공  
후

★★ 데이터 종류별 4가지 척도 중 어디에 해당 되는지, 또는 OX 문제로도 나옴

명목 척도  
(Nominal Scale)

- ✓ **단순 구분 Data** : 순서나 차이를 말할 수 없음  
예) [남자와 여자], [업체 1, 2, 3], [변경 전과 후], [20대 고객과 30대 고객], ...

순서 척도  
(Ordinal Scale)

- ✓ **등급 분류 Data** : 순서는 말할 수 있으나 차이를 정의할 수는 없음.  
예) [금메달, 은메달, 동메달], [상, 중, 하], [한도 견본 등급] → 주로 출수를 사용  
  
※ (금메달과 은메달의 간격) = (은메달과 동메달의 간격) ???

구간 척도  
(Interval Scale)


- ✓ **등간격 자료**로써 절대적 원점이 없는 Data :  
구간으로 나누어져 있으나 구간 사이에는 무수히 쪼갤 수 있음.  
예) 온도(20℃는 10℃보다 2배 뜨거운 것이 아니다), 특정지수(생산성, 공정능력) 등  
  
※ 리커트 척도로 측정된 만족도 등은 구간척도로 취급하여 분석할 수 있다.

비율 척도  
(Ratio Scale)

- ✓ **비율이 존재하는 Data** : 시간, 길이, 무게 등으로 원점인 0이 존재 함.  
예) 2m는 4m의 2배이다., 1inch = 2.54cm 이다.

리커트 척도(Likert scale)는 설문 조사 등에 사용되는 심리 검사 응답 척도의 하나로, 각종 조사에서 널리 사용되고 있다. 리커트 척도에서는 응답자가 제시된 문장에 대해 얼마나 동의하는지를 답변하도록 한다.

측정 척도는 측정해야 할 정보의 양을 결정하고, Data의 유형은 분석 방법을 결정한다.



- \* 연속형 데이터가 가장 많은 정보량을 갖고 가장 많은 분석 방법의 적용이 가능하다.
- \* 연속형 데이터는 정보량이 많으므로, 이산형 데이터에 비해 적은 수의 데이터로도 질 높은 분석이 가능하다.

★ ★ 데이터를 주고 등폭 또는 등빈도 이산화 하시오 문제 출제

- 등폭 이산화 : 데이터 범위를 동일하게 가질 수 있도록 범위 설정  
ex) 10 | 21 22 23 29 | 31 → 범위를 10단위로 끊음
- 등빈도 이산화 : 데이터 개수를 동일하게 가질 수 있도록 범위 설정  
ex ) 10, 21 | 22 ,23 | 29, 31 → 개수를 2개씩

다음의 데이터를 이산화 (범주화) 하는 방법 2가지와 해당 방식으로 3구역으로 어떻게 나뉘는지 기술

0 4 8 12 16 16 20 24 26 28

A.

등폭 이산화 : 범위를 10 단위로 끊음

0,4,8    12,16,16,20    24,26,28


등빈도 이산화 : 개수를 3개씩

0,4,8    12,16,16    20,24,26,28

★ 데이터 수집 방법의 종류 및 개념 이해하기

# 데이터 생성

일정한 기준에 근거하여, 관심 사항을 기록



- 측정, 관찰, 조사, 실험, 검사 등의 결과
- 데이터 생성 과정에 오차 발생

VS.

# 데이터 수집

여러 데이터 소스로부터 필요한 데이터 획득



- Zero Party Data : 고객이 자발적으로 제공
- 1st Party Data 자사 데이터
- 2nd Party Data 파트너/제휴사 등의 데이터
- 3rd Party Data **빅데이터의 위험 요소** 외부 제3자 데이터

★ ★ 데이터를 주고 평균, 중앙값, 최빈값, 사분위수, 삼평균, 범위 계산 문제

★ ★ 산술평균, 기하평균, 조하평균 계산하기

★ 최빈값 개념 이해 : 최빈값을 없앨수도 있고 복수(여러 개) 일수도 있다

Case 1 : 1,2,3,4,5 -> 최빈값 없음,  
Case 2 : 1,2,2,3,3,4,5 -> 최빈값은 2, 3 임

삼평균 (tri-mean)과 4분위수 범위

LGE Internal Use Only

5. 문자값 요약

$$\text{삼평균} = \frac{F_L + 2M + F_U}{4} = \frac{1}{2} \left( M + \frac{F_L + F_U}{2} \right)$$

평균은 모든 데이터를 사용해서 계산되지만, 중앙값은 순위를 기초로 1개(또는 2개)의 값만을 사용한다는 단점이 있다. 이를 보완하기 위하여 중앙값과 2개의 4분위수를 반영한 삼평균을 사용할 수 있다.

$$\text{4분위수 범위(fourth spread, inter-quartile range)} = F_U - F_L \quad (= Q_3 - Q_1)$$

표준편차(standard deviation)는 가장 널리 사용되는 산포를 나타내는 값이다. 하지만 이는 평균처럼 극단값(outlier)의 영향을 크게 받는다. 이러한 이유로 탐색적 단계에서는 표준편차나 범위(range)보다는 저항성이 좋은 4분위수 범위(IQR)을 선호한다. 이는 전체 데이터에서 중심 부분 50%를 포함하는 범위이다.

★★★ 심슨의 패러독스 설명하기

발생 원인 : 데이터 불균형(데이터 크기 차이), 중요변수 누락, 교호작용

부분에서 성립하던 성질이 부분을 합한 전체에선 성립하지 않는 것을  
심슨의 역설(Simpson's Paradox)라고 합니다.  
요약 통계량을 사용할 때에는 주의해야 합니다.


| 전체  | 지원자  | 합격자 | 합격률 |
|-----|------|-----|-----|
| 남학생 | 1150 | 815 | 71% |
| 여학생 | 820  | 185 | 23% |

48%의 차이 → 여성 차별 ???

| 문학부 | 지원자  | 합격자 | 합격률 |
|-----|------|-----|-----|
| 남학생 | 150  | 15  | 10% |
| 여학생 | 700  | 85  | 12% |
| 공학부 | 지원자  | 합격자 | 합격률 |
| 남학생 | 1000 | 800 | 80% |
| 여학생 | 120  | 100 | 83% |

오히려 여학생의  
합격율이 높았음

★ 존튜키 4R's





EDA (Exploratory data analysis, 탐색적 자료 분석)에서는  
특히 이상점outlier, 패턴과 추iTrend, 인자 간의 비교Comparison와 관계Relationship에 주목한다.

EDA는 철저히, 살살히, 하나 하나 분석하는 끈질김이 필요합니다. 때문에 상당히 고단한 작업입니다.  
주어진 Data 본연의 모습에 집중하여 통계적 가정이 포함되지는 않지만,  
데이터의 변환, 변수 결합 등을 통해 훨씬 풍성하고, 많은 분석을 할 수 있다.

목적에 적합한 시각화 기법 선택



다양한 데이터 시각화 방법의 예 (출처: datavizcatalogue.com)

단변량 : 독립변수가 하나인 경우  
이변량 : 독립변수가 2개인 경우  
다변량 : 독립변수가 2개 초과인 경우

정해진 절차가 있는 것은 아니나, 다음과 같은 순서를 따를 것을 추천

|              |                       |
|--------------|-----------------------|
| 순서1. 단변량의 분포 | 중심위치, 산포, 모양, 이상점, 패턴 |
| 순서2. 변수 간 비교 | 이상점, 패턴               |
| 순서3. 변수 간 관계 | 이상점, 패턴               |
| 순서4. 시계열 변화  | 이상점, 패턴, 추이           |
| 순서5. 공간 분포   | 이상점, 패턴, 추이           |

적합한 데이터가 있을 때

저항성(resistance)이란 자료의 일부가 파손되었을 때 영향을 적게 받는 성질을 말한다  
= 이상치 등

|                               | <u>평균</u> | <u>중앙값</u> | <u>표준편차</u> | <u>IQR</u> |
|-------------------------------|-----------|------------|-------------|------------|
| [데이터#1] 1, 2, 3, 4, 5, 6, 100 | 17.3      | 4          | 36.5        | 3          |
| [데이터#2] 1, 2, 3, 4, 5, 6      | 3.5       | 3.5        | 1.9         | 3          |


평균과 표준편차에 비해서, 순위에 기반한 중앙값과 4분위 범위(IQR)은 극단값의 영향을 덜 받는다.

탐색적 분석에서는 평균과 표준편차 보다는 주로 중앙값과 IQR을 사용한다.

잔차(residual)란 개별 관측값이 주된 경향에서 벗어나 있는 정도를 말한다.  
중심(평균 또는 중앙값)에서 떨어진 정도를 계량화 할 수 있다.

[예] 중앙값을 기준으로 잔차를 계산한 경우

| 번호              | #1  | #2 | #3 | #4 | #5 | #6 | #7 | #8 | #9 | #10 | #11 |
|-----------------|-----|----|----|----|----|----|----|----|----|-----|-----|
| 관측값             | 5   | 8  | 9  | 10 | 11 | 15 | 16 | 19 | 21 | 29  | 310 |
| 잔차<br>(관측값-중앙값) | -10 | -7 | -6 | -5 | -4 | 0  | 1  | 4  | 6  | 14  | 295 |



☞ 유난히 잔차가 크다.  
왜 이렇게 큰 잔차가  
나왔는지 그 이유를 탐색  
(Outlier의 탐색)


추론 통계(가설검정,CDA)에서 이상치는 분석의 ‘적’이지만,  
탐색적 분석에서 이상치는 Insight 발굴을 위한 소중한 탐색의 대상 이다.

★ 이상점 탐색 방법: Outlier로 판단되는 경우



각 데이터 포인트가 평균으로부터 얼마나 떨어져 있는지를 표준편차 단위로 측정.  
일반적으로 z-점수가 ±3을 초과하는 경우 아웃라이어로 간주.

1 정규 분포 기반 : Z값, Tukey's Fence

- ✓ Scaling 필요
- ✓ 분포가 맞는 경우, 신뢰구간 등 통계적 의사 결정 활용
- ✓ 그러나 특히 고차원에서는 분포가 들어 맞지 않는 경우가 많다.




2 회귀 모형 기반 : 강건회귀 적합 후 잔차의 크기를 Outlier Score로 활용




✓ Scaling, 특히 선형 모델 적합 시

3 히스토그램 기반 : 구간에 포함된 개체의 빈도를 Outlier Score로 활용



- ✓ 빈의 수 (혹은 빈의 너비)를 잘 설정하는 것이 중요
- ✓ 자료가 다변량이면 각 속성에 대한 히스토그램으로 이상 점수를 구한 뒤 그것들을 모아 총 이상 점수를 구하는 방법이 기본적 방법이다.
- ✓ 혹은 다변량 자료를 선형 결합을 통해 차원 축소 후 탐색할 수 있다.
- ✓ 변수 사이의 교호작용을 볼 수 없다. 어떤 개체가 두 속성 각각에서 흔한 값을 가지면서도 그 조합은 매우 드문 경우, 히스토그램 기반 기법은 이것을 이상값으로 잡아내지 못 할 것이다.

1 신경망(Neural network) 기반



Multi-Class와 One-Class에 모두 적용할 수 있다.


Multi-Class의 경우, 신경망이 여러 정상 클래스를 학습한 후에 테스트 자료를 투입하여, 그 출력 값으로 이상 여부 판단.

One-Class인 경우 복제 신경망 사용. 학습된 신경망으로 압축한 뒤 복원하였을 때 발생하는 복원 오차가 크면 이상으로 판단

복원오차  $D = \sum (X_i - X'_i)^2$  (원 데이터 값 - 복제 후 데이터 값)<sup>2</sup>

$\frac{1}{2} \sum (X_i - X'_i)^2 \rightarrow Anomaly$

2 베이저안 네트워크(Bayesian network) 기반



Multi-Class 문제에 적용.


분류 문제일 때 나이브 베이저안 네트워크로 테스트 개체의 각 정상 클래스와 이상에 대한 사후 확률을 추정해 가장 높은 확률에 해당하는 클래스로 지정하다

3 SVM(Support vector machine) 기반


One-Class 문제에 적용.

SVM을 이용하여 결정 경계를 학습.

결정 경계에만 초점을 맞추므로, 분포에 강건한 장점이 있다.



4 결정 규칙(Decision rule) 기반



Multi-Class와 One-Class 모두를 지원.  
의사결정나무 등의 결정 규칙 학습 알고리즘을 이용해 결정 규칙을 학습한다. 범주형 자료의 이상치 탐색에 특히 유용하다.


분류 기반 이상 탐지 기법의 장단점

- 여러 강력한 알고리즘들을 이용할 수 있다.
- 이미 학습된 모형에 대해 예측만 하면 되므로 테스트 과정이 매우 빠르다.
- Multi-Class에서는 각 정상 개체 종류에 대한 Label을 구하기 어려울 수 있다.
- 신경망 모형의 경우 학습을 위해서 뛰어난 성능의 모형이 필요하다는 점이 문제 될 수 있고, SVM을 사용할 때 어떠한 커널을 사용해야 할지 결정해야 한다.
- 각 개체에 대한 이상 점수가 필요한 경우에는 라벨만 지정하는 기법들을 활용하기 어렵다.




① 「정상값들은 하나 또는 몇 개의 군집에 모여 있고, 이상 값은 군집에 속하지 않는다」고 가정

- 모든 개체를 군집에 넣지 않아도 되는 DBSCAN Density-based spatial clustering of applications with noise, ROCK, SNN 군집화 등의 알고리즘을 활용
- 군집을 찾아내는 것이 주된 목적이기 때문에 이상 탐지에 최적화되어 있지 않다는 단점이 있다.




② 「군집의 중심(centroid) 중 가장 가까운 것과의 거리가 짧으면 정상값, 길면 이상값이다」라고 가정

- 먼저 군집화를 하고, 개체가 포함된 군집의 중심과 개체 사이의 거리를 이상 점수로 활용
- SOM(self-organizing map.), K-Means, EM 알고리즘 활용
- 이상값들이 군집을 이룰 때 매우 취약한 성능을 보임



### ③ 「정상 값은 크거나 조밀한 군집에, 이상값은 작거나 한산한(sparse) 군집에 속한다」고 가정

- 개체가 속한 군집의 크기나 밀도가 이상 여부 판단 기준
- CBLOF(cluster-based local outlier factor) 등의 응용 기법




#### 군집화 기반 이상 탐지 기법의 장단점

- 비지도 방식으로 작동된다.
- 적당한 군집화 알고리즘만 있으면 복잡한 자료도 다룰 수 있다.
- 테스트 과정이 빠르다.
- 성능이 군집화 알고리즘이 정상 개체의 군집을 얼마나 잘 잡아내는지에 달려 있다.
- 많은 방법이 군집화의 부산물로 이상 탐지를 진행하므로, 이상 탐지에 최적화되어 있지 않다.
- 다수의 군집화 알고리즘이 모든 개체에 군집을 지정하기 때문에, 이상 값이 큰 군집에 들어가 정상값으로 판단될 수 있다.
- 이상값이 군집을 이루는 경우 극도로 취약해지는 기법들이 있다.




- 데이터를 차원 축소 후, 축소된 차원에서 정상과 이상을 식별하는 방법
- 주성분 분석이 차원 축소 방법으로 가장 많이 이용된다.



#### 스펙트럴 이상 탐지 기법의 장단점

- 고차원 자료 처리에 적합하며, 다른 기법의 적용을 위한 전처리처럼 사용할 수도 있다.
- 비지도 학습이 가능하다.
- 자료를 보낼 저차원 공간에서 정상, 이상값이 제대로 분리되어야만 유용하다.
- 보통 계산 복잡도가 크다.

- '이상값은 정보량의 불규칙을 유발한다'고 가정하고 아래의 흐름을 따른다.
- 이때 Kolmogorov 복잡도, 엔트로피, 상대 엔트로피와 같은 척도로 구한 자료의 정보량(information content)을 분석한다.



정보 이론 이상 탐지 기법의 장단점

- 비지도 방식이 가능하다.
- 자료의 분포에 대한 가정이 필요하지 않다.
- 성능이 정보량 척도에 크게 의존하며, 이상값이 많이 있어야 검출이 가능할 때가 많다.
- 순차, 공간 자료에 대한 기법의 성능은 부분구조의 크기에 영향을 받는 데, 최적의 크기를 구하기 쉽지 않다.
- 각 개체의 이상 점수를 구하기 까다롭다.

재표현시 주요 point: 목적이 훼손(정보가 손질) 되지 않는 변환이어야 함.

**재표현(Re-expression)이란 원래의 값을 적절한 척도로 변환하는 것을 말한다.**  
(예, 로그 변환, 제곱근 변환, 역수 변환 등)

분석의 목적 달성을 위한 수단

| A   | B  | C  |
|-----|----|----|
| 100 | 60 | 40 |




Data Transformation

| $A^2$ | $B^2$ | $C^2$ |
|-------|-------|-------|
| 10000 | 3600  | 1600  |


Feature Extraction

| A+B | A+C | A+B+C |
|-----|-----|-------|
| 160 | 140 | 200   |


■ 실수



■ 비율



■ 점유율



특징추출 **Feature Extraction** 은 원본 특징의 조합으로 새로운 특징을 생성 하는 것으로  
현상을 보는 새로운 관점을 제공

키와 몸무게

|         |         |
|---------|---------|
| 키 크고 뚱뚱 | 키 크고 날씬 |
| 표준?!    |         |
| 키 작고 뚱뚱 | 키 작고 날씬 |



= 체중(kg) / 키(m)<sup>2</sup>

BMI(Body Mass Index, 체질량 지수)

단위 : kg/m<sup>2</sup>


|                                 |       |         |       |      |
|---------------------------------|-------|---------|-------|------|
| BMI(체질량지수) = 체중(kg) / 신장 2(m2)% |       |         |       |      |
| 바디                              | 지방 부족 | 표준      | 지방과다  | 비만   |
| BMI<br>체질량지수                    | <16.5 | 16.5~25 | 25-30 | > 30 |

데이터 변환은 데이터를 보다 손쉽게 다룰 수 있도록 도울 수 있다.  
👉 분석의 명확성, 해석의 용이성





왜도(skewness) =  $S = \frac{(Q_3 - M) - (M - Q_1)}{(Q_3 - M) + (M - Q_1)}$

$Q_3 = F_U$   
 $M = Q_2$   
 $Q_1 = F_L$



- $-1 < S < 1$
- $S \approx 0$ , 데이터는 좌우 대칭형태 이다.
- $S > 0$ , 데이터의 분포는 오른쪽 긴 꼬리 형태이고, 1에 가까울 수록 그 정도가 심하다. 이를 양의 왜도라고 한다.
- $S < 0$ , 데이터의 분포는 왼쪽 긴 꼬리 형태이고, -1에 가까울 수록 그 정도가 심하다. 이를 음의 왜도라고 한다.




# 힌클리의 간편법 (Hinkley's Quick Method)

$$d = \frac{\bar{X} - M}{d_F = IQR}$$

$\bar{X}$  =평균  
M=중앙값  
 $d_F$ =사분위범위

- $d > 0$  이면 양(+)의 왜도를 가진다.
- $d < 0$  이면 음(-)의 왜도를 가진다.
- $d \approx 0$  이면 분포는 분포는 대략적으로 좌우 대칭 형태를 가진다.





## 대칭성 진단 Ⅱ. 대칭도(symmetric plot)

### 대칭성 진단 Ⅱ. 대칭도(symmetric plot)

- (1) 데이터를 오름 차순으로 순서화 한다.
- (2)  $(v_i, u_i), i = 1, \dots, n/2$  또는  $(n+1)/2$ 를 도식한다.
  - $v_i = \text{median} - x(i)$
  - $u_i = x(n+1-i) - \text{median}$
- (3)  $u = v$ 의 기준 직선을 추가한다.

### 해석 기준

- $(v_i, u_i)$  점들이 기준 직선에 가까이 위치하면, 데이터가 좌우대칭 형태를 가진다.
- 데이터가 양의 왜도를 가지면 점들이 기준선의 위에 위치한다.
- 데이터가 음의 왜도를 가지면 점들이 기준선의 아래에 위치한다.
- 원점(0,0)에 가까운 점은 데이터의 중앙값과 가까운 값에 해당하고, 오른쪽에 위치한 점들은 순서화된 데이터의 양쪽 끝에 위치하는 점들에 해당한다. 왜도가 크면 클수록 오른쪽에 타점된 값들은 기준선에서 더욱 멀어진다.

## 재표현의 사다리

## 기준 함수

올라가기

**p=2**

**p=1**

**p=0.5**

**p=0**

**p=-0.5**

**p=-1**

**p=-2**

 $x^2$  $x$ 
$$\sqrt{x}$$
 $\log x$ 
$$\frac{-1}{\sqrt{x}}$$
$$\frac{-1}{x}$$
$$\frac{-1}{x^2}$$

## 내려가기

### 재표현의 사다리 타기 : p의 결정

- 양(+)의 왜도인 경우  
: 재표현의 사다리를 아래로 내려가면서 변환을 시도한다.
- 음(-)의 왜도인 경우  
: 재표현의 사다리를 위로 올라가면서 변환을 시도한다.
- $p$ 는 가능한 0.5씩 증감하면서 적용한다.

### 3-요약점(3-summary point)을 이용하여 관계의 선형성을 진단하는 방법

#### 3-요약점과 절반의 기울기 비 (Three Summary Points and Half-slope Ratio)

데이터  $(x_i, y_i)$ 로  $n$ 개의 데이터 쌍이 주어져 있을 때 ( $i = 1, 2, \dots, n$ )


1.  $x$  기준으로 순서화된 데이터를 3개 그룹으로 나눈다.  
 이때 그룹 내의 데이터 수는 가능한 동일하게 한다.  
 즉, 데이터 수가  $3k$ 개면 각 그룹에  $k$ 개의 데이터를 할당  
 데이터 수가  $3k+1$ 개 이면, 중간 그룹에  $k+1$ 개를 할당하고, 나머지 그룹은  $k$ 개 할당  
 데이터 수가  $3k+2$ 개 이면, 중간 그룹에  $k+2$ 개를 할당하고, 나머지 그룹은  $k$ 개 할당
2. 데이터의 각 그룹(left, center, right)의  $(X_{\text{median}}, y_{\text{median}})$ 으로 3개의 기준점을 선택한다.  
 즉,  $(x_L, y_L)$ ,  $(x_C, y_C)$ ,  $(x_R, y_R)$
3. 중심을 기준으로 왼쪽과 오른쪽을 연결한 2개 선의 기울기를 계산하고, 이를 이용하여 절반 기울기의 비 (half-slope ratio,  $b_H$ )를 계산한다. 즉,  $b_H = b_R/b_L$   
 여기서,  $b_L = (y_L - y_C) / (x_L - x_C)$ ,  $b_R = (y_C - y_R) / (x_C - x_R)$ 이며, 동일한 부호를 가져야 한다.

3-요약점(3-summary point)을 이용하여 관계의 선형성을 진단하는 방법

$b_H$ 의 해석


- $b_H > 1$ ,  $y=f(x)$ 는 아래로 오목한 형태
- $b_H < 1$ ,  $y=f(x)$ 는 위로 오목한 형태
- $b_H \cong 1$ ,  $y=f(x)$ 는 직선에 가까운 형태

계산된  $b_H$ 값에 의하여  
직선이 아니라고 판단되면  
재표현의 사다리를 이용하여  
적절하게 변환한다.



★★ 데이터를 주고 4가지 유형중 어떤 것인지 데이터로 확인하고 변환 공식을 적기

계산된  $b_H$  값에 의하여 직선이 아니라고 판단되면, [그림 6.11]과 재표현의 사다리를 이용하여 선형 관계를 만족시키는 개별  $x$ 와  $y$ 의 멱승 변환을 고려할 수 있다.




변수 별로 (1) 큰 방향인 경우, 재표현 사다리를 위로 (2) 작은 방향인 경우, 재표현 사다리를 아래로 적용

그림 6.11:  $y = f(x)$  그래프 형태에 따른 재표현의 사다리 적용 기준



★★ 데이터를 활용하여 이상점 탐색하기



Box plot을 통해 얻을 수 있는 정보

- 5개의 통계량과 자료의 평균값, 사분위수 범위를 쉽게 파악
- 이상치에 대한 추가적 조사를 할 수 있도록 함
- 자료 분포의 비 대칭도를 파악→자료의 평균과 중앙값을 비교
- 특히 그룹간의 분포를 비교하는 데 효과적

사분위수

$$Q_1(25\%) = X_{\frac{(n+1)}{4}}$$
$$Q_2(Median) = X_{\frac{2(n+1)}{4}}$$
$$Q_3(75\%) = X_{\frac{3(n+1)}{4}}$$

★★ Box Plot 단점


박스 그림은 다음과 같은 단점을 갖는다.

- 고려된 데이터의 수( $n$ )를 확인할 수 없다.
- 서로 다른 집단이 혼합(Mix)된 다봉 구조(multi-modal)를 진단하지 못한다.


박스 그림



박스 그림 + 점 그림



바이올린 그림




- \* 산포가 안정적이지 않는 경우 3가지
  - 1) 빈도를 기준으로 집계된 데이터
  - 2) 일정 집계 단위 별로 비율로 정리된 데이터
  - 3) 서로 다른 집계 단위 또는 서로 다른 환경에서 측정된 데이터


★★★ Box Plot으로 두 집단의 평균 비교시 반드시 산포가 안정화 되어 있어야 한다

Box Plot은 단일집단에 대한 대략적인 정보를 표현하는 것 보다는 여러 집단을 비교할 때 더욱 유용하다. 일반적으로 집단의 비교를 위해서는 산포(spread)가 유사해야 한다.

[예시적] 남녀 흡연에 따른 입원 일수 비교



[예시적] 월별 지진 강도 비교 (추이/경향)






★그래프 분석을 통해 B 사업장이 법적 Risk가 없는 것으로 확인된다. 라는 결론을 내렸다. 이경우 문제점과 해결 방안을 적으세요

▪ 비교Comparison/ 이산형 X에 따른 Y 혹은 다른 X의 값이나 범주 비중의 비교


✓ 평균 비교의 함정:누가 더 우수한가?

- COD 농도 (1회/일 측정 관리)
- 규격 10 mg/l 이하 (망소 특성)
- 제반 조건은 동일한 것으로 가정




지난 1개월 간의 측정 결과 평균



A 사업장




B 사업장



■ 비교 Comparison / 이산형 X에 따른 Y 혹은 다른 X의 값이나 범주 비중의 비교


✓ 빈도 비교의 함정...

이슈 발생건수 비교




|       |     |     |
|-------|-----|-----|
| 구분    | A   | B   |
| 검토 대상 | 500 | 100 |
| 이슈 건수 | 100 | 50  |
| 불만율   | 20% | 50% |

이슈 발생을 비교



✓ 비율 비교의 함정...

합격을 비교



|       |      |     |
|-------|------|-----|
| 구분    | A    | B   |
| 검토 대상 | 3    | 100 |
| 합격수   | 3    | 80  |
| 합격율   | 100% | 80% |





기준점의 과도한 차이는 비교 자체를 의미없게 만듭니다.

★ 위 그래프 분석결과 B 사업장이 사고(이슈) 건수가 적다고결론을 내릴려고 한다. 이때의 문제점과 개선방안을 적으세요

✓ 상관관계와 인과관계

★★ [O/X 문제] : 상관 관계가 있으면 인과관계가 있다 ?

상관관계가 모두 인과관계인 것은 아니다.



★★★ 목적에 따른 구현 가능한 그래프 종류 이해하기

| 구분              | 막대<br>Bar | 파이<br>Pie | 히스토그램<br>Histogram | 박스<br>Box | 산점도<br>Scatter | 히트 맵<br>Heat Map | 모자이크<br>Mosaic | 등고선<br>Contour | 지도<br>Map |
|-----------------|-----------|-----------|--------------------|-----------|----------------|------------------|----------------|----------------|-----------|
| 크기 Magnitude    | ◎         | ○         |                    | ○         |                |                  |                |                |           |
| 순서 Order        | ◎         | ○         |                    | ○         |                |                  |                |                |           |
| 비율 Proportion   | ◎         | ◎         |                    |           |                |                  | ◎              |                |           |
| 편차 Deviation    | ◎         |           |                    | ○         | ◎              |                  |                |                |           |
| 분포 Distribution |           |           | ◎                  | ◎         |                |                  |                | ○              | ○         |
| 흐름 Flow         |           |           |                    |           | ◎              |                  |                |                |           |
| 변화 Change       |           |           |                    |           | ◎              |                  |                |                |           |
| 상관 Correlation  |           |           |                    |           | ◎              | ◎                |                |                |           |
| 연관 Association  |           |           |                    |           |                | ◎                | ◎              |                |           |
| 공간 Space        |           |           |                    |           |                | ○                |                | ◎              | ◎         |

데이터의 원래 값에서 노이즈를 제거하고, 더 부드러운 곡선을 생성하여 데이터의 기본적인 패턴이나 추세를 강조하는 과정입니다


평활화(smoothing)란 데이터 시퀀스에서 y의 변화 패턴을 탐색하는 방법

부드러운 곡선 적합을 통하여 데이터 시퀀스가 크게 변화는 지점-상승 또는 하강 등-의 규칙성과 주기의 존재 여부 그리고 주기 발생의 빈도를 검토한다.

$$data = smooth + rough$$

- 평활(smooth) : 추정된 곡선
- 거침(rough) : 평활을 벗어나는 잔차

※ 평활의 수학적 해석 보다 패턴의 해석이 중요하다.



## [예시] 3-중앙값 평활과 3-중앙값 평활 2번 반복

| 구분  | temp | 3  | 33 |
|-----|------|----|----|
| y1  | 60   | NA | NA |
| y2  | 70   | 60 | NA |
| y3  | 54   | 56 | 56 |
| y4  | 56   | 56 | 56 |
| y5  | 70   | 66 | 66 |
| y6  | 66   | 66 | 66 |
| y7  | 53   | 66 | 66 |
| y8  | 95   | 70 | 70 |
| y9  | 70   | 70 | NA |
| y10 | 69   | NA | NA |

3-중앙값 평활의 결과

- $m_1^{(3)} = \text{median}(y_0, y_1, y_2)$ , 즉 적용 불가
- $m_2^{(3)} = \text{median}(y_1, y_2, y_3) = \text{median}(60, 70, 54) = 60$
- $m_{10}^{(3)}$  역시 적용 불가

y1과 y10이 데이터 시퀀스의 끝점(End Points)

[예시] 끝점의 추정

| 구분 | temp | 3  |       |
|----|------|----|-------|
| y1 | 60   | NA | 끝점    |
| y2 | 70   | 60 | 끝점-1P |
| y3 | 54   | 56 | 끝점-2P |


- 끝점-2P와 끝점-P의 차이 =  $56 - 60 = -4$
- 끝점과 끝점-1P의 변화의 한계 =  $[0, 2] * (-4) = [0, -8]$
- 끝점 값은  $[60 + 0, 60 - 8]$  즉, 52~60 중 어느 값이라도 가능
- 평활된 끝점 값은 원데이터의 끝점 값과 가능한 같아야 하므로 60으로 결정

|     |    |    |       |
|-----|----|----|-------|
| y8  | 95 | 70 | 끝점-2P |
| y9  | 70 | 70 | 끝점-1P |
| y10 | 69 | NA | 끝점    |


- 끝점-2P와 끝점-P의 차이 =  $70 - 70 = 0$
- 끝점과 끝점-1P의 변화의 한계 =  $[0, 2] * 0 = 0$
- 따라서 평활된 끝점 값은 70으로 결정

평활이 완료된 데이터

| 구분  | temp | 3  | 33 |
|-----|------|----|----|
| y1  | 60   | 60 | 60 |
| y2  | 70   | 60 | 60 |
| y3  | 54   | 56 | 56 |
| y4  | 56   | 56 | 56 |
| y5  | 70   | 66 | 66 |
| y6  | 66   | 66 | 66 |
| y7  | 53   | 66 | 66 |
| y8  | 95   | 70 | 70 |
| y9  | 70   | 70 | 70 |
| y10 | 69   | 70 | 70 |




평활화



| 구분  | temp | 3  | 33 | rough |
|-----|------|----|----|-------|
| y1  | 60   | 60 | 60 | 0     |
| y2  | 70   | 60 | 60 | -10   |
| y3  | 54   | 56 | 56 | 2     |
| y4  | 56   | 56 | 56 | 0     |
| y5  | 70   | 66 | 66 | -4    |
| y6  | 66   | 66 | 66 | 0     |
| y7  | 53   | 66 | 66 | 13    |
| y8  | 95   | 70 | 70 | -25   |
| y9  | 70   | 70 | 70 | 0     |
| y10 | 69   | 70 | 70 | 1     |

*data = smooth + rough*

rough 추가 분석




숫자보다 패턴에 집중!!!



**분리 평활 (Split Smoothing)**

- (1) 중앙값 평활기 적용
- (2) 동일한 값으로 평활된 피크 또는 밸리를 기준으로 2개의 데이터 시퀀스로 분리(split)
- (3) 각각에 대하여 End Point Rule 적용
- (4) 통합하여 중앙값 평활기 적용



재평활(Rerough)은 거침(rough)에 남아있는 패턴을 추가로 설명하기 위하여 실행

$$\mathbf{data} = \mathbf{smooth} + \mathbf{rough}$$

여기서,

$$\mathbf{rough} = \mathbf{smooth}(\mathbf{rough}) + \mathbf{rough}(\mathbf{rough})$$

여기서,

$$\begin{aligned}\mathbf{data} &= [\mathbf{smooth} + \mathbf{smooth}(\mathbf{rough})] + \mathbf{rough}(\mathbf{rough}) \\ &= \mathbf{final. smooth} + \mathbf{final. rough}\end{aligned}$$

앞의 예제에서는 10개 데이터에서 변화가 없다.

해닝(Hanning)

- 데이터 시퀀스에서 인접한 3개의 값들에 대한 가중평균(weighted mean)으로 평활
- 중앙값 평활기 보다 부드러운 적합을 제공한다.

$$h_1 = y_1$$

$$h_i = \frac{1}{4}y_{i-1} + \frac{1}{2}y_i + \frac{1}{4}y_{i+1}, \quad i>1$$

$$\text{삼평균} = \frac{F_L + 2M + F_U}{4}$$

rerough 후 hanning 결과

| 구분  | temp | 3  | 33 | split | rerough | hanning |
|-----|------|----|----|-------|---------|---------|
| y1  | 60   | 60 | 60 | 60    | 60      | 60      |
| y2  | 70   | 60 | 60 | 60    | 60      | 60      |
| y3  | 54   | 56 | 56 | 60    | 60      | 61.5    |
| y4  | 56   | 56 | 56 | 66    | 66      | 64.5    |
| y5  | 70   | 66 | 66 | 66    | 66      | 66      |
| y6  | 66   | 66 | 66 | 66    | 66      | 66      |
| y7  | 53   | 66 | 66 | 66    | 66      | 67      |
| y8  | 95   | 70 | 70 | 70    | 70      | 69      |
| y9  | 70   | 70 | 70 | 70    | 70      | 70      |
| y10 | 69   | 70 | 70 | 70    | 70      | 70      |


원시 데이터에서 해닝을 적용하면 또 다른 결과를 얻을 수 있다.

# Different ?!

XXX Task에서  
고객의 Pain Point를 발굴 및 개선하여  
제품에 반영 후 판매 데이터를 수집한  
결과는 아래와 같다.

| 구분  | 개선 전   | 개선 후   |
|-----|--------|--------|
| 1분기 | 9,284  | 9,352  |
| 2분기 | 8,563  | 9,022  |
| 3분기 | 11,231 | 11,298 |
| 4분기 | 7,779  | 8,595  |
|     | 28,303 | 38,267 |

Task 활동을 통해 판매가 증가 되었다고 말할 수 있는  
가?



점추정

LGE Internal Use Only

- ❖ 점추정(Point estimation)
  - 모수에 가장 가까울 것으로 생각되는 하나의 값으로 모수를 추정
  - 추정량(확률변수, 측정전), 추정값(표본으로 부터 구한 측정값)
  - 예) 모집단의 평균은 55kg이다
- ❖ 점추정 방법
  - 적률법(method of moments): 기대값 이용
  - 최대가능도(우도)추정법(maximum likelihood estimation): 조건부 확률
  - 최소제곱법(least squares estimation): 회귀분석에서 사용

| 모수   |            | 점추정       |           |
|------|------------|-----------|-----------|
|      |            | 추정량       | 추정값       |
| 평균   | $\mu$      | $\bar{X}$ | $\bar{x}$ |
| 비율   | $\theta$   | $P$       | $p$       |
| 분산   | $\sigma^2$ | $S^2$     | $s^2$     |
| 표준편차 | $\sigma$   | $S$       | $s$       |

## 구간추정

### ❖ 구간추정(Interval estimation)

- 모수의 값이 속할 것으로 기대되는 일정한 범위(신뢰구간)를 이용하여 모수를 추정
- 표본오차가 존재 → 추정 시에는 점추정 보다는 구간추정을 이용

### ❖ 신뢰구간 (Confidence Interval)

- 일반적으로 신뢰수준은  $(1 - \alpha)$  로 측정
- 신뢰수준의 확률: 90%, 95%, 99% 중에서 95%
- 신뢰구간 95%의 의미

동일한 모집단에 대해서 동일한 방법으로 표본을 다시 뽑아서 신뢰구간을 구하게 되면 100번 중 95번은 모수를 포함 (표본분포의 의미)

### ❖ 방법

- (가정)모집단의 표준편차  $\sigma$ 를 알 경우 : 표준정규분포

$$\mu = \bar{x} \pm \frac{z_{\frac{\alpha}{2}} \sigma}{\sqrt{n}}$$

- (실제)모집단의 표준편차  $\sigma$ 를 모를 경우 : Student  $t$  분포

$$\mu = \bar{x} \pm \frac{t_{\frac{\alpha}{2}} s}{\sqrt{n}}$$

## 구간추정(표준정규분포)

LGE Internal Use Only

## ❖ 표준정규분포 사례)

- H자동차에서는 새로운 하이브리드 차량을 만들었다.
- 하이브리드 자동차의 평균연비는 정규분포를 따른다고 알려져 있고,
- 표준편차( $\sigma$ )는 1.0km/l로 알려져 있다.
- 랜덤하게 표본 10개의 자동차를 추출해서 연비를 조사했더니 16km/l가 나왔다.
- 새로운 하이브리드 차량 연비의 95% 신뢰구간은?

$$P\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

$$\begin{aligned}\mu &= \bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \\ &= 16 \pm 1.96 \frac{1.0}{\sqrt{10}} \\ &= 16 \pm 0.62 \\ &[15.38, 16.62]\end{aligned}$$

90% ( $z_{\alpha/2} = 1.645$ ), 95% ( $z_{\alpha/2} = 1.96$ ), 99% ( $z_{\alpha/2} = 2.576$ ):

**통상 신뢰 구간 수준은 95%로 주어짐 (1.96 암기)**

## 구간추정(t분포)

LGE Internal Use Only

## ❖ t분포 사례)

새로운 하이브리드 자동차의 평균연비를 측정하기 위해 표본 100개를 추출하여 연비를 측정하였다.

- 표본(n): 100
- 표본평균( $\bar{X}$ ): 16km/l
- 표본표준편차(s): 1.5, 표준오차( $\frac{s}{\sqrt{n}}$ ): 0.15

$$P\left(\bar{x} - t_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + t_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

$$\begin{aligned}\mu &= \bar{x} \pm t_{\alpha/2} \frac{\sigma}{\sqrt{n}} \\ &= 16 \pm 1.984 \frac{1.5}{\sqrt{100}} \\ &= 16 \pm 0.30 \\ &[15.70, 16.30]\end{aligned}$$

자유도에 따라  
t-분포표에서 확인

| DF  | t(0.1) | t(0.05) | t(0.025) | t(0.01) | t(0.005) | t(0.0025) |
|-----|--------|---------|----------|---------|----------|-----------|
| 1   | 3.078  | 6.314   | 12.706   | 31.821  | 63.657   | 127.321   |
| 2   | 1.886  | 2.920   | 4.303    | 6.965   | 9.925    | 14.089    |
| 3   | 1.638  | 2.353   | 3.182    | 4.541   | 5.841    | 7.453     |
| 4   | 1.533  | 2.132   | 2.776    | 3.747   | 4.604    | 5.598     |
| 5   | 1.476  | 2.015   | 2.571    | 3.365   | 4.032    | 4.773     |
| 6   | 1.440  | 1.943   | 2.447    | 3.143   | 3.707    | 4.317     |
| 7   | 1.415  | 1.895   | 2.365    | 2.998   | 3.499    | 4.029     |
| 8   | 1.397  | 1.860   | 2.306    | 2.896   | 3.355    | 3.833     |
| 9   | 1.383  | 1.833   | 2.262    | 2.821   | 3.250    | 3.690     |
| 10  | 1.372  | 1.812   | 2.228    | 2.764   | 3.169    | 3.581     |
| 20  | 1.328  | 1.729   | 2.086    | 2.539   | 2.845    | 3.091     |
| 30  | 1.294  | 1.699   | 2.045    | 2.479   | 2.750    | 2.947     |
| 40  | 1.282  | 1.684   | 2.021    | 2.449   | 2.717    | 2.901     |
| 50  | 1.274  | 1.674   | 2.009    | 2.433   | 2.699    | 2.877     |
| 60  | 1.269  | 1.668   | 2.000    | 2.427   | 2.691    | 2.871     |
| 70  | 1.266  | 1.665   | 1.995    | 2.423   | 2.687    | 2.867     |
| 80  | 1.264  | 1.663   | 1.993    | 2.421   | 2.685    | 2.865     |
| 90  | 1.263  | 1.662   | 1.992    | 2.420   | 2.684    | 2.864     |
| 100 | 1.262  | 1.661   | 1.991    | 2.419   | 2.683    | 2.863     |
| 110 | 1.261  | 1.660   | 1.990    | 2.418   | 2.682    | 2.862     |
| 120 | 1.260  | 1.659   | 1.989    | 2.417   | 2.681    | 2.861     |
| Z   | 1.282  | 1.645   | 1.960    | 2.326   | 2.576    | 2.807     |

모비율 추정

LGE Internal Use Only

❖ 비율의 추정

- 비율의 평균

$$\pi = \frac{x}{N} \qquad p = \frac{x}{n}$$

- 비율의 표준오차(중심극한정리)

$$\sigma_p = \sqrt{\frac{\pi(1-\pi)}{n}} \qquad \sigma_p = \sqrt{\frac{p(1-p)}{n}}$$

- 비율의 정규분포 조건 (양쪽 표본 모두 5명 이상)

$$n\pi \geq 5 \text{ and } n(1-\pi) \geq 5$$

★ 만약, 조건이 충족되지 않으면 이항분포 또는 포아송 분포로

- 비율의 신뢰구간(정규분포일 경우)

$$\pi = p \pm z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}}$$

모비율 추정

LGE Internal Use Only

- ❖ G텔레콤은 고객의 이탈율을 조사하기 위해 500명의 고객을 샘플로 이탈가능성을 조사하였다. 500명 중 50명이 앞으로 이탈할 것으로 나타났다. 이탈율의 신뢰구간은?

$$p = \frac{x}{n} = \frac{50}{500} = 0.100 \qquad np = 50 \times 0.1 = 5$$

$$\begin{aligned} \pi &= p \pm z_{\alpha/2} \sqrt{\frac{p(1-p)}{n}} \\ &= 0.100 \pm 1.96 \sqrt{\frac{0.100(1-0.100)}{500}} \\ &= 0.100 \pm 0.026 \\ &[0.074, 0.126] \end{aligned}$$




데이터 수와 신뢰 구간


고객 50명 조사 결과 만족도 평균 4.0


- ▶ “ 모든 고객의 만족도를 조사하여 평균을 취하면, 평균은 0점에서 5점 안에 존재할 것이다.”  
→ 신뢰도 100%지만, 추정의 의미가 없다.  
따라서, 통상 신뢰수준 95%에서 구간을 구한다.

★★★ 데이터 수에 따른 신뢰구간의 관계



- 1. 데이터 수가 많아지면 구간은 좁아진다.
- 2. 산포가 크면 구간은 넓어진다.
- 3. 신뢰수준이 커지면 구간은 넓어진다.






# One sample-t

❖ 문제의 정의

- B아이스크림회사에서 판매하는 아이스크림 중 파인트의 무게는 320g이다.
- 그러나 G대학 앞에 있는 점포에서 파는 아이스크림의 무게가 320g이 아니라는 소비자들의 불만이 있었다.
- 이에 따라 소비자단체에서는 B아이스크림회사에서 만든 아이스크림이 320g인지를 검사하고자 한다.



One Sample t-test(일표본 t-검정)


- 가설검정
- $H_0: \mu = 320$
- $H_1: \mu \neq 320$

| 무게1   |
|-------|
| 304.9 |
| 305.2 |
| 304.0 |
| 304.7 |
| 305.2 |
| 307.2 |
| 309.9 |
| 313.3 |
| 314.8 |
| 314.9 |
| 315.4 |
| 315.8 |
| 317.9 |
| 315.1 |
| 315.8 |
| 316.8 |
| 317.6 |

# Two sample-t

❖ 문제의 정의

- 이교수는 이번에 자동차 타이어를 교체하려고 하는데 수명이 긴 타이어로 교체하려고 한다.
- 시중에는 A회사의 타이어와 B회사의 타이어가 있는데, 이 교수는 이 중에서 어느 타이어를 골라야 하는가?



Independent Sample t-test(독립표본 t-검정)


- 가설검정
- $H_0: \mu_1 = \mu_2$
- $H_1: \mu_1 \neq \mu_2$

| 회사   | 수명1 |
|------|-----|
| A타이어 | 50  |
| A타이어 | 52  |
| B타이어 | 51  |
| B타이어 | 52  |
| A타이어 | 52  |
| B타이어 | 56  |
| B타이어 | 50  |
| B타이어 | 56  |
| A타이어 | 46  |
| A타이어 | 44  |
| A타이어 | 56  |
| A타이어 | 49  |
| B타이어 | 51  |
| B타이어 | 52  |
| A타이어 | 52  |
| B타이어 | 56  |
| B타이어 | 50  |
| B타이어 | 56  |
| B타이어 | 52  |
| B타이어 | 44  |

# Paired Sample t-test

❖ 문제의 정의

- K제약회사는 새롭게 개발한 다이어트약이 효과가 있는지를 보고하기 위하여 약의 효능을 검증하였다.
- 약을 먹기 전의 체중과 약을 먹은 후 3개월 후의 체중을 조사하였다.
- 과연 새로운 약은 다이어트에 효과가 있는가?



Paired Sample t-test(대응표본 t-검정)

- 가설검정

$H_0: \mu_d = 0$

$H_1: \mu_d \neq 0$

| 사전    | 사후1   |
|-------|-------|
| 83.69 | 77.01 |
| 71.80 | 69.03 |
| 78.45 | 71.03 |
| 75.11 | 71.04 |
| 78.19 | 71.06 |
| 71.70 | 74.08 |
| 62.43 | 62.08 |
| 76.16 | 73.10 |
| 82.23 | 75.10 |
| 74.41 | 74.10 |
| 76.36 | 73.10 |
| 76.17 | 73.11 |
| 75.68 | 76.11 |
| 71.01 | 69.12 |
| 75.85 | 77.12 |
| 54.43 | 50.12 |
| 76.00 | 71.13 |
| 68.65 | 67.13 |
| 75.73 | 71.14 |
| 75.11 | 71.15 |

# ANOVA

❖ 다중검정


- t-test를 여러 번 하기 위한 귀무가설 (3개의 귀무가설)

$H_{0_1}: \mu_1 = \mu_2, H_{0_2}: \mu_1 = \mu_3, H_{0_3}: \mu_2 = \mu_3$

- 여러 번 t-test 를 해주게 되면 1종 오류( $\alpha$ )를 범할 확률이 증가

❖ ANOVA(Analysis of Variance)

- 그룹내 분산의 비율을 통해 평균의 차이를 비교할 수 있음
- 분산분석을 실시한 후에 집단 간에 평균이 차이가 있다고 결과가 나타나면, 각 집단간 평균을 비교
- Post-hoc 분석: Bonferroni, Duncan, Tukey 등 오류를 보정한 방법 이용



# One-Way ANOVA

❖ 문제의 정의

- G거피회사는 강남(1), 강동(2), 강서(3)에 매장을 보유하고 있다. 매장 별로 고객만족도가 차이가 있는지를 조사하기 위해 매장별 고객만족도를 조사하였다.
- 과연 3곳 매장의 고객만족도는 차이가 있는지? 있다면 어느 레스토랑의 서비스 만족도가 가장 안 좋은가 확인해보자



One Way ANOVA(일원 분산분석)

- 가설검정

$$H_0: \mu_1 = \mu_2 = \mu_3$$
$$H_1: \text{not } H_0, \mu_1 \neq \mu_2 \text{ or } \mu_1 \neq \mu_3 \text{ or } \mu_2 \neq \mu_3$$


| group | 만족도 1 |
|-------|-------|
| 강동    | 85    |
| 강동    | 82    |
| 강서    | 90    |
| 강동    | 88    |
| 강남    | 93    |
| 강동    | 83    |
| 강서    | 89    |
| 강서    | 88    |
| 강남    | 94    |
| 강동    | 93    |
| 강서    | 97    |
| 강서    | 94    |
| 강남    | 95    |
| 강동    | 84    |
| 강서    | 82    |
| 강동    | 87    |
| 강남    | 86    |
| 강동    | 85    |
| 강서    | 91    |
| 강동    | 92    |



# Two-Way ANOVA

❖ 문제의 정의

- 치킨의 맛을 결정하는 두 가지 요인은 튀길 때의 기름 온도와 튀기는 방법이다.
- 튀길 때의 온도를 200도(1)와 300도(2)로 하고, 튀기는 방법을 오븐(1)과 기름(2)으로 하여 치킨을 튀긴 후에 사람들에게 맛을 평가하도록 하였다.
- 과연 온도와 방법이 맛을 결정하는데 중요한 요인인가? 이 두 가지 요인들 간의 상호작용효과는 없었는가?



Two Way ANOVA(이원 분산분석)

| method | temp | 맛점수1 |
|--------|------|------|
| 오븐     | 200도 | 84   |
| 오븐     | 200도 | 87   |
| 오븐     | 200도 | 85   |
| 오븐     | 200도 | 89   |
| 오븐     | 200도 | 85   |
| 오븐     | 200도 | 87   |
| 오븐     | 200도 | 89   |
| 오븐     | 200도 | 88   |
| 오븐     | 200도 | 89   |
| 오븐     | 200도 | 87   |
| 오븐     | 200도 | 86   |
| 오븐     | 200도 | 88   |
| 오븐     | 200도 | 90   |
| 오븐     | 200도 | 91   |
| 오븐     | 300도 | 95   |
| 오븐     | 300도 | 93   |
| 오븐     | 300도 | 94   |
| 오븐     | 300도 | 98   |
| 오븐     | 300도 | 97   |
| 오븐     | 300도 | 94   |

## 2 Proportion Test

성인남자 100명과 독립적으로 성인여자 64명을 무작위로 추출하여 흡연 여부를 조사했더니, 남자는 100명 중 33명이 흡연자였고, 여자는 64명 중 17명이 흡연자였다. 남자와 여자의 흡연율은 같다고 할 수 있는가?

남자는 100명중 33명  
여자는 64명중 17명

| 구분   | 남자   | 여자   |
|------|------|------|
| 조사인원 | 100  | 64   |
| 흡연자  | 34   | 17   |
| 흡연율  | 0.34 | 0.26 |

일단 샘플에서는 남녀의 흡연율은 각각 34%, 26%로서 차이가 있다. 그렇다면, 모든 남녀에서 차이가 있다고 할 수 있을까???

code

```
> sample_size = c(100, 66)
> smoke <- c(34, 17)
>
> prop.test(n=sample_size, x=smoke)
```

2-sample test for equality of proportions with continuity correction

```
data: smoke out of sample_size
x-squared = 0.91138, df = 1, p-value = 0.3397
alternative hypothesis: two.sided
95 percent confidence interval:
 -0.07068834  0.23553682
sample estimates:
 prop 1      prop 2 
0.3400000 0.2575758
```

P-value가 0.05보다 크므로 남녀 간 흡연율은 차이가 없다

# Chi Square Test

◎ 빈도수의 동질성 검정 사례

4가지 교육 과정에 대해서, 교육 수강 후 만족와 불만족을 조사하였다.

만족 인원 비율이 서로 다르다고 할 수 있는가?

| 과정명 | 조사인원수 | 만족인원수 | 불만족인원수 | 불만족비율 |
|-----|-------|-------|--------|-------|
| 과정A | 50    | 45    | 5      | 0.11  |
| 과정B | 50    | 43    | 7      | 0.16  |
| 과정C | 50    | 48    | 2      | 0.04  |
| 과정D | 50    | 44    | 6      | 0.14  |

```
index <- read_excel("실습data.xlsx", sheet=11)
index
```

```
install.packages("dplyr")
library(dplyr)
```

```
course_data <- index %>% select('과정명', '조사인원수', '불만족인원수')
course_data
```

```
table_data <- as.table(as.matrix(course_data[, -1]))
chisq.test(table_data)
```

```
> course_data <- index %>% select('과정명', '조사인원수', '불만족인원수')
> course_data
# A tibble: 4 x 3
  과정명 조사인원수 불만족인원수
<chr>      <dbl>      <dbl>
1 과정A         50           5
2 과정B         50           7
3 과정C         50           2
4 과정D         50           6
>
> table_data <- as.table(as.matrix(course_data[, -1]))
> chisq.test(table_data)

Pearson's Chi-squared test


data: table_data
X-squared = 2.6111, df = 3, p-value = 0.4555
```

P-value가 0.05보다 크므로  
과정별 만족율은 차이가 없다

# Correlation(상관분석)

❖ 문제의 정의

- K제약회사는 새롭게 개발한 다이어트약이 효과가 있는지를 보고하기 위하여 약의 효능을 검증하였다.
- 약을 먹기 전의 체중과 약을 먹은 후 3개월 후의 체중을 조사하였다.
- 과연 새로운 약은 다이어트에 효과가 있는가?



Paired Sample t-test(대응표본 t-검정)

- 가설검정

$H_0: \mu_d = 0$

$H_1: \mu_d \neq 0$

| 사전    | 사후1   |
|-------|-------|
| 83.69 | 77.01 |
| 71.80 | 69.03 |
| 78.45 | 71.03 |
| 75.11 | 71.04 |
| 78.19 | 71.06 |
| 71.70 | 74.08 |
| 62.43 | 62.08 |
| 76.16 | 73.10 |
| 82.23 | 75.10 |
| 74.41 | 74.10 |
| 76.36 | 73.10 |
| 76.17 | 73.11 |
| 75.68 | 76.11 |
| 71.01 | 69.12 |
| 75.85 | 77.12 |
| 54.43 | 50.12 |
| 76.00 | 71.13 |
| 68.65 | 67.13 |
| 75.73 | 71.14 |
| 75.11 | 71.15 |

## 실험계획법

---

### ❖ 요인 수준 선택에 따른 ANOVA 종류


- 고정효과모형(fixed effect model) : 요인을 실험자가 선택
- 변량효과모형(random effect model) : 요인을 무작위로 선택
- 혼합모형(mixed effect model): 두 개의 요인 중에서 하나는 실험자가 하나는 무작위로 선택

★★★ 데이터 스누핑의 사례 암기하기


✓ Data Snooping(p-Hacking)

분석가들이 자신도 모르게 혹은 일부러 p-값을 슬쩍 조작하는 것

Snoop이란 '기웃거리다, 엿람하다'라는 뜻을 가지고 있습니다.  
즉, 데이터 스누핑이란, 데이터를 엿람하여 자신이 원하는 결과를 이끌어내는 것을 말합니다.  
다음 용어들은 모두 같은 의미로 사용됩니다.  
Data fishing, data dredging, data butchery, significance chasing, significance questing, selective inference, p-hacking



p값은 명확한 의사 결정의 기준을 제공해줍니다. 문제는 어떻게 하면 p값을 0.05 미만으로 만들 수 있는 가를 너무도 잘 알고 있다는 것입니다.




- ① p값에 유리한 데이터만 수집    예를 들어, 개선 전과 후를 비교할 때, 개선 전에는 양좋은 값만 수집하고, 개선 후에는 좋은 값만을 수집
- ② Data를 수집한 후, 일부 데이터를 추가 혹은 삭제하면서 p값을 0.05 미만으로 맞춤
- ③ Data를 수집한 후, p값이 0.05 미만으로 나오는 것 만으로 논리를 구성
- ④ p값이 0.05 미만으로 나올 때 까지 데이터를 결합 혹은 변환  
예를 들어, X, Y는 유의하지 않으나,  $X^2Y^3$  혹은  $\log(X^2Y)$ 은 유의할 수 있습니다.  
데이터를 무한히 변환하면 어디선가는 p값 0.05 미만을 찾아낼 수 있습니다.

이는 결코 데이터를 조작하는 것은 아니지만,  
데이터를 이용한 사기일 뿐입니다.



선택 편향, 확증 편향에 대해 기재 할 수 있을 것

✓ **선택 편향**     데이터를 잘못 선택함으로써 발생하는 데이터 분석의 왜곡 문제.



데이터 수집 과정 중 선택 편향이 존재한다면,  
아무리 데이터 양이 많더라도  
그런 데이터를 분석하여 얻은 결과는  
적합성과 유용성이 크게 상처를 받게 됩니다.

모르고 데이터를 수집했다면 안타까운 일이고  
알고도 그렇게 수집했다면 **Data를 이용한 사기**가 될 것입니다.


Historical Big Data를 이용한 소급연구에서는  
이와 같은 선택 편향이 발생할 우려가 항상 존재합니다.  
환경을 비롯한 제반 조건이 과거와 현재 그리고 미래가  
똑같을 수 없기 때문입니다.

또한 데이터 수집 영역에 따라 난이도 등이 다른 경우에도  
선택 편향이 발생할 수 있습니다.  
데이터 수집이 어려우면 피하고 싶고,  
돈이 너무 많이 들면 불가능할 수도 있습니다.

**확증 편향** Confirmation bias은 원래 가지고 있는 생각이나 신념을 확인하려는 경향성을 말합니다.

흔히 하는 말로 “사람은 보고 싶은 것만 본다”와 같은 것이 바로 확증 편향입니다.  
사람들은 자신이 원하는 결과를 간절히 바랄 때,  
또는 어떤 사건을 접하고 감정이 앞설 때,  
그리고 저 마다의 뿌리 깊은 신념을 지키고자 할 때 확증 편향을 보입니다.

확증 편향은 원하는 정보만 선택적으로 모으거나,  
어떤 것을 설명하거나 주장할 때 편향된 방법을 동원합니다.  
사람들은 원하는 결과가 있을 때 소망적 사고에 따라  
자신의 관찰과 경험을 편향적으로 재해석하고자 합니다.



확증편향은 대표적인 인지편향Cognitive bias의 하나 입니다. 인지편향이란 경험에 의한 비논리적 추론으로 잘못된 판단을 하는 것을 말합니다.  
입력된 인식으로부터 사람들이 자신만의 "주체적인 현실"을 창조하기 때문에 발생하는 인지 편향입니다.

- 인지 편향은 여러 차원에서 구분될 수 있습니다.
- 개인적 차원에서의 인지 편향과 대조되는, 집단 차원에서 발생하는 인지 편향 (예: 집단 편향)
  - 선택의 만족도를 판단할 때 발생할 수 있는 인지 편향 (예: 매몰비용 오류)
  - 인과관계의 오류
  - 일반화의 오류
  - 긍정적인 자아 형성을 향한 욕구와, 논리적 충돌을 회피하고자 하는 욕구에서 비롯된 의도적 합리화(Motivated reasoning)

출처 : 위키 백과



시스템 1 : 직관적인 빠른 사고

- 고속으로 자동적으로 행하여 멈출 수 없음
- 생각해야하는 노력이 거의 불필요
- 인상을 바로 느끼거나 연상이 가능
- 편견이 있음




시스템 2 : 논리적으로 느린 사고

- 시스템 1에서 답이 없을 때 행함
- 생각하는데 주의력이 필요
- 논리적 / 통계적 사고 가능
- 최종 결정권은 시스템 2가 가짐



✓ 데이터 생성 오차    데이터가 만들어 질 때, 오차가 포함되어 데이터 분석의 왜곡 문제



데이터 수집에는 큰 관심을 기울이지만  
데이터 생성에는 상대적으로 관심이 낮은 경향이 있습니다.  
그러나, 데이터 생성 과정의 문제가 있는 경우  
아무리 수집을 제대로 하더라도  
생성 과정에 문제가 있다면  
데이터는 이미 왜곡을 포함하고 있게 됩니다.

예를 들어,  
집 값 하락을 막기 위하여, 범죄 신고를 하지 않는 경우

가장 대표적으로 데이터 생성 과정에  
왜곡이 발생하는 경우는 평가용 데이터인 경우입니다.  
평가를 잘 받기 위하여

- ① 실제 효과와 무관한 지표 선정
- ② 달성 가능한 지표만 선정
- ③ 이미 달성된 것을 지표로 선정
- ④ 평가 결과 조작 등

[예시]  
밀수 금액과 밀수 건수


계측기를 이용하여 데이터를 생성하는 경우는  
Gage R&R이란 방법으로 생성과정의 신뢰성을 확보

[데이터 전처리]

1)Data Cleansing

- 결측치(Missing Value) 처리: ①결측치 포함 항목 모두 제거, ②적절한 값(중앙값, 평균 등)으로 대체, ③분석 단계로 처리를 넘김
- 틀린값 처리: 상기 결측치 처리 3가지와 동일
- 이상치(Outlier) 처리: 아래 ①의 경우만 데이터 전처리에 해당 함
  - 목적에 따라 ①이상치 제거(비합리적 이상치): 모델의 성능을 높이기 위해 학습 데이터에서 제거하는 경우
  - ②이상치 검출(합리적 이상치): 이상치를 찾는 것 자체가 목적인 경우(도난카드 사용, 기기 이상 등)
- 노이즈(Noise) 처리: 평활화(Smoothing) – 고급EDA에 기재

2)Data Integration



|            |                                                                                      |
|------------|--------------------------------------------------------------------------------------|
| Inner Join | 공동된 feature을 가진 두 개의 테이블을 합치는 조인 연산 - 조인 조건에 맞는 행들만 결과에 포함                           |
| Outer Join | 두 개의 테이블을 합치는 조인 연산 중 하나로, 조인 조건에 맞지 않는 행들도 결과에 포함<br>- 조인 조건에 맞지 않는 경우는 NULL 값이 채워짐 |
| Left Join  | 왼쪽 테이블의 모든 행을 결과에 포함 시키는 조인 연산                                                       |
| Right Join | 오른쪽 테이블의 모든 행을 결과에 포함 시키는 조인 연산                                                      |

[데이터 전처리]

3)Data Transformation: 로그를 적용하거나 역수를 취하거나 카테고리 변수를 적용하는 것

①선형변환(Linear Transformation):  $X \rightarrow aX + b$

- Data Scaling: 원 데이터가 갖는 값의 범위를 조정하여 모델의 성능을 높이는 것

|                | 설명                                                      | 사용                                |
|----------------|---------------------------------------------------------|-----------------------------------|
| Z-Score        | 각 데이터 포인트에서 평균을 뺀 후, 표준 편차로 나누어 데이터를 평균 0, 표준편차 1로 만든다. | 데이터가 정규분포를 이루고 있을 경우 사용           |
| Robust Z-Score | 중위수와 IQR을 사용하여 데이터 변환. (이상치에 민감하지 않음)                   | 이상치가 있는 데이터에서 사용                  |
| Decimal 변환     | 데이터를 10의 거듭제곱으로 나누어 스케일 조정                              | 데이터의 크기와 단위를 일관되게 만들 때 사용         |
| Min-Max 변환     | 데이터 값을 최소값과 최대값 사이의 범위로 스케일링 (데이터를 0과 1 사이로 매핑)         | 이미지 픽셀 값 또는 신경망 입력 데이터 스케일 조정에 사용 |

※ 머신러닝 알고리즘 중에서 데이터 **스케일링을 반드시** 고려 해야하는 것은? (거리 기반 모형, 선형 모형이 주로 해당 됨)

- K-Means 클러스터링: 데이터 포인트 간의 거리를 기반으로 클러스터링을 형성함  
데이터 스케일링을 수행하지 않으면 변수 간 크기 차이로 인해 클러스터링 결과가 왜곡될 수 있음
- 서포트 벡터 머신(SVM): 데이터 포인트 간의 거리에 영향을 받는 알고리즘  
변수의 단위 차이로 인해 모델의 성능이 저하될 수 있음
- 주성분 분석(PCA): 변수 간의 크기 차이가 주성분 추출에 영향을 미칠 수 있음
- 신경망(Neural Networks): 인공 신경망 모델은 입력 특성의 범위에 민감할 수 있음
- KNN (K-Nearest Neighbors): 데이터 포인트 간의 거리를 사용하여 예측을 수행하는데, 변수 간의 스케일 차가 거리에 영향을 미칠 수 있음
- 선형 회귀 (Linear Regression): 입력 변수와 목표 변수 간의 선형 관계를 가정한다.  
변수 간의 스케일 차이가 있는 경우 회귀 계수 추정에 영향을 미칠 수 있음

[데이터 전처리]

3)Data Transformation: 로그를 적용하거나 역수를 취하거나 카테고리 변수를 적용하는 것

① 선형변환(Linear Transformation):  $X \rightarrow aX + b$

- Data Scaling

※ 머신러닝 알고리즘 중에서 데이터 **스케일링**이 필요 없는 모델은?  
- 의사결정 트리/랜덤 포레스트: 데이터의 순서나 분포에 무관하게 동작, 스케일링을 수행하지 않아도 일반적으로 좋은 결과를 얻을 수 있음

② 비선형변환(Non-linear Transformation)  
- 나이브 베이즈 (Naive Bayes): 입력 변수 간의 독립 가정을 기반으로 하며, 스케일링에 대한 민감성이 낮음

- 역승 변환: 재표현의 사다리, '고급EDA'에서 설명
- 로그 변환: 큰 변화를 약화시키는 효과(소리, 빛, 냄새, 압력 등의 자극 등)
- 범주형 변환: 수치 데이터를 범주형으로 변환하는 것(나이, 연간소득, 성정 등)
- 역수 변환: 역수를 취하면 입력-출력 관계가 선형이 되는 경우(자동차 마일리지, 속도와 시간 관계 등)
- Box-cox transformation
- Johnson transformation

[데이터 전처리]

4)Data Selection

- Instance Selection

- : 데이터 수가 너무 많아 연산량이 많을 때, Train/Test set으로 나눌 때 활용
- : Sampling방식에 따라 구분하여 이해 필요

① 확률 표본 추출 – 단순 무작위 추출(Simple random sampling): 모집단에 포함된 개체들의 추출 확률을 모두 같게 하는 방법, 의도 /주관 개입하지 않음

계통 추출(Systematic sampling): 일정 간격을 두고 체계적으로 뽑는 방법, 첫 번째 표본 임의 선택 후 두 번째 부터 k간격두고 선택

층화 추출(Stratified sampling): 서로 비슷한 개체끼리 나누고 나누어진 층에서 단순임의 추출로 뽑는 방법

군집(집락) 추출(Cluster sampling): 군집으로 나누고, 일부 군집을 추출 후 추출 된 군집의 일부 or 전부를 추출하는 방법

#층화 vs. 군집: 층화는 집단 내에서는 동질적이고, 집단 간은 이질적임 / 군집은 집단 내에서는 이질적이고, 집단 간은 동질적임

② 비확률 표본 추출 – 편의 추출(Convenience sampling): 연구자 편의에 따라 빠르게 추출, 규칙 X / 대표성 X

판단 추출(Purposive sampling): 연구자의 판단에 따라 대상 특성에 맞게 주관적으로 추출, 예)안경을 착용한 사람

할당 추출(Quota sampling): 그룹을 나눈 후 그룹 내 비율에 맞게 추출, 예)각 연령대별 10명씩 추출

지원자 추출(Volunteer sampling): 특성에 맞는 지원자 중에서 추출, 예)00기술을 보유한 지원자 중 추출

눈덩이 추출(Snowball sampling): 초기 표본 선택 후 이들이 추천하는 대상으로 표본 확대, 예)조사가 어려

은 대상(마약사범) 선정

[데이터 전처리]

4)Data Selection

- Feature selection

: 중요하지 않은 변수 제거 - 예)상수, 값이 모두 동일하고 산포가 없는

: 중요한 변수를 선택

① Filter Method: 원인(X)과 결과(Y) 변수 사이의 상관계수를 구한 후 상관성이 높은 변수 위주로 선택하는 기법

|       | 연속형 Y         | 범주형 Y                   |
|-------|---------------|-------------------------|
| 연속형 X | 상관분석, 회귀 분석   | 로지스틱 회귀                 |
| 범주형 X | t-test, ANOVA | Chi-Square test, p-test |

② Wrapper Method: 머신러닝 알고리즘에 변수의 Subset을 input으로 넣어가면서 성능을 측정하는 기법

모형적합도(AIC)라는 퍼포먼스 측정값을 만들고 성능이 좋지 않으면 변수를 계속 늘리거나 축소하기를

반복하며 Subset을 찾음

- 전진선택법(Feedforward selection): 변수를 하나부터 개수를 추가하며 성능지표를 비교해가는 방법
- 후진소거법(Backward Elimination): 전체 변수부터 변수 개수를 줄여가며 성능지표를 비교해가는 방법
- 단계적선택법(Stepwise): 변수를 하나부터 개수를 추가하는 단계마다 변수의 중요성을 체크하고 중요하지 않은 변수를 제거

하는 방법

③ Embedded Method: 변수 선택 모델링 과정 안에서 변수가 선택되는 경우, 회귀분석과 같이 변수가 모델링에서 나오는 경우

- Lasso, Ridge, Elastic net

## [데이터 전처리]

### 4)Data Selection

#### - Dimension Reduction

- ① 주성분 분석(PCA, Principal Components Analysis): 여러 개의 독립변수들을 잘 설명해줄 수 있는 주성분을 추출하는 기법으로  
독립변수를 줄이고 차원의 저주를 방지하기 위한 방법으로 활용 됨

#차원의 저주: 데이터 학습을 위해 차원이 증가하면서 학습데이터 수가 차원 수보다 적어 성능이 저하되는 현상

- ② 중앙값 정제(Median Polish): 서로 다른 2개의 변수들의 영향을 분리하는 기법.

예)성별과 스마트폰 모델에 따른 매출 분석



▶ 지도학습 용 데이터 : Labeled Data

| 키    | 무게   | 색깔  | 분류  |
|------|------|-----|-----|
| 3300 | 6000 | 회색  | 코끼리 |
| 580  | 800  | 점박이 | 기린  |

▶ 비지도학습 용 데이터 : Unabeled Data

| 키    | 무게   | 색깔  | 분류 |
|------|------|-----|----|
| 3300 | 6000 | 회색  |    |
| 580  | 800  | 점박이 |    |

▶ 데이터 없이도 스스로 학습





# 머신러닝 모델 비교

| 머신러닝 유형                                                                                                                                                                                                                                                                                                                                                                     |                     | 알고리즘                                                             | 특징                                           |
|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------|------------------------------------------------------------------|----------------------------------------------|
| 지도학습<br>- 분류 문제<br>- 회귀 문제<br>- 이미지 인식<br>- 음성 인식<br>- 추천 시스템<br>- 자연어 처리<br>- 컴퓨터 비전<br>- 의료 진단<br>- 금융 분석<br>- 마케팅<br>- 고객 서비스<br>- 보안<br>- 제조업<br>- 농업<br>- 환경<br>- 에너지<br>- 교통<br>- 건설<br>- 유통<br>- 서비스업<br>- 공공기관<br>- 교육<br>- 의료<br>- 엔터테인먼트<br>- 스포츠<br>- 미디어<br>- 광고<br>- 정치<br>- 군사<br>- 과학<br>- 연구<br>- 개발<br>- 테스트<br>- 배포<br>- 모니터링<br>- 유지보수<br>- 업데이트<br>- 종료 | 선형 계열<br>선형 회귀, SVM | 선형 모델, SVM<br>로지스틱회귀                                             | 곱셈과 덧셈으로 점수를 구하고 이를 이용하여 회귀와 분류 예측           |
|                                                                                                                                                                                                                                                                                                                                                                             | 신경망<br>DNN          | MLP, CNN, RNN, Transformer<br>Graph Network                      | 매트릭스 연산을 기반으로 점수를 계산하며 활성화 함수 도입             |
|                                                                                                                                                                                                                                                                                                                                                                             | 트리 계열               | 결정 트리, 랜덤포레스트,<br>그라디언트부스팅 → 위계적으로<br>가중치나 tree를 여러개 쌓아서 성능이 좋아짐 | True/False 선택을 반복하여 회귀와 분류 예측 수행. 스케일링이 필요없다 |
|                                                                                                                                                                                                                                                                                                                                                                             | 기타                  | kNN, 베이지스(랜덤화 학습) . 로컬 .<br>Sampled → 많은 데이터를 정교하게               | 특성 공간상의 거리를 기준, 또는 조건부 확률을 기준으로 예측           |
|                                                                                                                                                                                                                                                                                                                                                                             | 클러스터링               | k-means, DBSCAN                                                  | 특성 공간상 거리 또는 유사도를 기준으로 샘플을 그룹핑               |
| 비지도학습                                                                                                                                                                                                                                                                                                                                                                       | 데이터 변환              | 스케일링, 로그변환,<br>카테고리 인코딩                                          | 모델의 성능을 높이 위한 데이터 전처리                        |
|                                                                                                                                                                                                                                                                                                                                                                             | 차원 축소               | PCA, t-SNE                                                       | 계산량을 줄이고 모델 성능을 향상, 또는 시각화를 위한 차원 축소         |

★★ 유형별 대표 알고리즘의 이해 : 분류 모델 n가지 이상 적고 설명하시고, Tree 기반 앙상블 모형 3가지 이상 적고 답하

예측적 분석의 유형

머신러닝 알고리즘

|                                         |                                                                  |                                                                                                                                                                                           |
|-----------------------------------------|------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 연관 규칙 분석<br>(Association Rule Analysis) | 동시발생 관계가 있는 사건이나 활동을 발견(반복 가능한 규칙을 확률로 표현)                       | Collaborative Filtering, Contents-based Filtering, Knowledge-based Filtering, Hybrid Filtering, Frequent Itemset Mining, Association Rule Mining                                          |
| 분류 분석<br>(Classification Analysis)      | 대상 개체를 사전에 정해진 범주 중의 하나로 할당하는 것 (Y가 이산형인 Labeled Data를 이용한 지도학습) | 1R(1 rule), Naïve Bayesian, k-NN(k-Nearest Neighborhood), Regression, Logistic Regress, Discriminant Analysis, Decision Tree, Ensemble Method, SVM(Support Vector Machine) Neural Network |
| 군집 분석<br>(Cluster Analysis)             | 주어진 Data의 구조를 파악하기 위하여 유용한 그룹으로 나누는 것 (unlabeled Data를 이용한 자율학습) | 연결 기반 군집분석(계층적 군집분석)<br>중심 기반 군집분석(K-means, K-Medoids)<br>분포 기반 군집분석, 밀도 기반 군집분석, 그래프 기반 군집분석                                                                                             |
| 회귀 분석<br>(Regression Analysis)          | 독립변수 값이 주어졌을 때, 결과변수 값 추정 (Y가 연속형인 Labeled Data를 이용한 지도학습)       | Linear Regression, Non-linear Regression, Regularized Regression(Ridge, LASSO, Elastic), Generalized Regression(Logistic Regression, Poisson Regression)                                  |
| 시계열분석<br>(Time Series Analysis)         | 시계열 데이터에 바탕을 둔 분석으로, 회귀분석의 특수한 경우                                | AR(Auto-Regression), MA(Moving Average), ARMA, ARIMA(Auto-Regressive Integrated Moving Average) RNN, LSTM, NARX                                                                           |

기출유형. 분류모델 n가지 이상 적고 설명하시오.  
기출문제. Tree기반 앙상블 모형 3가지 이상 적고 설명하시오. 답: Bagging, Boosting, Voting,

# 과대적합

학습하면서 찾아낸 공통. overfitting은 항상 나쁜데. 이걸 다른 데이터로 확실히 입증.

- ▶ 모델이 훈련 데이터에 대해서만 잘 동작하도록 만들어져서 새로운 데이터에 대해서는 오히려 잘 동작하지 못하는 경우를 과대적합(over fitting)되었다고 한다
- ▶ 과대적합은 주어진 훈련 데이터를 너무 세밀하게 학습에 반영하여 발생하는 현상이다
- ▶ 머신러닝에서는 과대적합을 피해서 일반적으로 잘 동작하게 모델을 만드는 것이 매우 중요하다
  - ▶ 이를 모델의 일반화(generalization)라고 한다
- ▶ 일반화 방법
  - ▶ 모델을 단순하게 만든다(이를 규제화(regularization)라고도 한다)
  - ▶ 더 많은 훈련 데이터를 확보한다

→ 모델 Simple화: 신경망 층에 depth 조절

신경망은 직진성이라 과대적합이 있으나 (간 리어원도 넣으면 과대적합이 될수 있음).

특히노이즈가 많이 있는 경우는. 선형이 아니라 (polynomial term). 복잡성이되어서 과대적합이 될수 있음



# 과소적합

- ▶ 과대적합과 반대로 모델이 너무 간단하거나 학습이 덜 되어 성능이 미흡한 경우를 과소적합(under fitting)이라고 한다
- ▶ 과소적합을 피하려면
  - ▶ 좀 더 상세한 모델 구조를 사용한다
  - ▶ 학습을 더 오래 수행한다 (같은 데이터를 반복하여 학습에 사용)
- ▶ 머신러닝에서는 과대적합과 과소적합을 모두 피해야 한다

- ▶ 대표적인 손실함수와 성능 평가 지표
  - ▶ 분류에서는 정확도 외에 성능 지표로 정밀도(precision), 재현률(recall), F1-지수 등이 추가로 사용된다.

|                  | 손실함수                        | 성능평가지표                          |
|------------------|-----------------------------|---------------------------------|
| 정의               | 손실함수를 줄이는 방향으로<br>모델이 학습을 함 | 성능을 높이는 것이<br>머신러닝을 사용하는<br>목적임 |
| 회귀 모델의<br>대표적인 값 | MSE (오차 자승의 평균치)            | $R^2$                           |
| 분류 모델의<br>대표적인 값 | 크로스 엔트로피                    | 정확도, 정밀도, 재현률,<br>F1점수          |

분류

범주의 값을 분류하는 목적

정확도,정밀로,F1,AUC,ROC 곡선


예측

특정 값을 예측하는 목적

R square 값

R<sup>2</sup>가 낮게 나오는 경우

① 모형 선택이 잘못된 경우




② 중요한 인자(X, 독립변수)가 누락된 경우

(예)  $Y = a + bX_1 \rightarrow R^2 = 50.0\%$   
 $Y = a + bX_1 + cX_2 \rightarrow R^2 = 70.0\%$   
 $Y = a + bX_1 + cX_2 + dX_3 \rightarrow R^2 = 70.1\%$

인자 수가 늘어날 수록 모형의 설명력은 커진다. 그러나 인자 수가 늘어나면, 데이터를 더 많이 수집해야 하고, 모형이 복잡해서 해석하기 어렵다

③ Data Size와 품질 문제

특히, 이상치, 서로 다른 집단의 혼합 등 품질 문제 확인 필요



④ 하이퍼 파라미터 최적화 문제

★★★★★ 계산하기 문제 출제

혼동 행렬 (Confusion matrix)

|        |          | Predicted          |                    |
|--------|----------|--------------------|--------------------|
|        |          | Negative           | Positive           |
| Actual | Negative | True Negative(TN)  | False Positive(FP) |
|        | Positive | False Negative(FN) | True Positive(TP)  |

정확도(Accuracy) =  $\frac{TP+TN}{TP+TN+FP+FN}$


정밀도(Precision) =  $\frac{TP}{TP+FP}$

F1 = 2 \*  $\frac{\text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}}$


재현율(Recall) =  $\frac{TP}{TP+FN}$




# ROC (Receiver Operating Characteristic)



## Threshold



## AUC(Area Under Curve)



- ✓ True Positive Rate(Y축) : Positive 를 Positive 로 올바르게 예측 (재현율 , 민감도)
- ✓ False Positive Rate(X축) : Negative를 Positive로 잘못 예측 (1종 오류, 1-특이도)

✓ 예측정확도는 낮은 성능을 숨길 수 있다.  
특히, Test-Set 데이터가 불균형한 경우는 유의해야 합니다.

[예시] 이탈 10, 잔류 90

모형 1

| 구분 |    | 예측 |    |
|----|----|----|----|
|    |    | 잔류 | 이탈 |
| 실제 | 잔류 | 90 | 0  |
|    | 이탈 | 9  | 1  |

예측정확도  
= 91/100  
= 91%

잔류를 잔류로 예측한 비율과  
이탈을 이탈로 예측한 비율의 평균

평균 예측 정확도

산술평균  $(100\% + 10\%)/2 = 55\%$   
조화평균  $\frac{1}{\frac{1}{2} \left( \frac{1}{1.0} + \frac{1}{0.1} \right)} = \frac{1}{5.5} = 18.2\%$

모형 2

| 구분 |    | 예측 |    |
|----|----|----|----|
|    |    | 잔류 | 이탈 |
| 실제 | 잔류 | 70 | 20 |
|    | 이탈 | 2  | 8  |

= 78/100  
= 78%

산술평균  $(77.8\% + 80\%)/2 = 83.9\%$   
조화평균  $\frac{1}{\frac{1}{2} \left( \frac{1}{0.778} + \frac{1}{0.800} \right)} = \frac{1}{1.268} = 78.873\%$

모형 3

| 구분 |    | 예측 |    |
|----|----|----|----|
|    |    | 잔류 | 이탈 |
| 실제 | 잔류 | 90 | 0  |
|    | 이탈 | 10 | 0  |

= 90/100  
= 90%

☞ 모두 잔류한다고 예측해도  
예측 정확도는 90% ????

불량율이 1%라면  
모두 양품이라고 예측해도  
예측 정확도는 99%



음성기준 Confusion Matrix계산

|    |    | 예측  |    |
|----|----|-----|----|
|    |    | 양성  | 음성 |
| 실제 | 양성 | 100 | 0  |
|    | 음성 | 9   | 1  |

변환 후 계산

|    |    | 예측 |     |
|----|----|----|-----|
|    |    | 음성 | 양성  |
| 실제 | 음성 | 1  | 9   |
|    | 양성 | 0  | 100 |

양성기준 Confusion Matrix계산

|    |    | 예측 |     |
|----|----|----|-----|
|    |    | 음성 | 양성  |
| 실제 | 음성 | 0  | 100 |
|    | 양성 | 1  | 9   |

변환 후 계산

|    |    | 예측  |    |
|----|----|-----|----|
|    |    | 양성  | 음성 |
| 실제 | 양성 | 9   | 1  |
|    | 음성 | 100 | 0  |

★★★ 평균 정확도를 구하세요

분류모형의 성능지표

✓ 예측정확도는 낮은 성능을 숨길 수 있다.  
특히, Test-Set 데이터가 불균형한 경우는 유의해야 합니다.

[예시] 이탈 10, 잔류 90

모형 1

| 구분 |    | 예측 |    |
|----|----|----|----|
|    |    | 잔류 | 이탈 |
| 실제 | 잔류 | 90 | 0  |
|    | 이탈 | 9  | 1  |

예측정확도  
= 91/100  
= 91%

잔류를 잔류로 예측한 비율과  
이탈을 이탈로 예측한 비율의 평균

평균 예측 정확도

산술평균  $(100\% + 10\%)/2 = 55\%$   
조화평균  $\frac{1}{\frac{1}{2} \left( \frac{1}{1.0} + \frac{1}{0.1} \right)} = \frac{1}{5.5} = 18.2\%$

모형 2

| 구분 |    | 예측 |    |
|----|----|----|----|
|    |    | 잔류 | 이탈 |
| 실제 | 잔류 | 70 | 20 |
|    | 이탈 | 2  | 8  |

= 78/100  
= 78%

산술평균  $(77.8\% + 80\%)/2 = 83.9\%$   
조화평균  $\frac{1}{\frac{1}{2} \left( \frac{1}{0.778} + \frac{1}{0.800} \right)} = \frac{1}{1.268} = 78.873\%$

모형 3


| 구분 |    | 예측 |    |
|----|----|----|----|
|    |    | 잔류 | 이탈 |
| 실제 | 잔류 | 90 | 0  |
|    | 이탈 | 10 | 0  |

= 90/100  
= 90%


☞ 모두 잔류한다고 예측해도  
예측 정확도는 90% ????

불량율이 1%라면  
모두 양품이라고 예측해도  
예측 정확도는 99%

imbalanced data-set으로 모형을 적합 시키는 경우 모형의 성능이 저하될 수 있습니다.  
예를 들어 봅시다.



왼쪽 그림과 같은 경우,  
분류 모델은 두 개의 범주를 잘 분류하고 있습니다.




Imbalanced Data-set인 경우,  
모형의 학습 시에는 잘 분류되는 것 같지만,  
발생 가능한 모든 상황을 고려한다면  
성능이 좋지 못합니다.  
즉, 모형 개발 시에는 그럴듯해 보이지만  
실무에 적용하면 맞지 않는 것입니다.

Confusion Matrix 계산 문제에서 Threshold 값이 커진다면 어떻게 변화하는가?

Threshold의 역할  
: confusion matrix는 분류 모델의 성능을 평가하는 데 사용되는 표로, 예측 결과와 실제 값을 비교하여 모델의 성능을 시각적으로 표현합니다. 이 매트릭스에서 임계값 (Threshold)은 모델이 예측한 확률 값을 기준으로 이진 분류를 수행할 때 중요한 역할을 합니다. 즉, 임계값은 모델이 예측한 확률이 어느 수준 이상일 때 특정 클래스(예: Positive 클래스)로 분류할지를 결정하는 기준입니다.

로지스틱 회귀 모형에서 특정 이메일이 스팸일 확률이 0.9이면 스팸일 가능성이 매우 높다고 예측할수 있다  
이와 반대로 0.03이라면 스팸이 아닐 가능성이 높다. 그렇다면 0.6인 이메일의 경우는 어떻게 분류해야 할까?  
이때 분류의 기준이 필요한데, 이 기준을 Threshold(임계값)이라고 한다




Threshold 값과 Precision은 양의 상관관계  
Recall은 음의 상관관계

어떤 분류기의 임계값에 따른 정밀도와 재현율을 그래프로 나타내면 위와 같으며  
Precision과 Recall이 만나는 점이 최적의 임계값이다

$$\text{Precision} = \frac{TP}{TP + FP}$$
$$\text{Recall} = \frac{TP}{TP + FN}$$

회귀모형의 성능지표



① 설명력(기여율) :  $R^2$   $R^2 = 1 - \frac{SS_{RES}}{SS_{TOT}} = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$

실제값    예측값  
y값    평균

② 평균제곱예측오차  
MSE(mean squared error)

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

실제값    예측값

③ RMSE  
root mean squared error

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

④ 평균절대예측오차  
MAE(mean absolute error)

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i|$$

⑤ 평균절대백분위에측오차 MAPE(mean absolute percentage prediction error)


$$MAPE = \frac{100}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{f}(x_i)}{y_i} \right|$$

실제값    예측값

1. MSE는 작은 오차에 많은 패널티를 추가하는 방식이다 X -> 작은 오차가 아닌 큰 오차에 부가하는 방식  
2. MAE는 큰 오차에 많은 테널티를 부과하는 방식이다 X -> 모든 크기의 오차를 동일하게 적용하는 방식

kNN(K-nearest neighborhood) : k개 최근접 이웃을 기준으로 분류하는 알고리즘

[예] k = 1 , 3, 9 일때  $\oplus$  의 kNN 분류 결과




k 값이 적으면 : 과대적합의 위험이 높아지며, 훈련 데이터에 지나치게 적합하게 됨.(분산이 커짐)  
k 값이 크면 : 과소적합의 위험이 있으며, 데이터의 복잡성을 충분히 반영하지 못할 수 있음.(평균으로 회귀함)

로지스틱 회귀분석

로지스틱 회귀분석  
(Logistic regression analysis)

분류 범주가 2개인 경우 사용




sigmoid

- ▶ 입출력의 관계를 s형 커브를 사용하여 선형값을 확률로 매핑할 때 사용되는 함수
- ▶ s 커브를 시그모이드 함수라고 한다

소프트맥스

- ▶ 이진 분류가 아니라 3개 이상의 클래스 중에 하나를 예측해야 하는 경우는 로지스틱 회귀를 사용할 수 없다
- ▶ 이때는 소프트맥스 (softmax) 함수를 이용한다
  - ▶ 각 클래스로 분류될 가능성을 나타내는 점수를 먼저 구하고 이 점수들을 사용하여 상대적인 확률의 비율을 구한다

재귀적 분할을 통해 범주를 분류 하는 방법



- ▶ 선형계열 모델과 다른점
  - ▶ 선형 모델은 입력 특성들을 대상으로 곱셈과 덧셈을 하고 그 값을 사용하여 회귀나 분류를 예측했고 스케일링이 필요했다
- ▶ 결정 트리(decision tree) 모델은 이와 달리 각 특성을 독립적으로 하나씩 검토하여 분류 작업을 수행한다
  - ▶ 마치 스무고개 하여 예측을 하듯이 동작 한 번에 한 특성을 따져보는 방법이다
  - ▶ Yes/No 이진 판별만 수행하며 나누어지는 그룹의 순도의 합이 가장 낮아지도록 그룹을 나눈다
- ▶ 결정 트리는 분류와 회귀에 모두 사용된다
  - ▶ 각각 DecisionTreeClassifier, DecisionTreeRegressor 사용
  - ▶ 회귀모델로 동작할 때는, 나누어진 그룹의 샘플의 분산값이 가능하면 적게 되도록 분류를 수행한다 (손실함수로 MSE 사용)

\* 앙상블 모형

1) 랜덤 포레스트



다수결 원칙에 따라 판단

2) (그라디언트) 부스팅




모델의 성능을 개선시켜 가는 방식

- Entropy : 분류가 잘 안 되어 섞여 있는 정도. 작을수록 좋다
- Gini index : 데이터를 잘 구분하는지 평가하는 지표. 클수록 변별력이 좋다



- 계층적 군집 분석    군집 개수 미지정


- 가까운 개체끼리 차례로 묶거나 멀리 떨어진 개체를 차례로 분리해 가는 방법
- 한 번 병합된 개체는 다시 분리 되지 않음




우리의 고객을 몇 개의 그룹이 될지는 모르겠지만 유사한 그룹으로 나눠볼래

- 비계층적 군집 분석    사전에 군집의 개수 지정

- 다변량 자료의 산포를 나타내는 여러 측도를 이용하여 판정기준을 최적화 시키는 방법으로 군집을 나누는 방법
- 한번 분리된 개체도 반복적으로 시행하는 과정에서 재분류 될 수 있음
- 대표적인 예로 K-means Clustering이 있음



## 군집분석이란...




- 관측된 여러 개의 변수로부터 유사성에 기초하여 N개의 군집으로 집단화하여 집단의 특성을 분석하는 다변량 분석
- 변수들이 속한 모집단 또는 범주에 대한 사전 정보가 없는 경우 관측값들 사이의 거리(또는 유사성)를 이용하여 개체들을 자연스럽게 몇 개의 그룹 또는 군집(Cluster)으로 나누는 분석법
- 통계 기법이지만 머신러닝의 대표적인 방법 : 비지도 학습

★★ 유클리디안, 맨하탄 거리 계산하기

유사성 Similarity = 거리 Distance


거리가 가까우면 유사하고, 거리가 멀면 유사하지 않다.



Data-set

| #  | X1  | X2  |
|----|-----|-----|
| #1 | X11 | X21 |
| #2 | X12 | X22 |

[예] #1 관측값과 #2 관측값의 유사성




✓ ① 유클리디안 거리 Euclidean Distance

$$= \sqrt{(X11-X12)^2 + (X21-X22)^2}$$

② 맨하탄 거리 Manhattan Distance

$$= |X11-X12| + |X21-X22|$$



③ 마할라노비스 거리 Mahalanobis distance

$$d(x,y) = \sqrt{(x-y)\Sigma^{-1}(x-y)^T}$$

where  $x = (x_1, x_2, \dots, x_n), y = (y_1, y_2, \dots, y_n)$

$$\Sigma = \begin{pmatrix} Cov(X_1, X_1) & \cdots & Cov(X_1, X_n) \\ \vdots & \ddots & \vdots \\ Cov(X_n, X_1) & \cdots & Cov(X_n, X_n) \end{pmatrix}$$


계층적 군집분석은 가장 오래된 군집분석 방법이지만 아직도 유용하게 활용.

짜장면  
짬뽕  
볶음면  
라면



| Data-set |     |    |
|----------|-----|----|
|          | 염도  | 채소 |
| #1       | 3   | 1  |
| #2       | 3.5 | 2  |
| #3       | 1.5 | 4  |
| #4       | 1   | 2  |

- ① 4개 원소간의 거리를 모두 구해서 비교한다.
- ② 가장 가까운 2개를 grouping  
예, #1과 #2가 상대적으로 가장 가까웠다면  
이것이 하나의 집단이 된다
- ③ 위에서 한 번의 집단이 나와서 두 개의 원소 간의 거리를 모두 구해서 비교한다.  
이때, 집단과의 연결 방법은 오른쪽 참조
- ④ 가장 가까운 2개를 grouping  
예, #1과 #2가 묶인 집단과 #4가 상대적으로 가장 가까웠다면...

연결 방법




덴드로그램



Step 1

|   | A | B  | C  | D  |
|---|---|----|----|----|
| A |   | 20 | 7  | 2  |
| B |   |    | 10 | 25 |
| C |   |    |    | 3  |
| D |   |    |    |    |



라면    볏음면    짜장면    짬뽕


A    B    C    D



Step 2


|   | A | B  | C  | D  |
|---|---|----|----|----|
| A |   | 20 | 7  | 2  |
| B |   |    | 10 | 25 |
| C |   |    |    | 3  |
| D |   |    |    |    |

|    | AD | B  | C  |
|----|----|----|----|
| AD |    | 20 | 3  |
| B  |    |    | 10 |
| C  |    |    |    |




Step 3

|     | ADC | B  |
|-----|-----|----|
| ADC |     | 10 |
| B   |     |    |



계층적 군집분석은 결과를 덴드로그램으로 표현해주므로 이해하기 쉽고, 군집간의 크기가 달라도 적용가능한 장점이 있습니다.



계층적 군집분석의 단점은...


- 1. 데이터가 클 수록 계산 횟수가 급격히 증가한다.
- 2. 이상치가 존재하는 경우, 생성된 군집의 질에 문제가 있다.
- 3. 안정성이 낮다. 즉, 데이터를 재정렬하거나 일부 데이터를 제거할 경우 완전히 다른 결과가 나올 수 있다.
- 4. 사용하는 거리 척도에 따라 다른 결과가 나올 수 있다.

각 군집을 대표하는 데이터 포인트가 존재한다고 가정하고 각 관측치를 가장 가까운 대표성을 갖는 데이터 포인트로 할당하는 것. 이는 계층적 군집분석과는 달리 한번 분할하여 K개의 군집을 생성하는데, 생성된 군집의 중심점을 재 계산한 후 관측치의 재할당 작업을 반복하여 최종 군집을 찾아간다


평균을 이용하는  
**K-means**가  
가장 많이 활용된다.

K=2인 경우 ➡

- ① 임의의 k수를 군집에 할당
- ② k를 기준으로 군집을 형성
- ③ 형성된 군집의 중심을 계산
- ④ 중심으로부터 새롭게 군집을 형성(거리)
- ⑤ 중심이 더 이상 바뀌지 않을 때까지 상기 행위를 반복



- 장점
  - 계산이 쉬움: 다른 군집화 알고리즘에 비해 복잡도가 낮음.
  - 구현이 쉽고 다양한 언어와 플랫폼에서 제공되는 알고리즘
- 단점
  - 노이즈에 매우 민감함.
  - 군집의 개수를 사전에 정의해야 함.



**K-means 알고리즘 사용 시의 주의 사항**

- (1) 지역 최적점을 찾아주는 것에 불과하므로, 더 좋은 군집을 찾기 위해서는 군집의 수, 초기 중심점을 변화시켜가면서 K-Means 알고리즘을 여러 번 수행한 후 선택하는 것이 바람직하다.
- (2) 초기 중심점 선정 문제 : 초기 중심점을 최대한 거리를 유지하라고 권고하지만, 이상점의 영향을 무시할 수 없다. 이러한 문제점을 해결하기 위하여 중심점을 변화시키면서 여러 번 수행할 것을 권고한다.
- (3) 군집 수 K 선정 문제 : 직관에 의존하는 경우가 많지만, ①계층적 군집분석의 선행 실시 ②주성분 분석 등을 실행하여 선정할 수도 있다.
- (4) 이상치의 영향 : 이상치를 제거 후 실행
- (5) 빈 군집이 발생 : 어떤 관측치도 할당되지 않는 경우가 발생하면 중심점을 교체해야 한다



★★★ 군집분석이 내부 평가 척도 문제

군집분석 성능 척도

군집이 잘 형성되었는가를 판단하는 아래와 같은 척도가 존재합니다만,  
잘 사용되지는 않습니다. 분석의 목적 달성 여부 등 정성적 해석이 더 중요하기 때문입니다.

외부  
평가척도

군집에 대한 사전 지식 혹은 전문가의 지식을 이용한 평가. 즉, Data에 내재되지 않은 정보를 이용.  
K개의 군집이 존재한다는 것을 미리 안다면, 이를 근거로 성능을 평가한다.

- 군집 단위 관점 : 순수도, 엔트로피, F척도
- 개별 관측치 관점
  1. 자카드 계수 =  $TP / (TP + FN + FP)$
  2. 랜드 지수 =  $(TP + TN) / GS$
  3. Forkes-Meloows 척도
    - 정밀도 =  $TP / (TP + FP)$
    - 재현율 =  $TP / (TP + FN)$
    - FM 기하평균 =  $(정밀도 * 재현율)^{1/2}$

|    |       | 예측   |       |    |
|----|-------|------|-------|----|
|    |       | true | false | 계  |
| 실제 | true  | TP   | FN    | AT |
|    | false | FP   | TN    | AF |
|    | 계     | PT   | PF    | GS |

내부  
평가척도

군집 분석에 사용한 데이터만을 사용한 평가로서 대부분의 현실 상황에 적용된다.  
→ 군집 내 유사도는 크고, 군집 간 유사도는 작아야 한다는 관점에서 ...

응집도(cohesion)      분리도(separation)


1. Dunn 지표 = (군집간 거리 중 가장 작은 값) / (군집간 거리 중 가장 큰 값)
2. C지표 = (전체 중심과 군집 중심으로 계산한 분리도) / (군집 중심과 관측치 사이의 응집도)
3. DB 지표 = 응집도/분리도
4. Brock 지표
5. 실루엣 지수 : 1에 가까울 수록 군집이 잘 되었다고 본다.

군집의 개수 선정 방법

- (1) Dendrogram : 계층적 군집분석의 덴드로그램 시각화를 이용
- (2) The Elbow Method : Scree Plot의 활용
- (3) The Silhouette Method : 실루엣 지수를 활용


1

Hierarchical Clustering




2

The Elbow Method



3

The silhouette Method



- ▶ 기존 머신러닝 모델은 전처리가 필수이다 (스케일링 필수)
- ▶ 딥러닝은 전처리의 비중을 줄이고 (특성 공학을 줄이고) 모델이 특성을 스스로 추출하도록 한다
- ▶ 딥러닝은 표현 학습을 수행한다고도 한다
  - ▶ Representation learning
  - ▶ 예측에 필요한 특성(feature)을 데이터를 보고 스스로 찾아내는 것
- ▶ 딥러닝은 비정형 데이터 분석에 유용하다
  - ▶ 이미지, 텍스트, 사운드 등 동일한 성격의 다량의 데이터
- ▶ 전이학습 (transfer learning)
  - ▶ 신경망의 중요한 장점은 다른 데이터로 학습한 모델을 재사용하기가 쉽다
  - ▶ 전이학습을 이용하면 학습시간도 줄일 수 있고 적은 데이터로도 성능이 좋은 모델을 만들 수가 있다
- ▶ 딥러닝의 단점
  - ▶ 딥러닝은 블랙박스 형태로 동작한다. 성능은 우수하나 내부 동작 이유를 알 수는 없다

## 합성곱신경망 (CNN)

- ▶ 아래와 같이 임의의 크기와 모양을 가진 이미지 판독에서는 MLP가 동작하지 않는다
  - ▶ MLP에서는 입력신호 전체를 한번에 다룬다
- ▶ 합성곱 신경망 (Convolution Neural Network, CNN)은 이를 개선하였다



- ▶ 합성곱 필터의 출력을 활성화값(activation)이라고 부른다
- ▶ 활성화값의 집합, 즉 다음 계층의 입력으로 사용되는 배열을 특성맵(feature map)이라고 한다
  - ▶ 합성곱 필터를 커널(kernel)이라고도 하며 커널수가 많을수록 다양한 패턴을 찾아낼 수 있다
  - ▶ 특성맵을 수십~수백 가지를 사용한다 (필터 수로 조정)
- ▶ 풀링 (max pooling)
  - ▶ 합성곱을 수행 결과를 다음 계층으로 전달할 때, 모든 정보를 전달하지 않고 풀링을 통해 일부만 샘플링하여 넘겨준다
  - ▶ 풀링을 하여 좀 더 가치 있는 정보를 축소하여 다음 단계로 넘겨준다
- ▶ CNN은 합성곱 필터와 풀링을 여러 계층 반복 수행한다
  - ▶ 하지만 단계에서는 전결합망을 사용하여 회귀 또는 분류를 수행한다

## 최대풀링(max pooling)

|     |     |    |    |
|-----|-----|----|----|
| 12  | 20  | 30 | 0  |
| 8   | 12  | 2  | 0  |
| 34  | 70  | 37 | 4  |
| 112 | 100 | 25 | 12 |

 $\xrightarrow{2 \times 2 \text{ Max-Pool}}$ 

|     |    |
|-----|----|
| 20  | 30 |
| 112 | 37 |

- ▶ 특정한 패턴이 공간상의 어느 위치에 있든 이 활성화값이 다음 단계로 넘어가면서 좌우로 조금씩 움직일 수 있다
- ▶ 풀링은 과대적합을 해소하는 데에도 기여한다

## 드롭아웃

- ▶ 랜덤하게 신경망 유닛을 선택하여 신호를 전달하지 않는 방법
- ▶ 입력과 출력간의 특정 관계를 기억하지 못하게 한다
- ▶ 드롭아웃은 학습을 하는 동안에만 적용된다

